

Preparación Técnica para Presentación ante Sinodales

Trabajo Terminal 2027-A098 · Sistema de comunicación asistida basado en EEG (P300 Speller)

Este documento resume lo esencial de la señal P300, el pipeline de procesamiento de EEG hasta la clasificación, y el hallazgo del primer avance del proyecto: la comparación de arquitecturas de red neuronal y la identificación de la configuración ganadora, contrastada con el estado del arte y con un trabajo de referencia similar (tesis de maestría, ESCOM–IPN).

Fuentes utilizadas: Protocolo del Trabajo Terminal (2027-A098); código experimental *p300speller.py* (Google Colab); reporte técnico "Arquitecturas de Redes Neuronales para Interfaces Cerebro-Computadora: Clasificación de Señales P300" (resultados completos de las corridas); y la tesis de maestría de A. E. Contreras Martínez (ESCOM–IPN, 2021), citada en el protocolo como antecedente nacional.

1. ¿Qué es la señal P300 y el paradigma P300 Speller?

1.1 El componente P300

El P300 es un **Potencial Relacionado con Eventos (ERP)**: una deflexión positiva de la señal EEG que aparece aproximadamente **300 ms después** de que el cerebro percibe un estímulo relevante dentro de una secuencia de estímulos irrelevantes. Es la respuesta neuronal a la *actualización de un contexto atencional*: cuando un estímulo es inusual o relevante y el sujeto le asigna recursos atencionales, la representación mental se "actualiza" y esto se refleja en la deflexión P300 (mientras que estímulos esperados solo generan potenciales sensoriales tempranos como N100/P200/N200).

Este fenómeno se enmarca en el **paradigma del estímulo raro ("oddball")**: se presentan dos categorías de estímulos, una mucho menos frecuente que la otra. La amplitud del P300 es proporcional a la relevancia del estímulo e inversamente proporcional a su probabilidad de aparición — por eso el estímulo "raro" (el carácter que el usuario quiere seleccionar) genera una señal más marcada que los estímulos frecuentes.

1.2 El P300 Speller (Farwell & Donchin, 1988)

Es la aplicación clásica del P300 a la comunicación asistida. El usuario observa una **matriz de caracteres** (en el caso típico, 6×6) cuyas filas y columnas se iluminan de manera aleatoria e intermitente. El usuario fija su atención visual en el carácter que desea seleccionar. Cuando la fila o columna que contiene ese carácter se ilumina, se genera la señal P300; el resto de las iluminaciones (que no contienen el objetivo) no la generan. El carácter objetivo se identifica como la **intersección de la fila y la columna que provocaron la mayor respuesta P300 acumulada** tras varias repeticiones del ciclo completo de iluminación.

Este paradigma es central para BCIs (Interfaces Cerebro-Computadora) de comunicación dirigidas a personas con compromisos motores severos (p. ej. ELA), porque no depende de ningún movimiento muscular: la selección se hace solo con la atención visual y la señal cerebral evocada.

1.3 Por qué es un problema difícil

- La señal EEG tiene **baja relación señal-ruido**: el P300 es de baja amplitud y está mezclado con ruido fisiológico (parpadeos, actividad muscular) y ambiental (ruido de línea eléctrica).
- Existe **alta variabilidad entre sujetos** e incluso entre repeticiones del mismo sujeto: el P300 no aparece de forma idéntica cada vez.
- Cada carácter no se asocia a una sola muestra, sino a **múltiples ventanas EEG** (una por cada iluminación de fila/columna), por lo que hace falta integrar varias predicciones para decidir con confianza el carácter final.
- Existe un **desbalance de clases** fuerte: en una matriz de 6×6 con 12 intensificaciones por ciclo, solo 2 de esas 12 contienen al objetivo (relación aproximada 5:1 entre estímulos "no objetivo" y "objetivo").

2. Pipeline de procesamiento: de la señal cruda a la clasificación

Este es el flujo implementado en el proyecto (código *p300speller.py*, usando el **Dataset II de la competencia BCI III** — Wadsworth Center, 64 canales EEG, 240 Hz, 2 sujetos, matriz 6×6, 15 repeticiones por carácter). Es también, en esencia, el flujo estándar de cualquier sistema P300 Speller basado en deep learning, por lo que conviene tenerlo muy claro para la defensa.

1. Adquisición

Señal EEG cruda de 64 electrodos a 240 Hz, junto con las señales discretas *Flashing* (marca cada iluminación), *StimulusCode* (qué fila/columna se iluminó) y *StimulusType* (si esa iluminación contenía o no el carácter objetivo — la etiqueta de entrenamiento).

2. Filtrado paso banda

Filtro Butterworth de orden 4 entre **0.1–20 Hz**. Conserva la banda donde vive la información del P300 y elimina derivas de baja frecuencia (drift) y ruido muscular/eléctrico de alta frecuencia.

3. Remuestreo (downsampling)

De 240 Hz a **120 Hz**, para reducir la carga computacional sin perder la información temporal relevante para el P300 (que ocurre en una ventana de cientos de milisegundos). Las señales discretas (*Flashing*, *StimulusCode*, *StimulusType*) se remuestrean igual, para mantener todo alineado en el tiempo.

4. Normalización Z-score

Se resta la media y se divide entre la desviación estándar, de forma **independiente por canal**. Evita que electrodos con mayor amplitud dominen el aprendizaje y estabiliza el entrenamiento de la red.

5. Segmentación en ventanas (epoching)

Se extrae una ventana de EEG alineada a cada evento de iluminación ("flash"), de **78 muestras $\approx$ 0.65 s a 120 Hz** — suficiente para capturar la respuesta P300 completa. Cada ventana queda etiquetada como Clase 1 (P300 / estímulo objetivo) o Clase 0 (No-P300). La entrada final a los modelos tiene forma (*ventanas, 1, 64 canales, 78 muestras*).

6. Extracción de características (dentro de la red)

En vez de ingeniería manual de características, las arquitecturas usadas aprenden automáticamente: primero una **convolución espacial** que combina la información entre los 64 electrodos, y después una **convolución temporal** que aprende los patrones de forma de onda a lo largo del tiempo (el propio "perfil" del P300).

7. Clasificación binaria

Una capa totalmente conectada final decide, por ventana, si hay P300 (clase 1) o no (clase 0). **El modelo nunca predice directamente el carácter**: solo clasifica ventanas individuales.

8. Decodificación fila/columna → carácter

Las probabilidades de P300 de todas las ventanas de un carácter se acumulan por fila y por columna (suma de probabilidades a lo largo de las repeticiones). El carácter predicho es la **intersección de la fila y la columna con mayor puntaje acumulado**. Esta es la métrica que más importa: "*Accuracy de Letras*", porque evalúa el objetivo funcional real del speller.

3. Arquitecturas de red neuronal evaluadas

En el proyecto (código y reporte técnico) se implementaron y compararon **tres familias de arquitecturas** (cuatro variantes en total), todas atacando el mismo problema: clasificación binaria P300 / No-P300 por ventana.

Arquitectura	Cómo procesa la señal	Idea de diseño
CNN clásica para P300 (basada en Cecotti & Gräser, 2011)	Convolución espacial (colapsa los 64 canales en N_s mapas de características) seguida de una convolución temporal (kernel 1×13 , reduce el eje temporal de 78 a 66 muestras) y una capa totalmente conectada (100 neuronas, sigmoide) antes de la salida de 2 clases.	Simple, pocos parámetros, converge rápido.
EEGNet (implementación propia)	Arquitectura compacta diseñada específicamente para EEG: convolución temporal $\rightarrow$ convolución depthwise espacial (un filtro espacial por cada filtro temporal) $\rightarrow$ convolución separable (depthwise + pointwise) $\rightarrow$ pooling y clasificación. Usa muchos menos parámetros que una CNN 2D convencional gracias a las convoluciones separables.	Pensada para bajo ruido/pocos datos; más parámetros de ajuste (F1, D, F2, dropout).
Híbrida CNN + LSTM (bidireccional)	Las mismas convoluciones espacial/temporal iniciales, pero en vez de una capa densa final, la secuencia temporal se procesa con una LSTM bidireccional que modela dependencias de corto y largo plazo (pensada para la variabilidad de latencia del P300 entre repeticiones y sujetos).	Mayor capacidad teórica; entrena más lento y es más sensible a hiperparámetros (con hidden=64 no dio resultados satisfactorios).
EEGNet (Braindecode)	La misma familia EEGNet pero usando la implementación de la librería especializada <i>braindecode</i> , con más filtros (F1=16, F2=32) y ajuste fino de dropout.	Variante exploratoria adicional, usada como referencia de una implementación "de librería" vs. la propia.

Todas se entrenaron con el optimizador **Adam** y función de pérdida de **entropía cruzada**, probando distintas combinaciones de canales (todos los 64, o subconjuntos reducidos de 15 y 10 electrodos), tasa de aprendizaje, weight decay, tamaño de batch y número de épocas — buscando además evaluar si es posible reducir canales sin sacrificar demasiado desempeño (uno de los objetivos específicos del protocolo).

4. Resultados: ¿cuál arquitectura ganó y por qué?

Se evaluaron con 5 métricas: *Accuracy*, *Precision*, *Recall*, *F1-score* (las cuatro a nivel de ventana individual) y **Accuracy de Letras** (a nivel de carácter, tras la decodificación por fila/columna — la métrica funcionalmente relevante). Estos son los resultados completos, por sujeto (A y B):

4.1 CNN clásica para P300

Exp.	Sujeto	Accuracy	Precision	Recall	F1	Acc. Letras
1	A	0.8434	0.5676	0.2547	0.3516	0.96
	B	0.8586	0.6401	0.3457	0.4489	0.95
2	A	0.8432	0.5638	0.2623	0.3581	0.94
	B	0.8589	0.6486	0.3347	0.4415	0.95
3	A	0.8422	0.5544	0.2717	0.3547	0.93
	B	0.8573	0.6230	0.3647	0.4601	0.96
4 (15 canales)	A	0.8327	0.4553	0.0187	0.0359	0.63
	B	0.8333	0.5000	0.0913	0.1545	0.73
5 (10 canales)	A	0.8330	0.4545	0.0100	0.0196	0.69
	B	0.8324	0.4298	0.0173	0.0330	0.38

4.2 EEGNet

Exp.	Sujeto	Accuracy	Precision	Recall	F1	Acc. Letras
1	A	0.8407	0.5787	0.1630	0.2544	0.89
	B	0.8599	0.6630	0.3247	0.4359	0.98
2	A	0.8414	0.5849	0.1677	0.2606	0.85
	B	0.8557	0.6351	0.3157	0.4217	0.98
3 (15 canales)	A	0.8336	0.8571	0.0020	0.0040	0.72
	B	0.8338	0.5247	0.0283	0.0538	0.76
4 (10 canales)	A	0.8335	1.0000	0.0010	0.0020	0.69
	B	0.8333	0.5000	0.0013	0.0027	0.45

4.3 Híbrida CNN + LSTM

Exp.	Sujeto	Accuracy	Precision	Recall	F1	Acc. Letras
1	A	0.8322	0.4893	0.1520	0.2319	0.80
	B	0.8514	0.6385	0.2497	0.3590	0.94

Con 10 y 15 canales, la híbrida CNN+LSTM no dio resultados utilizables (accuracy de letras <30%), por lo que ni siquiera se reportan en la tabla final del proyecto.

4.4 Ganadora: CNN clásica para P300 (experimento 1, todos los canales)

La **CNN clásica**, en su configuración 1 (64 canales, $N_s=10$, $l_r=1e-4$, $\text{weight decay}=1e-5$, 30 épocas, $\text{batch}=128$), obtuvo el **mejor desempeño global: 96% de accuracy de letras para el sujeto A y 95% para el sujeto B** — el resultado más alto y, sobre todo, el más **equilibrado entre ambos sujetos**.

¿Por qué ganó la arquitectura más simple?

- **Menor riesgo de sobreajuste:** con relativamente pocos datos de entrenamiento (85 caracteres por sujeto), una red con menos parámetros generaliza mejor que EEGNet o la híbrida CNN-LSTM, que necesitan más datos y más épocas para estabilizarse.
- **Convergencia más rápida y estable:** el modelo básico llegó a un comportamiento estable en pocas épocas (30), mientras que las arquitecturas más complejas necesitaron entrenarse mucho más tiempo (hasta 300 épocas en EEGNet) para acercarse, sin llegar a superarla de forma consistente.
- **Comportamiento por sujeto:** EEGNet y la híbrida CNN-LSTM mostraron su mejor desempeño únicamente en el sujeto B (EEGNet incluso alcanzó 0.98 de accuracy de letras en B), pero fueron notablemente peores en el sujeto A. Esto sugiere que la mayor capacidad de estos modelos no se tradujo en mejores características aprendidas para todos los sujetos — variabilidad inter-sujeto real del EEG — mientras que la CNN simple fue consistente en ambos.
- **Reducir canales no compensó con estas arquitecturas:** los experimentos con 10 y 15 electrodos (en cualquiera de las tres familias) dieron accuracy de letras claramente inferior al usar los 64 canales completos, lo que indica que, en este dataset, incluso los canales periféricos aportan información complementaria relevante para el P300 — un hallazgo importante para el objetivo del protocolo de reducir canales sin perder desempeño: **con la configuración actual, esa reducción sí tiene un costo medible**.

Conclusión de este primer avance: una arquitectura más compleja **no garantiza mejor desempeño** — la CNN clásica de Cecotti & Gräser logró el mejor balance entre eficiencia computacional y precisión funcional (>95% en ambos sujetos), mientras que EEGNet y la híbrida CNN-LSTM mostraron potencial pero requieren más ajuste y no generalizaron igual entre sujetos.

5. Comparación con el estado del arte y con la tesis de referencia

El protocolo cita como antecedente nacional directo la tesis de maestría de **Adrián Eleazar Contreras Martínez** ("Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil", ESCOM–IPN, 2021), que también aborda detección de P300 con aprendizaje profundo, aunque orientada al control de una neuroprótesis (no a un speller de comunicación).

5.1 ¿Qué arquitectura ganó en esa tesis y por qué?

Ese trabajo comparó varias arquitecturas CNN de la literatura (CNN1/3, UCNN1/3, CNN-R, DeepConvNet, ShallowConvNet, BN3, EEGNet, OCLNN y **SepConv1D**) y seleccionó **SepConv1D** — una arquitectura muy ligera con **una sola capa convolucional 1D separable en profundidad** más una neurona sigmoide de salida.

Su AUC (0.84 intra-sujeto / 0.78 entre-sujetos) fue **comparable, no superior**, al de arquitecturas más grandes como EEGNet o DeepConvNet (también ~0.84 / ~0.79-0.80). La elección no se basó en máxima precisión, sino en **eficiencia computacional**: SepConv1D entrenaba entre 31 y 84 épocas más rápido y era 0.09–0.15 segundos más rápida en inferencia que sus competidores — crítico porque el objetivo final era ejecutar el modelo en un **dispositivo móvil** para controlar una neuroprótesis en tiempo real.

5.2 Diferencias clave con nuestro proyecto

Aspecto	Este proyecto (TT 2027-A098)	Tesis Contreras Martínez (ESCOM-IPN, 2021)
Objetivo del sistema	Deletreo/comunicación (P300 Speller, matriz de caracteres)	Control de neuroprótesis (secuencias de movimiento)
Dataset	BCI Competition III, Dataset II (2 sujetos, 64 canales, 240 Hz)	Registros propios con OpenBCI Ganglion (3 sujetos, 4 canales, 200 Hz)
Canales EEG	64 (línea completa del cuero cabelludo)	4 (línea media: Fz, Cz, Pz, Oz)
Métrica principal	Accuracy de Letras (decodificación funcional del carácter)	AUC de la curva ROC (detección binaria de P300)
Arquitectura ganadora	CNN clásica (Cecotti & Gräser) — simple, 5 capas	SepConv1D — aún más simple, 1 capa convolucional
Criterio de selección	Máxima precisión funcional (accuracy de letras) manteniendo balance entre sujetos	Eficiencia computacional para ejecución en dispositivo móvil, con precisión competitiva

Punto clave para la defensa: en ambos trabajos, la conclusión coincide en algo importante — *una arquitectura más simple resultó ganadora o igualmente competitiva frente a arquitecturas más complejas* (CNN clásica aquí, SepConv1D en la tesis de referencia). Esto no es casualidad: en tareas de detección de P300 con conjuntos de datos moderados, los modelos con menos parámetros generalizan mejor y evitan el sobreajuste, además de ser más viables para escenarios de uso real (bajo consumo, tiempo real, portabilidad) — justo la línea que persigue el protocolo de este TT al buscar reducir canales y repeticiones sin sacrificar desempeño.

5.3 Otros antecedentes citados en el protocolo (Tabla 1)

Trabajo	Enfoque	Canales	Desempeño
Farwell & Donchin, 1988	P300 Speller clásico (EEG)	6–16	Precisión = 78%
Contreras Martínez, IPN, 2021	Neuroprótesis con Deep Learning (EEG)	4	AUC=0.81 (intra) / 0.69 (inter, sin calibrar)

Trabajo	Enfoque	Canales	Desempeño
García Cossio et al., U. Antioquia, 2011	Deletreo libre, paradigma oddball (EEG)	6	Precisión = 85%
Brunner et al., 2011	P300 Speller online (ECoG, invasivo)	96 subdurales	17 caracteres/min
Hong et al. (ChatBCI), 2026	P300 Speller + predicción LLM (EEG)	32	Reducción de tiempo = 62.14%
Este proyecto (avance)	P300 Speller con Deep Learning (EEG)	64 (probado también con 15 y 10)	Accuracy de Letras = 96% (A) / 95% (B)

6. Guion resumido para la presentación ante sinodales

Ideas centrales que conviene poder explicar con seguridad, en este orden:

- **Qué es el P300:** respuesta cerebral evocada (~300 ms post-estímulo) ante un evento raro/relevante dentro de estímulos frecuentes irrelevantes (paradigma oddball).
- **Cómo se usa en el Speller:** matriz de caracteres con filas/columnas iluminadas al azar; el carácter objetivo se decodifica como la intersección de la fila/columna con mayor P300 acumulado tras varias repeticiones.
- **Pipeline aplicado:** filtrado paso banda (0.1–20 Hz) → remuestreo (240→120 Hz) → normalización Z-score por canal → segmentación en ventanas de ~0.65 s alineadas a cada flash → red neuronal (conv. espacial + temporal) → clasificación binaria P300/No-P300 por ventana → acumulación de probabilidades por fila/columna → carácter decodificado.
- **Primer avance concreto:** se implementaron y compararon 4 arquitecturas (CNN clásica, EEGNet propia, CNN+LSTM, EEGNet-Braindecode) sobre el Dataset II de BCI Competition III.
- **Resultado:** la CNN clásica (Cecotti & Gräser) fue la más consistente y precisa — 96%/95% de accuracy de letras — superando a arquitecturas más complejas, que solo destacaron parcialmente en un sujeto y necesitaron más entrenamiento.
- **Justificación:** con el tamaño de datos disponible, menor complejidad = menor sobreajuste y mejor generalización entre sujetos; además, reducir canales (10/15 en vez de 64) empeoró el desempeño en todas las arquitecturas probadas, lo que es un hallazgo relevante frente al objetivo específico de reducir canales.
- **Contraste con la literatura:** el mismo patrón (arquitectura simple gana o iguala a las complejas) se repite en la tesis de referencia de ESCOM-IPN, que eligió SepConv1D por eficiencia, no solo por precisión — coherente con la línea de este TT de priorizar sistemas prácticos y no solo entornos controlados.
- **Siguientes pasos (a partir de este avance):** profundizar el diseño experimental de reducción de canales y repeticiones, formalizar la metodología CRISP-ML para el modelo final, y comenzar el diseño del módulo de predicción de palabras y la interfaz gráfica (PyQt).

Referencias

- [1] L. A. Farwell y E. Donchin, "Talking off the top of your head...", *Electroencephalogr. Clin. Neurophysiol.*, vol. 70, no. 6, pp. 510-523, 1988.
- [2] H. Cecotti y A. Graeser, "Convolutional neural networks for P300 detection...", *IEEE TPAMI*, vol. 33, no. 3, pp. 433-445, 2011.
- [3] A. E. Contreras Martínez, "Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil", Tesis de maestría, ESCOM, IPN, Ciudad de México, 2021.
- [4] E. García Cossio et al., "Interfaz cerebro-computador basada en P300 para la comunicación alternativa...", *Rev. Fac. Ing. Univ. Antioquia*, no. 60, pp. 9-20, 2011.
- [5] P. Brunner et al., "Rapid communication with a P300 matrix speller using electrocorticographic signals", *Front. Neurosci.*, vol. 5, art. 5, 2011.
- [6] J. Hong, W. Wang y L. Najafizadeh, "ChatBCI, a P300 speller BCI with context-driven word prediction...", *Sci. Rep.*, vol. 16, art. 6379, 2026.
- [7] Arana Chávez E., Vázquez Pérez A. M., Vences Guevara A., "Arquitecturas de Redes Neuronales para Interfaces Cerebro-Computadora: Clasificación de Señales P300", reporte técnico, Universidad del País Vasco, 2026 (código: Google Colab).
- [8] Protocolo de Trabajo Terminal No. 2027-A098, ESCOM, IPN.