



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SUBDIRECCIÓN ACADÉMICA



No de TT: **2027-A098**

Fecha de presentación: **[TODO]**

Documento técnico

“Desarrollo de un sistema de comunicación asistida basado en señales electroencefalográficas mediante modelos de aprendizaje profundo”

Presentan:

Emiliano Arana Chávez¹

Alexis Vences Guevara²

Directores:

Mtro. René Baltazar Jiménez Ruíz, Dr. José Félix Serrano Talamantes

Resumen – Se propone el desarrollo de un sistema de comunicación asistida mediante señales electroencefalográficas (EEG), empleando el paradigma P300 Speller con una matriz de caracteres que se ilumina sistemáticamente para la clasificación del potencial de eventos P300 mediante modelos de aprendizaje profundo, permitiendo la identificación del carácter objetivo. Está dirigido a personas con compromisos motores severos. Así mismo, se evaluarán estrategias para optimizar la practicidad de la comunicación mediante la reducción del número de canales y repeticiones requeridas, sin comprometer el desempeño del modelo, con el propósito de mejorar la eficiencia en la comunicación de los usuarios.

Palabras clave – Aprendizaje profundo, Arquitecturas neuronales, Procesamiento de señales, Reconocimiento de patrones.

¹ earanac1900@alumno.ipn.mx | ² avencesg1900@alumno.ipn.mx

RESUMEN

Se propone el desarrollo de un sistema de comunicación asistida mediante señales electroencefalográficas (EEG), empleando el paradigma P300 Speller con una matriz de caracteres que se ilumina sistemáticamente para la clasificación del potencial de eventos P300 mediante modelos de aprendizaje profundo, permitiendo la identificación del carácter objetivo. Está dirigido a personas con compromisos motores severos. Así mismo, se evaluarán estrategias para optimizar la practicidad de la comunicación mediante la reducción del número de canales y repeticiones requeridas, sin comprometer el desempeño del modelo, con el propósito de mejorar la eficiencia en la comunicación de los usuarios.

Palabras clave - Aprendizaje profundo, Arquitecturas neuronales, Procesamiento de señales, Reconocimiento de patrones.

Índice

1. INTRODUCCIÓN	1
1.1. OBJETIVOS	2
1.1.1. <i>Objetivo general</i>	2
1.1.2. <i>Objetivos específicos</i>	2
1.2. JUSTIFICACIÓN	2
2. MARCO REFERENCIAL	4
2.1. INTELIGENCIA ARTIFICIAL	4
2.1.1. <i>Interfaces Cerebro-Computadora (BCI)</i>	4
2.1.2. <i>Señales electroencefalográficas (EEG)</i>	4
2.1.3. <i>Paradigma P300</i>	4

2.1.4. <i>Aprendizaje profundo y arquitecturas neuronales</i>	5
2.2. PROCESAMIENTO DIGITAL DE SEÑALES BIOMÉDICAS	5
2.3. ESTADO DEL ARTE	5
3. PROPUESTA A DESARROLLAR	7
4. SELECCIÓN DE MODELOS	8
4.1. SELECCIÓN DE LENGUAJES DE PROGRAMACIÓN	8
4.2. EVALUACIÓN DE ARQUITECTURAS DE APRENDIZAJE PROFUNDO PARA DETECCIÓN DE P300	8
4.3. SELECCIÓN DE TECNOLOGÍAS	8
5. ALCANCE DEL SISTEMA	9
6. ESTUDIO DE FACTIBILIDAD	10
6.1. RECURSOS HUMANOS	10
6.2. RECURSOS DE HARDWARE	10
6.3. INFRAESTRUCTURA	10

Índice de figuras

Índice de tablas

2.1 Resumen comparativo del estado del arte	6
---	---

1. Introducción

En las últimas décadas, las Interfaces Cerebro Computadora (BCI, por sus siglas en inglés) se han convertido en una de las áreas de investigación más relevantes dentro de la biónica y la inteligencia artificial orientada al área de la salud, al permitir entablar comunicación directa entre la actividad cerebral de un individuo y un dispositivo externo sin depender de ninguna señal o movimiento muscular. Como se menciona en el trabajo de Felton et al. [1], las BCI traducen señales cerebrales registradas en acciones en tiempo real, lo cual abre la posibilidad de restaurar funciones comunicativas o motoras en personas con discapacidad severa.

Dentro de los paradigmas más estudiados en BCI basadas en electroencefalografía (EEG) se encuentra el uso de los Potenciales Relacionados con Eventos (ERP), específicamente la componente P300, cuya detección mediante la iluminación intermitente de filas y columnas de una matriz de caracteres dio origen al llamado P300 Speller [2]. A partir de este paradigma se han desarrollado sistemas de comunicación asistida tanto en el ámbito nacional como internacional, alcanzando en algunos casos porcentajes de acierto de hasta 95 % en evaluaciones intrasujeto y tasas sostenidas superiores a 17 caracteres por minuto cuando se emplean señales invasivas de electrocorticografía (ECoG). Sin embargo, de estos antecedentes se identifican dos limitaciones persistentes en los sistemas P300 basados en EEG: la necesidad de múltiples canales para mantener niveles altos de precisión, y la dependencia de múltiples repeticiones de estímulos para asegurar la detección confiable del componente P300, lo que reduce la velocidad de comunicación y aumenta la carga cognitiva del usuario.

Bajo este contexto, el presente Trabajo Terminal se orienta al desarrollo de un sistema de comunicación asistida basado en el paradigma P300 Speller utilizando EEG, integrando modelos de aprendizaje profundo para la detección automática del componente P300 e incorporando estrategias para reducir el número de canales y el número de repeticiones requeridas por selección de carácter, con el objetivo de incrementar la velocidad de comunicación sin comprometer la precisión del sistema.

1.1. Objetivos

1.1.1. Objetivo general

Desarrollar un sistema de comunicación asistida implementado en Python que permita a las personas con problemas motrices severos comunicarse por medio de señales electroencefalográficas usando el paradigma P300 Speller, a través de una interfaz gráfica basada en una matriz de selección visual de caracteres mediante la iluminación intermitente de filas y columnas, clasificando las componentes P300 de las señales cerebrales utilizando un modelo de aprendizaje profundo desarrollado en Python.

1.1.2. Objetivos específicos

1. Analizar y recolectar bases de datos públicas de señales electroencefalográficas sobre el paradigma P300 Speller, con el fin de identificar las características más importantes para el desempeño del modelo.
2. Revisar el estado del arte para seleccionar y analizar los modelos de aprendizaje profundo más adecuados para la detección de la componente P300 en señales cerebrales.
3. Diseñar e implementar un modelo de aprendizaje profundo para la clasificación de la componente P300 en señales EEG.
4. Evaluar el desempeño del modelo mediante métricas de clasificación buscando minimizar los canales o ciclos necesarios para la detección de la componente P300.
5. Diseñar e implementar el sistema de comunicación asistida, integrando el modelo de detección de P300 con una interfaz que permita la construcción de palabras por parte del usuario.
6. Integrar un módulo de predicción de palabras o autocompletado, orientado a reducir el número de selecciones necesarias para la construcción de mensajes.
7. Evaluar el funcionamiento del sistema mediante pruebas que permitan analizar su desempeño en la selección de caracteres y construcción de palabras.

1.2. Justificación

El análisis de señales EEG en paradigmas basados en la componente P300 ha sido ampliamente utilizado en el desarrollo de interfaces cerebro-computadora, particularmente en sistemas de selección de caracteres mediante el paradigma P300 Speller. Estos sistemas permiten la comunicación

mediante la detección de respuestas cerebrales asociadas a estímulos visuales, lo que representa una alternativa para las personas con compromisos motores severos que tengan problemas de comunicación.

De acuerdo con el trabajo de Feigin et al. [3], los desórdenes neurológicos son la principal causa de discapacidad a nivel mundial, y es posible que la magnitud de estas aumente debido al crecimiento y envejecimiento de la población; en enfermedades como la esclerosis lateral amiotrófica (ELA) la comunicación puede verse gravemente limitada, lo que impacta directamente en la calidad de vida del paciente.

Dentro de este contexto, el paradigma P300 Speller puede resultar útil para permitir la comunicación a las personas con problemas motrices severos, mejorando así su calidad de vida. Sin embargo, la mayoría de los estudios se enfocan en maximizar la precisión de clasificación mediante entornos controlados difíciles de llevar a la práctica, de modo que este trabajo interviene en la integración estructural del sistema, priorizando no solo el desempeño del modelo, sino también su incorporación en un sistema funcional que le permita a los usuarios objetivo la construcción efectiva de mensajes.

La reducción del número de canales o ensayos, así como la incorporación de estrategias que faciliten la selección de caracteres, puede contribuir al desarrollo de sistemas BCI más accesibles, portables y de implementación simplificada, ampliando su viabilidad en distintos contextos tecnológicos y acercando su uso a escenarios reales de asistencia comunicativa. De esta manera, el proyecto no se centra solamente en la optimización bajo escenarios aislados, sino que propone un sistema orientado a la aplicación práctica.

En cuanto a la aportación del trabajo, su valor radica en la integración de un modelo de aprendizaje profundo para la detección de la componente P300 con un modelo de predicción de caracteres, combinación que permite no solo identificar la selección de caracteres mediante las señales obtenidas por electroencefalografía, sino también optimizar el proceso de construcción de mensajes mediante la asistencia de este otro módulo.

Por lo tanto, la complejidad del trabajo implica el procesamiento y análisis de señales EEG, la implementación y entrenamiento de modelos de aprendizaje profundo, la integración de estos modelos en una aplicación y la evaluación de los resultados, lo cual requiere la aplicación avanzada de conocimientos en procesamiento de señales, aprendizaje profundo y desarrollo de sistemas, competencias propias del área de ingeniería en inteligencia artificial. Finalmente, el proyecto resulta viable en términos de tiempo y recursos, ya que los modelos de aprendizaje profundo pueden entrenarse utilizando bases de datos públicas de paradigmas P300, evitando la necesidad de adquisición propia de las mismas y reduciendo costos asociados a hardware especializado con 64 canales de detección de señales EEG.

2. Marco Referencial

En el presente capítulo se abordan los fundamentos teóricos que sustentan el desarrollo del sistema de comunicación asistida propuesto, partiendo de los conceptos generales asociados a las interfaces cerebro-computadora, para posteriormente abordar el procesamiento de señales biomédicas y, finalmente, presentar el estado del arte de los sistemas de comunicación basados en el paradigma P300 Speller.

2.1. Inteligencia Artificial

2.1.1. Interfaces Cerebro-Computadora (BCI)

Las Interfaces Cerebro Computadora permiten entablar comunicación directa entre la actividad cerebral de un individuo y un dispositivo externo, sin depender de ninguna otra señal o movimiento muscular. Como se menciona en el trabajo de Felton et al. [1], las BCI traducen señales cerebrales registradas en acciones en tiempo real, lo cual abre la posibilidad de restaurar funciones comunicativas o motoras en personas con discapacidad severa; no obstante, en ese mismo trabajo se discute que, dentro de los distintos enfoques en señales neuronales, el uso de electroencefalografía (EEG) presenta limitaciones relacionadas con una baja resolución de la señal, alto ruido y baja relación señal-ruido en comparación con técnicas invasivas como la electrocorticografía (ECoG).

2.1.2. Señales electroencefalográficas (EEG)

A pesar de dichas limitaciones, la electroencefalografía ha sido ampliamente utilizada por su característica de no ser invasiva y por su viabilidad clínica, de manera que, por su practicidad, continúa siendo la alternativa más accesible para aplicaciones a gran escala y experimentales en entornos académicos [1].

2.1.3. Paradigma P300

Dentro de los paradigmas más estudiados en BCI basadas en EEG se encuentra el uso de los Potenciales Relacionados con Eventos (ERP), específicamente la componente P300. El trabajo clásico

de Farwell y Donchin introdujo el llamado P300 Speller, que consiste en la iluminación intermitente de filas y columnas de una matriz para la detección de la componente P300 que se produce después de iluminarse el carácter objetivo al que el usuario está prestando atención, demostrando que es posible identificar ciertos estímulos mediante la detección de una deflexión positiva de la señal alrededor de 300 ms posteriores al estímulo [2].

2.1.4. Aprendizaje profundo y arquitecturas neuronales

2.2. Procesamiento Digital de Señales Biomédicas

El preprocesamiento de las señales EEG constituye una etapa determinante para el desempeño de los modelos de clasificación, dado que estas señales presentan una relación señal-ruido baja y son susceptibles a artefactos de origen fisiológico y ambiental. Para atender esta problemática se emplean técnicas de filtrado pasa banda, orientadas a delimitar el rango de frecuencias asociado a la componente P300, así como la segmentación de la señal continua en ventanas temporales alrededor de cada estímulo y la normalización de las mismas, procedimientos que en conjunto permiten generar un conjunto de datos adecuado para el entrenamiento y la validación del modelo de detección de la componente P300.

2.3. Estado del arte

En el ámbito nacional, la tesis de maestría titulada “Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil” [4], desarrollada en la Escuela Superior de Cómputo del Instituto Politécnico Nacional, implementó un sistema basado en aprendizaje profundo para la detección del componente P300, reportando valores promedio de AUC cercanos a 0.81 en evaluaciones intrasujeto y 0.69 en escenarios intersujeto sin calibración individual. Este trabajo demostró la viabilidad técnica de integrar procesamiento EEG, extracción automática de características y modelos de aprendizaje profundo en un sistema funcional; sin embargo, su aplicación estuvo orientada al control de una neuroprótesis y no específicamente a la implementación de un sistema de comunicación mediante deletreo.

En el ámbito internacional, el estudio “Interfaz cerebro-computador basada en P300 para la comunicación alternativa” [5] implementó un sistema funcional de deletreo utilizando una matriz de estimulación visual, reportando porcentajes de acierto de hasta 95 % en evaluaciones intrasujeto. Por su parte, el trabajo de Brunner et al. [6] demostró la operación de un sistema P300 Speller utilizando señales de electrocorticografía, alcanzando tasas sostenidas superiores a 17 caracteres por minuto; no obstante, el uso de técnicas invasivas limita su aplicación en contextos clínicos generales, donde el EEG continúa siendo la alternativa más accesible. Más recientemente, la investigación

“ChatBCI” [7] incorporó modelos de lenguaje de gran escala para mejorar las selecciones dentro de un sistema P300 Speller, logrando una reducción del tiempo promedio de escritura de 62.14 %.

La Tabla 2.1 resume los enfoques descritos, contrastando el número de canales empleados y el desempeño reportado por cada trabajo frente a la propuesta del presente Trabajo Terminal.

Tabla 2.1: Resumen comparativo del estado del arte

Trabajo	Enfoque	Canales	Desempeño
Deletreador P300 clásico [2]	Primer sistema P300 Speller basado en EEG.	6–16	Precisión = 78 %
Sistema clasificador EEG para neuroprótesis (IPN, 2021) [4]	Sistema móvil con Deep Learning para detección de P300 (EEG).	4	AUC = 0.81 (intra-sujeto), AUC = 0.69 (intersujeto sin calibración)
Interfaz P300 para comunicación alternativa (U. de Antioquia, 2011) [5]	Sistema funcional de libre deletreo con paradigma oddball (EEG).	6	Precisión = 85 %
P300 Speller con ECoG (Brunner et al., 2011) [6]	Sistema online de comunicación con matriz P300 (ECoG).	96 subdu- rales	17 caracteres/min
ChatBCI con LLM (Hong et al., 2026) [7]	P300 Speller con predicción contextual basada en LLM (EEG).	32	Reducción de tiempo promedio = 62.14 %
Propuesta TT	Sistema de comunicación asistida P300 con Deep Learning y optimización espacial-temporal (EEG).	4	–

3. Propuesta a desarrollar

4. Selección de modelos

4.1. Selección de lenguajes de programación

4.2. Evaluación de arquitecturas de aprendizaje profundo para detección de P300

4.3. Selección de tecnologías

5. Alcance del sistema

6. Estudio de factibilidad

6.1. Recursos humanos

6.2. Recursos de hardware

6.3. Infraestructura

Referencias

- [1] E. A. Felton, J. A. Wilson, J. C. Williams y P. C. Garell, «Electrocorticographically controlled brain–computer interfaces using motor and sensory imagery in patients with temporary subdural electrode implants,» *J. Neurosurg.*, vol. 106, n.º 3, págs. 495-500, 2007.
- [2] L. A. Farwell y E. Donchin, «Talking off the top of your head: Toward a mental prosthesis utilizing event-related brain potentials,» *Electroencephalogr. Clin. Neurophysiol.*, vol. 70, n.º 6, págs. 510-523, 1988.
- [3] V. L. Feigin et al., «The global burden of neurological disorders: translating evidence into policy,» *Lancet Neurol.*, vol. 19, n.º 3, págs. 255-265, 2020.
- [4] A. E. Contreras Martínez, «Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil,» Tesis de maestría., Esc. Sup. Cómputo, Inst. Politéc. Nac., Ciudad de México, México, 2021.
- [5] E. García Cossio et al., «Interfaz cerebro–computador basada en P300 para la comunicación alternativa: estudio de caso en dos adolescentes en situación de discapacidad motora,» *Rev. Fac. Ing. Univ. Antioquia*, n.º 60, págs. 9-20, 2011.
- [6] P. Brunner et al., «Rapid communication with a P300 matrix speller using electrocorticographic signals,» *Front. Neurosci.*, vol. 5, 2011, **artno** 5.
- [7] J. Hong, W. Wang y L. Najafizadeh, «ChatBCI, a P300 speller BCI with context-driven word prediction leveraging large language models,» *Sci. Rep.*, vol. 16, 2026, **artno** 6379.