



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SUBDIRECCIÓN ACADÉMICA



No de TT: 2027-A098

Fecha de presentación: [fecha]

Documento técnico

“Desarrollo de un sistema de comunicación asistida basado en señales electroencefalográficas mediante modelos de aprendizaje profundo”

Presentan:

Emiliano Arana Chávez¹

Alexis Vences Guevara²

Directores:

Mtro. René Baltazar Jiménez Ruíz, Dr. José Félix Serrano Talamantes

Resumen – Se propone el desarrollo de un sistema de comunicación asistida mediante señales electroencefalográficas (EEG), empleando el paradigma P300 Speller con una matriz de caracteres que se ilumina sistemáticamente para la clasificación del potencial de eventos P300 mediante modelos de aprendizaje profundo, permitiendo la identificación del carácter objetivo. Está dirigido a personas con compromisos motores severos. Así mismo, se evaluarán estrategias para optimizar la practicidad de la comunicación mediante la reducción del número de canales y repeticiones requeridas, sin comprometer el desempeño del modelo, con el propósito de mejorar la eficiencia en la comunicación de los usuarios.

Palabras clave – Aprendizaje profundo, Arquitecturas neuronales, Procesamiento de señales, Reconocimiento de patrones.

¹ earanac1900@alumno.ipn.mx | ² avencesg1900@alumno.ipn.mx

Índice

1. INTRODUCCIÓN	1
1.1. OBJETIVOS	1
1.1.1. <i>Objetivo general</i>	1
1.1.2. <i>Objetivos específicos</i>	2
1.2. JUSTIFICACIÓN	2
2. MARCO REFERENCIAL	4
2.1. DISCAPACIDAD MOTORA SEVERA Y COMUNICACIÓN	4
2.2. ELECTROENCEFALOGRAFÍA	5
2.2.1. <i>Adquisición de la señal</i>	5
2.2.2. <i>Sistema internacional 10-20</i>	5
2.2.3. <i>Ritmos cerebrales</i>	6
2.2.4. <i>Artefactos en la señal de EEG</i>	6
2.3. POTENCIALES RELACIONADOS CON EVENTOS Y COMPONENTE P300	8
2.3.1. <i>Potenciales relacionados con eventos</i>	8
2.3.2. <i>Promediado coherente</i>	8
2.3.3. <i>La componente P300</i>	10
2.3.4. <i>Paradigma del evento raro</i>	11
2.4. INTERFACES CEREBRO-COMPUTADORA	11
2.4.1. <i>Definición y componentes</i>	11
2.4.2. <i>Clasificación de las BCI</i>	12
2.4.3. <i>Paradigmas de control</i>	12
2.5. EL PARADIGMA P300 SPELLER	12
2.5.1. <i>Deletreador de Farwell y Donchin</i>	12
2.5.2. <i>Parámetros de estimulación</i>	13
2.5.3. <i>Épocas de EEG y decodificación del carácter</i>	14
2.5.4. <i>Variantes del paradigma</i>	14
2.5.5. <i>Bases de datos públicas</i>	15
2.6. PROCESAMIENTO DIGITAL DE SEÑALES BIOMÉDICAS	15
2.6.1. <i>Muestreo y teorema de Nyquist</i>	15

2.6.2.	<i>Transformada de Fourier y densidad espectral de potencia</i>	16
2.6.3.	<i>Convolución y sistemas lineales</i>	16
2.6.4.	<i>Filtros digitales</i>	17
2.6.5.	<i>Remuestreo</i>	17
2.6.6.	<i>Referencia y corrección de línea base</i>	18
2.6.7.	<i>Segmentación en épocas</i>	18
2.6.8.	<i>Normalización</i>	18
2.6.9.	<i>Remoción de artefactos</i>	19
2.7.	INTELIGENCIA ARTIFICIAL Y APRENDIZAJE AUTOMÁTICO	19
2.7.1.	<i>Aprendizaje automático</i>	20
2.7.2.	<i>Clasificadores clásicos para la detección de la P300</i>	20
2.7.3.	<i>Sobreajuste y generalización</i>	20
2.7.4.	<i>Esquemas de validación</i>	21
2.8.	REDES NEURONALES ARTIFICIALES Y APRENDIZAJE PROFUNDO	22
2.8.1.	<i>La neurona artificial</i>	22
2.8.2.	<i>Funciones de activación</i>	23
2.8.3.	<i>Función de pérdida</i>	23
2.8.4.	<i>Descenso de gradiente y retropropagación</i>	24
2.8.5.	<i>Regularización</i>	24
2.9.	REDES CONVOLUCIONALES Y RECURRENTES PARA LA DETECCIÓN DE LA P300	24
2.9.1.	<i>Redes neuronales convolucionales</i>	24
2.9.2.	<i>Convoluciones separables en profundidad</i>	25
2.9.3.	<i>EEGNet</i>	26
2.9.4.	<i>Arquitecturas convolucionales para la detección de la P300</i>	26
2.9.5.	<i>Redes neuronales recurrentes</i>	26
2.10.	MÉTRICAS DE EVALUACIÓN	27
2.10.1.	<i>Matriz de confusión</i>	27
2.10.2.	<i>Métricas de clasificación</i>	27
2.10.3.	<i>Curva ROC y área bajo la curva</i>	28
2.10.4.	<i>Métricas a nivel de sistema</i>	29
2.11.	REDUCCIÓN DE CANALES Y REPETICIONES	29
2.11.1.	<i>Selección de canales</i>	30
2.11.2.	<i>Reducción de repeticiones</i>	30
2.12.	MODELADO DEL LENGUAJE Y PREDICCIÓN DE PALABRAS	31
2.12.1.	<i>Predicción de palabras en la comunicación asistida</i>	31
2.12.2.	<i>Modelos de lenguaje probabilísticos</i>	31
2.12.3.	<i>Modelos de lenguaje neuronales</i>	31
2.12.4.	<i>Integración del lenguaje en el P300 Speller</i>	32

2.13. ESTADO DEL ARTE	32
2.13.1. <i>Sistemas P300 Speller y competencias BCI</i>	32
2.13.2. <i>Sistemas de comunicación con usuarios con discapacidad</i>	32
2.13.3. <i>Aprendizaje profundo para la detección de la P300</i>	33
2.13.4. <i>Resumen comparativo</i>	33
3. PROPUESTA A DESARROLLAR	35
4. SELECCIÓN DE MODELOS	36
4.1. SELECCIÓN DE LENGUAJES DE PROGRAMACIÓN	36
4.2. EVALUACIÓN DE ARQUITECTURAS DE APRENDIZAJE PROFUNDO PARA DETECCIÓN DE P300	36
4.3. SELECCIÓN DE TECNOLOGÍAS	36
5. ALCANCE DEL SISTEMA	37
6. ESTUDIO DE FACTIBILIDAD	38
6.1. RECURSOS HUMANOS	38
6.2. RECURSOS DE HARDWARE	38
6.3. INFRAESTRUCTURA	38

Índice de figuras

2.1	Posiciones de los electrodos del sistema internacional 10-20 (vista superior). Se resaltan los electrodos de la línea media Fz, Cz, Pz y Oz. Elaboración propia con base en [18].	6
2.2	Forma de onda ilustrativa de los principales ritmos del EEG. Elaboración propia.	7
2.3	(a) Forma de onda ilustrativa de un ERP ante un estímulo objetivo y uno no objetivo. (b) Efecto del promediado de N ensayos sobre la visibilidad de la componente P300. Señales sintéticas, elaboración propia.	9
2.4	Modelo de actualización del contexto de la componente P300. Elaboración propia con base en [22].	10
2.5	Secuencia de estímulos en el paradigma del evento raro (<i>oddball</i>). Elaboración propia.	11
2.6	Diagrama general de una interfaz cerebro-computadora. Elaboración propia con base en [7], [28].	12

2.7	Matriz de 6×6 caracteres del P300 Speller. Si el usuario atiende a la letra N (recuadro), tanto la intensificación de la fila 3 como la de la columna 2 son eventos objetivo que provocan una P300. Las diez intensificaciones restantes son eventos no objetivo. Elaboración propia con base en [2].	13
2.8	Parámetros de estimulación del P300 Speller con los valores de la base de datos II de la competencia BCI III (F = fila, C = columna). Elaboración propia con base en [14].	14
2.9	Densidad espectral de potencia estimada con el método de Welch para una señal de EEG sintética. Elaboración propia.	16
2.10	Respuesta en magnitud de (a) un filtro pasa banda Butterworth de cuarto orden entre 0.1 y 20 Hz y (b) un filtro <i>notch</i> en 60 Hz, para $f_s = 240$ Hz. Elaboración propia.	17
2.11	Segmentación de la señal continua en épocas de 0 a 650 ms a partir de cada intensificación. Señal sintética, elaboración propia.	18
2.12	Relación entre la inteligencia artificial, el aprendizaje automático y el aprendizaje profundo. Elaboración propia con base en [39].	19
2.13	Curvas de pérdida de entrenamiento y validación: a partir de cierto punto el modelo comienza a sobreajustarse. Elaboración propia.	21
2.14	Modelo de la neurona artificial y su analogía con la neurona biológica. Elaboración propia con base en [47].	22
2.15	Gráfica de las funciones de activación sigmoide, tangente hiperbólica, ReLU y ELU. Elaboración propia.	23
2.16	Arquitectura general de EEGNet. Elaboración propia con base en [49].	26
2.17	Matriz de confusión para la clasificación binaria de épocas. Elaboración propia.	28
2.18	(a) Distribuciones de puntajes de un clasificador para ambas clases y un umbral de decisión. (b) Curvas ROC para distintos grados de separación entre clases. Elaboración propia.	29
2.19	(a) Bits por selección en función de la exactitud para $N = 36$ según la Ecuación (2.10). (b) ITR teórica en función del número de repeticiones para tres niveles de exactitud, considerando 175 ms por intensificación y 2.5 s entre caracteres. Elaboración propia.	30

Índice de tablas

2.1	Bandas de frecuencia del EEG	7
-----	--	---

2.2	Artefactos comunes en el registro de EEG	8
2.3	Principales componentes de los ERP en paradigmas visuales	9
2.4	Bases de datos públicas del paradigma P300	15
2.5	Tipos de aprendizaje automático	20
2.6	Clasificadores clásicos utilizados en la detección de la P300	21
2.7	Funciones de activación más utilizadas	23
2.8	Técnicas de regularización y estabilización del entrenamiento	25
2.9	Algunas arquitecturas convolucionales para la detección de la P300 y AUC pro- medio reportada en [46]	27
2.10	Métricas de evaluación para la clasificación binaria	28
2.11	Trabajos que integran modelos de lenguaje en el P300 Speller	32
2.12	Resumen comparativo del estado del arte	34

1. Introducción

En las últimas décadas, las Interfaces Cerebro Computadora (BCI, por sus siglas en inglés) se han convertido en una de las áreas de investigación más relevantes dentro de la biónica y la inteligencia artificial orientada al área de la salud, al permitir entablar comunicación directa entre la actividad cerebral de un individuo y un dispositivo externo sin depender de ninguna señal o movimiento muscular. Como se menciona en el trabajo de Felton et al. [1], las BCI traducen señales cerebrales registradas en acciones en tiempo real, lo cual abre la posibilidad de restaurar funciones comunicativas o motoras en personas con discapacidad severa.

Dentro de los paradigmas más estudiados en BCI basadas en electroencefalografía (EEG) se encuentra el uso de los Potenciales Relacionados con Eventos (ERP), específicamente la componente P300, cuya detección mediante la iluminación intermitente de filas y columnas de una matriz de caracteres dio origen al llamado P300 Speller [2]. A partir de este paradigma se han desarrollado sistemas de comunicación asistida tanto en el ámbito nacional como internacional, alcanzando en algunos casos porcentajes de acierto de hasta 95% en evaluaciones intrasujeto y tasas sostenidas superiores a 17 caracteres por minuto cuando se emplean señales invasivas de electrocorticografía (ECoG). Sin embargo, de estos antecedentes se identifican dos limitaciones persistentes en los sistemas P300 basados en EEG: la necesidad de múltiples canales para mantener niveles altos de precisión, y la dependencia de múltiples repeticiones de estímulos para asegurar la detección confiable del componente P300, lo que reduce la velocidad de comunicación y aumenta la carga cognitiva del usuario.

Bajo este contexto, el presente Trabajo Terminal se orienta al desarrollo de un sistema de comunicación asistida basado en el paradigma P300 Speller utilizando EEG, integrando modelos de aprendizaje profundo para la detección automática del componente P300 e incorporando estrategias para reducir el número de canales y el número de repeticiones requeridas por selección de carácter, con el objetivo de incrementar la velocidad de comunicación sin comprometer la precisión del sistema.

1.1. Objetivos

1.1.1. Objetivo general

Desarrollar un sistema de comunicación asistida implementado en Python que permita a las personas con problemas motrices severos comunicarse por medio de señales electroencefalográficas usando el paradigma P300 Speller, a través de una interfaz gráfica basada en una matriz de selección visual de caracteres mediante la iluminación intermitente de filas y columnas, clasificando las componentes P300 de las señales cerebrales utilizando un modelo de aprendizaje profundo desarrollado en Python.

1.1.2. Objetivos específicos

1. Analizar y recolectar bases de datos públicas de señales electroencefalográficas sobre el paradigma P300 Speller, con el fin de identificar las características más importantes para el desempeño del modelo.
2. Revisar el estado del arte para seleccionar y analizar los modelos de aprendizaje profundo más adecuados para la detección de la componente P300 en señales cerebrales.
3. Diseñar e implementar un modelo de aprendizaje profundo para la clasificación de la componente P300 en señales EEG.
4. Evaluar el desempeño del modelo mediante métricas de clasificación buscando minimizar los canales o ciclos necesarios para la detección de la componente P300.
5. Diseñar e implementar el sistema de comunicación asistida, integrando el modelo de detección de P300 con una interfaz que permita la construcción de palabras por parte del usuario.
6. Integrar un módulo de predicción de palabras o autocompletado, orientado a reducir el número de selecciones necesarias para la construcción de mensajes.
7. Evaluar el funcionamiento del sistema mediante pruebas que permitan analizar su desempeño en la selección de caracteres y construcción de palabras.

1.2. Justificación

El análisis de señales EEG en paradigmas basados en la componente P300 ha sido ampliamente utilizado en el desarrollo de interfaces cerebro-computadora, particularmente en sistemas de selección de caracteres mediante el paradigma P300 Speller. Estos sistemas permiten la comunicación mediante la detección de respuestas cerebrales asociadas a estímulos visuales, lo que representa una alternativa para las personas con compromisos motores severos que tengan problemas de comunicación.

De acuerdo con el trabajo de Feigin et al. [3], los desórdenes neurológicos son la principal causa de discapacidad a nivel mundial, y es posible que la magnitud de estas aumente debido al crecimiento y envejecimiento de la población; en enfermedades como la esclerosis lateral amiotrófica (ELA) la comunicación puede verse gravemente limitada, lo que impacta directamente en la calidad de vida del paciente.

Dentro de este contexto, el paradigma P300 Speller puede resultar útil para permitir la comunicación a las personas con problemas motrices severos, mejorando así su calidad de vida. Sin embargo, la mayoría de los estudios se enfocan en maximizar la precisión de clasificación mediante entornos controlados difíciles de llevar a la práctica, de modo que este trabajo interviene en la integración estructural del sistema, priorizando no solo el desempeño del modelo,

sino también su incorporación en un sistema funcional que le permita a los usuarios objetivo la construcción efectiva de mensajes.

La reducción del número de canales o ensayos, así como la incorporación de estrategias que faciliten la selección de caracteres, puede contribuir al desarrollo de sistemas BCI más accesibles, portables y de implementación simplificada, ampliando su viabilidad en distintos contextos tecnológicos y acercando su uso a escenarios reales de asistencia comunicativa. De esta manera, el proyecto no se centra solamente en la optimización bajo escenarios aislados, sino que propone un sistema orientado a la aplicación práctica.

En cuanto a la aportación del trabajo, su valor radica en la integración de un modelo de aprendizaje profundo para la detección de la componente P300 con un modelo de predicción de caracteres, combinación que permite no solo identificar la selección de caracteres mediante las señales obtenidas por electroencefalografía, sino también optimizar el proceso de construcción de mensajes mediante la asistencia de este otro módulo.

Por lo tanto, la complejidad del trabajo implica el procesamiento y análisis de señales EEG, la implementación y entrenamiento de modelos de aprendizaje profundo, la integración de estos modelos en una aplicación y la evaluación de los resultados, lo cual requiere la aplicación avanzada de conocimientos en procesamiento de señales, aprendizaje profundo y desarrollo de sistemas, competencias propias del área de ingeniería en inteligencia artificial. Finalmente, el proyecto resulta viable en términos de tiempo y recursos, ya que los modelos de aprendizaje profundo pueden entrenarse utilizando bases de datos públicas de paradigmas P300, evitando la necesidad de adquisición propia de las mismas y reduciendo costos asociados a hardware especializado con 64 canales de detección de señales EEG.

2. Marco Referencial

En el siguiente capítulo se presentan los fundamentos teóricos que sustentan el desarrollo del sistema de comunicación asistida que se propone. El recorrido parte del contexto de las personas con problemas motores severos, además se aborda la electroencefalografía, los potenciales relacionados con eventos y las interfaces cerebro-computadora basadas en el paradigma P300 Speller, a continuación se explican los conceptos necesarios para el desarrollo de este proyecto sobre el procesamiento digital de las señales, los modelos de aprendizaje automático y profundo empleados para su clasificación, las métricas de evaluación y los modelos de lenguaje orientados a la predicción de palabras, para finalmente presentar el estado del arte en cuanto a los sistemas de comunicación basados en este paradigma.

2.1. Discapacidad motora severa y comunicación

De acuerdo con el Informe mundial sobre la discapacidad de la Organización Mundial de la Salud (OMS) y el Banco Mundial, más de mil millones de personas en el mundo viven con alguna forma de discapacidad. De ellas, cerca de 200 millones tienen dificultades considerables para realizar actividades básicas de la vida diaria [4]. Más concretamente, en México, la Encuesta Nacional de la Dinámica Demográfica de 2018 reportó que el 6.3 % de la población, alrededor de 7.8 millones de habitantes, tiene alguna discapacidad. De este grupo, el 17.8 % tenía dificultad para mover o usar brazos o manos, y el 10.5 % presentaba dificultad severa para hablar o comunicarse [5]. Asimismo, Feigin et al. señalan que los trastornos neurológicos son actualmente la principal causa de discapacidad a nivel mundial y que su carga tiende a crecer con el envejecimiento de la población [3].

Dentro de este grupo se encuentran padecimientos como la esclerosis lateral amiotrófica (ELA), las lesiones medulares altas o los eventos vasculares del tallo cerebral, que en sus etapas avanzadas pueden llevar al llamado síndrome de enclaustramiento (*locked-in*), condición en la que la persona conserva sus funciones cognitivas pero pierde prácticamente todo el control muscular voluntario, incluido el del habla. Uno de los primeros dispositivos de deletreo controlados únicamente con la actividad cerebral fue presentado por Birbaumer et al. precisamente para pacientes con ELA en esta condición, quienes lograron escribir mensajes a partir del control voluntario de potenciales corticales lentos, aunque tras semanas de entrenamiento y a una velocidad de escritura considerablemente baja [6].

La comunicación aumentativa y alternativa agrupa las estrategias y herramientas que complementan o sustituyen el habla, desde tableros de letras hasta sistemas de seguimiento ocular. Sin embargo, casi todas ellas dependen de algún canal muscular residual, ya sea el movimiento de los ojos, de un dedo o de los párpados, por lo que dejan de ser útiles cuando dicho control se pierde por completo. Es en este punto donde las interfaces cerebro-computadora (BCI) ofrecen

un canal de salida que no depende de los nervios periféricos ni de los músculos [7], y en este sentido Sellers y Donchin realizaron las primeras pruebas de un sistema basado en la componente P300 con pacientes con ELA, mostrando que estos podían operarlo a pesar del avance de la enfermedad [8].

2.2. Electroencefalografía

El electroencefalograma (EEG) se define como el registro de la actividad eléctrica del cerebro tomado por medio de electrodos colocados en la superficie de la cabeza, mientras que la electroencefalografía corresponde a la disciplina que se encarga de registrar e interpretar dichos registros [9]. El primer registro de este tipo en humanos fue reportado en 1929 por el psiquiatra alemán Hans Berger, quien además acuñó el término electroencefalograma y describió el ritmo que hoy se conoce como alfa [10].

2.2.1. Adquisición de la señal

Los potenciales registrados en el cuero cabelludo tienen amplitudes que van de unos cuantos microvolts hasta alrededor de $100\ \mu\text{V}$, por lo que deben amplificarse considerablemente antes de digitalizarse [11]. Los electrodos más comunes son discos de plata recubiertos de cloruro de plata (Ag/AgCl). Se colocan con un gel conductor para reducir la impedancia de contacto, que idealmente debe ser menor a $5\ \text{k}\Omega$. También existen electrodos secos, que no necesitan gel y se colocan más rápido. Su desventaja es que tienen mayor impedancia y son más sensibles a los artefactos de movimiento [12]. En este sentido, el trabajo de Contreras [13] utilizó electrodos secos de un sistema de bajo costo con cuatro canales, mientras que las bases de datos públicas del paradigma P300, como la empleada en este trabajo, fueron adquiridas con equipos de grado de investigación de 64 canales [14].

Cada canal de EEG mide en realidad una diferencia de potencial, por lo que es necesario definir contra qué punto se mide. En un montaje unipolar, cada electrodo se compara con un electrodo de referencia común, ubicado en un sitio con poca actividad cerebral, como el lóbulo de la oreja o las mastoides. En un montaje bipolar, en cambio, se registra la diferencia entre pares de electrodos vecinos [15]. Una tercera alternativa, muy utilizada en el procesamiento digital, es la referencia promedio común (CAR), en la que a cada canal se le resta el promedio de todos los canales en cada instante de tiempo [16].

2.2.2. Sistema internacional 10-20

Para que los registros sean comparables entre sujetos y laboratorios, la posición de los electrodos se estandariza mediante el sistema internacional 10-20, propuesto originalmente por Jasper [17] y actualizado por la Federación Internacional de Neurofisiología Clínica (IFCN) [18]. Su nombre se debe a que las posiciones se obtienen dividiendo las distancias entre cuatro puntos de referencia anatómicos (el nasión, el inión y los dos puntos preauriculares) en segmentos del 10 % y del 20 % de su longitud total. Cada electrodo se nombra con una o dos letras según

la región que cubre: Fp (frontopolar), F (frontal), C (central), T (temporal), P (parietal) y O (occipital). Después se agrega un número impar si el electrodo está en el hemisferio izquierdo, un número par si está en el derecho, o la letra z si está sobre la línea media [18]. La Figura 2.1 muestra la distribución de los 21 electrodos del sistema, resaltando los de la línea media (Fz, Cz, Pz y Oz), que fueron los utilizados en el trabajo de Contreras [13]. Las bases de datos del paradigma P300 suelen utilizar la extensión 10-10, que agrega posiciones intermedias hasta completar 64 o más canales [14].




Figura 2.1: Posiciones de los electrodos del sistema internacional 10-20 (vista superior). Se resaltan los electrodos de la línea media Fz, Cz, Pz y Oz. Elaboración propia con base en [18].

2.2.3. Ritmos cerebrales

Un ritmo cerebral se define como la actividad del EEG formada por ondas de un periodo aproximadamente constante [9], y de acuerdo con su frecuencia se clasifica en las bandas delta, theta, alfa, beta y gamma. Cada banda se asocia con estados de actividad distintos: el ritmo alfa, por ejemplo, predomina en la región occipital cuando la persona está despierta, en reposo y con los ojos cerrados, y se sustituye por actividad beta de menor amplitud cuando la atención se dirige a una tarea, fenómeno conocido como bloqueo alfa [15], [19]. La Tabla 2.1 resume sus características y la Figura 2.2 ilustra su forma de onda.

2.2.4. Artefactos en la señal de EEG

Debido a su baja amplitud, el EEG es muy susceptible a señales que no provienen de la actividad cerebral, conocidas como artefactos. Los más frecuentes son de origen fisiológico, como los parpadeos y movimientos oculares, cuya amplitud puede ser varias veces mayor que la del propio EEG, la actividad eléctrica de los músculos de la cara y el cuello o la actividad cardiaca. Otros que se pueden presentar son los de origen técnico, como la interferencia de la

Tabla 2.1: Bandas de frecuencia del EEG

Ritmo	Frecuencia	Amplitud	Región	Estado asociado
Delta (δ)	0.5–4 Hz	20–200 μV	Variable	Sueño profundo, lactancia; en vigilia puede indicar patología.
Theta (θ)	4–8 Hz	10–50 μV	Parietal, temporal	Somnolencia, niñez, algunos estados de estrés emocional.
Alfa (α)	8–13 Hz	50–100 μV	Occipital	Vigilia relajada con ojos cerrados; se bloquea al atender.
Beta (β)	13–30 Hz	<30 μV	Frontal, central	Alerta, concentración y actividad mental.
Gamma (γ)	>30 Hz	<10 μV	Difusa	Procesamiento sensorial y atención focalizada.

Elaboración propia con información de [9], [15], [19].




Figura 2.2: Forma de onda ilustrativa de los principales ritmos del EEG. Elaboración propia.

red eléctrica, que en México se presenta a 60 Hz, o los cambios de impedancia de los electrodos [11], [12]. La Tabla 2.2 presenta los principales artefactos junto con las técnicas más comunes para mitigarlos, algunas de las cuales se retoman en la Sección 2.6.

Tabla 2.2: Artefactos comunes en el registro de EEG

Artefacto	Origen	Banda afectada	Mitigación
Parpadeo y movimiento ocular (EOG)	Fisiológico	<4 Hz	Filtrado pasa altas, regresión con canales EOG, ICA.
Actividad muscular (EMG)	Fisiológico	>20 Hz	Filtrado pasa bajas, instrucciones al sujeto, ICA.
Actividad cardíaca (ECG)	Fisiológico	1–2 Hz y armónicos	Referencia adecuada, ICA.
Sudoración y deriva de línea base	Fisiológico / electrodo	<0.5 Hz	Filtrado pasa altas, corrección de línea base.
Interferencia de la red eléctrica	Técnico	60 Hz (México)	Filtro notch, blindaje, buena impedancia.
Movimiento o mal contacto del electrodo	Técnico	Banda ancha	Rechazo de épocas por umbral de amplitud.

Elaboración propia con información de [11], [12], [20].

2.3. Potenciales relacionados con eventos y componente P300

2.3.1. Potenciales relacionados con eventos

Los ritmos del EEG se presentan de manera espontánea. En cambio, los potenciales relacionados con eventos (ERP, por sus siglas en inglés) son variaciones del voltaje que aparecen ligadas en el tiempo a un evento específico. Este evento puede ser un estímulo sensorial, una respuesta motora o una operación cognitiva, como reconocer un estímulo [21]. En el cuero cabelludo, un ERP se registra como una serie de ondas positivas y negativas llamadas componentes. Cada componente se nombra con la letra P o N según su polaridad, seguida de un número que indica su latencia aproximada en milisegundos o su posición en la secuencia [16]. La Tabla 2.3 describe las componentes que aparecen con mayor frecuencia en paradigmas de estimulación visual.

2.3.2. Promediado coherente

El principal problema para observar un ERP es que su amplitud, de unos cuantos microvolts, es considerablemente menor que la de la actividad de fondo del EEG, que para estos fines se comporta como ruido. La forma clásica de resolverlo consiste en presentar el mismo estímulo repetidas veces, extraer los segmentos de señal sincronizados con cada presentación y promediarlos [23]. Si cada ensayo $x_i(n)$ se modela como la suma de una respuesta $s(n)$ que se repite

Tabla 2.3: Principales componentes de los ERP en paradigmas visuales

Componente	Latencia	Polaridad	Proceso asociado
N100 (N1)	100–200 ms	Negativa	Procesamiento sensorial y orientación de la atención hacia el estímulo.
P200 (P2)	150–250 ms	Positiva	Evaluación de las características físicas del estímulo.
N200 (N2)	200–350 ms	Negativa	Detección de desajuste entre el estímulo y lo esperado; clasificación del estímulo.
P300 (P3)	250–500 ms	Positiva	Actualización del contexto en la memoria de trabajo ante estímulos relevantes o poco frecuentes.

Elaboración propia con información de [16], [21], [22].

de forma idéntica y de un ruido $r_i(n)$ de media cero y varianza σ^2 , independiente entre ensayos, el promedio de N ensayos queda como

$$\bar{x}(n) = \frac{1}{N} \sum_{i=1}^N x_i(n) = s(n) + \frac{1}{N} \sum_{i=1}^N r_i(n), \quad (2.1)$$

donde la desviación estándar del ruido residual se reduce a $\sigma/\sqrt{N}$, de modo que la relación señal-ruido mejora en proporción a la raíz cuadrada del número de ensayos [16]. La Figura 2.3 ilustra ambas ideas. El panel (a) muestra la forma de onda típica ante un estímulo objetivo y ante uno no objetivo. El panel (b) muestra cómo la P300 se vuelve visible conforme aumenta el número de ensayos promediados. Esta relación explica por qué el P300 Speller necesita repetir varias veces la intensificación de cada fila y columna, y por qué reducir dichas repeticiones, objetivo de este trabajo, compromete directamente la confiabilidad de la detección.




Figura 2.3: (a) Forma de onda ilustrativa de un ERP ante un estímulo objetivo y uno no objetivo. (b) Efecto del promediado de N ensayos sobre la visibilidad de la componente P300. Señales sintéticas, elaboración propia.

2.3.3. La componente P300

La componente P300 fue descrita por primera vez en 1965 por Sutton et al., quienes observaron que los estímulos cuya ocurrencia era incierta para el sujeto evocaban una onda positiva de gran amplitud alrededor de 300 ms después de su presentación [24]. Años más tarde, Squires, Squires y Hillyard distinguieron dos variantes de esta onda [25]. La P3a aparece antes, se registra en la región frontocentral y la provocan estímulos novedosos que captan la atención de forma involuntaria. La P3b se registra en la región parietal y aparece ante estímulos relevantes para la tarea que el sujeto está realizando. Es esta última la que se aprovecha en el P300 Speller, pues su aparición depende de que el usuario atienda deliberadamente al carácter que desea seleccionar [22].

La explicación más aceptada sobre el origen de la P300 es la teoría de actualización del contexto, propuesta inicialmente por Donchin [26] y posteriormente integrada por Polich [22]. Según esta teoría, cada estímulo nuevo se compara con la representación del contexto guardada en la memoria de trabajo. Si no hay cambio, el modelo mental se mantiene y solo aparecen los potenciales sensoriales tempranos. Si el estímulo es diferente y el sujeto le presta atención, la representación se actualiza y se genera la P300, como se muestra en la Figura 2.4.




Figura 2.4: Modelo de actualización del contexto de la componente P300. Elaboración propia con base en [22].

La P300 se describe principalmente con dos medidas. La amplitud es la diferencia entre el voltaje de la línea base previa al estímulo y el pico positivo más alto, que se busca típicamente entre 250 y 500 ms. La latencia es el tiempo que pasa desde el inicio del estímulo hasta ese pico [22]. En los electrodos de la línea media, la amplitud aumenta de las regiones frontales hacia las parietales y alcanza su máximo en Pz [27]. La amplitud es mayor cuando el estímulo objetivo es menos probable y más relevante para la tarea. En cambio, disminuye con la fatiga, la habituación y los intervalos cortos entre estímulos. La latencia refleja el tiempo que se tarda en clasificar el estímulo y tiende a aumentar con la edad [22], [27].

2.3.4. Paradigma del evento raro

El procedimiento experimental más utilizado para provocar la P300 es el paradigma del evento raro, conocido en inglés como *oddball*. En él se presenta al sujeto una secuencia de estímulos de dos categorías, una de las cuales aparece con mucha menor frecuencia que la otra, y se le pide que atienda o cuente únicamente los estímulos de la categoría poco frecuente [2], [22]. Los estímulos raros, que en el contexto de una BCI corresponden al objetivo elegido por el usuario, producen una P300 cuya amplitud es inversamente proporcional a su probabilidad de aparición [2]. La Figura 2.5 representa una secuencia típica de este paradigma.




Figura 2.5: Secuencia de estímulos en el paradigma del evento raro (*oddball*). Elaboración propia.

2.4. Interfaces cerebro-computadora

2.4.1. Definición y componentes

Las interfaces cerebro-computadora (BCI) permiten entablar comunicación directa entre la actividad cerebral de un individuo y un dispositivo externo, sin depender de ninguna otra señal o movimiento muscular. De acuerdo con Wolpaw et al., una BCI es un sistema de comunicación en el que los mensajes o comandos que el usuario envía al mundo exterior no pasan por las vías de salida normales del cerebro, es decir, por los nervios periféricos y los músculos [7], y como se menciona en el trabajo de Felton et al., estos sistemas traducen las señales cerebrales registradas en acciones en tiempo real, lo cual abre la posibilidad de restaurar funciones comunicativas o motoras en personas con discapacidad severa [1].

Independientemente de la señal que utilice, una BCI se compone de una serie de etapas que se ejecutan de forma cíclica, como se ilustra en la Figura 2.6. Primero se adquiere y digitaliza la señal cerebral. Después se preprocesa para reducir el ruido y los artefactos. Luego se extraen las características que mejor representan la intención del usuario, y un clasificador las convierte en un comando para el dispositivo. Finalmente, el resultado se muestra al usuario como retroalimentación para que pueda ajustar su estrategia [28], [29].




Figura 2.6: Diagrama general de una interfaz cerebro-computadora. Elaboración propia con base en [7], [28].

2.4.2. Clasificación de las BCI

Las BCI pueden clasificarse bajo distintos criterios. Según la forma en que se registra la señal, se dividen en invasivas, que requieren colocar electrodos dentro o sobre el cerebro, y no invasivas, que registran la actividad desde el exterior [29]. Según el origen de la actividad que aprovechan, se distinguen las exógenas, que dependen de una estimulación externa como la iluminación de una matriz de caracteres, y las endógenas, en las que el usuario modula voluntariamente su actividad cerebral sin estímulo alguno, por ejemplo al imaginar el movimiento de una mano [29]. Asimismo, una BCI es síncrona cuando el sistema determina los intervalos en los que el usuario puede emitir un comando, y asíncrona cuando el usuario puede hacerlo en cualquier momento, lo que exige detectar también los periodos en los que no desea comunicarse [28]. Bajo estos criterios, el P300 Speller es una BCI no invasiva, exógena y síncrona.

2.4.3. Paradigmas de control

Las BCI basadas en EEG utilizan principalmente cuatro tipos de señales. Las basadas en ritmos sensoriomotores aprovechan la disminución de los ritmos mu y beta sobre la corteza motora al imaginar un movimiento. Las de potenciales evocados visuales de estado estable (SS-VEP) usan la respuesta de la corteza visual a estímulos que parpadean a una frecuencia fija. Las de potenciales corticales lentos requieren que el usuario aprenda a modificar voluntariamente la línea base de su EEG. Por último, las basadas en la P300 aprovechan la respuesta del paradigma del evento raro descrita en la sección anterior [7], [29]. Una de las principales ventajas de este último enfoque es que la P300 es una respuesta natural ante los estímulos relevantes, por lo que prácticamente no requiere entrenamiento previo del usuario [2], [13].

2.5. El paradigma P300 Speller

2.5.1. Deletreador de Farwell y Donchin

En 1988 Farwell y Donchin publicaron el sistema que hoy se conoce como P300 Speller o deletreador de Donchin. En su artículo original todavía no se habla de una BCI, sino de una prótesis mental pensada como canal de comunicación para personas cuya discapacidad motora les impide comunicarse [2]. El sistema muestra en pantalla una matriz de 6×6 celdas con las

letras del alfabeto, algunos números y comandos simples. Durante su funcionamiento, las filas y columnas se iluminan una por una en orden aleatorio. Mientras tanto, el usuario se concentra en la celda que desea seleccionar, por ejemplo, contando mentalmente cuántas veces se ilumina [2]. De los doce eventos posibles, seis filas y seis columnas, solamente dos contienen al carácter objetivo, de modo que estas intensificaciones funcionan como los estímulos raros del paradigma *oddball* y provocan una P300 que no aparece en las diez restantes, tal como se representa en la Figura 2.7.

A	B	C	D	E	F
G	H	I	J	K	L
M	N	O	P	Q	R
S	T	U	V	W	X
Y	Z	1	2	3	4
5	6	7	8	9	—

(a) Intensificación de la fila 3 (b) Intensificación de la columna 2

Figura 2.7: Matriz de 6×6 caracteres del P300 Speller. Si el usuario atiende a la letra N (recuadro), tanto la intensificación de la fila 3 como la de la columna 2 son eventos objetivo que provocan una P300. Las diez intensificaciones restantes son eventos no objetivo. Elaboración propia con base en [2].

El sistema original registraba el EEG únicamente en el electrodo Pz y, con cuatro participantes sanos, alcanzó una exactitud cercana al 95 % con un tiempo promedio de 26 segundos por carácter, equivalente a 2.3 caracteres o 12 bits por minuto [2]. Aunque esta velocidad es muy baja comparada con la escritura convencional, la arquitectura y el principio de operación de este deletreador siguen siendo la base de la mayoría de los sistemas BCI basados en la P300 [13].

2.5.2. Parámetros de estimulación

El desempeño del P300 Speller depende en buena medida de los tiempos con que se presentan los estímulos. La duración de la intensificación es el tiempo que una fila o columna permanece iluminada. El intervalo entre estímulos (ISI) es el tiempo que la matriz permanece sin iluminar antes del siguiente evento. La suma de ambos se conoce como intervalo entre inicios de estímulos (SOA). A una secuencia completa de las doce intensificaciones se le llama repetición, y el número de repeticiones que se hacen antes de elegir el carácter determina el equilibrio entre velocidad y exactitud [30]. La Figura 2.8 representa estos parámetros con los valores de la base de datos II de la tercera competencia BCI, utilizada en este trabajo, en la que cada intensificación dura 100 ms seguida de 75 ms sin estímulo, y cada carácter se deletrea con 15 repeticiones, es decir, con 180 intensificaciones [14].




Figura 2.8: Parámetros de estimulación del P300 Speller con los valores de la base de datos II de la competencia BCI III (F = fila, C = columna). Elaboración propia con base en [14].

2.5.3. Épocas de EEG y decodificación del carácter

Para clasificar la señal, el registro continuo se divide en segmentos que inician en el instante de cada intensificación, llamados épocas. Una época es atendida si corresponde a una fila o columna que contiene el carácter objetivo, y no atendida en caso contrario [13]. En lo sucesivo, x_j^f y x_j^c denotan las épocas asociadas a la fila f y a la columna c en la repetición j .

Una vez que un clasificador asigna a cada época un puntaje $g(\cdot)$ que refleja la probabilidad de que contenga una P300, el carácter se decide sumando los puntajes de cada fila y cada columna a lo largo de las J repeticiones y eligiendo aquellas con el valor más alto [31]:

$$\hat{f} = \arg \max_{f \in \{1, \dots, 6\}} \sum_{j=1}^J g(x_j^f), \quad \hat{c} = \arg \max_{c \in \{1, \dots, 6\}} \sum_{j=1}^J g(x_j^c), \quad (2.2)$$

de modo que el carácter seleccionado es el que se encuentra en la intersección de la fila $\hat{f}$ y la columna $\hat{c}$. Con esta estrategia, el ganador de la competencia BCI III alcanzó una exactitud del 96.5 % al utilizar las 15 repeticiones disponibles [31].

Cabe destacar que, por la propia estructura del paradigma, el conjunto de épocas está fuertemente desbalanceado: en cada repetición solo dos de las doce intensificaciones son objetivo, lo que produce una proporción de una época positiva por cada cinco negativas [32]. Si este desbalance no se considera durante el entrenamiento, un clasificador puede alcanzar una exactitud aparente cercana al 83 % simplemente prediciendo siempre la clase negativa, razón por la cual las métricas de evaluación de la Sección 2.10 deben elegirse con cuidado.

2.5.4. Variantes del paradigma

El paradigma de filas y columnas presenta algunos problemas conocidos. Los errores de adyacencia ocurren cuando el sistema elige un carácter vecino al objetivo, porque las filas o columnas cercanas también atraen parte de la atención del usuario. El problema del doble destello aparece cuando la misma fila o columna objetivo se ilumina dos veces seguidas. En ese caso, la segunda P300 se atenúa o se mezcla con la primera [33]. Para mitigarlos se han propuesto distintas variantes, entre las que destacan el paradigma de tablero de ajedrez de Townsend et al., que intensifica grupos de caracteres no contiguos [33], y el uso de rostros conocidos superpues-

tos a los caracteres, con el que Kaufmann et al. obtuvieron ERP de mayor amplitud y redujeron el número de secuencias necesarias para una selección correcta [34].

2.5.5. Bases de datos públicas

Gran parte de la investigación sobre detección de la P300 se apoya en bases de datos públicas, lo que permite comparar métodos bajo las mismas condiciones sin tener que adquirir señales propias. Las más utilizadas provienen de la segunda y tercera competencias internacionales de BCI, ambas registradas con 64 canales a 240 Hz con el paradigma de filas y columnas [14], [35], mientras que la base de datos de la Escuela Politécnica Federal de Lausana (EPFL) incluye registros de personas con discapacidad motora con un paradigma de seis imágenes [36]. La Tabla 2.4 resume sus características. En el presente trabajo se emplea la base de datos II de la competencia BCI III, que contiene registros de dos sujetos con 85 caracteres de entrenamiento y 100 de prueba cada uno.

Tabla 2.4: Bases de datos públicas del paradigma P300

Base de datos	Sujetos	Canales	Frec. (Hz)	Paradigma
BCI Competition II, conjunto IIb [35]	1	64	240	Matriz 6×6 , filas y columnas, 15 repeticiones.
BCI Competition III, conjunto II [14]	2	64	240	Matriz 6×6 , filas y columnas, 15 repeticiones; 85 caracteres de entrenamiento y 100 de prueba por sujeto.
EPFL [36]	8	32	2048	Seis imágenes intensificadas de una en una; incluye sujetos con discapacidad motora.

Elaboración propia.

2.6. Procesamiento Digital de Señales Biomédicas

El preprocesamiento de las señales EEG constituye una etapa determinante para el desempeño de los modelos de clasificación, dado que estas señales presentan una relación señal-ruido baja y son susceptibles a artefactos de origen fisiológico y ambiental. Para atender esta problemática se emplean técnicas de filtrado pasa banda, orientadas a delimitar el rango de frecuencias asociado a la componente P300, así como la segmentación de la señal continua en ventanas temporales alrededor de cada estímulo y la normalización de las mismas, cuyos fundamentos se describen a lo largo de esta sección.

2.6.1. Muestreo y teorema de Nyquist

Las señales fisiológicas son analógicas, es decir, están definidas en todo instante y su amplitud puede tomar cualquier valor. Para procesarlas en una computadora se deben muestrear a intervalos regulares $T_s = 1/f_s$, lo que produce la secuencia discreta $x(n) = x_a(nT_s)$ [37]. El

teorema de muestreo establece que una señal cuyo contenido en frecuencia está limitado a $f_{\text{máx}}$ puede reconstruirse sin pérdida a partir de sus muestras siempre que

$$f_s \geq 2f_{\text{máx}}, \quad (2.3)$$

y si esta condición no se cumple, las componentes de frecuencia superiores a $f_s/2$, conocida como frecuencia de Nyquist, se reflejan sobre las frecuencias bajas en un fenómeno llamado *aliasing* [38]. La base de datos utilizada en este trabajo fue muestreada a 240 Hz, por lo que su frecuencia de Nyquist de 120 Hz está muy por encima de la banda de interés de la P300, que se concentra por debajo de 20 Hz.

2.6.2. Transformada de Fourier y densidad espectral de potencia

La transformada discreta de Fourier (DFT) permite representar una señal como una suma de componentes sinusoidales de distintas frecuencias, y en la práctica se calcula con el algoritmo de la transformada rápida de Fourier (FFT) [37]. A partir de ella se estima la densidad espectral de potencia (PSD), que describe cómo se distribuye la potencia de la señal en función de la frecuencia. En el caso del EEG suele emplearse el método de Welch, que divide la señal en segmentos traslapados, calcula el espectro de cada uno y los promedia para obtener una estimación más estable [38]. Contreras utilizó este análisis para identificar que la información útil para detectar la P300 en sus registros se encontraba entre 1 y 25 Hz [13]. La Figura 2.9 muestra una PSD típica, en la que se observan el pico del ritmo alfa y la interferencia de la red eléctrica.




Figura 2.9: Densidad espectral de potencia estimada con el método de Welch para una señal de EEG sintética. Elaboración propia.

2.6.3. Convolución y sistemas lineales

Un sistema lineal e invariante en el tiempo queda completamente descrito por su respuesta al impulso $h(n)$, y su salida ante cualquier entrada $x(n)$ se obtiene mediante la operación de

convolución [37]:

$$y(n) = (x * h)(n) = \sum_{k=-\infty}^{\infty} x(k) h(n-k). \quad (2.4)$$

Esta operación es la base de los filtros digitales que se describen a continuación y, como se verá en la Sección 2.9, también de las capas de las redes neuronales convolucionales, en las que los coeficientes de $h(n)$ ya no se diseñan manualmente sino que se aprenden a partir de los datos [39].

2.6.4. Filtros digitales

Los filtros digitales se clasifican en dos grandes familias. Los filtros de respuesta finita al impulso (FIR) calculan la salida solo a partir de las muestras de entrada y siempre son estables. Los filtros de respuesta infinita al impulso (IIR) también usan salidas anteriores, lo que les permite lograr una buena selectividad con un orden mucho menor [37], [38]. Entre los filtros IIR, el de Butterworth es uno de los más utilizados en EEG porque su respuesta en magnitud es máximamente plana en la banda de paso [38]. De acuerdo con la banda que dejan pasar, los filtros pueden ser pasa bajas, pasa altas, pasa banda o rechaza banda. El filtro *notch* es un tipo de filtro rechaza banda que elimina una sola frecuencia, como la de la red eléctrica. La Figura 2.10 muestra la respuesta en frecuencia de un filtro pasa banda entre 0.1 y 20 Hz, como el aplicado en el trabajo preliminar, y de un filtro *notch* en 60 Hz.




Figura 2.10: Respuesta en magnitud de (a) un filtro pasa banda Butterworth de cuarto orden entre 0.1 y 20 Hz y (b) un filtro *notch* en 60 Hz, para $f_s = 240$ Hz. Elaboración propia.

2.6.5. Remuestreo

El remuestreo permite reducir la frecuencia de muestreo después de filtrar la señal. En la decimación por un factor M se conserva una de cada M muestras. Antes de hacerlo, se debe aplicar un filtro antialiasing que elimine el contenido por encima de la nueva frecuencia de Nyquist [37]. En el trabajo preliminar se redujo la frecuencia de 240 Hz a 120 Hz, lo que disminuye a la mitad el tamaño de cada época sin perder información en la banda de 0.1 a 20 Hz.

2.6.6. Referencia y corrección de línea base


Además del filtrado en frecuencia, es común modificar la referencia de los canales después del registro. La referencia promedio común resta a cada canal $x_{ch}(n)$ el promedio de los C canales en cada instante,

$$x_{ch}^{CAR}(n) = x_{ch}(n) - \frac{1}{C} \sum_{c=1}^C x_c(n), \quad (2.5)$$

con lo que se atenúan las componentes comunes a todos los electrodos, como las derivadas de la propia referencia [16]. De forma complementaria, la corrección de línea base resta a cada época el valor promedio de un intervalo previo al estímulo, típicamente de 100 a 200 ms, para que las amplitudes de los componentes del ERP se midan respecto a un nivel común [16].

2.6.7. Segmentación en épocas

La segmentación consiste en dividir la señal continua en ventanas sincronizadas con cada estímulo, que constituyen las muestras de entrada al clasificador. La longitud de la ventana debe ser suficiente para contener la P300 completa. Contreras empleó ventanas de 1005 ms a partir del estímulo [13], mientras que en el trabajo preliminar se utilizaron ventanas de 78 muestras, equivalentes a unos 650 ms a 120 Hz. Dado que el intervalo entre inicios de estímulos es de solo 175 ms, las épocas de intensificaciones consecutivas se traslapan, como se observa en la Figura 2.11, de modo que una época no objetivo puede contener parte de la P300 provocada por una intensificación objetivo cercana.



Líneas: inicio de cada intensificación (guinda = fila/columna objetivo)

Figura 2.11: Segmentación de la señal continua en épocas de 0 a 650 ms a partir de cada intensificación. Señal sintética, elaboración propia.

2.6.8. Normalización

Las amplitudes del EEG varían entre canales, sesiones y sujetos, por lo que antes de entrenar un modelo se acostumbra normalizar los datos. La normalización *z-score* transforma cada canal

para que tenga media cero y desviación estándar unitaria, mientras que la normalización *min-max*, utilizada por Contreras [13], escala los valores al intervalo $[0, 1]$:

$$z(n) = \frac{x(n) - \mu}{\sigma}, \quad x'(n) = \frac{x(n) - \min(x)}{\max(x) - \min(x)}. \quad (2.6)$$

La primera es menos sensible a valores atípicos, lo cual resulta conveniente en presencia de artefactos de gran amplitud, y fue la empleada de manera independiente por canal en el trabajo preliminar para evitar que los electrodos con mayor amplitud dominen el aprendizaje de la red.

2.6.9. Remoción de artefactos

Cuando los artefactos se traslapan en frecuencia con la señal de interés, como ocurre con los parpadeos y la banda de la P300, el filtrado no basta para eliminarlos. La estrategia más simple es descartar las épocas cuya amplitud supere un umbral, aunque así se pierden datos. Otra opción es el análisis de componentes independientes (ICA), que separa la señal en fuentes independientes para identificar y eliminar las asociadas a movimientos oculares o musculares [20].

2.7. Inteligencia Artificial y aprendizaje automático

La inteligencia artificial (IA) es la rama de las ciencias de la computación que estudia el diseño de agentes capaces de percibir su entorno y actuar de manera que maximicen la probabilidad de alcanzar sus objetivos, automatizando actividades que se asocian con el pensamiento humano, como la resolución de problemas y el aprendizaje [40]. No existe un método universal para todas las áreas de aplicación de la IA, y dentro de la gran variedad de enfoques disponibles el aprendizaje automático se ha convertido en una de sus ramas más importantes [41]. A su vez, el aprendizaje profundo es un subconjunto del aprendizaje automático basado en redes neuronales con múltiples capas de procesamiento, relación que se ilustra en la Figura 2.12.




Figura 2.12: Relación entre la inteligencia artificial, el aprendizaje automático y el aprendizaje profundo. Elaboración propia con base en [39].

2.7.1. Aprendizaje automático

En 1959, Arthur Samuel describió el aprendizaje automático como el campo de estudio que da a las computadoras la capacidad de aprender sin ser programadas de forma explícita, a partir de su experiencia con un programa que aprendía a jugar damas mejor que su propio creador [42]. En términos más formales, se trata de un conjunto de métodos que construyen modelos a partir de los datos mediante el descubrimiento de patrones estadísticamente significativos, para después aplicarlos a datos nuevos de la misma naturaleza [43]. Según la información disponible durante el entrenamiento, el aprendizaje puede ser supervisado o no supervisado, como se resume en la Tabla 2.5. La detección de la P300 corresponde a un problema de clasificación binaria supervisada, pues cada época está etiquetada como objetivo o no objetivo.

Tabla 2.5: Tipos de aprendizaje automático

Tipo	Descripción	Ejemplos
Supervisado	Aprende a partir de datos con etiquetas conocidas y ajusta sus parámetros según el error entre su salida y la etiqueta.	Clasificar cada época como P300 o no P300.
No supervisado	Busca patrones en datos sin etiquetas, por ejemplo agrupándolos o reduciendo su dimensión.	Agrupamiento de datos y ICA para separar artefactos.

Elaboración propia con información de [40], [43].

2.7.2. Clasificadores clásicos para la detección de la P300

Antes del auge del aprendizaje profundo, la detección de la P300 se realizaba extrayendo características de manera manual, generalmente las amplitudes de la señal submuestreada en cada canal, y clasificándolas con modelos lineales. Krusienski et al. compararon cinco técnicas de clasificación para el P300 Speller y encontraron que el análisis discriminante lineal por pasos (SWLDA) y el discriminante lineal de Fisher ofrecían el mejor desempeño global [44], mientras que Rakotomamonjy y Guigue ganaron la competencia BCI III con un conjunto de máquinas de soporte vectorial (SVM) lineales entrenadas sobre distintas particiones de los datos [31]. En el ámbito de la ESCOM, Santos, Romero y Fernández utilizaron el discriminante lineal de Fisher con promediado sincronizado para controlar un brazo robótico virtual, alcanzando una precisión de 90.01 % con 20 sujetos [45]. La Tabla 2.6 resume estos métodos.

2.7.3. Sobreajuste y generalización

El objetivo de un modelo de aprendizaje automático no es reproducir los datos con los que fue entrenado sino desempeñarse correctamente con datos que nunca ha visto, capacidad conocida como generalización [39]. Cuando un modelo es demasiado complejo para la cantidad de datos disponibles, o se entrena durante demasiadas iteraciones, empieza a memorizar el ruido del conjunto de entrenamiento. En ese momento, el error de entrenamiento sigue bajando,

Tabla 2.6: Clasificadores clásicos utilizados en la detección de la P300

Clasificador	Descripción	Ventajas	Desventajas
LDA / Fisher [44], [45]	Proyecta los datos sobre la dirección que maximiza la separación entre las medias de las clases respecto a su dispersión.	Simple, rápido y con pocos parámetros; buen desempeño en P300.	Supone clases gaussianas con igual covarianza; sensible con muchas características.
SWLDA [44]	LDA con selección de características por pasos (se agregan o eliminan según su significancia estadística).	Reduce la dimensión y el sobreajuste; de los mejores en la comparación de [44].	Selección costosa con muchos canales.
SVM lineal [31]	Busca el hiperplano que maximiza el margen entre clases.	Robusta en alta dimensión; ganó la competencia BCI III.	Requiere ajustar el parámetro de regularización; entrenamiento más lento.

Elaboración propia.

pero el error de validación deja de disminuir y comienza a subir. Este fenómeno se conoce como sobreajuste y se ilustra en la Figura 2.13 [39], [43]. En el caso del EEG este riesgo es particularmente alto, pues las bases de datos suelen contener pocos sujetos y un número limitado de épocas objetivo.




Figura 2.13: Curvas de pérdida de entrenamiento y validación: a partir de cierto punto el modelo comienza a sobreajustarse. Elaboración propia.

2.7.4. Esquemas de validación

Para estimar la capacidad de generalización, los datos se dividen en tres conjuntos [39]. El de entrenamiento sirve para ajustar el modelo. El de validación se usa para ajustar hiperparámetros y decidir cuándo detener el entrenamiento. El de prueba solo se utiliza al final. La validación

cruzada de k particiones repite este proceso k veces rotando el subconjunto de validación, lo que ofrece una estimación más estable cuando hay pocos datos [43]. En las BCI, además, se distinguen dos tipos de evaluación. En la evaluación intrasujeto, el modelo se entrena y se prueba con datos de la misma persona. En la evaluación intersujeto, se prueba con una persona que no participó en el entrenamiento [46]. Contreras evaluó ambos escenarios y obtuvo valores promedio de AUC cercanos a 0.82 en la evaluación intrasujeto y de 0.70 en la intersujeto al considerar filas y columnas en conjunto [13].

2.8. Redes neuronales artificiales y aprendizaje profundo

2.8.1. La neurona artificial

Las redes neuronales artificiales son modelos inspirados en el sistema nervioso, en los que las unidades de cómputo, llamadas neuronas, se conectan entre sí mediante pesos que cumplen un papel análogo al de la fuerza de las conexiones sinápticas en los organismos biológicos [47]. Cada neurona recibe un vector de entradas $\mathbf{x} = (x_1, \dots, x_n)$, las multiplica por sus pesos w_i , suma el resultado junto con un sesgo b y aplica una función de activación φ no lineal [48]:

$$y = \varphi \left(\sum_{i=1}^n w_i x_i + b \right) = \varphi \left(\mathbf{w}^\top \mathbf{x} + b \right). \quad (2.7)$$

La Figura 2.14 muestra la correspondencia entre este modelo y la neurona biológica: las entradas desempeñan el papel de las dendritas, la suma ponderada el del soma y la salida el del axón. Al organizar muchas de estas unidades en capas, de forma que la salida de una capa sea la entrada de la siguiente, se obtiene el perceptrón multicapa. Las capas intermedias se llaman ocultas, y el número de capas se conoce como profundidad de la red. De ahí proviene el término aprendizaje profundo [39].




Figura 2.14: Modelo de la neurona artificial y su analogía con la neurona biológica. Elaboración propia con base en [47].

2.8.2. Funciones de activación

Sin la función de activación, una red de cualquier profundidad sería equivalente a una sola transformación lineal, por lo que esta es la que permite a la red representar relaciones no lineales [39]. Las funciones sigmoide y tangente hiperbólica fueron las más utilizadas en las primeras redes. Todavía se emplean en la capa de salida de los clasificadores binarios y en arquitecturas para P300 como la de Cecotti y Gräser o SepConv1D [32], [46]. Sin embargo, ambas se saturan con valores grandes de entrada, lo que hace que sus gradientes se acerquen a cero y dificulta el entrenamiento de redes profundas. La función ReLU resolvió en gran medida este problema y hoy es la opción por defecto en las capas ocultas [39], mientras que la ELU, utilizada en EEGNet, permite valores negativos suaves que acercan la media de las activaciones a cero [49]. La Tabla 2.7 presenta su definición y la Figura 2.15 su forma.

Tabla 2.7: Funciones de activación más utilizadas

Función	Definición	Rango	Uso típico
Sigmoide	$\sigma(z) = \frac{1}{1 + e^{-z}}$	$(0, 1)$	Salida de clasificación binaria (probabilidad de P300).
Tangente hiperbólica	$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	$(-1, 1)$	Capas ocultas en [32], [46]; redes recurrentes.
ReLU	$\max(0, z)$	$[0, \infty)$	Capas ocultas de redes profundas.
ELU	z si $z > 0$; $\alpha(e^z - 1)$ si $z \leq 0$	$(-\alpha, \infty)$	Capas ocultas de EEGNet [49].
Softmax	$\frac{e^{z_k}}{\sum_j e^{z_j}}$	$(0, 1)$, suma 1	Salida de clasificación multiclase.

Elaboración propia con información de [39], [47].




Figura 2.15: Gráfica de las funciones de activación sigmoide, tangente hiperbólica, ReLU y ELU. Elaboración propia.

2.8.3. Función de pérdida

El entrenamiento de una red consiste en ajustar sus pesos para minimizar una función de pérdida que mide la diferencia entre la salida de la red y la etiqueta esperada. Para la clasificación binaria, con etiquetas $y_i \in \{0, 1\}$ y salidas $\hat{y}_i \in (0, 1)$, se utiliza la entropía cruzada binaria

[39]:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{M} \sum_{i=1}^M \left[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \right]. \quad (2.8)$$

Debido al desbalance de las épocas del P300 Speller, en el que por cada época positiva hay cinco negativas, es común ponderar el primer término con un factor $\alpha > 1$ para que los errores sobre la clase minoritaria tengan mayor peso.

2.8.4. Descenso de gradiente y retropropagación

Para minimizar la pérdida se utiliza el método de descenso de gradiente, que actualiza los pesos en la dirección opuesta al gradiente de la función de pérdida,

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}^{(t)}), \quad (2.9)$$

donde η es la tasa de aprendizaje. Si es muy pequeña, el entrenamiento resulta lento, y si es muy grande, los pesos oscilan alrededor del mínimo sin alcanzarlo [39]. En redes de varias capas, este gradiente se calcula con el algoritmo de retropropagación, popularizado por Rumelhart, Hinton y Williams. Este algoritmo propaga el error desde la capa de salida hacia las capas anteriores aplicando la regla de la cadena [50]. En la práctica, el gradiente se estima sobre pequeños subconjuntos de datos llamados lotes. Además, en lugar de una tasa fija se usan optimizadores adaptativos como Adam, que ajusta la tasa de aprendizaje de cada parámetro según el comportamiento de sus gradientes [51]. Adam fue el optimizador utilizado en la comparación de arquitecturas para P300 de Alvarado-González et al. [46].

2.8.5. Regularización

Dado que las redes profundas tienen una gran cantidad de parámetros y los conjuntos de datos de EEG son relativamente pequeños, es indispensable emplear técnicas de regularización para evitar el sobreajuste. Entre las más utilizadas se encuentran el *dropout*, que desactiva aleatoriamente una fracción de las neuronas en cada iteración de entrenamiento [52], la normalización por lotes, que normaliza las activaciones de cada capa y estabiliza el entrenamiento [53], y la parada temprana, que detiene el entrenamiento cuando la pérdida de validación deja de mejorar [39]. La Tabla 2.8 resume estas técnicas junto con su uso en arquitecturas para la detección de la P300.

2.9. Redes convolucionales y recurrentes para la detección de la P300

2.9.1. Redes neuronales convolucionales

Las redes neuronales convolucionales (CNN) están diseñadas para trabajar con datos organizados en forma de cuadrícula, como las imágenes o las series de tiempo, en los que los valores cercanos están muy relacionados. Su nombre se debe a que usan la operación de convolución en al menos una de sus capas [39]. En una capa convolucional, un filtro o *kernel* de pesos apren-

Tabla 2.8: Técnicas de regularización y estabilización del entrenamiento

Técnica	Funcionamiento	Uso en P300
<i>Dropout</i> [52]	Anula aleatoriamente una fracción p de las activaciones durante el entrenamiento.	EEGNet y BN3 [49], [54].
Normalización por lotes [53]	Normaliza la media y varianza de las activaciones de cada lote y las reescala con parámetros aprendidos.	BN3, EEGNet [49], [54].
Regularización L_2	Agrega a la pérdida un término proporcional a $\ \mathbf{w}\ ^2$.	Modelos lineales y redes pequeñas.
Parada temprana	Detiene el entrenamiento cuando la pérdida de validación deja de mejorar durante cierto número de épocas.	50 épocas de paciencia en [46].

Elaboración propia.

dibles se desplaza sobre la entrada y en cada posición calcula la suma ponderada de los valores que cubre, de forma análoga a la Ecuación (2.4). El resultado se denomina mapa de características. Como el mismo filtro se aplica en todas las posiciones, el número de parámetros es mucho menor que en una capa totalmente conectada [47]. Además, estas capas tienen tres parámetros importantes [39]:

- **Paso (*stride*):** controla cuánto se desplaza el filtro en cada posición.
- **Relleno (*padding*):** agrega ceros en los bordes para conservar la longitud de la salida.
- **Agrupamiento (*pooling*):** reduce la resolución de los mapas conservando el valor máximo o promedio de cada región.

En el caso del EEG, cada época puede verse como una matriz de C canales por T muestras, lo que permite separar el procesamiento en dos dimensiones con significado fisiológico distinto: las convoluciones temporales, con filtros de tamaño $1 \times K$, aprenden patrones en el tiempo equivalentes a filtros de frecuencia, mientras que las convoluciones espaciales, con filtros de tamaño $C \times 1$, aprenden combinaciones ponderadas de los electrodos equivalentes a un filtrado espacial. Cecotti y Gräser aplicaron esta separación en la primera CNN diseñada específicamente para detectar la P300, en la que una primera capa espacial es seguida de una capa temporal, alcanzando en la base de datos de la competencia BCI III una exactitud de alrededor del 95 % con 15 repeticiones [32]. Esta misma arquitectura fue implementada en el trabajo preliminar.

2.9.2. Convoluciones separables en profundidad

Una convolución separable en profundidad descompone la convolución estándar en dos pasos: primero una convolución *depthwise*, que aplica un filtro independiente a cada canal de entrada, y después una convolución *pointwise* de tamaño 1×1 , que combina los canales resultantes [55]. Esta descomposición reduce drásticamente el número de parámetros respecto a

una convolución estándar [55]. Esta idea es la base de dos de las arquitecturas más compactas para EEG, EEGNet [49] y SepConv1D [46], que resultan especialmente convenientes cuando se dispone de pocos datos o cuando el modelo debe ejecutarse en dispositivos con recursos limitados.

2.9.3. EEGNet

EEGNet es una red convolucional compacta propuesta por Lawhern et al. para clasificar señales de EEG en distintos paradigmas de BCI, entre ellos la P300, con un número muy reducido de parámetros [49]. Como se muestra en la Figura 2.16, su primer bloque aplica una convolución temporal que funciona como un banco de filtros de frecuencia. Después, una convolución *depthwise* espacial aprende, para cada filtro temporal, una combinación de electrodos, lo que equivale a un filtrado espacial. El segundo bloque aplica una convolución separable que resume cada mapa de características en el tiempo y combina los mapas entre sí. Por último, la clasificación se realiza con una capa densa con activación softmax [49]. En el trabajo preliminar esta arquitectura se implementó con ocho filtros temporales de tamaño 1×16 sobre épocas de 64 canales por 78 muestras.




Figura 2.16: Arquitectura general de EEGNet. Elaboración propia con base en [49].

2.9.4. Arquitecturas convolucionales para la detección de la P300

A partir del trabajo de Cecotti y Gräser se han propuesto numerosas arquitecturas convolucionales para detectar la P300. Alvarado-González et al. compararon doce de ellas en cuatro bases de datos distintas, bajo los esquemas intrasujeto y entre sujetos, y encontraron que las diferencias de AUC entre arquitecturas eran pequeñas, al grado de que SepConv1D, con una sola capa convolucional separable de cuatro filtros seguida de una neurona sigmoide, obtuvo un desempeño comparable al de redes con muchos más parámetros [46]. La Tabla 2.9 resume algunas de las arquitecturas evaluadas y los valores de AUC reportados. Cabe mencionar que Contreras utilizó SepConv1D en su sistema con cuatro canales [13].

2.9.5. Redes neuronales recurrentes

A diferencia de las redes convolucionales, las redes neuronales recurrentes (RNN) procesan una secuencia elemento por elemento y mantienen un estado oculto que resume la información de los pasos anteriores, lo que las hace adecuadas para modelar series de tiempo [39]. Su principal limitación es el desvanecimiento del gradiente, que les impide aprender dependencias de largo plazo. Para resolverlo, Hochreiter y Schmidhuber propusieron las redes de memoria

Tabla 2.9: Algunas arquitecturas convolucionales para la detección de la P300 y AUC promedio reportada en [46]

Arquitectura	Descripción	AUC intra	AUC inter
CNN-1 [32]	4 capas: convolución espacial (10 filtros) y temporal con tangente hiperbólica escalada; salida sigmoide.	0.82	0.78
DeepConvNet [56]	Cuatro bloques convolucionales seguidos de softmax.	0.84	0.79
EEGNet [49]	Red compacta con convoluciones <i>depthwise</i> y separables.	0.84	0.80
SepConv1D [46]	Una capa convolucional 1D separable (4 filtros) y una neurona sigmoide.	0.84	0.78

Elaboración propia con información de [13], [46].

de corto y largo plazo (LSTM). Estas incorporan una celda de memoria y tres compuertas (de entrada, de olvido y de salida), que regulan qué información se agrega, se descarta o se entrega en cada paso [57]. En el contexto de la P300 se han utilizado principalmente en arquitecturas híbridas, en las que una CNN extrae características de cada época y una capa recurrente modela su evolución temporal, enfoque que también fue explorado en el trabajo preliminar.

2.10. Métricas de evaluación

El desempeño de un sistema basado en la P300 puede evaluarse en dos niveles: el de la clasificación de cada época como objetivo o no objetivo, que mide la calidad del modelo de aprendizaje profundo, y el del sistema completo, que mide qué tan rápido y con qué exactitud el usuario logra seleccionar caracteres.

2.10.1. Matriz de confusión

En un problema de clasificación binaria, las predicciones del modelo pueden compararse con las etiquetas reales mediante una tabla cruzada conocida como matriz de confusión, representada en la Figura 2.17. Sus cuatro celdas son las siguientes [58]:

- **Verdaderos positivos (TP):** épocas con P300 clasificadas correctamente.
- **Falsos positivos (FP):** épocas sin P300 clasificadas como positivas.
- **Verdaderos negativos (TN):** épocas sin P300 clasificadas correctamente.
- **Falsos negativos (FN):** épocas con P300 que el modelo no detectó.

2.10.2. Métricas de clasificación

A partir de estos cuatro valores se calculan las métricas que se presentan en la Tabla 2.10. La exactitud mide el porcentaje total de aciertos, pero como se discutió en la Sección 2.5, en un conjunto con una proporción de 1 a 5 entre clases puede resultar engañosa, por lo que conviene

		Predicción del modelo	
		P300	No P300
Clase real	P300	TP Verdaderos positivos	FN Falsos negativos
	No P300	FP Falsos positivos	TN Verdaderos negativos

Figura 2.17: Matriz de confusión para la clasificación binaria de épocas. Elaboración propia.

complementarla con la sensibilidad, que indica qué proporción de las épocas con P300 fueron detectadas, la precisión, que indica qué proporción de las detecciones fueron correctas, y el F1-score, que es la media armónica de ambas [58]. La exactitud balanceada, que promedia la sensibilidad y la especificidad, es otra alternativa que no se ve afectada por el desbalance.

Tabla 2.10: Métricas de evaluación para la clasificación binaria

Métrica	Descripción	Fórmula
Exactitud (<i>accuracy</i>)	Proporción de predicciones correctas sobre el total.	$\frac{TP + TN}{TP + TN + FP + FN}$
Precisión (<i>precision</i>)	Proporción de épocas clasificadas como P300 que realmente lo son.	$\frac{TP}{TP + FP}$
Sensibilidad (<i>recall</i> , TPR)	Proporción de épocas con P300 que fueron detectadas.	$\frac{TP}{TP + FN}$
Especificidad (TNR)	Proporción de épocas sin P300 clasificadas correctamente.	$\frac{TN}{TN + FP}$
Tasa de falsos positivos (FPR)	Proporción de épocas sin P300 clasificadas como positivas.	$\frac{FP}{FP + TN} = 1 - \text{TNR}$
F1-score	Media armónica entre precisión y sensibilidad.	$2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$
Exactitud balanceada	Promedio de la sensibilidad y la especificidad.	$\frac{\text{TPR} + \text{TNR}}{2}$

Elaboración propia con información de [58].

2.10.3. Curva ROC y área bajo la curva

Los clasificadores de la P300 suelen producir un puntaje continuo, y la etiqueta final depende del umbral que se elija: al disminuirlo se detectan más épocas con P300, pero también aumentan los falsos positivos. La curva ROC (*Receiver Operating Characteristic*) representa este compromiso. Para ello, grafica la sensibilidad contra la tasa de falsos positivos en todos los umbrales posibles. El área bajo esta curva (AUC) resume el desempeño en un solo número. Este valor indica la probabilidad de que el clasificador dé un puntaje mayor a una época positiva que a una negativa, ambas elegidas al azar [58]. Un AUC de 0.5 corresponde a un clasificador

aleatorio, en el que los puntajes de ambas clases se superponen. Un AUC de 1 indica una separación perfecta, como se ilustra en la Figura 2.18. Esta es la métrica utilizada en los trabajos de Alvarado-González et al. y de Contreras. Este último la considera aceptable a partir de 0.7 [13], [46].




Figura 2.18: (a) Distribuciones de puntajes de un clasificador para ambas clases y un umbral de decisión. (b) Curvas ROC para distintos grados de separación entre clases. Elaboración propia.

2.10.4. Métricas a nivel de sistema

Una alta AUC en la clasificación de épocas no garantiza por sí sola una comunicación eficiente, pues la velocidad depende también del número de repeticiones necesarias para seleccionar cada carácter. Por ello, en los sistemas de deletreo se reporta la exactitud por carácter en función del número de repeticiones, los caracteres por minuto y la tasa de transferencia de información (ITR), que de acuerdo con Wolpaw et al. se calcula en bits por selección como [7], [59]

$$B = \log_2 N + P \log_2 P + (1 - P) \log_2 \left(\frac{1 - P}{N - 1} \right), \quad (2.10)$$

donde N es el número de opciones posibles, 36 en una matriz de 6×6 , y P es la exactitud por carácter. Al multiplicar B por el número de selecciones por minuto se obtiene la ITR en bits por minuto. La Figura 2.19 muestra que, para una misma exactitud, reducir el número de repeticiones incrementa notablemente la ITR. Sin embargo, en la práctica menos repeticiones también reducen la exactitud, por lo que el número óptimo de repeticiones es el que mejor equilibra ambos efectos.

2.11. Reducción de canales y repeticiones

Como se señaló en la introducción, los sistemas P300 basados en EEG suelen alcanzar una alta exactitud a costa de utilizar muchos electrodos y de repetir varias veces la estimulación de cada fila y columna. Ambos factores afectan directamente la practicidad del sistema: un mayor número de canales incrementa el costo del equipo y el tiempo necesario para colocar los




Figura 2.19: (a) Bits por selección en función de la exactitud para $N = 36$ según la Ecuación (2.10). (b) ITR teórica en función del número de repeticiones para tres niveles de exactitud, considerando 175 ms por intensificación y 2.5 s entre caracteres. Elaboración propia.

electrodos, además de dificultar su uso fuera del laboratorio, mientras que un mayor número de repeticiones reduce la velocidad de comunicación y aumenta la fatiga del usuario [13], [30].

2.11.1. Selección de canales

La selección de canales busca identificar el subconjunto mínimo de electrodos que conserve la información necesaria para detectar la P300. Krusienski et al. evaluaron distintos conjuntos de electrodos. El mejor fue un conjunto de ocho canales (Fz, Cz, Pz, P3, P4, PO7, PO8 y Oz), que combina posiciones de la línea media con posiciones parieto-occipitales. Este conjunto superó a los tres canales de la línea media que se usaban tradicionalmente [30]. Por otra parte, Cecotti y Gräser aprovecharon los pesos aprendidos por la capa espacial de su CNN para ordenar los electrodos según su contribución a la clasificación y eliminar los menos relevantes [32], estrategia que resulta natural en arquitecturas como EEGNet, cuya convolución *depthwise* aprende explícitamente un peso por electrodo [49]. En el extremo opuesto, Contreras trabajó con solo cuatro electrodos de la línea media y obtuvo valores de AUC aceptables en la evaluación intrasujeto [13].

2.11.2. Reducción de repeticiones

De acuerdo con la Ecuación (2.1), cada repetición adicional mejora la relación señal-ruido de la P300 en un factor proporcional a $\sqrt{N}$, pero también añade alrededor de 2.1 s al tiempo de cada selección con los parámetros de la base de datos utilizada. Una primera estrategia para reducir las repeticiones consiste en mejorar la clasificación de ensayo único, es decir, la capacidad del modelo de detectar la P300 en una sola época sin promediarla con otras, objetivo que persiguen las arquitecturas convolucionales descritas en la Sección 2.9 [32], [49]. Una segunda estrategia es la parada dinámica, en la que el sistema deja de presentar repeticiones en cuanto la confianza acumulada sobre algún carácter supera un umbral, en lugar de usar siempre un núme-

ro fijo. Speier et al. mostraron que combinar este tipo de clasificación dinámica con información del lenguaje mejora tanto la exactitud como la tasa de transferencia del P300 Speller [60].

2.12. Modelado del lenguaje y predicción de palabras

2.12.1. Predicción de palabras en la comunicación asistida

Aun con una detección perfecta de la P300, escribir carácter por carácter en un P300 Speller es un proceso lento, pues cada selección requiere varios segundos. La predicción de palabras, ampliamente utilizada en los sistemas de comunicación aumentativa, reduce el número de selecciones necesarias al ofrecer al usuario una lista de palabras probables a partir de los caracteres que ya ha escrito, de modo que puede completar una palabra con una sola selección adicional. Ryan et al. integraron este mecanismo en un P300 Speller agregando a la matriz una región con las palabras sugeridas, y encontraron que los participantes completaban las frases en menos tiempo que con el deletreador convencional, aunque con una exactitud por selección ligeramente menor [61]. El beneficio de estos sistemas suele medirse mediante el ahorro de selecciones,

$$AS = \frac{S_{\sin} - S_{\text{con}}}{S_{\sin}} \times 100\%, \quad (2.11)$$

donde $S_{\sin}$ y S_{con} son el número de selecciones necesarias para escribir un mismo texto sin y con predicción, respectivamente.

2.12.2. Modelos de lenguaje probabilísticos

Un modelo de lenguaje asigna una probabilidad a cada secuencia de palabras, lo que permite estimar cuál es la palabra, o el carácter, más probable dado lo que se ha escrito. Los modelos más simples son los de n -gramas, que suponen que cada palabra depende únicamente de las $n - 1$ palabras anteriores. Sus probabilidades se estiman contando cuántas veces aparece cada secuencia en un corpus de texto [62].

2.12.3. Modelos de lenguaje neuronales

Los modelos de n -gramas están limitados a un contexto corto y fijo, por lo que fueron reemplazados progresivamente por modelos neuronales. Las redes recurrentes, y en particular las LSTM, permitieron condicionar la predicción en un contexto de longitud variable [57], [62], y posteriormente la arquitectura Transformer, basada exclusivamente en mecanismos de atención, eliminó la recurrencia y permitió entrenar modelos mucho más grandes de forma paralela [63]. Sobre esta arquitectura se construyen los modelos de lenguaje de gran escala (LLM), entrenados con enormes cantidades de texto, que son capaces de realizar tareas nuevas a partir de unas cuantas instrucciones o ejemplos [64].

2.12.4. Integración del lenguaje en el P300 Speller

La información del lenguaje puede incorporarse al P300 Speller de dos maneras: como sugerencias explícitas que el usuario selecciona, o como una probabilidad previa que se combina con los puntajes del clasificador para decidir el carácter. Speier et al. siguieron la segunda vía, integrando un modelo de lenguaje en el proceso de clasificación dinámica, y reportaron mejoras tanto en la exactitud como en la tasa de transferencia de información [60]. Más recientemente, Hong et al. propusieron ChatBCI, un P300 Speller que utiliza un LLM para predecir palabras según el contexto de la frase, logrando una reducción del tiempo promedio de escritura de 62.14 % [65]. La Tabla 2.11 compara estos enfoques.

Tabla 2.11: Trabajos que integran modelos de lenguaje en el P300 Speller

Trabajo	Modelo de lenguaje	Forma de integración	Resultado
Ryan et al., 2011 [61]	Predicción de palabras por diccionario	Región adicional con palabras sugeridas en la interfaz.	Menor tiempo para completar frases, con exactitud ligeramente menor.
Speier et al., 2012 [60]	Modelo probabilístico de lenguaje natural	Probabilidad previa combinada con la clasificación dinámica.	Mejor exactitud y tasa de transferencia.
Hong et al., 2026 [65]	LLM	Predicción contextual de palabras.	Reducción del tiempo promedio de 62.14 %.

Elaboración propia.

2.13. Estado del arte

2.13.1. Sistemas P300 Speller y competencias BCI

A partir del deletreador de Farwell y Donchin [2], la investigación sobre el P300 Speller se centró durante varios años en mejorar la clasificación de las épocas con métodos lineales. Las competencias internacionales de BCI jugaron un papel central en este proceso, pues pusieron a disposición de la comunidad bases de datos comunes. En la tercera de ellas, el conjunto de SVM lineales propuesto por Rakotomamonjy y Guigue obtuvo el primer lugar al identificar correctamente el 96.5 % de los caracteres de prueba con 15 repeticiones [31]. En paralelo, Krusienski et al. mostraron que el SWLDA y el discriminante de Fisher eran los clasificadores más robustos entre los evaluados [44], y posteriormente que una adecuada selección de ocho electrodos permitía mejorar el desempeño respecto al uso exclusivo de la línea media [30].

2.13.2. Sistemas de comunicación con usuarios con discapacidad

La validación con usuarios reales ha sido otra línea importante de investigación. Sellers y Donchin realizaron las primeras pruebas de un P300 Speller con pacientes con ELA [8]. Hoffmann et al. propusieron un sistema de seis opciones que evaluaron con personas con distintas discapacidades motoras. Sus registros son hoy una de las bases de datos públicas más utilizadas

[36]. En el ámbito latinoamericano, García Cossio et al. desarrollaron un sistema de deletreo con una matriz de estimulación visual [66]. Lo probaron con dos adolescentes con discapacidad motora y obtuvieron porcentajes de acierto promedio de 95 % y 85 % en la prueba de libre deletreo. Por su parte, el trabajo de Brunner et al. [67] demostró la operación de un sistema P300 Speller utilizando señales de electrocorticografía, alcanzando tasas sostenidas superiores a 17 caracteres por minuto. Sin embargo, al ser una técnica invasiva, su uso en contextos clínicos generales es limitado, y el EEG continúa siendo la alternativa más accesible.

2.13.3. Aprendizaje profundo para la detección de la P300

Con la introducción de las redes convolucionales, Cecotti y Gräser mostraron que era posible aprender directamente los filtros espaciales y temporales a partir de la señal, obteniendo en la competencia BCI III resultados comparables a los del ganador [32]. A partir de entonces se propusieron arquitecturas como BN3 [54], OCLNN [68] y EEGNet [49], y la comparación de Alvarado-González et al. mostró que redes muy compactas como SepConv1D, con apenas cuatro filtros en su única capa convolucional, pueden alcanzar un AUC similar a la de redes mucho más grandes [46].

En el ámbito nacional, Contreras desarrolló en la Escuela Superior de Cómputo del Instituto Politécnico Nacional la tesis de maestría “Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil” [13]. Su sistema usa la arquitectura SepConv1D para detectar la P300 con solo cuatro electrodos secos. Al considerar filas y columnas, reportó valores promedio de AUC cercanos a 0.82 en la evaluación intrasujeto y de 0.70 en la intersujeto, esta última sin calibración individual. Este trabajo demostró la viabilidad técnica de integrar procesamiento EEG, extracción automática de características y modelos de aprendizaje profundo en un sistema funcional. Sin embargo, su aplicación estuvo orientada al control de una neuroprótesis y no específicamente a la implementación de un sistema de comunicación mediante deletreo. En la misma escuela, Santos, Romero y Fernández desarrollaron una aplicación para manipular un brazo robótico virtual mediante potenciales P300 con matrices de 5×5 de iconos y de letras, clasificadas con el discriminante lineal de Fisher [45].

2.13.4. Resumen comparativo

De los trabajos revisados se identifican dos limitaciones persistentes en los sistemas P300 basados en EEG: la necesidad de múltiples canales para mantener niveles altos de precisión y la dependencia de múltiples repeticiones de estímulos para asegurar una detección confiable. La Tabla 2.12 resume los enfoques descritos, contrastando el número de canales empleados, el clasificador, el uso de un modelo de lenguaje y el desempeño reportado por cada trabajo frente a la propuesta del presente Trabajo Terminal.

Tabla 2.12: Resumen comparativo del estado del arte

Trabajo	Señal / canales	Clasificador	Modelo de lenguaje	Desempeño
Farwell y Donchin, 1988 [2]	EEG / 1 (Pz)	SWDA, pico, área y covarianza	No	Exactitud $\approx 95\%$; 2.3 caracteres/min
Sellers y Donchin, 2006 [8]	EEG	–	No	Primeras pruebas con pacientes con ELA
Rakotomamonjy y Guigue, 2008 [31]	EEG / 64	Conjunto de SVM	No	96.5 % de caracteres con 15 repeticiones
Krusienski et al., 2008 [30]	EEG / 8	SWLDA	No	Conjunto de 8 canales superior a la línea media
Cecotti y Gräser, 2011 [32]	EEG / 64	CNN	No	$\approx 95\%$ de caracteres con 15 repeticiones
García Cossio et al., 2011 [66]	EEG / 6	–	No	Acierto de 95 % y 85 % en libre deletreo
Brunner et al., 2011 [67]	ECoG / 96 subdurales	SWLDA	No	17 caracteres/min
Ryan et al., 2011 [61]	EEG	–	Diccionario	Menor tiempo por frase
Speier et al., 2012 [60]	EEG	Clasificación dinámica	Probabilístico	Mayor exactitud y tasa de transferencia
Santos et al., 2017 (ESCOM) [45]	EEG	LDA de Fisher	No	Precisión de 90.01 % (20 sujetos)
Alvarado-González et al., 2021 [46]	EEG / varios	SepConv1D y otras 11 redes	No	AUC intra ≈ 0.84 ; inter ≈ 0.78
Contreras, 2021 (IPN) [13]	EEG / 4	SepConv1D	No	AUC ≈ 0.82 (intrasujeto), ≈ 0.70 (intersujeto)
ChatBCI, Hong et al., 2026 [65]	EEG / 32	–	LLM	Reducción de tiempo promedio de 62.14 %
Propuesta TT	EEG / 4	Aprendizaje profundo (CNN)	Predicción de palabras	–

Elaboración propia.

3. Propuesta a desarrollar

4. Selección de modelos

4.1. Selección de lenguajes de programación

4.2. Evaluación de arquitecturas de aprendizaje profundo para detección de P300

4.3. Selección de tecnologías

5. Alcance del sistema

6. Estudio de factibilidad

6.1. Recursos humanos

6.2. Recursos de hardware

6.3. Infraestructura

Referencias

- [1] E. A. Felton, J. A. Wilson, J. C. Williams y P. C. Garell, «Electrocorticographically controlled brain–computer interfaces using motor and sensory imagery in patients with temporary subdural electrode implants,» *J. Neurosurg.*, vol. 106, n.º 3, págs. 495-500, 2007.
- [2] L. A. Farwell y E. Donchin, «Talking off the top of your head: Toward a mental prosthesis utilizing event-related brain potentials,» *Electroencephalogr. Clin. Neurophysiol.*, vol. 70, n.º 6, págs. 510-523, 1988.
- [3] V. L. Feigin et al., «The global burden of neurological disorders: translating evidence into policy,» *Lancet Neurol.*, vol. 19, n.º 3, págs. 255-265, 2020.
- [4] Organización Mundial de la Salud y Banco Mundial, «Informe mundial sobre la discapacidad,» Organización Mundial de la Salud, Ginebra, Suiza, 2011.
- [5] Instituto Nacional de Estadística y Geografía, «Encuesta Nacional de la Dinámica Demográfica (ENADID) 2018,» INEGI, Aguascalientes, México, 2018.
- [6] N. Birbaumer et al., «A spelling device for the paralysed,» *Nature*, vol. 398, n.º 6725, págs. 297-298, 1999. DOI: 10.1038/18581
- [7] J. R. Wolpaw, N. Birbaumer, D. J. McFarland, G. Pfurtscheller y T. M. Vaughan, «Brain–computer interfaces for communication and control,» *Clin. Neurophysiol.*, vol. 113, n.º 6, págs. 767-791, 2002. DOI: 10.1016/S1388-2457(02)00057-3
- [8] E. W. Sellers y E. Donchin, «A P300-based brain–computer interface: Initial tests by ALS patients,» *Clin. Neurophysiol.*, vol. 117, n.º 3, págs. 538-548, 2006. DOI: 10.1016/j.clinph.2005.06.027
- [9] N. Kane et al., «A revised glossary of terms most commonly used by clinical electroencephalographers and updated proposal for the report format of the EEG findings. Revision 2017,» *Clin. Neurophysiol. Pract.*, vol. 2, págs. 170-185, 2017. DOI: 10.1016/j.cnp.2017.07.002
- [10] H. Berger, «Über das Elektrenkephalogramm des Menschen,» *Arch. Psychiatr. Nervenkr.*, vol. 87, págs. 527-570, 1929. DOI: 10.1007/BF01797193
- [11] S. Sanei y J. A. Chambers, *EEG Signal Processing*. Chichester, U.K.: John Wiley & Sons, 2007.
- [12] E. Niedermeyer y F. Lopes da Silva, *Electroencephalography: Basic Principles, Clinical Applications, and Related Fields*, 5.^a ed. Philadelphia, PA, USA: Lippincott Williams & Wilkins, 2005.

- [13] A. E. Contreras Martínez, «Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil,» Tesis de mtría., Esc. Sup. Cómputo, Inst. Politéc. Nac., Ciudad de México, México, 2021.
- [14] B. Blankertz et al., «The BCI competition III: Validating alternative approaches to actual BCI problems,» *IEEE Trans. Neural Syst. Rehabil. Eng.*, vol. 14, n.º 2, págs. 153-159, 2006. DOI: 10.1109/TNSRE.2006.875642
- [15] K. E. Barrett, S. M. Barman, S. Boitano y H. L. Brooks, *Ganong. Fisiología médica*, 23.^a ed. México: McGraw-Hill, 2010.
- [16] S. J. Luck, *An Introduction to the Event-Related Potential Technique*, 2.^a ed. Cambridge, MA, USA: MIT Press, 2014.
- [17] H. H. Jasper, «The ten-twenty electrode system of the International Federation,» *Electroencephalogr. Clin. Neurophysiol.*, vol. 10, págs. 371-375, 1958.
- [18] M. Seeck et al., «The standardized EEG electrode array of the IFCN,» *Clin. Neurophysiol.*, vol. 128, n.º 10, págs. 2070-2077, 2017. DOI: 10.1016/j.clinph.2017.06.254
- [19] J. E. Hall, *Guyton y Hall. Tratado de fisiología médica*, 13.^a ed. Barcelona, España: Elsevier, 2016.
- [20] T.-P. Jung et al., «Removing electroencephalographic artifacts by blind source separation,» *Psychophysiology*, vol. 37, n.º 2, págs. 163-178, 2000. DOI: 10.1111/1469-8986.3720163
- [21] J. D. Kropotov, *Quantitative EEG, Event-Related Potentials and Neurotherapy*. San Diego, CA, USA: Academic Press/Elsevier, 2009.
- [22] J. Polich, «Updating P300: An integrative theory of P3a and P3b,» *Clin. Neurophysiol.*, vol. 118, n.º 10, págs. 2128-2148, 2007. DOI: 10.1016/j.clinph.2007.04.019
- [23] S. Tong y N. V. Thakor, eds., *Quantitative EEG Analysis Methods and Clinical Applications*. Norwood, MA, USA: Artech House, 2009.
- [24] S. Sutton, M. Braren, J. Zubin y E. R. John, «Evoked-potential correlates of stimulus uncertainty,» *Science*, vol. 150, n.º 3700, págs. 1187-1188, 1965. DOI: 10.1126/science.150.3700.1187
- [25] N. K. Squires, K. C. Squires y S. A. Hillyard, «Two varieties of long-latency positive waves evoked by unpredictable auditory stimuli in man,» *Electroencephalogr. Clin. Neurophysiol.*, vol. 38, n.º 4, págs. 387-401, 1975. DOI: 10.1016/0013-4694(75)90263-1
- [26] E. Donchin, «Surprise!... Surprise?» *Psychophysiology*, vol. 18, n.º 5, págs. 493-513, 1981. DOI: 10.1111/j.1469-8986.1981.tb01815.x
- [27] T. W. Picton, «The P300 wave of the human event-related potential,» *J. Clin. Neurophysiol.*, vol. 9, n.º 4, págs. 456-479, 1992. DOI: 10.1097/00004691-199210000-00002

- [28] J. R. Wolpaw y E. W. Wolpaw, eds., *Brain–Computer Interfaces: Principles and Practice*. New York, NY, USA: Oxford University Press, 2012.
- [29] L. F. Nicolas-Alonso y J. Gomez-Gil, «Brain computer interfaces, a review,» *Sensors*, vol. 12, n.º 2, págs. 1211-1279, 2012. DOI: 10.3390/s120201211
- [30] D. J. Krusienski, E. W. Sellers, D. J. McFarland, T. M. Vaughan y J. R. Wolpaw, «Toward enhanced P300 speller performance,» *J. Neurosci. Methods*, vol. 167, n.º 1, págs. 15-21, 2008. DOI: 10.1016/j.jneumeth.2007.07.017
- [31] A. Rakotomamonjy y V. Guigue, «BCI competition III: Dataset II—Ensemble of SVMs for BCI P300 speller,» *IEEE Trans. Biomed. Eng.*, vol. 55, n.º 3, págs. 1147-1154, 2008. DOI: 10.1109/TBME.2008.915728
- [32] H. Cecotti y A. Gräser, «Convolutional neural networks for P300 detection with application to brain–computer interfaces,» *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 33, n.º 3, págs. 433-445, 2011. DOI: 10.1109/TPAMI.2010.125
- [33] G. Townsend et al., «A novel P300-based brain–computer interface stimulus presentation paradigm: Moving beyond rows and columns,» *Clin. Neurophysiol.*, vol. 121, n.º 7, págs. 1109-1120, 2010. DOI: 10.1016/j.clinph.2010.01.030
- [34] T. Kaufmann, S. M. Schulz, C. Grönzinger y A. Kübler, «Flashing characters with famous faces improves ERP-based brain–computer interface performance,» *J. Neural Eng.*, vol. 8, n.º 5, 2011, art. n.º 056016. DOI: 10.1088/1741-2560/8/5/056016
- [35] B. Blankertz et al., «The BCI competition 2003: Progress and perspectives in detection and discrimination of EEG single trials,» *IEEE Trans. Biomed. Eng.*, vol. 51, n.º 6, págs. 1044-1051, 2004. DOI: 10.1109/TBME.2004.826692
- [36] U. Hoffmann, J.-M. Vesin, T. Ebrahimi y K. Diserens, «An efficient P300-based brain–computer interface for disabled subjects,» *J. Neurosci. Methods*, vol. 167, n.º 1, págs. 115-125, 2008. DOI: 10.1016/j.jneumeth.2007.03.005
- [37] J. G. Proakis y D. G. Manolakis, *Tratamiento digital de señales*, 4.^a ed. Madrid, España: Pearson Prentice Hall, 2007.
- [38] A. V. Oppenheim y R. W. Schaffer, *Discrete-Time Signal Processing*, 3.^a ed. Upper Saddle River, NJ, USA: Pearson, 2010.
- [39] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [40] S. Russell y P. Norvig, *Artificial Intelligence: A Modern Approach*, 3.^a ed. Upper Saddle River, NJ, USA: Pearson Prentice Hall, 2010.
- [41] W. Ertel, *Introduction to Artificial Intelligence*, 2.^a ed. Cham, Suiza: Springer, 2017.
- [42] A. L. Samuel, «Some studies in machine learning using the game of checkers,» *IBM J. Res. Dev.*, vol. 3, n.º 3, págs. 210-229, 1959. DOI: 10.1147/rd.33.0210

- [43] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.
- [44] D. J. Krusienski et al., «A comparison of classification techniques for the P300 Speller,» *J. Neural Eng.*, vol. 3, n.º 4, págs. 299-305, 2006. DOI: 10.1088/1741-2560/3/4/007
- [45] I. Santos, R. Romero y A. Fernández, «Estudio de las ondas cerebrales captadas por una BCI asociada a biomecanismos,» Trabajo Terminal, Esc. Sup. Cómputo, Inst. Politéc. Nac., Ciudad de México, México, 2017.
- [46] M. Alvarado-González, G. Fuentes-Pineda y J. Cervantes-Ojeda, «A few filters are enough: Convolutional neural network for P300 detection,» *Neurocomputing*, vol. 425, págs. 37-52, 2021. DOI: 10.1016/j.neucom.2020.10.104
- [47] C. C. Aggarwal, *Neural Networks and Deep Learning*. Cham, Suiza: Springer, 2018.
- [48] B. Martín del Brío y A. Sanz Molina, *Redes neuronales y sistemas difusos*, 2.^a ed. México: Alfaomega, 2002.
- [49] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung y B. J. Lance, «EEGNet: A compact convolutional neural network for EEG-based brain-computer interfaces,» *J. Neural Eng.*, vol. 15, n.º 5, 2018, art. n.º 056013. DOI: 10.1088/1741-2552/aace8c
- [50] D. E. Rumelhart, G. E. Hinton y R. J. Williams, «Learning representations by back-propagating errors,» *Nature*, vol. 323, n.º 6088, págs. 533-536, 1986. DOI: 10.1038/323533a0
- [51] D. P. Kingma y J. Ba, «Adam: A method for stochastic optimization,» en *Proc. 3rd Int. Conf. Learn. Represent. (ICLR)*, San Diego, CA, USA, 2015.
- [52] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdinov, «Dropout: A simple way to prevent neural networks from overfitting,» *J. Mach. Learn. Res.*, vol. 15, n.º 56, págs. 1929-1958, 2014.
- [53] S. Ioffe y C. Szegedy, «Batch normalization: Accelerating deep network training by reducing internal covariate shift,» en *Proc. 32nd Int. Conf. Mach. Learn. (ICML)*, ép. PMLR, vol. 37, 2015, págs. 448-456.
- [54] M. Liu, W. Wu, Z. Gu, Z. Yu, F. Qi e Y. Li, «Deep learning based on batch normalization for P300 signal detection,» *Neurocomputing*, vol. 275, págs. 288-297, 2018. DOI: 10.1016/j.neucom.2017.08.039
- [55] F. Chollet, «Xception: Deep learning with depthwise separable convolutions,» en *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2017, págs. 1251-1258. DOI: 10.1109/CVPR.2017.195

- [56] R. T. Schirrmeister et al., «Deep learning with convolutional neural networks for EEG decoding and visualization,» *Hum. Brain Mapp.*, vol. 38, n.º 11, págs. 5391-5420, 2017. DOI: 10.1002/hbm.23730
- [57] S. Hochreiter y J. Schmidhuber, «Long short-term memory,» *Neural Comput.*, vol. 9, n.º 8, págs. 1735-1780, 1997. DOI: 10.1162/neco.1997.9.8.1735
- [58] T. Fawcett, «An introduction to ROC analysis,» *Pattern Recognit. Lett.*, vol. 27, n.º 8, págs. 861-874, 2006. DOI: 10.1016/j.patrec.2005.10.010
- [59] J. R. Wolpaw et al., «Brain–computer interface technology: A review of the first international meeting,» *IEEE Trans. Rehabil. Eng.*, vol. 8, n.º 2, págs. 164-173, 2000. DOI: 10.1109/TRE.2000.847807
- [60] W. Speier, C. Arnold, J. Lu, R. K. Taira y N. Pouratian, «Natural language processing with dynamic classification improves P300 speller accuracy and bit rate,» *J. Neural Eng.*, vol. 9, n.º 1, 2012, art. n.º 016004. DOI: 10.1088/1741-2560/9/1/016004
- [61] D. B. Ryan et al., «Predictive spelling with a P300-based brain–computer interface: Increasing the rate of communication,» *Int. J. Hum.-Comput. Interact.*, vol. 27, n.º 1, págs. 69-84, 2011. DOI: 10.1080/10447318.2011.535754
- [62] D. Jurafsky y J. H. Martin, *Speech and Language Processing*, 3.^a ed. 2025, Borrador en línea. visitado 23 de sep. de 2026. dirección: <https://web.stanford.edu/~jurafsky/slp3/>
- [63] A. Vaswani et al., «Attention is all you need,» en *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017, págs. 5998-6008.
- [64] T. B. Brown et al., «Language models are few-shot learners,» en *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020, págs. 1877-1901.
- [65] J. Hong, W. Wang y L. Najafizadeh, «ChatBCI, a P300 speller BCI with context-driven word prediction leveraging large language models,» *Sci. Rep.*, vol. 16, 2026, art. n.º 6379.
- [66] E. García Cossio, C. Fernández, M. E. Gaviria, C. Palacio, L. Alvarán y R. A. Torres Villa, «Interfaz cerebro–computador basada en P300 para la comunicación alternativa: estudio de caso en dos adolescentes en situación de discapacidad motora,» *Rev. Fac. Ing. Univ. Antioquia*, n.º 60, págs. 9-19, 2011.
- [67] P. Brunner, A. L. Ritaccio, J. F. Emrich, H. Bischof y G. Schalk, «Rapid communication with a P300 matrix speller using electrocorticographic signals,» *Front. Neurosci.*, vol. 5, 2011, art. n.º 5. DOI: 10.3389/fnins.2011.00005
- [68] H. Shan, Y. Liu y T. Stefanov, «A simple convolutional neural network for accurate P300 detection and character spelling in brain computer interface,» en *Proc. 27th Int. Joint Conf. Artif. Intell. (IJCAI)*, 2018, págs. 1604-1610. DOI: 10.24963/ijcai.2018/222