



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SECCIÓN DE ESTUDIOS DE POSGRADO E
INVESTIGACIÓN



“Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil”

Línea de generación y aplicación del conocimiento:

Sistemas Digitales para el Cómputo Móvil

Presenta:

Adrian Eleazar Contreras Martínez

Directores:

Dra. Blanca Esther Carvajal Gámez

Dr. Jorge Luis Rosas Trigueros

Agradecimientos

Al CONCACyT por la beca para el desarrollo de la investigación de la maestría. El desarrollo de la Ciencia y la Tecnología son pilares fundamentales para el crecimiento de México.

Resumen

Las Interfaces Cerebro-Computadora (*BCI*, por sus siglas en inglés) basadas en la Electroencefalografía (EEG), permiten a personas que tienen algún tipo de discapacidad motora severa o padecen afecciones neurológicas o enfermedades neurodegenerativas, establecer comunicación con dispositivos electrónicos a través del procesamiento de los impulsos o las señales eléctricas generadas por el cerebro humano.

En este trabajo se propone el desarrollo de un sistema que genere las secuencias de control para una neuroprótesis que será utilizada en la rehabilitación de pacientes que no pueden controlar sus propios músculos mediante vías neuronales.

Esta propuesta se basa en el registro EEG durante la operación de una BCI mientras se presentan cambios inesperados entre una serie de estímulos visuales monótonos, que llaman la atención de las personas y los obliga a comparar el estímulo visual raro o infrecuente (paradigma de evento raro).

El cambio en los estímulos visuales tiene como fin identificar la presencia o no de la onda P300 del Potencial Relacionado a Eventos (*ERP, por sus siglas en inglés*). La extracción de características y la clasificación serán implementadas en un dispositivo móvil utilizando Python como plataforma.

La clasificación de las señales EEG se llevará a cabo haciendo uso de aprendizaje profundo (deep learning) y su procesamiento permitirá obtener la información para que un sistema implementado en el dispositivo móvil, se encargue de determinar las secuencias de control que serán ejecutadas por una neuroprótesis.

Las secuencias de control obtenidas en este trabajo se probarán en el control de una neuroprótesis desarrollada por el Instituto Nacional de Rehabilitación, que tiene como fin la estimulación del movimiento de una extremidad superior de una persona.

Abstract

The Electroencephalography (EEG) based Brain-Computer Interfaces (BCI), allow people who have some type of severe motor disability or suffer from neurological conditions or neurodegenerative diseases, to establish communication with electronic devices through the processing of electrical impulses or signals generated by the human brain.

In this work we propose the development of an expert system that generates the control sequences for a neuroprosthesis that will be used in the rehabilitation of patients who cannot control their own muscles through neural pathways.

This proposal is based on recording the EEG during the operation of a BCI while unexpected, infrequent events are intertwined under the rare event paradigm and whether the P300 wave of the Event-Related Potential (ERP) is present or not. Feature extraction and classification will be implemented on a mobile device using Python as a platform.

The classification of the EEG signals will be carried out through deep learning and their

processing will allow obtaining the information so that a system implemented in the mobile device generates the control sequences that will be executed in a neuroprosthesis.

The tests are to be performed by controlling a neuroprosthesis developed by the Instituto Nacional de Rehabilitación in México, which stimulates the movement of the upper limb of a patient.

Índice general

Índice general	I
Índice de figuras	III
índice de tablas	VI
1. Introducción	1
1.1. Planteamiento del problema	4
1.1.1. Preguntas de investigación	4
1.1.2. Objetivo general	4
1.1.3. Objetivos específicos	5
1.2. Justificación	5
1.3. Estado del arte	6
2. Marco teórico	11
2.1. El impulso nervioso, el sistema nervioso, el sistema nervioso central	12
2.1.1. Función integradora del sistema nervioso central	12

2.2.	El cerebro	13
2.2.1.	Control cognitivo	13
2.2.2.	Origen de las ondas cerebrales	14
2.2.3.	Ondas cerebrales	14
2.3.	Electroencefalograma	15
2.3.1.	Sistema internacional 10-20 EEG	16
2.3.2.	Ritmos α , β , γ y μ	18
2.4.	ERPs	20
2.4.1.	Componente P300	21
2.4.2.	Paradigma del evento raro	23
2.5.	Deletreador de Donchin	23
2.6.	Épocas EEG	24
2.7.	Inteligencia Artificial	25
2.7.1.	Aprendizaje Automático / Aprendizaje Máquina	25
2.7.2.	Redes neuronales artificiales	27
2.7.3.	Redes neuronales convolucionales	31
2.8.	Métricas para la clasificación binaria	32
3.	Metodología	37
3.1.	Adquisición de señales	38
3.1.1.	Base de registros	38
3.1.2.	Muestra poblacional	39
3.1.3.	Registro de EEG: Hardware y Software	39
3.1.3.1.	Eventos de estimulación	41
3.1.3.2.	Registro dirigido	44
3.2.	Pre-procesamiento	45
3.2.1.	Segmentación	46
3.2.2.	Filtrado	48
3.3.	Extracción de Características	54
3.4.	Clasificación	56
3.4.1.	Precisión	57
3.5.	Control	57

<i>ÍNDICE GENERAL</i>	III
4. Resultados	58
4.1. Conjunto de datos	58
4.2. Detección P300	60
4.2.1. Detección P300 intra-sujetos	62
4.2.2. Detección P300 entre-sujetos	64
4.3. Control	71
Discusión	72
Conclusiones	73

Índice de figuras

2.1. AC: Colocación de los electrodos estándar del sistema 10-20. A: vista lateral, B: vista frontal, C: desde la parte superior. Tomada de: [23]. pp. 2071 . . .	17
2.2. Modelo de actualización de contexto del componente P300. Los estímulos ingresan al sistema de procesamiento y se activa un proceso de comparación de memoria que determina si el estímulo actual es el mismo que el estímulo anterior o no. Si el estímulo entrante es el mismo, el modelo neural del entorno del estímulo no cambia y se obtienen potenciales evocados sensoriales (N100, P200, N200) después del promedio de la señal. Si el estímulo entrante no es el mismo y el sujeto asigna recursos de atención al objetivo, la representación neuronal del entorno del estímulo cambia o se actualiza, de modo que se genera un potencial P300. Modificada de [27].	22

2.3. Matriz de 6x6 símbolos de un Deletreador de Donchin. La fila que se muestra iluminada se denomina un estímulo atendido solo si el símbolo objetivo (aquel que el sujeto desea deletrear) es alguna de las letras M, N, O, P, Q o R, y como un estímulo no atendido en cualquier otro caso. Las épocas de EEG sincronizadas al instante de presentación de ese estímulo se consideran, bajo la misma lógica, como épocas atendidas o no atendidas.	24
2.4. Relación de la inteligencia artificial y sus subcampos.	26
2.5. Arquitectura de una red neuronal artificial. Modificada de [32].	27
2.6. Función logística sigmoidea.	29
2.7. Función tangente hiperbólica.	30
2.8. Matriz de confusión en una clasificación binaria.	32
2.9. Modelo general de una clasificación binaria.	33
2.10. Modificación del umbral de un modelo general de clasificación binaria. . . .	34
2.11. Relación de AUC con respecto a dos distribuciones de un modelo general de clasificación.	36
3.1. Diagrama a bloques de la metodología.	38
3.2. Configuración de los electrodos utilizados del Sistema Internacional 10-20. .	40
3.3. Diseño de la interfaz que muestra imágenes asociadas a movimientos de la extremidad superior.	41
3.4. Valor representativo de filas y columnas de la interfaz.	42
3.5. Sincronización de procesos durante la estimulación visual.	43
3.6. Intensificación (iluminación) de filas o columnas de la matriz de la interfaz consideradas en los eventos de estimulación.	44
3.7. Registro de señales. Los canales corresponden a las posiciones Fz, Cz, Pz y Oz del Sistema Internacional 10-20. El último registro representa el instante en que se genera el evento de estimulación.	46
3.8. Épocas EEG, hacen referencia a las ventanas de 1005 <i>ms</i> de señales EEG que se registran desde el inicio de un evento de estimulación visual.	47
3.9. PSD de los registros de las señales de los canales Fz, Cz, Pz, Oz que corresponden al Sistema Internacional 10-20.	50
3.10. Filtro de los componentes de la transformada discreta de Fourier de una época EEG.	52

3.11. Señales originales y filtradas de los canales Fz, Cz, Pz y Oz de una época EEG.	53
3.12. Señales filtradas y normalizadas de los canales Fz, Cz, Pz y Oz de una época EEG.	54
3.13. Pre-procesamiento y extracción de características. De la señal cruda EEG se extraen las épocas EEG de 1005 <i>mseg.</i> de duración post-estímulo. Se filtran los componentes de frecuencia de la señal cruda EEG de cada canal, en cada registro del registro dirigido. Las señales filtradas se reparten en 4 grupos: épocas P300 de filas o de columnas, y épocas que no son P300 de filas o de columnas. Se genera un vector de características por cada grupo.	55
3.14. Vector de las épocas de los canales Fz, Cz, Pz y Oz que son P300.	55
3.15. Etapas generales consideradas en el proceso de clasificación.	56
3.16. Esquema general de la arquitectura SepConv1D.	57

Índice de cuadros

3.1. Datos de los sujetos que corresponden a la muestra poblacional.	39
3.2. Filas o columnas intensificadas en cada objetivo durante el proceso de estimulación.	42
3.3. Sesiones de registro dirigido por cada sujeto.	45
4.1. Total de estímulos generados en las sesiones de registro dirigido por cada sujeto.	59
4.2. Total de estímulos generados por filas y columnas en las sesiones de registro dirigido por cada sujeto	60
4.3. Arquitectura SepConv1D para detección del P300.	61
4.4. Relación AUC con respecto a ROC, AUC media y desviación estándar de las evaluaciones intra-sujeto considerando solamente la estimulación de las filas.	62
4.5. Relación AUC con respecto a ROC, AUC media y desviación estándar de las evaluaciones intra-sujeto considerando solamente la estimulación de las columnas.	63

4.6. Relación AUC con respecto a ROC, AUC media y desviación estándar de las evaluaciones intra-sujeto considerando la estimulación de las filas y columnas	64
4.7. Relación AUC con respecto a ROC de las evaluaciones entre-sujetos considerando solamente la estimulación de las filas.	66
4.8. Relación AUC con respecto a ROC de las evaluaciones entre-sujetos considerando solamente la estimulación de las columnas.	68
4.9. Relación AUC con respecto a ROC de las evaluaciones entre-sujetos considerando la estimulación de las filas y columnas.	70
4.10. AUC media y desviación estándar de las evaluaciones entre-sujetos.	71
4.11. Secuencias de control asociadas a cada objetivo de la interfaz.	71

CAPÍTULO 1

Introducción

De acuerdo con el Informe mundial sobre la discapacidad emitido por la Organización Mundial de la Salud (OMS)[1] se estima que más de 1,000 millones de personas en el mundo viven con alguna forma de discapacidad; de ellas, casi de 200 millones tienen dificultades considerables para ejecutar acciones o tareas que se consideran normales para un ser humano.

En México, según los datos al 2018 del Instituto Nacional de Estadística y Geografía[2], la prevalencia de la discapacidad representaba un 6.3 % de la población, es decir, 7.8 millones de habitantes del país tenían mucha dificultad o no podían realizar alguna actividad considerada como básica. De dicha población, el 52.7 % tenía dificultad para caminar, subir o bajar usando sus piernas; el 17.8 % tenía dificultad para mover o usar brazos o manos y el 10.5 % tenía dificultad severa para hablar o comunicarse. Es por ello que se han buscado

mecanismos por medio de los cuales se puedan mejorar las habilidades de las personas con discapacidad y, por tanto, esten más capacitados para vivir de forma autónoma y tengan una mejor calidad de vida.

En el área médica, la rehabilitación física ha sido utilizada para el reentrenamiento de personas afectadas por lesiones del sistema nervioso, y es a través de la Estimulación Eléctrica Funcional (*FES por sus siglas en inglés*) la forma en que se activan de manera artificial los nervios motores provocando contracciones musculares que generen un movimiento funcional mediante la aplicación de pulsos eléctricos de corriente.

El registro y procesamiento de las señales derivadas de la actividad cerebral en los humanos ha permitido que a través de las Interfaces Cerebro-Computadora (*BCI por sus siglas en inglés*) basadas en la Electroencefalografía (EEG), las personas puedan comunicarse y controlar dispositivos que facilitan la interacción con su entorno y propicien su autonomía.

Dentro de los BCI basados en EEG, el componente de la onda P300 del Potencial Relacionado a Eventos (*ERP por sus siglas en inglés*) es comúnmente utilizado para el procesamiento de las señales cerebrales debido a que requiere muy poco entrenamiento para que una persona pueda operar una BCI [3].

El componente P300 del ERP se considera un potencial cognitivo, y se presenta cuando una persona detecta un cambio inesperado entre una serie de estímulos visuales monótonos. Dicho cambio llama la atención de la persona, obligándolo a utilizar la memoria de trabajo para comparar el estímulo visual raro o infrecuente con los estímulos visuales que son frecuentes [3].

Por otro lado, las redes neuronales artificiales (RNA) a través del enfoque de aprendizaje profundo (deep learning), se han convertido en una técnica útil para extraer características de las señales EEG y detectar el componente P300, permitiendo representar los datos de manera más efectiva y compacta.

En este trabajo se propone el desarrollo de un sistema que genere las secuencias de control para una neuroprótesis que será utilizada en la rehabilitación de pacientes que no pueden

controlar sus propios músculos mediante vías neuronales.

Esta propuesta se basa en el registro EEG durante la operación de una BCI mientras se presentan cambios inesperados entre una serie de estímulos visuales monótonos, que llaman la atención de las personas y los obliga a comparar el estímulo visual raro o infrecuente (paradigma de evento raro).

El cambio en los estímulos tiene como fin identificar la presencia o no de la onda P300 del ERP. La extracción de características y la clasificación serán implementadas en un dispositivo móvil utilizando Python como plataforma.

La clasificación de las señales EEG se llevará a cabo haciendo uso de aprendizaje profundo (deep learning) y su procesamiento permitirá obtener la información para que un sistema implementado en el dispositivo móvil, se encargue de determinar las secuencias de control que serán ejecutadas por una neuroprótesis.

Las secuencias de control obtenidas en este trabajo se probarán en el control de una neuroprótesis desarrollada por el Instituto Nacional de Rehabilitación, que tiene como fin la estimulación del movimiento de una extremidad superior de una persona.

1.1. Planteamiento del problema

El registro de las señales de la actividad cerebral ha permitido que mecanismos no invasivos, como las BCI basadas en la EEG, puedan establecer una vía de comunicación entre el cerebro humano y dispositivos externos, como son las neuroprótesis.

Sin embargo, existen pocos BCI basados en la EEG que haciendo uso de dispositivos móviles interpreten las señales electroencefalográficas que están asociadas a estímulos visuales para controlar una neuroprótesis que pueda ser utilizada en la rehabilitación de pacientes que no pueden controlar sus propios músculos mediante vías neuronales.

1.1.1. Preguntas de investigación

¿Cómo pueden ser procesadas por un dispositivo móvil las señales electroencefalográficas que corresponden a la respuesta de un estímulo visual?

¿Cómo puede un dispositivo móvil generar las secuencias de control para una neuroprótesis a partir de señales electroencefalográficas procesadas que corresponden a la respuesta de un estímulo visual?

1.1.2. Objetivo general

Desarrollar un sistema clasificador basado en señales electroencefalográficas para generar las secuencias de control de una neuroprótesis por medio de un dispositivo móvil.

1.1.3. Objetivos específicos

- Adecuar un método que sincronice el registro de señales electroencefalográficas con un estímulo visual externo.
- Adecuar un algoritmo que permita caracterizar y clasificar las señales electroencefalográficas asociadas a un estímulo visual.
- Desarrollar los componentes de un sistema que genere las secuencias de control de una neuroprótesis.

1.2. Justificación

En una región que presenta una evolución digital con un mercado en vías de desarrollo, la tecnología móvil es uno de los motores que impulsa fuertemente la adopción digital en su población, lo cual se refleja en el comportamiento de las personas cuando realizan sus actividades habituales.

En tal sentido, para las personas con discapacidades, se hace indispensable el desarrollo de tecnologías que les permita, aumentar las capacidades para realizar sus actividades cotidianas.

Las BCI basadas en la EEG, son herramientas que permiten el registro de señales eléctricas cerebrales con el fin de crear un canal de comunicación no-muscular entre las intenciones mentales y los dispositivos electrónicos; por lo que a través del reconocimiento y procesamiento de las señales cerebrales, es posible reconocer por medio de un dispositivo móvil, los potenciales cognitivos que tengan como objetivo el control de una neuroprótesis que sirva para la rehabilitación de las personas con discapacidad o que se encuentren afectadas por lesiones del sistema nervioso.

1.3. Estado del arte

En esta sección se hace una revisión de los trabajos más representativos relacionados con el enfoque del uso de información del EEG para la identificación del potencial P300 en el contexto del Deletreador de Donchin. Se describen brevemente los principios de las métricas de identificación del potencial P300 en el Deletreador de Donchin original. Posteriormente, se presenta una revisión de trabajos representativos que exploran el uso de la información del EEG para detectar/identificar el potencial P300 en el contexto de las BCI.

En 1988 Farwell y Donchin publicaron un artículo [4] donde se presentó un sistema basado en el componente P300 del ERP, el cual es conocido como el *Deletreador de Donchin* y es el fundamento de las BCI. El sistema tiene como propósito establecer un canal de comunicación entre una computadora y un usuario, con el objetivo principal de ayudar a las personas con discapacidad motora que les impide comunicarse.

El sistema presenta una matriz con 36 símbolos y comandos simples en la pantalla de un monitor controlado por una computadora. El sujeto enfoca su atención en una celda o símbolo en particular mientras que se presentan eventos de estimulación que consisten en la iluminación intensa de una fila o columna de la matriz. La iluminación intensa de la columna y la fila que contienen a la celda del símbolo se convierten en eventos relevantes para la atención del sujeto.

La arquitectura y el principio de operación básico del *Deletreador de Donchin*, son la base de diversos sistemas BCI, sin embargo, fue de preocupación para los autores la baja tasa de transferencia de información y velocidad de comunicación del sistema, debido a la necesidad de presentar múltiples series de estímulos al sujeto para obtener por promediación coherente, un potencial P300 claramente identificable y con ello disminuir el número de errores de deletreo.

A partir de [4], en un sistema de interfaz cerebro-computadora (BCI), se identificó que la extracción de características y la clasificación de características de las señales EEG son las tareas importantes para el reconocimiento de dichas señales. De acuerdo con [5] para

una clasificación eficiente, la extracción de características es un paso importante; ya que, las características más relevantes proporcionan un mejor rendimiento de clasificación.

En [6], haciendo uso del método PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), fueron identificados y recolectados 90 estudios para revisión de aplicaciones de aprendizaje profundo con al menos 2 capas ocultas utilizadas para la clasificación de señales de EEG. Las tareas identificadas en los estudios, utilizaron el aprendizaje profundo para identificar: reconocimiento de emociones (*ER*, *Emotion recognition*), imágenes motoras (*MI*, *Motor imagery*), carga de trabajo mental (*MW*, *Mental workload*), detección de convulsiones (*SD*, *Seizure detection*), detección de potencial relacionado con eventos (*ERP*, *event related potential*) y puntuación de la etapa del sueño (*SS*, *Sleep stage scoring*). En la etapa de la clasificación se identificó que el uso de las redes neuronales convolucionales (*CNN*, *Convolutional neural network*), las redes neuronales recurrentes (*RNN*, *Recurrent neural network*), las redes de creencias profundas (*DBN*, *Deep belief network*) superan en precisión a los autocodificadores apilados (*SAE*, *Stacked auto-encoder*) y a las redes neuronales de perceptrón de múltiples (*MLPNN*, *Multi-layer perceptron neural network*).

De acuerdo con [6] en el nivel más básico, un conjunto de datos de EEG consiste en una matriz bidimensional (tiempo y canal) de valores reales que representan los potenciales generados por el cerebro registrados en el cuero cabelludo asociados a condiciones de tareas específicas; por lo que, esta forma altamente estructurada hace que los datos del EEG sean adecuados para que puedan ser utilizados en técnicas de aprendizaje automático *ML*, *Machine Learning*. Asimismo, en [6] se menciona que los datos del EEG se analizan comúnmente en el dominio de la frecuencia porque a menudo se encuentran asociados con patrones de comportamiento. La densidad espectral de potencia (PSD), la descomposición de las ondas y las medidas estadísticas de la señal (es decir, la media, la desviación estándar) son las tres formulaciones de entrada más comunes utilizadas en los estudios revisados.

De los estudios de [6], para las tareas ERP se identificó el uso de tres tipos diferentes de arquitecturas de aprendizaje profundo: SAE, DBN y CNN. En [7], [8], compararon el rendimiento entre las arquitecturas SAE y las MLPNN, y ambos encontraron que las SAE son las que mejor funcionan, en [7] se obtuvo una tasa de éxito de clasificación del 79.38 % y

en [8] se obtuvo una precisión de 73.6 %. En [9] compararon específicamente el rendimiento entre los DBN y los SAE y encontraron que los DBN tenían una ligera ventaja en la precisión de la clasificación (86.9 % y 86.01 % respectivamente). En [6] hacen referencia a cinco estudios que utilizaron diferentes variaciones de los CNN, pero no ofrecieron ninguna comparación directa entre otros tipos de arquitectura. Finalmente en [6] se menciona que las CNN como las DBN fueron consideradas como buenas arquitecturas candidatas para las tareas de ERP.

En [10], estudian el rendimiento de arquitecturas CNN para la detección de P300 de la información registrada en tareas ERP de una sola prueba para un sujeto (clasificación intra-sujeto), así como también de la información recuperada por otros sujetos en cuatro conjuntos de datos diferentes (clasificación entre sujetos) e indican que no es requerida una cantidad tan grande de parámetros para tener un porcentaje alto (mayor a 79 %) en la etapa de clasificación, permitiendo con ello considerar la posibilidad eliminar la etapa de calibración BCI basada en señales de ERP para cada sujeto utilizando en su lugar la información adquirida previamente para otros sujetos

Las arquitecturas estudiadas en [10] fueron: *CNN-1*, arquitectura de 4 capas propuesta por [11], la primer y segunda capa tienen una función de activación de tangente hiperbólica escalada, la capa de clasificación está compuesta por dos neuronas sigmoideas; *CNN-3* propuesta por [11], es una variante de la CNN-1 que tiene solo un filtro en la primera capa convolucional en contraste con los 10 filtros de CNN-1; *UCNN-1* y *UCNN-3*, propuestas por [10] y que son variaciones de CNN-1 y CNN-3 respectivamente, las cuales tienen una función de activación Softmax; *CNN-R* propuesta por [12], que contiene dos bloques de agrupación convolucional-max, una capa convolucional, dos capas completamente conectadas y una capa de clasificación Softmax; *DeepConvNet*, propuesta por [13] y consiste en una arquitectura que consta de cuatro bloques convolucionales seguidos de una capa de clasificación Softmax; *ShallowConvNet*, propuesta por [13] y es una variante de DeepConvNet; *BN3*, [14] propuso una arquitectura CNN de seis capas que combina técnicas de Batch Normalization y Dropout; *EEGNet*, propuesto por [15] y es una arquitectura CNN compacta que consta de dos bloques convolucionales seguidos de una capa de clasificación Softmax; *OCLNN*, propuesto por [16] y es una arquitectura de una capa convolucional, que consiste en una capa convolucional 1D con una función de activación ReLU, seguida de una capa

de clasificación Softmax; *SepConv1D*, propuesto por [10] y es una arquitectura CNN muy simple que consta de una única capa convolucional 1D separable en profundidad seguida de una neurona de clasificación Sigmoide completamente conectada.

En el análisis de [10], fueron ejecutadas 200 iteraciones de entrenamiento (épocas) del optimizador de Adam y realizaban una parada temprana si la pérdida de validación no mejoraba en 50 iteraciones. Se utilizó entropía cruzada binaria como función de pérdida para BN3, FCNN y SepConv1D, error cuadrático medio para CNN1 y CNN3, y entropía cruzada categórica para el resto de arquitecturas. El inicializador uniforme Glorot se utilizó para todas las arquitecturas, excepto CNN1, UCNN1, CNN3 y UCNN3, que emplearon el inicializador propuesto por Cecotti y Gräser [11].

Posteriormente en [10], calcularon el área bajo la curva (AUC) de las curvas ROC (*Receiver Operating Characteristic*) sobre el conjunto de datos de prueba en cada división. Los valores de AUC de la clasificación entre sujetos son más bajos que los del intra-sujeto (CNN1: 0.82 y 0.78; UCNN1 0.84 y 0.78; CNN3 0.78 y 0.73; UCNN3 0.83 y 0.76; CNN-R 0.83 y 0.79; DeepConvNet 0.84 y 0.79; ShallowConvNet 0.82 y 0.79; BN3 0.83 y 0.78; EEGNet 0.84 y 0.8; OCLNN 0.83 y 0.79; FCNN 0.83 y 0.75; SepConv1D 0.84 y 0.78), y señalan, que la diferencia no es particularmente grande, por lo que este tipo de detección puede proporcionar un rendimiento razonable en comparación con la detección dentro del sujeto cuando la calibración del sujeto no es posible.

Finalmente en [10], analizaron el tiempo de entrenamiento y el número de épocas necesarias para cumplir con los criterios de detección temprana, así como el tiempo de inferencia (es decir, el tiempo necesario para procesar el conjunto de prueba). La diferencia de tiempo entre SepConv1D y las arquitecturas con el AUC medio más alto (EEGNet y DeepConvNet) son 0.09 y 0.15 segundos respectivamente, mientras que las diferencias en el número de épocas son 84.49 y 31.4 respectivamente.

En [17] realizaron un estudio sobre las ondas cerebrales captadas por una BCI asociada a biomecanismos, el método de extracción de características fue el promediado sincronizado, el clasificador análisis de discriminante lineal y se detalló su algoritmo demostrando el discriminante lineal de Fisher. También, diseñaron una aplicación para la manipulación de

un brazo robótico virtual por medio de los potenciales evocados P300.

Finalmente en [17] utilizaron una matriz de iconos de 5x5 que correspondían a los movimientos que podía realizar el brazo robótico virtual y una matriz de letras de 5x5 con las letras de la A - Y. Fueron evaluados 20 sujetos sanos y obtuvieron una precisión del 90.01 %.

CAPÍTULO 2

Marco teórico

Para poder entender como puede ser registrada y procesada la actividad eléctrica del cerebro, es necesario conocer algunos conceptos definidos por medio de las Ciencias Bioquímica y Fisiológica, ya que a través de dichas Ciencias han sido estudiadas las estructuras químicas y funciones de los seres vivos, así como también, las funciones de los seres orgánicos, como es la de los seres humanos.

De tal forma que, en esta sección se presentan términos que son relevantes para el estudio de la actividad eléctrica del cerebro, como es la relación entre el sistema nervioso y el cerebro, siendo uno de los métodos que ha permitido el registro de dicha actividad eléctrica el que se denomina Electroencefalografía (EEG).

2.1. El impulso nervioso, el sistema nervioso, el sistema nervioso central

La membrana que rodea las *células neuronales* mantiene una asimetría del voltaje interno-externo (*potencial eléctrico*) y es sensible a excitación con electricidad por la presencia de canales activados por voltaje. Cuando un área considerable de la membrana se despolariza, una perturbación electroquímica se propaga por la membrana, lo que genera un *impulso nervioso* [18]. La información se difunde en el sistema nervioso en forma de potenciales de acción nerviosos, llamados *impulsos nerviosos*, que viajan a través de una sucesión de neuronas [19].

El sistema nervioso se puede analizar en tres partes principales: *la porción de aferencia sensitiva*, *el sistema nervioso central* (que constituye la *porción integradora*) y *la porción eferente motora*. Una de las funciones preponderantes del sistema nervioso consiste en procesar la información que recibe de tal modo que sean emitidas las respuestas motoras y mentales adecuadas.

El *sistema nervioso central* consta de más de 100.000 millones de neuronas y está estructurado primariamente para conducir impulsos [19]. El *sistema nervioso central*, el *encéfalo* y la *médula espinal* son los principales centros en los que se produce la correlación y la integración de la información nerviosa [20].

2.1.1. Función integradora del sistema nervioso central

El inicio de las actividades del sistema nervioso suele darse cuando las experiencias sensitivas excitan los receptores sensitivos, que pueden ser de carácter visual en los ojos, auditivo en los oídos, táctil en la superficie del organismo o de otros tipos. Estas experiencias sensitivas pueden causar reacciones inmediatas del encéfalo, o guardar un recuerdo y determinar reacciones corporales en un futuro.

El encéfalo parece ignorar más del 99 % de toda la información sensitiva que recibe por no revestir mayor interés o importancia. Sin embargo, cuando una experiencia sensitiva importante llega, de inmediato es enviada hacia las regiones motoras e integradoras pertinentes del encéfalo para obtener las respuestas deseadas. Esta canalización y procesamiento de la información es la *función integradora* del sistema nervioso.

En función de la actividad nerviosa, puede considerarse que el pensamiento tiene su origen en un «patrón» de estimulación en múltiples componentes del sistema nervioso al unísono [19].

2.2. El cerebro

El *cerebro* tiene entre sus funciones las de almacenar información, generar los pensamientos y determinar las reacciones que deben manifestar distintas partes del cuerpo en respuesta a las experiencias sensitivas para, a continuación, transmitir las señales apropiadas mediante la porción motora *eferente* del sistema nervioso para ejecutar las intenciones del sujeto [18]. El *cerebro*, es la mayor parte del encéfalo.

2.2.1. Control cognitivo

Por *conocimiento* o *cognición* se denota a los procesos de pensamiento del encéfalo, que usan las señales sensitivas recibidas por el cerebro en conjunto con la información ya almacenada en la memoria. Nuestras acciones motoras se producen como consecuencia de los pensamientos generados en la mente, fenómeno llamado *control cognitivo de la actividad motora*. El núcleo caudado tiene un rol importante en este proceso.

El cerebro cuenta con dos capacidades importantes para controlar el movimiento: 1) determinar la velocidad a la que se desea su ejecución, y 2) definir la amplitud con la que debe suceder [19].

2.2.2. Origen de las ondas cerebrales

La descarga de una neurona individual o de una sola fibra nerviosa en el encéfalo no ha podido ser registrada desde la superficie de la cabeza. Para conseguir la detección, es necesario que se disparen sincrónicamente miles o incluso millones de neuronas o de fibras; de esta manera se sumará una cantidad suficiente de potenciales procedentes de las neuronas o de las fibras aisladas como para detectar esta actividad con sensores sobre el cráneo.

La intensidad de las ondas cerebrales sensadas sobre el cuero cabelludo es función del número de neuronas y de fibras que disparan en sincronía entre sí, no por el nivel de actividad eléctrica total en el encéfalo. Además, las señales nerviosas potentes asincrónicas pueden anularse mutuamente debido a su polaridad opuesta y entonces no serían detectadas [19].

2.2.3. Ondas cerebrales

Las señales eléctricas que pueden ser recogidas en la superficie cerebral o incluso en la superficie de la cabeza indican que existe una actividad eléctrica constante en el encéfalo. La intensidad y los patrones de esta variable dependen del grado de excitación que presentan sus diversos componentes como consecuencia del sueño, la vigilia o trastornos cerebrales. Las ondulaciones de los potenciales eléctricos recogidos, se llaman *ondas cerebrales*, y el registro en su integridad recibe el nombre de *electroencefalograma* (EEG).

La amplitud de las ondas cerebrales sensadas en la superficie del cuero cabelludo varía de 0 a 200 μV , mientras que su frecuencia va desde una vez cada varios segundos hasta 50 o más por segundo. El carácter de las ondas depende del grado de actividad en las regiones respectivas de la corteza cerebral [19].

En las personas sin condiciones anormales, la mayoría de las ondas del EEG pueden clasificarse como ondas α , β , θ y δ ,

Las ondas α tienen una frecuencia entre 8 y 13 ciclos/s (Hz), y están presentes en el EEG de los adultos sanos mientras permanecen despiertos y en un estado de reposo tranquilo en su actividad cerebral. Estas ondas parecen tener mayor amplitud en la región occipital, pero también pueden detectarse en las regiones parietal y frontal del cuero cabelludo. Las ondas α desaparecen durante el sueño profundo [19]. Su voltaje está normalmente entre 50 y 100 μV [19][21].

Cuando una persona que se encuentra despierta dirige su atención a algún tipo específico de actividad mental, las ondas α son sustituidas por ondas β , asincrónicas de mayor frecuencia, pero menor voltaje. Las ondas β tienen frecuencias superiores a 14 ciclos/s y llegan hasta los 80. Se detectan sobre todo en las regiones parietal y frontal durante la activación específica de estas partes del cerebro.

Las ondas θ muestran frecuencias entre 4 y 7 ciclos/s. Se observan normalmente en los niños en las regiones parietal y temporal, pero también en algunos adultos en situaciones de estrés emocional, especialmente relacionadas con desánimo y de frustración. Las ondas θ están presentes en muchos trastornos nerviosos, por ejemplo, en los estados degenerativos cerebrales.

Las ondas δ son las ondas del EEG con frecuencias menores a 3,5 ciclos/s, y suelen tener voltajes del doble al cuádruple que la mayoría de los demás tipos de ondas cerebrales. Se observan a lo largo del sueño muy profundo, en la lactancia y en personas con enfermedades orgánicas serias del cerebro. Las ondas δ pueden presentarse estrictamente en la corteza de forma independiente a las actividades de las regiones inferiores del encéfalo.[19]

2.3. Electroencefalograma

En el siglo XIX se reporta por primera vez una descripción de la actividad eléctrica de fondo del encéfalo en animales no anestesiados. El término electroencefalograma (EEG) para referirse al registro de las variaciones en el potencial del cerebro, así como un análisis sistemático de esta actividad, se deben al psiquiatra alemán, Hans Berger [21].

El *electroencefalograma (EEG)* se define como el “registro de la actividad eléctrica del cerebro tomada por medio de electrodos colocados en la superficie de la cabeza, a menos que se especifique lo contrario”, por lo que el *electroencefalógrafo (EEG)* es “el Instrumento empleado para registrar electroencefalogramas”, siendo la *electroencefalografía (EEG)* “(1) La ciencia relacionada con la actividad eléctrica del cerebro. (2) La práctica de registrar e interpretar electroencefalogramas” [22].

El electroencefalograma puede obtenerse con electrodos en el cuero cabelludo con el cráneo intacto, pero en algunos casos se puede obtener con electrodos sobre o dentro del cerebro. Los experimentos de electroencefalograma pueden categorizarse como bipolares o unipolares. Los registros bipolares muestran fluctuaciones en la diferencia de potencial entre dos electrodos corticales; los registros unipolares muestran la diferencia de potencial entre un electrodo cortical y un electrodo de referencia (en teoría indiferente) que se coloca en alguna parte del cuerpo distante de la corteza. [21]

2.3.1. Sistema internacional 10-20 EEG

La estandarización de la posición y la nomenclatura de las matrices de electrodos para el cuero cabelludo, fue desarrollado por la Federación Internacional de Neurofisiología Clínica (*IFCN, International Federation of Clinical Neurophysiology por sus siglas en inglés*). Las posiciones de los electrodos se basan en porcentajes de las mediciones circunferenciales de puntos de referencia cefalométricos del cráneo. Los nombres de los electrodos consisten en letras y números. Las letras (F, T, P, O) indican el lóbulo subyacente (excepción: P7 / 8, que cubre el lóbulo temporal posterior). C indica la región central. Los estudios anatómicos mostraron que utilizando las medidas descritas aquí, los electrodos de C se ubican a 1 cm dentro del surco central. Los electrodos fronto-polares son anotados Fp. Los números impares están en el lado izquierdo, y los números pares en el lado derecho. Los electrodos en la línea media se anotan con z (para cero).

Los puntos de referencia en el cráneo son: los puntos preauriculares izquierdo y derecho (depresiones en la raíz del cigomático, justo delante del trago), nasión (depresión entre los

ojos, justo por encima del puente de la nariz, en la intersección del hueso frontal y los huesos nasales) y el inion (el punto más alto de la protuberancia del hueso occipital, en la línea media; figura 2.1) [23].




Figura 2.1: AC: Colocación de los electrodos estándar del sistema 10-20. A: vista lateral, B: vista frontal, C: desde la parte superior. Tomada de: [23]. pp. 2071

Sobre la base de los puntos de referencia anatómicos detallados anteriormente, se deben obtener las siguientes mediciones.

La primera medida circunferencial (longitudinal) es en el plano sagital, en la línea media del cráneo, desde el nasión, a través del vértice (el punto más alto de la cabeza) hasta el inion (figura 2.1 -A). Si se considera esta distancia como 100 %, se marcan cinco puntos entre nasión e inion, en la dirección anterior-posterior, lo que da el nivel (longitud) de los siguientes puntos: Fpz (10 % de nasión), Fz (20 % de Fp), Cz (20 % de F), Pz (20 % de C) y Oz (20 % de P y 10 % anterior al inion).

La segunda medida circunferencial (transversal) es en el plano coronal, desde el punto preauricular izquierdo hasta el derecho, a través del vértice (figura 2.1-B). Si se considera esta distancia como 100 %, siete puntos (latitudes) están marcados en esta dirección: T9 (en el punto preauricular izquierdo), T7 (10 % desde el punto preauricular), C3 (20 % desde T7), Cz (20 % desde C3, en la intersección de la primera y segunda medida circunferencial), C4 (20 % de Cz), T8 (20 % de C4) y T10 (10 % de T8, en el punto preauricular derecho).

La tercera medida circunferencial (figura 2.1-C) se toma de Fpz a Oz, en el lado izquierdo (a través de T7) y en el lado derecho (a través de T8). En la dirección anterior-posterior,

los puntos están marcados en el lado izquierdo / derecho para Fp1 / 2 (10 % de Fpz), F7 / 8 (20 % de Fp1 / 2), T7 / 8 (20 % de F7 / 8), P7 / 8 (20 % de T7 / 8) y O1 / 2 (20 % de P7 / 8 y 10 % de Oz).

La cuarta medición se realiza en el plano parasagital, oblicuo, en el lado izquierdo (de Fp1 a O1, a través de C3) y en el lado derecho (de Fp2, a través de C4 a O2). Esto representa el 80 % de la distancia de Fpz a Oz, a través de C3 / 4, por lo tanto, el 20 % de la distancia de Fpz a Oz equivale al 25 % de la medición parasagital de Fp1 / 2 a O1 / 2. Al 25 % de los segmentos de la medición parasagital, las siguientes posiciones están marcadas en la dirección anterior-posterior: F3 / 4, C3 / 4, P3 / 4.

2.3.2. Ritmos α , β , γ y μ

De acuerdo con [22] un ritmo cerebral se define como la “*actividad del EEG que consiste en ondas de un período aproximadamente constante*”.

Cuando una persona se encuentra en vigilia, pero en estado alerta, suele mostrar ondas β de alta frecuencia. Por otro lado, una situación de tranquilidad (despierto, pero con la mente libre y los ojos cerrados), suele asociarse a un patrón regular de las ondas α [19][21].

En adultos en situación de tranquilidad, el componente principal del electroencefalograma es un patrón mayormente regular de ondas con una frecuencia entre 8 y 13 Hz y amplitud entre 50 y 100 μ V cuando se registran en el cuero cabelludo (ritmo α).

Cuando la persona enfoca su atención en algo, la actividad cerebral cambia de su ritmo α a ser irregular y de voltaje bajo (el ritmo β). Este fenómeno se conoce como bloqueo α y se puede producir con cualquier forma de estimulación sensitiva o concentración mental, como por ejemplo la solución de problemas matemáticos. Este fenómeno también es conocido como excitación o respuesta de alerta, ya que se relaciona con el estado excitado, de alerta. También se le ha llamado desincronización, porque se interrumpe la actividad neural sincronizada evidente requerida para generar ondas regulares. En realidad, la actividad

electroencefalográfica rápida del estado de alerta también está sincronizada, aunque a una mayor frecuencia, de manera que el término desincronización es engañoso.

Las oscilaciones γ tienen frecuencias entre 30 y 80 Hz, aparecen cuando un individuo se encuentra alerta y enfoca su atención en algo. Estas oscilaciones pueden sustituir la actividad rápida irregular cuando el individuo inicia la acción motora como respuesta al estímulo [21].

El ritmo β se refiere a cualquier ritmo de EEG entre 14 y 30 Hz y que tiene una duración de onda entre 33 y 72 ms. El ritmo β es más característicamente registrado en las regiones fronto-centrales de la cabeza durante la vigilia. La amplitud del ritmo β fronto-central varía, pero en general está por debajo de 30 μ V. El bloqueo o la atenuación del ritmo β por el movimiento contralateral o la estimulación táctil es especialmente evidente en los electrocorticogramas. Otros ritmos beta son más prominentes en otras ubicaciones o son difusos, y pueden ser inducidos por fármacos (por ejemplo, alcohol, barbitúricos, benzodiazepinas y agentes anestésicos intravenosos) [22].

El ritmo μ tiene frecuencias semejantes a las del ritmo α , pero su configuración, topografía y reactividad son independientes. Las ondas del ritmo μ tienen aspecto más agudo y menos sinusoidal que el ritmo α , siendo característica su forma en arcos (*ritmo en arceau de la literatura francesa*) o de púas de peine (*comb o wicket rhythm de los autores ingleses*).

El ritmo μ aparece normalmente en trenes de unos pocos segundos de duración. Sus frecuencia están entre 7 y 12 Hz, usualmente se trata de una actividad de 8 y 10 Hz (también se conoce como actividad alfoide). La amplitud está entre 20 y 60 μ V. Suele ser simétrico en los dos hemisferios, si bien puede ser asimétrico en algún segmento del registro.

La reactividad del ritmo μ ha sido asociada a los sistemas sensorial y motor, no existiendo relación aparente con el sistema visual (no se atenúa con la apertura de los párpados) ni con la actividad mental. Parece ser bloqueado o atenuado por el movimiento contralateral, pensamiento de movimiento, disposición para moverse o estimulación táctil [24][22].

2.4. ERPs

La modulación del flujo de información se manifiesta en la sincronización y desincronización de los ritmos de EEG. Las etapas del flujo de información se miden por potenciales relacionados con eventos (ERP). A diferencia de los ritmos de EEG, la condición necesaria para provocar ERP es el bloqueo temporal de un determinado evento, ya sea un estímulo o un movimiento.

La suma de potenciales postsinápticos sincronizados y bloqueados por eventos se registra en el cuero cabelludo en forma de un componente ERP, una deflexión potencial que está espacialmente localizada y temporalmente confinada.

El método ERP se introdujo en la neurociencia cognitiva en la década de 1960 y los componentes se asociaron con picos y valles en los propios ERP o en las ondas de diferencia de ERP. Las deflexiones potenciales en las ondas de diferencia se pueden dividir en clases en función de su latencia y dirección de desviación (positiva o negativa) como P100, N100, N200, P200, P300, N400, donde P representa positividad, N para negatividad, y el número representa la latencia máxima en milisegundos [25].

Para provocar un ERP se necesita cumplir la condición de acoplamiento en el tiempo (bajo un paradigma experimental) a un cierto evento o tarea motora, cognitiva o sensorial. Esas tareas hacen uso de operaciones psicológicas, como la detección y reconocimiento de estímulos (como en el P300), la actualización de la memoria de trabajo, represión de acciones, etc. Dichas operaciones dan origen a un patrón temporal de activación/inhibición neuronal en ciertas áreas del cerebro. Esta actividad se registra en el EEG como una deflexión en el potencial, con localización y latencia bien definidas: un componente del ERP [3].

La forma común de analizar las señales de EEG relacionadas con eventos es el cálculo de potenciales relacionados con eventos (ERP). Esto se hace presentando repetidamente un evento de interés, como un estímulo visual en la pantalla de una computadora, y analizando la pequeña fracción de la actividad EEG que evoca este evento. Computacionalmente, el

ERP se revela al extraer las épocas de EEG acopladas en el tiempo para la presentación del estímulo y calcular el promedio sobre las épocas de EEG [26].

2.4.1. Componente P300

El componente P300 indexa las actividades cerebrales subyacentes a la revisión de la representación mental inducida por estímulos entrantes. Después del procesamiento sensorial inicial, un proceso de comparación dirigido por la atención evalúa la representación del evento anterior en la memoria de trabajo. Si no se detecta ningún cambio en el tipo de estímulo, se mantiene el modelo mental actual o el “esquema” del contexto de estímulo, y solo se registran los potenciales evocados sensoriales (N100, P200, N200). Si se detecta un nuevo estímulo, los procesos de atención regulan un cambio o “actualización” de la representación del estímulo que es simultáneo con la P300. Estas ideas dan forma a la teoría de actualización del contexto del P300 [27], y se puede representar a través del esquema de la figura 2.2.




Figura 2.2: Modelo de actualización de contexto del componente P300. Los estímulos ingresan al sistema de procesamiento y se activa un proceso de comparación de memoria que determina si el estímulo actual es el mismo que el estímulo anterior o no. Si el estímulo entrante es el mismo, el modelo neural del entorno del estímulo no cambia y se obtienen potenciales evocados sensoriales (N100, P200, N200) después del promedio de la señal. Si el estímulo entrante no es el mismo y el sujeto asigna recursos de atención al objetivo, la representación neuronal del entorno del estímulo cambia o se actualiza, de modo que se genera un potencial P300. Modificada de [27].

El componente P300 se mide evaluando su amplitud y latencia. La amplitud (μV) se define como la diferencia entre el voltaje de línea base previo al estímulo y el pico positivo más grande de la forma de onda ERP dentro de una ventana de tiempo (por ejemplo, 250–500 ms, aunque el rango puede variar dependiendo de la modalidad del estímulo, condiciones de la tarea, edad del sujeto, etc.). La latencia (ms) se define como el tiempo desde el inicio del estímulo hasta el punto de máxima amplitud positiva dentro de una ventana de tiempo. La distribución P300 del cuero cabelludo se define como el cambio de amplitud sobre los electrodos de la línea media (Fz, Cz, Pz), que generalmente aumenta en magnitud desde el frontal [27].

2.4.2. Paradigma del evento raro

Cuando a un sujeto se le presenta una serie de estímulos de 2 categorías distintas, mostrándose una de ellas con menor frecuencia, y se le pide que determine a cual de las 2 categorías pertenece cada estímulo, los eventos infrecuentes o raros provocan un ERP con un componente positivo aumentado, a una latencia aproximada de 300 ms, llamado P300. A este tipo de experimento se le llama paradigma de evento raro [4].

La amplitud del componente P300 es directamente proporcional a la relevancia de los estímulos que lo provocan, e inversamente proporcional a la probabilidad de dichos estímulos [4]. Además, la aparición del P300 depende de la habilidad del sujeto para discriminar los eventos y asignarlos de acuerdo su categoría.

2.5. Deletreador de Donchin

En 1988 Farwell y Donchin publicaron un artículo [4] donde se presenta un sistema BCI basado en el componente P300 del ERP. Aunque en ese artículo no se encuentra el término BCI (se habla de un canal biocibernético), el sistema ahí reportado es la base de la BCI ampliamente conocida como Deletreador de Donchin en la actualidad. El sistema busca servir como un canal de comunicación entre la computadora y el usuario, con el objetivo principal de ayudar a las personas con discapacidad motora que les impide comunicarse del todo.

El sistema permite al sujeto usar un switch poniendo su atención a uno de entre una serie de eventos de estimulación. La discriminación entre el evento en el cual está enfocándose el sujeto y los otros eventos en la serie, codifican la información que el sujeto desea comunicar. Al detectar cuál de los eventos en la serie genera un P300, el algoritmo implementado puede identificar y enviar el mensaje que el sujeto trata de comunicar. Para llevar esto a cabo, el sistema presenta una matriz con 36 símbolos y comandos simples en la pantalla de un monitor controlado por una computadora (Fig. 2.3). Los eventos de estimulación consisten

en la intensificación (iluminación) de una fila o columna de la matriz. El sujeto intenta comunicar el contenido de una celda de la matriz a la vez. Conforme el sujeto enfoca su atención en una celda o símbolo en particular, la columna y la fila (su intensificación) que contienen a la celda se convierten en eventos relevantes.



Figura 2.3: Matriz de 6x6 símbolos de un Deletreador de Donchin. La fila que se muestra iluminada se denomina un estímulo atendido solo si el símbolo objetivo (aquel que el sujeto desea deletrear) es alguna de las letras M, N, O, P, Q o R, y como un estímulo no atendido en cualquier otro caso. Las épocas de EEG sincronizadas al instante de presentación de ese estímulo se consideran, bajo la misma lógica, como épocas atendidas o no atendidas.

Hay 12 posibles eventos: 6 filas y 6 columnas, de los cuales solo 2 son relevantes a la tarea en cuestión, y se consideran raros o infrecuentes en el contexto del paradigma de evento raro. Por lo tanto, cualquier intensificación que contiene a la celda o símbolo en la cual el sujeto se está enfocando, debería provocar un potencial P300. En ese trabajo [4], mediante varios algoritmos se evalúa la amplitud del P300 posterior a cada estimulación (intensificación), y el símbolo atendido por el sujeto se identifica, después de varias secuencias de intensificación, como la intersección de la fila y la columna que provocan el P300 más grande.

2.6. Épocas EEG

De acuerdo con [3] las sesiones de registro EEG se pueden expresar como $x_{i,ch}(n)$, donde i representa el número de registro, ch el número de canal, $n = 1, 2, \dots, N$ son los instantes

de tiempo de muestreo de la señal EEG, y N es el número total de muestras del registro i .

Una época de EEG se expresa como $x_{i,ch}^{k,y}(n)$, con $n = \{1, 2, \dots, N\}$ y se define como una ventana de N muestras (posteriores al instante de estimulación) del registro i y clase $k \in \{a, u\}$ donde $k = a$ indica una época de la clase atendida y $k = u$ una época de la clase no-atendida.

El superíndice $k = a$, corresponde a la época sincronizada con la intensificación de una fila o columna de la matriz del Deletreador P300, que contiene al símbolo objetivo (evento infrecuente), y $k = u$ corresponde a una época de EEG asociada a una intensificación que no incluye un símbolo objetivo (evento frecuente). El superíndice y indica el tipo de época: filas ($y = f$) o columnas ($y = c$).

2.7. Inteligencia Artificial

Existen diversas definiciones que pueden ser utilizadas para el término de Inteligencia Artificial (AI, *Artificial Intelligence*), sin embargo, en la dimensión del pensamiento humano podría considerarse a la AI como “[La automatización de] actividades que asociamos con el pensamiento humano, . . . la resolución de problemas, el aprendizaje. . . ”. No existe un método universal para todas las áreas de aplicación de la AI, sino un gran número de posibles soluciones para la gran cantidad de problemas cotidianos, grandes y pequeños; por lo que, la investigación de los mecanismos de aprendizaje y el desarrollo de algoritmos de aprendizaje automático (*Machine Learning*) es una de las ramas más importantes de la AI [28][29].

2.7.1. Aprendizaje Automático / Aprendizaje Máquina

El aprendizaje automático o el aprendizaje máquina (*ML*, *Machine Learning*) es una colección de métodos que permiten a las computadoras automatizar la creación y progra-

mación de modelos basados en datos a través de un descubrimiento sistemático de patrones estadísticamente significativos en los datos disponibles. El aprendizaje automático permite que una máquina interprete un conjunto de datos y aprenda de esas interpretaciones para aplicarlas a otro conjunto similar de resultados. En 1959, Arthur Samuel definió el aprendizaje automático como un “campo de estudio que brinda a las computadoras la capacidad de aprender sin estar programadas explícitamente” [30].

El aprendizaje automático tiene muchos subcampos y aplicaciones, incluidos métodos de aprendizaje estadístico, redes neuronales, aprendizaje basado en instancias, algoritmos genéticos, minería de datos, reconocimiento de imágenes, procesamiento del lenguaje natural (NLP), teoría del aprendizaje computacional, programación de lógica inductiva y aprendizaje por refuerzo [31].

Las redes neuronales artificiales *ANN*, (*Artificial Neural Network*) son un tipo de técnica de aprendizaje automático que simula la estructura y función de las redes neuronales en el cerebro. Con la computación digital tradicional, los pasos computacionales son secuenciales y siguen técnicas de modelado lineal. Por el contrario, las redes neuronales modernas utilizan técnicas de modelado de datos estadísticos no lineales que responden en paralelo al patrón de entradas que se les presenta [31].




Figura 2.4: Relación de la inteligencia artificial y sus subcampos.

2.7.2. Redes neuronales artificiales

Las redes neuronales artificiales (*ANN*, *Artificial Neural Network* ó *NN*, *Neural Network*) son técnicas populares de aprendizaje automático (*ML*, *Machine Learning*) que simulan el mecanismo de aprendizaje en organismos biológicos. El sistema nervioso humano contiene células, que se conocen como neuronas. Las neuronas están conectadas entre sí mediante el uso de *axones* y *dendritas*, y las regiones de conexión entre *axones* y *dendritas* se denominan *sinapsis*. Las fortalezas de las conexiones sinápticas a menudo cambian en respuesta a estímulos externos. Este cambio es cómo se produce el aprendizaje en los organismos vivos [32].

Este mecanismo biológico se simula en *redes neuronales artificiales*, que contienen unidades de cálculo que se denominan *neuronas*. Las unidades computacionales están conectadas entre sí a través de pesos (*weights*), que cumplen el mismo papel que las fortalezas de las conexiones sinápticas en los organismos biológicos. Cada entrada a una neurona se escala con un peso, que afecta la función calculada en esa unidad [32]. Esta arquitectura es ilustrada en la Figura 2.5.




Figura 2.5: Arquitectura de una red neuronal artificial. Modificada de [32].

Una *red neuronal artificial* calcula una función de las entradas propagando los valores calculados desde las neuronas de entrada a las neuronas de salida y utilizando los pesos

como parámetros intermedios. El aprendizaje ocurre cambiando los pesos que conectan las neuronas. Así como los estímulos externos son necesarios para el aprendizaje en los organismos biológicos, el estímulo externo en las redes neuronales artificiales lo proporcionan los datos de entrenamiento que contienen ejemplos de pares de entrada y salida de la función que se va a aprender. Estos pares de datos de entrenamiento se alimentan a la red neuronal utilizando las representaciones de entrada para hacer predicciones sobre las etiquetas de salida. Los datos de entrenamiento brindan retroalimentación sobre la exactitud de los pesos en la red neuronal dependiendo de qué tan bien la salida predicha para una entrada en particular coincide con la etiqueta de salida anotada en los datos de entrenamiento. Uno puede ver los errores cometidos por la red neuronal en el cálculo de una función como una especie de retroalimentación desagradable en un organismo biológico, que conduce a un ajuste en las fuerzas sinápticas. De manera similar, los pesos entre neuronas se ajustan en una red neuronal en respuesta a errores de predicción. El objetivo de cambiar los pesos es modificar la función calculada para que las predicciones sean más correctas en futuras iteraciones. Por lo tanto, los pesos se cambian cuidadosamente de una manera matemáticamente justificada para reducir el error de cálculo en ese ejemplo. Al ajustar sucesivamente los pesos entre las neuronas en muchos pares de entrada-salida, la función calculada por la red neuronal se refina con el tiempo para proporcionar predicciones más precisas. Esta capacidad de calcular con precisión funciones de entradas invisibles mediante el entrenamiento sobre un conjunto finito de pares de entrada-salida se conoce como generalización del modelo (*model generalization*) [32].

Las redes tienen un número de capas el cual se conoce como profundidad de la red y el número de los nodos en una capa se conoce como la anchura de la capa. Las capas intermedias se denominan ocultas. Los valores de la capa oculta se obtienen a través de funciones de activación. La función de activación al igual que en el ser humano la unidad o neurona puede estar activa (excitada) o inactiva (no excitada), es por ello que las neuronas “artificiales” tienen diferentes estados de activación algunas simplemente pueden tener dos estados de activación pero otras pueden tener varios estados de activación [33].

Algunas funciones de activación utilizadas en la detección de P300 son la función de activación logística sigmoidea (2.1) y la función de activación tangente hiperbólica

(2.2) [33].

$$g(z) = \sigma(z) \quad (2.1)$$

$$g(z) = \tanh(z) \quad (2.2)$$

Estas funciones de activación están estrechamente relacionadas porque $\tanh(z) = 2\sigma(2z) - 1$ [33]. La función de activación logística sigmoidea corresponde a lo especificado en (2.3).

$$f(x) = \sigma(x) = \frac{1}{1 + e^{-x}} \quad (2.3)$$

El sigmoide se usa comúnmente para producir el parámetro ϕ de una distribución de Bernoulli porque su rango es $(0,1)$, que se encuentra dentro del rango válido de valores para el parámetro ϕ . La función sigmoidea se satura a un valor alto cuando z es muy positivo, se satura a un valor bajo cuando z es muy negativo, lo que significa que la función se vuelve muy plana e insensible a pequeños cambios en su entrada [33]. El sigmoide es muy utilizada en el Deep Learning y el Machine Learning, sobre todo para problemas de clasificación binaria. Tiene buen rendimiento en la última capa.




Figura 2.6: Función logística sigmoidea.

La función de activación tangente hiperbólica corresponde a lo especificado en (2.4).

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.4)$$

En la función tangente hiperbólica los valores altos tienen de manera asintótica a 1 y los valores muy bajos tienden de manera asintótica a -1. A diferencia de la función sigmoidea, esta función tiene media 0 y desviación típica uno, por lo que para conjuntos de datos cuya media esté entorno a cero suele funcionar muy bien. Se utiliza en problemas de clasificación binaria y tiene desempeño en redes recurrentes.




Figura 2.7: Función tangente hiperbólica.

Cuando se debe utilizar una función de activación sigmoidea, la función de activación de la tangente hiperbólica típicamente funciona mejor que la sigmoidea logística. Se parece más a la función de identidad, en el sentido de que $\tanh(0) = 0$ mientras que $\sigma(0) = \frac{1}{2}$. Debido a que $\tanh$ es similar a la función de identidad cercana a 0, el entrenamiento de una red neuronal profunda $\hat{y} = w^T \tanh(U^T \tanh(V^T)x)$ se parece al entrenamiento de un modelo lineal $\hat{y} = w^T U^T V^T$ siempre que las activaciones de la red se puedan mantener pequeñas. Esto facilita el entrenamiento de la red $\tanh$ [33].

2.7.3. Redes neuronales convolucionales

Las redes neuronales convolucionales están diseñadas para trabajar con entradas estructuradas en cuadrícula, que tienen fuertes dependencias espaciales en las regiones locales de la cuadrícula. Las formas de datos secuenciales como texto, series de tiempo y secuencias pueden considerarse casos especiales de datos estructurados en cuadrícula con varios tipos de relaciones entre elementos adyacentes [32].

De acuerdo a [6] en el nivel más básico, un conjunto de datos de EEG consiste en una matriz bidimensional (tiempo y canal) de valores reales que representan los potenciales generados por el cerebro registrados por sensores en el cuero cabelludo asociados a condiciones de tareas específicas, por lo que, esta forma altamente estructurada hace que los datos del EEG sean adecuados para que puedan ser utilizadas en técnicas de aprendizaje automático *ML*, *Machine Learning* [32].

El nombre “red neuronal convolucional” indica que la red aprovecha una operación matemática llamada convolución (un tipo especializado de operación lineal). Las redes convolucionales son redes neuronales artificiales que emplean la convolución en lugar de la multiplicación de matrices general en al menos una de sus capas. En la forma más general una convolución es una operación sobre dos funciones de un argumento real [33].

La convolución permite para calcular la respuesta de un sistema a una entrada $x(n)$. Puede calcularse de dos formas, dadas por las expresiones (2.5) y (2.6), donde $x(n)$ es la entrada del sistema, $h(n)$ la respuesta al impulso del sistema e $y(n)$ la respuesta del sistema a la entrada $x(n)$ [34].

$$y(n) = \sum_{k=-\infty}^{\infty} x(k)h(n-k) \quad (2.5)$$

$$y(n) = \sum_{k=-\infty}^{\infty} x(n-k)h(k) \quad (2.6)$$

En la parte técnica de las redes convolucionales, el primer argumento de la ecuación (la función x) de la convolución normalmente se refiere a la entrada (*input*), y el segundo argumento de la ecuación (la función h) kernel. La salida o el resultado de la convolución se le conoce como el mapa de características (*feature map*). En las aplicaciones de aprendizaje automático, la entrada (*input*) se maneja como una matriz multidimensional de datos y el kernel como una matriz multidimensional de parámetros adaptados por el algoritmo de aprendizaje. Nos referiremos a estos arreglos multidimensionales como tensores (*tensors*). Cada elemento de la entrada y del kernel (o núcleo) debe almacenarse explícitamente por separado, por lo que es común asumir que estas funciones son cero en todas partes, excepto en el conjunto finito de puntos para los que almacenamos los valores. Esto significa que, en la práctica, podemos implementar la suma infinita como una suma sobre un número finito de elementos del arreglo [33].

2.8. Métricas para la clasificación binaria

En una clasificación binaria se obtienen dos tipo de clases: una Positiva y una Negativa; para su análisis puede ser considerada una tabla cruzada de las predicciones estimadas (matriz de confusión) a partir de las clasificaciones identificadas como reales, como se puede observar en la figura 2.8.

		Predicción	
		Positivo	Negativo
Real	Positivo	TP	FN
	Negativo	FP	TN

Figura 2.8: Matriz de confusión en una clasificación binaria.

De acuerdo a la figura 2.8 se tiene lo siguiente:

- Verdadero Positivo (TP, True Positives): reales positivos con predicción positiva, es decir, clasificados correctamente como positivos.
- Falso Positivo (FP, False Positives): reales negativos con predicción positiva, es decir, clasificados incorrectamente como positivos.
- Verdadero Negativo (TN, True Negatives): reales negativos con predicción negativa, es decir, clasificados correctamente como negativos.
- Falso Negativos (FN, False Negatives): reales positivos con predicción negativa, es decir, clasificados incorrectamente como negativos.

La figura 2.9 ejemplifica un modelo general de una clasificación binaria.




Figura 2.9: Modelo general de una clasificación binaria.

La Presición puede considerarse como la proporción de los resultados calificados como positivos y que realmente lo sean, puede calcularse mediante lo especificado en 2.7.

$$P = \frac{TP}{TP + FP} \quad (2.7)$$

La Sensibilidad, Exhaustividad (*Recall*) puede considerarse como la proporción de todos los positivos clasificados como positivos, puede calcularse mediante lo especificado en 2.8.

$$R = \frac{TP}{TP + FN} \quad (2.8)$$


La Tasa de Falsos Positivos (*FPR*) puede considerarse como la proporción de todos los negativos que se clasifican como positivos, puede calcularse mediante lo especificado en 2.9.

$$FPR = \frac{TP}{TN + FP} \quad (2.9)$$

Medida F_1 , es la media armónica de P y R, puede calcularse mediante lo especificado en 2.10.

$$MedidaF_1 = 2x \frac{PxR}{p + R} \quad (2.10)$$

En un modelo general de clasificación binaria, si se disminuye el valor del umbral, se obtienen más valores positivos, aumentando R pero disminuye P; por otro lado, si se aumenta el umbral, se obtienen más valores negativos, lo que aumenta P y disminuye R, como puede ser observado en 2.10.



(a) Disminución del umbral en un modelo general de clasificación binaria. (b) Aumento del umbral en un modelo general de clasificación binaria.

Figura 2.10: Modificación del umbral de un modelo general de clasificación binaria.

De acuerdo a lo anterior se puede considerar lo siguiente:

- Una Precisión (P) alta significa pocos falsos positivos
- Un Recall (R) alta significa pocos falsos negativos.
- La relación entre P y R debe considerar lo siguiente:
 - Un clasificador que todo lo predijera positivo, obtendría $R = 1$, pero habría muchos falsos negativos y P sería muy baja.
 - Un clasificador que sólo predijera positivo a un único ejemplo (positivo) y el resto como negativo, tendría R muy baja pero $P = 1$.
 - Un clasificador perfecto tendría $P = R = 1$.


Las curvas más utilizadas son:

- Curva PR (Precision-Recall): representa como va cambiando el par (P,R), siendo ideal que tuviera precisión y recall altos.
- Curva ROC (Receiver Operating Characteristic): representa como va cambiando el par (FPR,R), siendo ideal que el recall sea alto y la tasa de falso positivo bajo.


El Área Bajo la Curva (AUC) se suele utilizar como métrica y se considera aceptable al menos un valor superior a 0.7, siendo deseable un valor lo más cercano a 1. El AUC puede interpretarse como la probabilidad de que el modelo haga una predicción más alta para un ejemplo positivo que para un ejemplo negativo.

En un modelo general de clasificación binaria, cuando dos distribuciones no se superponen en absoluto, el modelo tiene una medida ideal de separación, lo que permite distinguir entre clase positiva y clase negativa (ver figura 2.11a); cuando las dos distribuciones se superponen parcialmente, existen errores, por lo que dependiendo del umbral, pueden ser

minimizados o maximizados, por ejemplo, cuando AUC es 0.7, significa que hay 70 % de probabilidad de que el modelo pueda distinguir entre la clase positiva y la clase negativa (ver figura 2.11b); cuando las dos distribuciones se encuentran una encima de otra, el AUC es aproximadamente 0.5, por lo que el modelo no tiene capacidad de discriminación para distinguir entre clase positiva y clase negativa (ver figura 2.11c); cuando las dos distribuciones no se encuentran clasificados de forma correcta, el AUC es aproximadamente 0 y el modelo predice la clase negativa como una clase positiva y viceversa (ver figura 2.11d)



(a) Distribuciones no superpuestas en absoluto, AUC=1. (b) Distribuciones superpuestas parcialmente, AUC=0.7.



(c) Distribuciones superpuestas una sobre otra, AUC=0.5. (d) Distribuciones invertidas, AUC=0.

Figura 2.11: Relación de AUC con respecto a dos distribuciones de un modelo general de clasificación.

CAPÍTULO 3

Metodología

En este Capítulo se presenta el procedimiento que se ha realizado para el desarrollo de este trabajo.

Para llevar a cabo el procesamiento de los registros EEG para que un sistema se encargue de determinar las secuencias de control que serán enviadas a una neuroprótesis, serán consideradas las siguientes etapas:

- Adquisición de señales.
- Pre-procesamiento.
- Extracción de Características.

- Clasificadores.
- Control.

En la figura 3.1 se muestra un diagrama a bloques que ilustra de forma general la metodología considerada en el presente trabajo.




Figura 3.1: Diagrama a bloques de la metodología.

3.1. Adquisición de señales

La etapa de adquisición de las señales fue realizada a través de electrodos secos que son parte del EEG OpenBCI [35], los cuales fueron conectados con la OpenBCI Ganglion Biosensing Board [36].

3.1.1. Base de registros

Haciendo uso de la GUI de OpenBCI [37] fueron registrados los datos de las señales que OpenBCI Ganglion Biosensing Board [36] adquiría y que comunicaba de forma inalámbrica al dispositivo móvil a través del OpenBCI USB dongle [38]. Los datos de las señales fueron guardados en formato .txt por cada sesión de registro y corresponden a la medida de la diferencia de potencial entre cada electrodo y el electrodo de referencia.

3.1.2. Muestra poblacional

Consiste en 5 sesiones de 3 sujetos de entre 35 y 39 años de edad. No se recopiló información sobre algunas condiciones previas a los registros de EEG. A cada sujeto, bajo su consentimiento, se les explicó a detalle el proceso del registro y la actividad que debían realizar en cada sesión de registro. Cada sujeto fue identificado como S_n , donde $n = \{1, 2, 3\}$. Los datos de los sujetos se pueden consultar en la Tabla 3.1.

Muestra poblacional		
Sujeto	Sexo	Edad
S1	H	35
S2	H	37
S3	H	39

Cuadro 3.1: Datos de los sujetos que corresponden a la muestra poblacional.

3.1.3. Registro de EEG: Hardware y Software

El dispositivo OpenBCI Ganglion Biosensing Board [36] cuenta con 4 entradas de alta impedancia, las cuales fueron conectadas individualmente a un electrodo para medir EEG [39].

Los electrodos se colocaron según el Sistema Internacional 10-20 [23] en los puntos Fz, Cz, Pz, Oz con el fin de registrar el cambio de amplitud y el aumento en magnitud sobre los electrodos de la línea media [27]. El electrodo de referencia se colocó en el lóbulo de la oreja derecha y el electrodo de tierra en el lóbulo de la oreja izquierda. Las frecuencias de interés corresponden a las que se encuentran entre 1 Hz y 30 Hz, por lo que las señales se muestrearon a una frecuencia de 200 Hz en cada uno de los 4 canales, cumpliendo con el Teorema de Nyquist. Los datos fueron registrados en el orden de los μV . La figura 3.2 muestra la configuración de los electrodos.





Figura 3.2: Configuración de los electrodos utilizados del Sistema Internacional 10-20.

La GUI de OpenBCI se creó utilizando Processing [40], por lo que haciendo uso de dicho software fue incorporada a la GUI una interfaz que ha sido desarrollada de forma específica para generar una serie de estímulos visuales monótonos. El diseño de la interfaz corresponde a una matriz similar a un tablero de ajedrez, 3 filas y 3 columnas, en el que se muestran 5 imágenes asociadas a movimientos de la extremidad superior, como se muestra en la figura 3.3a y fueron etiquetados con un valor representativo como se muestra en la figura 3.3b.



(a) De izquierda a derecha y de arriba a abajo: Adducción, Flexión, Prensión, Extensión, Abducción.
 (b) De izquierda a derecha y de arriba a abajo: 1.-Adducción, 2.-Flexión, 3.-Prensión, 4.-Extensión, 5.-Abducción.

Figura 3.3: Diseño de la interfaz que muestra imágenes asociadas a movimientos de la extremidad superior.

3.1.3.1. Eventos de estimulación

Los eventos de estimulación consisten en la intensificación (iluminación) de una fila o columna de la matriz de la interfaz, los cuales fueron etiquetados con un valor representativo, del 1 al 6, para su identificación durante el registro EEG. Los valores representativos se pueden observar en la figura 3.4.




Figura 3.4: Valor representativo de filas y columnas de la interfaz.

El evento de estimulación tuvo una duración de 62.5 *mseg.* y entre cada uno de ellos hubo una pausa inter-estímulo de 125 *mseg.* Cada imagen asociada a los movimientos de la extremidad superior de la interfaz (ver Figura 3.3b) se denominó como *objetivo*. Durante el evento de estimulación cada *objetivo* estuvo asociado a un proceso de intensificación (iluminación) por una fila o una columna, como se puede observar en la Figura 3.4a y la Figura 3.4b, por lo que en la Tabla 3.2 se detallan la relación de las filas o columnas intensificadas por cada *objetivo* en el proceso de estimulación.

Objetivo	Fila intensificada	Columna intensificada
1	1	4
2	1	6
3	2	5
4	3	4
5	3	6

Cuadro 3.2: Filas o columnas intensificadas en cada objetivo durante el proceso de estimulación.

La figura ilustra el diseño considerado para la sincronización de los procesos durante la estimulación visual.




Figura 3.5: Sincronización de procesos durante la estimulación visual.

Los eventos de estimulación se muestran en la figura 3.6.




Figura 3.6: Intensificación (iluminación) de filas o columnas de la matriz de la interfaz consideradas en los eventos de estimulación.

3.1.3.2. Registro dirigido

En cada sesión de registro le fué indicado a los sujetos lo siguiente:

1. Observar la interfaz visual que muestra las imágenes asociadas a los movimientos de la extremidad superior.
2. Centrar su mirada en el objetivo específico que sea indicado en la sesión de registro.
3. Mantener concentración en el objetivo hasta que finalice el proceso de registro.

En cada sesión de registro solo fué considerado un solo objetivo, por lo que cada sujeto participó en 5 sesiones de registro dirigido. El registro dirigido fue considerado como proceso de calibración, lo que permitió identificar épocas EEG con una alta posibilidad de presencia del P300. La Tabla 3.3 detalla los datos correspondientes a las sesiones de registro dirigido.

Sesiones de registro dirigido		
Sujeto	Sesión	Objetivo
S1	sesión 1	1
	sesión 2	2
	sesión 3	3
	sesión 4	4
	sesión 5	5
S2	sesión 1	1
	sesión 2	2
	sesión 3	3
	sesión 4	4
	sesión 5	5
S3	sesión 1	1
	sesión 2	2
	sesión 3	3
	sesión 4	4
	sesión 5	5

Cuadro 3.3: Sesiones de registro dirigido por cada sujeto.

3.2. Pre-procesamiento

La mayoría de las señales biomédicas aparecen como señales débiles en un ambiente que está lleno con muchas otras señales de diversos orígenes. Cualquier señal que no sea de interés podría ser denominada como una interferencia, artefacto o simplemente ruido. En esta etapa fue considerada la segmentación de señales en épocas EEG, el filtrado y eliminación de artefactos de las épocas EEG, así como su normalización.

Durante el registro de las señales fueron etiquetados los eventos de estimulación (ver

3.1.3.1), por lo que para la etapa de pre-procesamiento dentro del conjunto de datos fueron identificados los registros que correspondían al instante en que se generaba el evento de estimulación. La figura 3.7 ilustra las señales del registro EEG y las señales que representan los eventos de estimulación que fueron generados durante el registro.






Figura 3.7: Registro de señales. Los canales corresponden a las posiciones Fz, Cz, Pz y Oz del Sistema Internacional 10-20. El último registro representa el instante en que se genera el evento de estimulación.

3.2.1. Segmentación


De forma general, la segmentación de señales consiste en dividir la señal en segmentos que sean estacionarios (momentos de la señal que se mantienen a lo largo del tiempo de forma idéntica), es por ello que, para las etapas posteriores fueron considerados segmentos de señales EEG que inician en el instante de la estimulación visual y tienen una ventana de 1005 *mseg.* (201 muestras) posteriores al inicio del estímulo, lo cual fue considerado como una *época EEG* con posible presencia del P300. La figura 3.8 ilustra el conjunto registro de señales EEG y tres épocas de las señales EEG.



(a) Época EEG, considera una ventana de 1005 ms a partir del inicio de estímulo visual n .



(b) Época EEG, considera una ventana de 1005 ms a partir del inicio de estímulo visual $n + 1$.




(c) Época EEG, considera una ventana de 1005 ms a partir del inicio de estímulo visual $n + 2$.

Figura 3.8: Épocas EEG, hacen referencia a las ventanas de 1005 ms de señales EEG que se registran desde el inicio de un evento de estimulación visual.


3.2.2. Filtrado

Las señales de origen fisiológico son, en su gran mayoría, de naturaleza analógica, es decir, están definidas en todo momento de tiempo y su valor de amplitud es continuo en su rango dinámico. Debido a que las señales EEG contienen distintas frecuencias, con ayuda del método de Welch, es posible visualizarlas dichas frecuencias mediante una división traslapada, con el objetivo de reducir la varianza y posterior aplicación de la transformada discreta de Fourier, por lo que se procesan las épocas en el dominio de la frecuencia; con ello es posible, conocer la Densidad de Potencia Espectral (o spectrum) (*PSD, Power Spectral Density*) y conocer la distribución de la potencia de la señal en función de la frecuencia.


Considerando lo anterior, y haciendo uso de las herramientas de Python, fue analizada la Densidad Potencia Espectral de las épocas EEG, con el fin de identificar la variación de energía que hay dentro de las épocas EEG en función de la frecuencia toda vez que la mayor cantidad de energía se debería encontrar en bajas frecuencias (menor a 30 Hz). La figura 3.9 ilustra el PSD de una época EEG para los cuatro canales Fz, Cz, Pz y Oz del Sistema Internacional 10-20.




(a) PSD del canal Fz



(b) PSD del canal Cz




(c) PSD del canal Pz




(d) PSD del canal Oz

Figura 3.9: PSD de los registros de las señales de los canales Fz, Cz, Pz, Oz que corresponden al Sistema Internacional 10-20.


Una vez que fueron identificadas las frecuencias principales y haciendo uso de las herramientas de Python, fueron filtrados los componentes de las épocas EEG a través de la transformada discreta de Fourier (*DFT, Discrete Fourier Transform*). Derivado del análisis realizado a través del PSD fue identificado que los componentes principales de las épocas EEG para determinar la presencia del P300 se encuentra entre 1 Hz y 25 Hz, por lo que fueron definidos filtros que eliminaban los componentes no requeridos para la clasificación. En la figura 3.10 se ilustra los componentes de frecuencia filtrados.




(a) Filtro de los componentes de la transformada discreta de Fourier de una época EEG del canal Fz.



(b) Filtro de los componentes de la transformada discreta de Fourier de una época EEG del canal Cz.



(c) Filtro de los componentes de la transformada discreta de Fourier de una época EEG del canal Pz.



(d) Filtro de los componentes de la transformada discreta de Fourier de una época EEG del canal Oz.

Figura 3.10: Filtro de los componentes de la transformada discreta de Fourier de una época EEG.

Se obtuvo la inversa de la transformada discreta de Fourier de la época EEG filtrada, para ser utilizada en las etapas posteriores. Las figuras 3.11a y 3.11b ilustran los registros de señales originales y lo registros de las señales filtradas.





Figura 3.11: Señales originales y filtradas de los canales Fz, Cz, Pz y Oz de una época EEG.

Finalmente la época EEG es normalizada entre 0 y 1 para que pueda ser utilizada en la clasificación.




Figura 3.12: Señales filtradas y normalizadas de los canales Fz, Cz, Pz y Oz de una época EEG.

3.3. Extracción de Características

La etapa de extracción de características sirve para transformar señales EEG en una representación que facilita la clasificación. Fue considerada esta etapa porque la salida corresponde a la entrada del clasificador, de tal forma que la sencillez permite disponer de un buen funcionamiento en etapas posteriores.

Las épocas EEG se dividen en dos conjuntos distintos, el primero corresponde al conjunto de épocas que son P300 y el segundo conjunto de épocas que no son P300. Cada conjunto se integra por dos grupos, filas y columnas, por lo que cada grupo se concatena y se denomina vector de características, lo cual permitió realizar el entrenamiento del clasificador. La figura 3.13 ilustra el proceso general.



Figura 3.13: Pre-procesamiento y extracción de características. De la señal cruda EEG se extraen las épocas EEG de 1005 *mseg.* de duración post-estímulo. Se filtran los componentes de frecuencia de la señal cruda EEG de cada canal, en cada registro del registro dirigido. Las señales filtradas se reparten en 4 grupos: épocas P300 de filas o de columnas, y épocas que no son P300 de filas o de columnas. Se genera un vector de características por cada grupo.

La figura 3.14 ilustra un vector de épocas que son P300.




Figura 3.14: Vector de las épocas de los canales Fz, Cz, Pz y Oz que son P300.

3.4. Clasificación

La clasificación se realiza a través de una red neuronal convolucional (CNN). La figura 3.15 ilustra las etapas generales de la clasificación.




Figura 3.15: Etapas generales consideradas en el proceso de clasificación.

La CNN utilizada corresponde a SepConv1D [10] y es una arquitectura que consta de dos capas. Las entradas corresponden a los vectores característicos de las épocas filtradas y normalizadas por canal, para este caso, Fz, Cz, Pz y Oz. En la primera capa, se aplica por canal de entrada una convolución 1D separable en profundidad a lo largo del tiempo, considerando un núcleo (kernel) con tamaño de 16. Dado que esta operación se ejecuta en todos los electrodos simultáneamente, esta capa aprende características del dominio temporal. Se utiliza un paso o zancada (stride) de 8 para la operación de la convolución y una tangete hiperólica como función de activación. Conforme a lo especificado en [10], fueron utilizados 32 filtros en la capa convolucional; finalmente la clasificación la realiza una neurona con una función de activación sigmoidea, a partir de la salida aplanada (flattened) de la capa convolucional. La figura 3.16 muestra un esquema de la arquitectura general de la CNN.




Figura 3.16: Esquema general de la arquitectura SepConv1D.

3.4.1. Precisión

La precisión de la clasificación se calcula a través del área bajo la curva (*AUC*, por sus siglas en inglés) de la curva ROC (*Receiver Operating Characteristic*), esto es posible ya que la curva ROC permite identificar la sensibilidad y especificidad de cada uno de los posibles puntos de corte de una prueba cuya escala de medición es continua, y se utiliza el AUC como métrica, la cual puede interpretarse como la probabilidad de que el modelo haga una predicción más alta para un ejemplo positivo que para un ejemplo negativo, por lo que, mientras más cercano a 1 sea el AUC es mejor (ver sección 2.8).

3.5. Control

Por último, la etapa de control corresponde con la que directamente interactúa con la neuroprótesis desarrollada por el personal del Instituto Nacional de Rehabilitación. Una vez que han sido detectadas las características y se han clasificado (o traducido) éstas en señales de control, fueron enviadas por puerto USB una secuencia de bits asociada a cada movimiento de la extremidad superior.

CAPÍTULO 4

Resultados

En el presente trabajo se busca identificar la presencia del P300 en épocas EGG a través de un sistema, por lo que con base en la evidencia presentada en este Capítulo puede considerarse posible el control de dispositivos externos, como son las neuroprótesis, de acuerdo a la metodología desarrollada.

4.1. Conjunto de datos

Para generar el paradigma del evento raro, las filas y columnas de la matriz destellaban durante 62.5 *mseg.* cada 125 *mseg.* Se realizó el registro de 5 sesiones de 3 sujetos durante 5 minutos. En cada sesión de registro se pidió a cada sujeto fijar su atención en cada uno de

los 5 objetivos (registro dirigido) de la interfaz gráfica que fue desarrollada (ver la Figura 3.3 y Figura 3.6). La Tabla 4.1 detalla la cantidad de estímulos que fueron generados durante la sesión de registro por cada sujeto.

Cantidad de estímulos generados					
Sujeto	Sesión	Objetivo	Total	Total al azar	Total en el objetivo
S1	sesión 1	1	4598	3082	1516
	sesión 2	2	3543	2388	1155
	sesión 3	3	3552	2409	1143
	sesión 4	4	3516	2427	1089
	sesión 5	5	3531	2406	1125
S2	sesión 1	1	4566	3066	1500
	sesión 2	2	3511	2372	1139
	sesión 3	3	3520	2393	1127
	sesión 4	4	3484	2411	1073
	sesión 5	5	3499	2390	1109
S3	sesión 1	1	4582	3074	1508
	sesión 2	2	3527	2380	1147
	sesión 3	3	3536	2401	1135
	sesión 4	4	3500	2419	1081
	sesión 5	5	3515	2398	1117

Cuadro 4.1: Total de estímulos generados en las sesiones de registro dirigido por cada sujeto.

De acuerdo a la información del registro, se cuenta con dos conjuntos de épocas EEG, el primer conjunto considera los grupos de filas o columnas de épocas con presencia de P300 y el segundo conjunto, los grupos de filas o columnas de épocas sin presencia de P300. Debido a que el registro de las épocas fue dirigido, se consideró que las filas o columnas que coincidieron con el objetivo definido pertenecían a una época con presencia de P300, y que las filas o columnas que no coincidieron con el objetivo correspondían a una época sin presencia de P300. La tabla 4.2 detalla la cantidad de estímulos generados por filas y columnas; fueron marcadas las casillas que corresponden a la fila o columna asociada a la estimulación visual y que corresponden al Objetivo del registro dirigido.

			Filas			Columnas		
Sujeto	Sesión	Objetivo	1	2	3	4	5	6
S1	sesión 1	1	774	768	780	742	790	744
	sesión 2	2	507	585	585	543	675	648
	sesión 3	3	576	597	603	612	546	618
	sesión 4	4	693	588	546	543	546	600
	sesión 5	5	603	546	603	612	645	522
S2	sesión 1	1	770	764	776	730	786	740
	sesión 2	2	498	581	581	539	671	641
	sesión 3	3	572	590	599	608	537	614
	sesión 4	4	689	584	538	535	542	596
	sesión 5	5	599	542	596	608	641	513
S3	sesión 1	1	774	766	778	734	788	742
	sesión 2	2	502	583	583	541	673	645
	sesión 3	3	574	594	601	610	541	616
	sesión 4	4	691	586	542	539	544	598
	sesión 5	5	601	544	600	610	643	517

Cuadro 4.2: Total de estímulos generados por filas y columnas en las sesiones de registro dirigido por cada sujeto .

La identificación de filas y columnas asociadas a las épocas con presencia de P300 permitió generar los vectores caraterísticos que sirvieron como entradas para la red neuronal convolucional.

4.2. Detección P300

Para realizar la detección del P300, fue configurada la arquitectura SepConv1D[10] con cuatro filtros y señales EEG de cuatro canales y 201 muestras (época) filtradas y normalizadas como entrada. La configuración corresponde a lo que se especifica en la Tabla 4.3.

Arquitectura para detección del P300						
Capa	No. filtros	Tamaño	No. parámetros	Salida	Función de activación	opciones
Input	4	201 x 4	224	(209,4)	tanh	padding=4
ZeroPadding1D		kernel = 16, stride = 8		(25,32)		
SeparableConv1D				(25,32)		
Activation	1		801	(800)	Sigmoide	
Flatten				(1)		
Dense						

Cuadro 4.3: Arquitectura SepConv1D para detección del P300.

Con el fin de identificar la precisión de la clasificación se realizaron las pruebas de acuerdo a dos tipos de evaluaciones:

- intra-sujeto, que corresponde al cálculo de la precisión en la clasificación que considera como entradas de la CNN las épocas con presencia P300 derivadas de las sesiones registro dirigido por sujeto, excluyendo dentro del conjunto de entrenamiento, las sesiones de registro dirigido que puedan ser de otro sujeto, por ejemplo, para el caso del S1, solo considera la evaluación de una de sus sesiones de registro sin considerar dentro del conjunto de entrenamiento, las sesiones de registro dirigido del S2 y del S3.
- entre-sujetos, que corresponde al cálculo de la precisión de la clasificación considerando como entradas de la CNN las épocas con presencia P300 derivadas de las sesiones registro dirigido de cualquier sujeto, es decir, que no se consideran criterios de exclusión, por ejemplo, para el caso del S1, la evaluación de sus sesiones de registro podrían realizarse con respecto a cualquier otra sesión de registro de los sujetos S2 o S3 que forman parte del conjunto de entrenamiento.

La evaluación intra-sujeto, podría ser considerado como un proceso de calibración para el entrenamiento de la CNN.

4.2.1. Detección P300 intra-sujetos

Los datos de las épocas fueron evaluadas por la arquitectura SepConv1D de forma intra-sujeto, esto es, considerando solo los datos de cada sujeto derivados en su sesiones de registro dirigido. Se obtuvo la relación AUC con respecto a ROC, con el fin de identificar si los datos se encuentran clasificados correctamente; así mismo, fue calculada el AUC media y desviación estándar de los valores obtenidos.

La tabla 4.4 detalla los valores que fueron obtenidos considerando solo como entradas las épocas EEG de la estimulación que corresponden a las filas.

Valores AUC considerando filas				
Sujeto	Sesión	AUC	AUC media	Desviación estándar
S1	sesión 1 (sn1)	0.8519	0.8294	± 0.0163
	sesión 2 (sn2)	0.8255		
	sesión 3 (sn3)	0.8339		
	sesión 4 (sn4)	0.8015		
	sesión 5 (sn5)	0.8342		
S2	sesión 1 (sn6)	0.8410	0.8359	± 0.0133
	sesión 2 (sn7)	0.8420		
	sesión 3 (sn6)	0.8365		
	sesión 4 (sn9)	0.8105		
	sesión 5 (sn10)	0.8495		
S3	sesión 1 (sn11)	0.8425	0.8343	± 0.0172
	sesión 2 (sn12)	0.8077		
	sesión 3 (sn13)	0.8457		
	sesión 4 (sn14)	0.8212		
	sesión 5 (sn15)	0.8545		

Cuadro 4.4: Relación AUC con respecto a ROC, AUC media y desviación estándar de las evaluaciones intra-sujeto considerando solamente la estimulación de las filas.

La tabla 4.5 detalla los valores que fueron obtenidos considerando solo como entradas las épocas EEG de la estimulación que corresponden a las columnas.

Valores AUC considerando filas				
Sujeto	Sesión	AUC	AUC media	Desviación estándar
S1	sesión 1 (sn1)	0.8023	0.8254	± 0.0169
	sesión 2 (sn2)	0.8321		
	sesión 3 (sn3)	0.8239		
	sesión 4 (sn4)	0.8531		
	sesión 5 (sn5)	0.8159		
S2	sesión 1 (sn6)	0.8542	0.8311	± 0.0202
	sesión 2 (sn7)	0.8311		
	sesión 3 (sn6)	0.7999		
	sesión 4 (sn9)	0.8514		
	sesión 5 (sn10)	0.8194		
S3	sesión 1 (sn11)	0.8257	0.8300	± 0.0101
	sesión 2 (sn12)	0.8339		
	sesión 3 (sn13)	0.8309		
	sesión 4 (sn14)	0.8143		
	sesión 5 (sn15)	0.8452		

Cuadro 4.5: Relación AUC con respecto a ROC, AUC media y desviación estándar de las evaluaciones intra-sujeto considerando solamente la estimulación de las columnas.

La tabla 4.6 detalla los valores que fueron obtenidos considerando como entradas las épocas EEG de la estimulación que corresponden a las filas y columnas.

Valores AUC considerando filas y columnas				
Sujeto	Sesión	AUC	AUC media	Desviación estándar
S1	sesión 1 (sn1)	0.8435	0.8160	± 0.0224
	sesión 2 (sn2)	0.8357		
	sesión 3 (sn3)	0.7948		
	sesión 4 (sn4)	0.7859		
	sesión 5 (sn5)	0.8203		
S2	sesión 1 (sn6)	0.8499	0.8339	± 0.0175
	sesión 2 (sn7)	0.8191		
	sesión 3 (sn6)	0.8456		
	sesión 4 (sn9)	0.8069		
	sesión 5 (sn10)	0.8483		
S3	sesión 1 (sn11)	0.7859	0.8092	± 0.0231
	sesión 2 (sn12)	0.8015		
	sesión 3 (sn13)	0.8457		
	sesión 4 (sn14)	0.8255		
	sesión 5 (sn15)	0.7875		

Cuadro 4.6: Relación AUC con respecto a ROC, AUC media y desviación estándar de las evaluaciones intra-sujeto considerando la estimulación de las filas y columnas

Como puede ser apreciado, se cuenta con niveles aceptables en la precisión de la clasificación.

4.2.2. Detección P300 entre-sujetos

Utilizando la configuración de la arquitectura SepConv1D definida en la Tabla 4.3, fueron evaluadas épocas entre-sujetos, es decir, considerando los datos de las sesiones de registro dirigido de un sujeto y se compara con las sesiones de registro dirigido de otro sujeto distinto, con el fin de identificar si es posible considerar una base de registro de datos para detectar el P300 sin necesidad de realizar un proceso de calibración.

La tabla 4.7 detalla los valores que fueron obtenidos considerando solo como entradas las épocas EEG de la estimulación que corresponden a las filas.

AUC de la evaluación de épocas entre sujetos considerando filas			
Grupo de entrenamiento	Época considerada válida	Época evaluada	AUC
sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn7	sn1	0.7112
sn1, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn3	sn2	0.8455
sn1, sn2, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn7	sn3	0.6618
sn1, sn2, sn3, sn5, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn6	sn4	0.6549
sn1, sn2, sn3, sn4, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14	sn15	sn5	0.7268
sn1, sn2, sn3, sn4, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn5	sn6	0.8415
sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn1	sn7	0.7310
sn2, sn3, sn4, sn5, sn6, sn7, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn1	sn8	0.7648
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn10, sn11, sn12, sn13, sn14	sn15	sn9	0.8105

Continúa de tabla 4.7			
Grupo de entrenamiento	Época considerada válida	Época evaluada	AUC
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn11, sn12, sn13, sn15	sn14	sn10	0.7541
sn1, sn2, sn3, sn4, sn5, sn7, sn8, sn9, sn10, sn12, sn13, sn14, sn15	sn6	sn11	0.7241
sn1, sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn13, sn14, sn15	sn7	sn12	0.6632
sn1, sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn14, sn15	sn7	sn13	0.6989
sn1, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn15	sn2	sn14	0.6971
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn14	sn13	sn15	0.7159

Cuadro 4.7: Relación AUC con respecto a ROC de las evaluaciones entre-sujetos considerando solamente la estimulación de las filas.

La tabla 4.8 detalla los valores que fueron obtenidos considerando solo como entradas las épocas EEG de la estimulación que corresponden a las columnas.

AUC de la evaluación de épocas entre sujetos considerando columnas			
Grupo de entrenamiento	Época considerada válida	Época evaluada	AUC
sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn7	sn1	0.6582
sn1, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn3	sn2	0.8507
sn1, sn2, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn7	sn3	0.7157
sn1, sn2, sn3, sn5, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn6	sn4	0.8424
sn1, sn2, sn3, sn4, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14	sn15	sn5	0.6993
sn1, sn2, sn3, sn4, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn5	sn6	0.7646
sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn1	sn7	0.6449
sn2, sn3, sn4, sn5, sn6, sn7, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn1	sn8	0.8217
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn10, sn11, sn12, sn13, sn14	sn15	sn9	0.7249

Continúa de tabla 4.8			
Grupo de entrenamiento	Época considerada válida	Época evaluada	AUC
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn11, sn12, sn13, sn15	sn14	sn10	0.6797
sn1, sn2, sn3, sn4, sn5, sn7, sn8, sn9, sn10, sn12, sn13, sn14, sn15	sn6	sn11	0.7031
sn1, sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn13, sn14, sn15	sn7	sn12	0.6599
sn1, sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn14, sn15	sn7	sn13	0.6921
sn1, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn15	sn2	sn14	0.7469
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn14	sn13	sn15	0.7268

Cuadro 4.8: Relación AUC con respecto a ROC de las evaluaciones entre-sujetos considerando solamente la estimulación de las columnas.

La tabla 4.9 detalla los valores que fueron obtenidos considerando como entradas las épocas EEG de la estimulación que corresponden a las filas y columnas.

AUC de la evaluación de épocas entre sujetos considerando filas y columnas			
Grupo de entrenamiento	Época considerada válida	Época evaluada	AUC
sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn7	sn1	0.6449
sn1, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn3	sn2	0.8850
sn1, sn2, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn7	sn3	0.6200
sn1, sn2, sn3, sn5, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn6	sn4	0.6924
sn1, sn2, sn3, sn4, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14	sn15	sn5	0.7900
sn1, sn2, sn3, sn4, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn5	sn6	0.6750
sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn1	sn7	0.4550
sn2, sn3, sn4, sn5, sn6, sn7, sn9, sn10, sn11, sn12, sn13, sn14, sn15	sn1	sn8	0.6850
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn10, sn11, sn12, sn13, sn14	sn15	sn9	0.6000

Continúa de tabla 4.9			
Grupo de entrenamiento	Época considerada válida	Época evaluada	AUC
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn11, sn12, sn13, sn15	sn14	sn10	0.6749
sn1, sn2, sn3, sn4, sn5, sn7, sn8, sn9, sn10, sn12, sn13, sn14, sn15	sn6	sn11	0.6900
sn1, sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn13, sn14, sn15	sn7	sn12	0.8950
sn1, sn2, sn3, sn4, sn5, sn6, sn8, sn9, sn10, sn11, sn12, sn14, sn15	sn7	sn13	0.6400
sn1, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn13, sn15	sn2	sn14	0.7875
sn1, sn2, sn3, sn4, sn5, sn6, sn7, sn8, sn9, sn10, sn11, sn12, sn14	sn13	sn15	0.7400

Cuadro 4.9: Relación AUC con respecto a ROC de las evaluaciones entre-sujetos considerando la estimulación de las filas y columnas.

Asimismo, fue calculada el AUC media y desviación estándar de los valores obtenidos en tabla 4.9, los cuales se detallan en la tabla 4.10.

AUC de la evaluación de épocas entre sujetos		
Estimulación	AUC media	Desviación estándar
filas	0.7334	± 0.0584
columnas	0.7287	± 0.0633
filas y columnas	0.6983	± 0.1077

Cuadro 4.10: AUC media y desviación estándar de las evaluaciones entre-sujetos.

De acuerdo a lo anterior, se puede observar que se obtienen valores altos de la AUC media en la evaluación entre intra-sujeto, lo que indica que se tiene un porcentaje de precisión aceptable en la detección de P300. Por otro lado, el valor de la AUC media derivada de la evaluación entre-sujetos aunque no es tan alto, puede ser considerado para la detección de P300.

4.3. Control

Una vez que fue identificada la presencia del P300 en épocas EEG, fue desarrollado en Python un componente que sirve para el envío de datos a través del puerto serial. Fue definida una estructura de 4 Bits, en la que a cada objetivo de la interfaz gráfica (ver la Figura 3.3) le fue definido una secuencia de Bits. La Tabla 4.11 muestra las secuencias de bits generados a partir de la detección P300 para cada objetivo.

Secuencias de control	
Objetivo	Secuencia
objetivo 1	001
objetivo 2	010
objetivo 3	011
objetivo 4	100
objetivo 5	101

Cuadro 4.11: Secuencias de control asociadas a cada objetivo de la interfaz.

Discusión

Con respecto a la etapa de adquisición de señales, puede estandarizarse el proceso de calibración, con el fin de que el cantidad de estímulos generados al azar sea similar en todas las sesiones de registro, sin embargo, esto no garantizará que puedan ser generadas las mismas cantidades de estímulos en el objetivo; por lo que, otra posibilidad radica en controlar la cantidad de estímulos que deben ser generados sobre el objetivo, sin embargo, se trandrá que analizar si ello tiene impacto en el paradigma del evento raro.

Debido a que los componentes de frecuencia que fueron útiles para determinar la presencia del P300, conviene realizar un estudio particular comparando distintos registros EEG, con el fin de determinar si las frecuencias utilizadas pueden considerarse como referencia para otros casos de estudio.

Conclusiones

Se lograron los objetivos definidos.

- **Objetivo general:**

Se desarrolló un sistema que identifica la presencia del P300, lo que permite general secuencias de control que pueden ser enviadas a dispositivos externos, como son las neuroprótesis, para su control.

- **Objetivos específicos:**

Fue desarrollada una interfaz gráfica que genera estímulos visuales, la cual se sincroniza con las herramientas de registro de señales EEG.

A través del análisis de las señales en el dominio de la frecuencia fueron caracterizadas las señales EEG para eliminar artefactos no deseados y tener un nivel aceptable de clasificación a través de una red neuronal convolucional.

A través de la identificación del P300, fueron generadas secuencias de control para el control de dispositivos externos, como son las las neuroprótesis.

Fue identificado que para contar con una clasificación adecuada de registros EEG existen dos factores, el primero corresponde a la cantidad de datos EEG que son registrados y el segundo, el dispositivo a través del cual se realiza el registro, sin embargo, ambos factores no imposibilitan que la tecnología pueda ser utilizada en beneficio de la población que padece algún tipo de discapacidad o no pueden controlar sus propios músculos mediante vías neuronales.

Por otra parte, por asuntos no controlados en el desarrollo del presente trabajo, no se pudo realizar experimentación dentro del Instituto Nacional de Rehabilitación, lo que hubiera ayudado para incrementar la muestra poblacional que fue considerada en el registro de señales EEG.

Finalmente, se sugiere continuar experimentando con las diferentes herramientas de Inteligencia Artificial asociadas a la clasificación de señales EEG, con el fin de que se pueda disponerse de un mecanismo que no requiera un proceso de calibración, lo que podría ayudar a personas con lesiones cerebrales severas.

Bibliografía

- [1] Organización Mundial de la Salud and Banco Mundial, “Informe mundial sobre la discapacidad,” 2011.
- [2] Instituto Nacional de Estadística y Geografía, “Encuesta nacional de la dinámica demográfica,” 2018.
- [3] J. Mercado, “Implementación de una nueva estrategia de identificación del potencial p300 para interfaces cerebro-computadora utilizando información espectral del eeg,” Master’s thesis, Universidad Autónoma Metropolitana Iztapalapa, 8 2016.
- [4] L. Farwell and E. Donchin, “Talking off the top of your head: toward a mental prosthesis utilizing event-related brain potentials,” *Electroencephalography and Clinical Neurophysiology*, vol. 70, pp. 510–523, dec 1988.
- [5] S. Kundu and S. Ari, “A deep learning architecture for p300 detection with brain-

- computer interface application,” *IRBM*, vol. 41, no. 1, pp. 31 – 38, 2020.
- [6] A. Craik, Y. He, and J. Contreras-Vidal, “Deep learning for electroencephalogram (eeg) classification tasks: A review,” *Journal of Neural Engineering*, vol. 16, 02 2019.
- [7] L. Vařeka, T. Prokop, R. Mouček, P. Mautner, and J. Štěbeták, “Application of stacked autoencoders to p300 experimental data,” *Springer International Publishing*, pp. 187–198, 2017.
- [8] L. Vařeka and P. Mautner, “Stacked autoencoders for the p300 component detection,” *Frontiers in neuroscience*, p. 302, 2017.
- [9] J. P. Kulasingham, V. Vibujithan, and A. C. De Silva, “Deep belief networks and stacked autoencoders for the P300 Guilty Knowledge Test,” in *IECBES 2016 - IEEE-EMBS Conference on Biomedical Engineering and Sciences*, pp. 127–132, 2016.
- [10] M. Alvarado-González, G. Fuentes-Pineda, and J. Cervantes-Ojeda, “A few filters are enough: Convolutional Neural Network for P300 Detection,” 2020.
- [11] H. Cecotti and A. Gräser, “Convolutional neural networks for P300 detection with application to brain-computer interfaces,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 33, no. 3, pp. 433–445, 2011.
- [12] R. Manor and A. B. Geva, “Convolutional neural network for multi-category rapid serial visual presentation BCI,” *Frontiers in Computational Neuroscience*, vol. 9, p. 146, dec 2015.
- [13] R. T. Schirrmeister, J. T. Springenberg, L. D. J. Fiederer, M. Glasstetter, K. Eggensperger, M. Tangermann, F. Hutter, W. Burgard, and T. Ball, “Deep learning with convolutional neural networks for EEG decoding and visualization,” *Human Brain Mapping*, vol. 38, pp. 5391–5420, nov 2017.
- [14] M. Liu, W. Wu, Z. Gu, Z. Yu, F. F. Qi, and Y. Li, “Deep learning based on Batch

- Normalization for P300 signal detection,” *Neurocomputing*, vol. 275, pp. 288–297, jan 2018.
- [15] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. J. Lance, “EEGNet: A Compact Convolutional Network for EEG-based Brain-Computer Interfaces,” *Journal of Neural Engineering*, vol. 15, nov 2016.
- [16] H. Shan, Y. Liu, and T. Stefanov, “A simple convolutional neural network for accurate P300 detection and character spelling in brain computer interface,” in *IJCAI International Joint Conference on Artificial Intelligence*, vol. 2018-July, pp. 1604–1610, International Joint Conferences on Artificial Intelligence, 2018.
- [17] I. n Santos, R. Romero, and A. Fernández, “Estudio de las ondas cerebrales captadas por una bci asociada a biomecanismos,” Master’s thesis, Instituto Politécnico Nacional Escuela Superior de Cómputo, 12 2017.
- [18] R. K. Murray, D. A. Bender, K. M. Botham, P. J. Kennelly, V. W. Rodwell, and P. A. Weil, *Harper. Bioquímica ilustrada*. Mc Graw Hill, 28a ed., 2010.
- [19] J. E. Hall, *Guyton y Hall. Tratado de fisiología médica*. ELSEVIER, 13a ed., 2016.
- [20] R. S. Snell, *Neuroanatomía clínica*. Wolters Kluwer Health, 7a ed., 2014.
- [21] K. E. Barrett, S. M. Barman, S. Boitano, and H. L. Brooks, *GANONG Fisiología médica*. Mc Graw Hill, 23a ed., 2010.
- [22] N. Kane, J. Acharya, S. Beniczky, L. Caboclo, S. Finnigan, P. W. Kaplan, H. Shibasaki, R. Pressler, and M. J. van Putteng, “A revised glossary of terms most commonly used by clinical electroencephalographers and updated proposal for the report format of the eeg findings. revision 2017,” *Elsevier*, vol. 2, 2017.
- [23] M. Seeck, L. Koessler, T. Bast, F. Leijten, C. Michel, C. Baumgartner, B. He, and S. Beniczky, “The standardized EEG electrode array of the IFCN,” *Clinical Neurophy-*

- siology*, vol. 128, pp. 2070–2077, oct 2017.
- [24] J. T. Martínez, *Electroencefalografía clínica básica*. Viguera Editores, 2005.
- [25] J. D. Kropotov, *Quantitative EEG, Event-Related Potentials and Neurotherapy*. Elsevier, 1a ed., 2009.
- [26] S. Tong and N. V. T. eds., *Quantitative EEG analysis methods and clinical applications*. Engineering in Medicine and Biology, Artech House, 2009.
- [27] J. Polich, “Updating P300: An integrative theory of P3a and P3b,” oct 2007.
- [28] W. Ertel, *Introduction to Artificial Intelligence*. Springer, 2a ed., 2017.
- [29] S. Russell and P. Norving, *Artificial Intelligence A Modern Approach*. Pearson Prentice Hall, 3a ed., 2016.
- [30] M. Chowdhury, A. Apon, and K. Deyl, *Data Analytics for Intelligent Transportation Systems*. Elsevier, 2017.
- [31] D. D. Luxton, *Artificial Intelligence in Behavioral and Mental Health Care*. Elsevier, 2016.
- [32] C. C. Aggarwal, *Neural Networks and Deep Learning*. Springer, 2018.
- [33] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [34] J. G. Proakis and D. G. Manolakis, *Tratamiento digital de señales*. Pearson Prentice Hall, 4a ed., 2007.
- [35] “Openbci eeg headband kit (2020).” <https://shop.openbci.com/products/openbci-eeg-headband-kit?variant=8120393760782>, [Online; accessed December 30, 2020].

- [36] “Openbci ganglion biosensing board (2020).” <https://shop.openbci.com/products/ganglion-board?variant=13461804483>, [Online; accessed December 30, 2020].
- [37] “Openbci gui(2020).” <https://docs.openbci.com/docs/06Software/01-OpenBCISoftware/GUIDocs>, [Online; accessed December 30, 2020].
- [38] “Openbci usb dongle(2020).” <https://shop.openbci.com/products/ganglion-dongle?variant=154733526057>, [Online; accessed December 30, 2020].
- [39] “Eeg openbci (2020).” <https://docs.openbci.com/docs/01GettingStarted/02-Biosensing-Setups/EEGSetup>, [Online; accessed December 30, 2020].
- [40] “Processing (2020).” <https://processing.org/>, [Online; accessed December 30, 2020].