INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SUBDIRECCIÓN ACADÉMICA

No de TT: **2027-A098** *Fecha de presentación:* **30 de octubre de 2026**

Documento técnico

"Desarrollo de un sistema de comunicación asistida basado en señales electroencefalográficas mediante modelos de aprendizaje profundo"

Presentan:

Emiliano Arana Chávez[1]
Alexis Vences Guevara[2]

Directores:

Mtro. René Baltazar Jiménez Ruíz, Dr. José Félix Serrano Talamantes

Resumen – Se propone el desarrollo de un sistema de comunicación asistida mediante señales electroencefalográficas (EEG), empleando el paradigma P300 Speller con una matriz de caracteres que se ilumina sistemáticamente para la clasificación del potencial de eventos P300 mediante modelos de aprendizaje profundo, permitiendo la identificación del carácter objetivo. Está dirigido a personas con compromisos motores severos. Así mismo, se evaluarán estrategias para optimizar la practicidad de la comunicación mediante la reducción del número de canales y repeticiones requeridas, sin comprometer el desempeño del modelo, con el propósito de mejorar la eficiencia en la comunicación de los usuarios.

Palabras clave – Aprendizaje profundo, Arquitecturas neuronales, Procesamiento de señales, Reconocimiento de patrones.

[1] earanac1900@alumno.ipn.mx | [2] avencesg1900@alumno.ipn.mx

Índice

GLOSARIO DE TÉRMINOS VII

1. INTRODUCCIÓN **1**

1.1. OBJETIVOS 1

1.1.1. Objetivo general 1

1.1.2. Objetivos específicos 1

1.2. JUSTIFICACIÓN 2

2. MARCO REFERENCIAL **4**

2.1. DISCAPACIDAD MOTORA SEVERA Y COMUNICACIÓN 4

2.2. ELECTROENCEFALOGRAFÍA 5

2.2.1. Adquisición de la señal 5

2.2.2. Sistema internacional 10-20 5

2.2.3. Artefactos en la señal de EEG 6

2.3. POTENCIALES RELACIONADOS CON EVENTOS Y COMPONENTE P300 6

2.3.1. Potenciales relacionados con eventos 6

2.3.2. Promediado coherente 7

2.3.3. La componente P300 8

2.3.4. Paradigma del evento raro 9

2.4. INTERFACES CEREBRO COMPUTADORA 9

2.4.1. Definición y componentes 9

2.4.2. Paradigmas de control 10

2.5. EL PARADIGMA P300 SPELLER 10

2.5.1. Deletreador de Farwell y Donchin 10

2.5.2. Parámetros de estimulación 11

2.5.3. Épocas de EEG y decodificación del carácter 11

2.5.4. Bases de datos públicas 12

2.6. PROCESAMIENTO DIGITAL DE SEÑALES BIOMÉDICAS 12

2.6.1. Muestreo y teorema de Nyquist 12

2.6.2. Filtros digitales 13

2.6.3. Remuestreo 13

2.6.4. Segmentación en épocas 13

2.6.5. Normalización . . . 14
2.7. APRENDIZAJE AUTOMÁTICO . . . 14
2.7.1. Sobreajuste y generalización . . . 14
2.7.2. Esquemas de validación . . . 14
2.8. REDES NEURONALES ARTIFICIALES Y APRENDIZAJE PROFUNDO . . . 15
2.8.1. La neurona artificial . . . 15
2.8.2. Funciones de activación . . . 15
2.8.3. Función de pérdida . . . 16
2.8.4. Descenso de gradiente y retropropagación . . . 16
2.8.5. Regularización . . . 16
2.9. REDES CONVOLUCIONALES PARA LA DETECCIÓN DE LA P300 . . . 17
2.9.1. Redes neuronales convolucionales . . . 17
2.9.2. Convoluciones separables en profundidad . . . 17
2.9.3. EEGNet . . . 18
2.9.4. Arquitecturas convolucionales para la detección de la P300 . . . 18
2.10. MÉTRICAS DE EVALUACIÓN . . . 19
2.10.1. Matriz de confusión . . . 19
2.10.2. Métricas de clasificación . . . 19
2.10.3. Curva ROC y área bajo la curva . . . 19
2.10.4. Métricas a nivel de sistema . . . 20
2.11. REDUCCIÓN DE CANALES Y REPETICIONES . . . 21
2.11.1. Selección de canales . . . 21
2.11.2. Reducción de repeticiones . . . 21
2.12. MODELADO DEL LENGUAJE Y PREDICCIÓN DE PALABRAS . . . 22
2.12.1. Predicción de palabras en la comunicación asistida . . . 22
2.12.2. Modelos de lenguaje . . . 22
2.12.3. Integración del lenguaje en el P300 Speller . . . 22
2.13. ESTADO DEL ARTE . . . 23
2.13.1. Sistemas P300 Speller y competencias BCI . . . 23
2.13.2. Sistemas de comunicación con usuarios con discapacidad . . . 23
2.13.3. Aprendizaje profundo para la detección de la P300 . . . 23
2.13.4. Resumen comparativo . . . 24

3. PROPUESTA A DESARROLLAR **25**
3.1. ARQUITECTURA DEL SISTEMA . . . 25
3.2. FLUJO DE OPERACIÓN . . . 26
3.3. ALCANCE DEL SISTEMA . . . 27
3.4. METODOLOGÍA . . . 28
3.4.1. Metodología de desarrollo del sistema . . . 28

3.4.2. Metodología para el desarrollo del modelo de aprendizaje profundo . . 31

4. ANÁLISIS Y DISEÑO **34**

4.1. REGLAS DE NEGOCIO 34

4.2. REQUERIMIENTOS 35

4.2.1. Requerimientos funcionales 35

4.2.2. Requerimientos no funcionales 37

4.3. CATÁLOGO DE MENSAJES 38

4.3.1. Mensajes de error 38

4.3.2. Mensajes de confirmación 39

4.3.3. Mensajes informativos 40

4.4. CASOS DE USO 40

4.4.1. Actores 41

4.4.2. Casos de uso de gestión de sesiones 41

4.4.3. Casos de uso de adquisición y calibración 44

4.4.4. Casos de uso del deletreo 48

4.4.5. Casos de uso de predicción de palabras 51

4.4.6. Diagramas de casos de uso 53

4.5. ARQUITECTURA DE SOFTWARE 54

4.6. DIAGRAMA DE CLASES 55

4.7. DIAGRAMA DE OBJETOS 56

4.8. ESTRUCTURA DE ALMACENAMIENTO 57

4.9. DIAGRAMAS DE FLUJO 58

4.9.1. Preprocesamiento de las señales EEG 58

4.9.2. Entrenamiento y evaluación del modelo de detección 60

4.9.3. Decodificación del carácter seleccionado 61

4.10. DIAGRAMA DE ESTADOS 62

4.11. DIAGRAMAS DE SECUENCIA 63

4.11.1. Inicio de sesión 64

4.11.2. Calibración 64

4.11.3. Selección de un carácter 65

4.11.4. Selección de una sugerencia 66

4.12. DISEÑO DEL MÓDULO DE PREDICCIÓN DE PALABRAS 67

4.13. MOCKUPS 69

5. CONCLUSIONES **73**

Índice de figuras

2.1 Posiciones de los electrodos del sistema internacional 10-20 (vista superior). Se resaltan los electrodos de la línea media Fz, Cz, Pz y Oz. Elaboración propia con base en [17]. 6
2.2 Forma de onda ilustrativa de un ERP ante un estímulo objetivo y uno no objetivo, con las latencias de la Tabla 2.2. Elaboración propia con base en [19], [20]. 8
2.3 Secuencia de estímulos en el paradigma del evento raro (*oddball*). Elaboración propia. 9
2.4 Diagrama general de una interfaz cerebro computadora. Elaboración propia con base en [7], [25]. 10
2.5 Matriz de 6×6 caracteres del P300 Speller. Si el usuario atiende a la letra N (recuadro), tanto la intensificación de la fila 3 como la de la columna 2 son eventos objetivo que provocan una P300. Las diez intensificaciones restantes son eventos no objetivo. Elaboración propia con base en [2]. 11
2.6 Respuesta en magnitud de (a) un filtro pasa banda Butterworth de cuarto orden entre 0.1 y 20 Hz y (b) un filtro *notch* en 60 Hz, para $f_s = 240$ Hz. Elaboración propia. 13
2.7 Curvas de pérdida de entrenamiento y validación: a partir de cierto punto el modelo comienza a sobreajustarse. Elaboración propia. 15
2.8 Arquitectura general de EEGNet. Elaboración propia con base en [37]. 18
2.9 Matriz de confusión para la clasificación binaria de épocas. Elaboración propia. 19

3.1 Arquitectura del sistema. Elaboración propia. 26
3.2 Flujo de operación para la selección de un carácter o de una palabra sugerida. Elaboración propia. 27
3.3 Organización del desarrollo del sistema mediante el modelo incremental. Elaboración propia con base en [58]. 31
3.4 Fases de la metodología CRISP-ML aplicadas al desarrollo del modelo de detección de la componente P300. Elaboración propia con base en [57]. 33

4.1 Diagrama de casos de uso del sistema. Elaboración propia. 54
4.2 Arquitectura de software del sistema. Elaboración propia. 55

4.3 Diagrama de clases del sistema. Elaboración propia. 56
4.4 Diagrama de objetos durante la selección de un carácter. Elaboración propia. . . 57
4.5 Modelo relacional de la base de datos del sistema. Elaboración propia. 58
4.6 Estructura de carpetas del sistema. Elaboración propia. 58
4.7 Diagrama de flujo del preprocesamiento de las señales EEG. Elaboración propia. 59
4.8 Diagrama de flujo del entrenamiento y evaluación del modelo de detección. Elaboración propia. 61
4.9 Diagrama de flujo de la decodificación del carácter seleccionado. Elaboración propia. 62
4.10 Diagrama de estados de la sesión del sistema. Elaboración propia. 63
4.11 Diagrama de secuencia del inicio de sesión. Elaboración propia. 64
4.12 Diagrama de secuencia de la calibración. Elaboración propia. 65
4.13 Diagrama de secuencia de la selección de un carácter. Elaboración propia. . . . 66
4.14 Diagrama de secuencia de la selección de una sugerencia. Elaboración propia. . 67
4.15 Diagrama de flujo del módulo de predicción de palabras. Elaboración propia. . 69
4.16 Pantalla de creación de cuenta. Elaboración propia. 70
4.17 Pantalla de inicio de sesión. Elaboración propia. 70
4.18 Pantalla de conexión del casco y verificación de la señal. Elaboración propia. . 71
4.19 Pantalla de calibración y avance del entrenamiento. Elaboración propia. 71
4.20 Pantalla principal del deletreo. Elaboración propia. 72

Índice de tablas

2.1 Artefactos comunes en el registro de EEG 7
2.2 Principales componentes de los ERP en paradigmas visuales 7
2.3 Funciones de activación más utilizadas 16
2.4 Algunas arquitecturas convolucionales para la detección de la P300 y AUC promedio reportada en [34] 18
2.5 Métricas de evaluación para la clasificación binaria 20
2.6 Resumen comparativo del estado del arte 24

4.1 Reglas de negocio del sistema 35
4.2 Mensajes de error 39
4.3 Mensajes de confirmación 40
4.4 Mensajes informativos 40

4.5 Actores del sistema 41
4.6 Caso de uso crear cuenta de usuario 42
4.7 Caso de uso iniciar sesión 43
4.8 Caso de uso cerrar sesión 43
4.9 Caso de uso conectar el casco EEG 44
4.10 Caso de uso verificar la calidad de la señal 45
4.11 Caso de uso realizar la calibración 46
4.12 Caso de uso entrenar y validar el modelo 47
4.13 Caso de uso iniciar el deletreo 48
4.14 Caso de uso presentar los estímulos 49
4.15 Caso de uso decodificar el carácter 50
4.16 Caso de uso actualizar el texto 51
4.17 Caso de uso borrar el último elemento 51
4.18 Caso de uso generar sugerencias 52
4.19 Caso de uso seleccionar una sugerencia 53
4.20 Entradas y salidas del módulo de predicción de palabras 68

Glosario de términos

Ahorro de selecciones. Porcentaje de selecciones que se evitan al escribir un texto con ayuda de la predicción de palabras, respecto a escribirlo carácter por carácter.

Artefacto. Componente del registro de EEG que no proviene de la actividad cerebral, como los parpadeos, la actividad muscular o la interferencia de la red eléctrica.

AUC (área bajo la curva ROC). Métrica que indica la probabilidad de que un clasificador asigne un puntaje mayor a una época con P300 que a una sin ella. Un valor de 0.5 corresponde a un clasificador aleatorio y un valor de 1 a una separación perfecta.

BCI (interfaz cerebro computadora). Sistema de comunicación en el que los mensajes o comandos del usuario se obtienen de su actividad cerebral, sin pasar por los nervios periféricos ni por los músculos.

Calibración. Sesión en la que el usuario fija su atención en caracteres indicados por el sistema mientras se registran sus señales, con las que se entrena su propio modelo de detección.

CNN (red neuronal convolucional). Red neuronal que aplica filtros de pesos aprendibles sobre la entrada para extraer características, adecuada para datos como imágenes o series de tiempo.

EEG (electroencefalograma). Registro de la actividad eléctrica del cerebro tomado por medio de electrodos colocados en la superficie de la cabeza.

EEGNet. Red neuronal convolucional compacta diseñada para clasificar señales de EEG en distintos paradigmas de BCI, entre ellos la P300.

ELA (esclerosis lateral amiotrófica). Enfermedad neurológica que en sus etapas avanzadas puede provocar la pérdida casi total del control muscular voluntario, incluido el del habla.

Época. Segmento de la señal de EEG que inicia en el instante de una intensificación y que constituye la muestra de entrada al clasificador.

ERP (potencial relacionado con eventos). Del inglés *Event-Related Potential*. Variación del voltaje del EEG que aparece ligada en el tiempo a un evento específico, como un estímulo sensorial, una respuesta motora o una operación cognitiva. Se registra como una serie de ondas positivas y negativas llamadas componentes, que se nombran con la letra P o N según su polaridad, seguida de su latencia aproximada en milisegundos. Debido a que su amplitud es mucho menor que la de la actividad de fondo del EEG, para observarlo se suelen promediar varias repeticiones del mismo estímulo. La P300 es la componente de este tipo que aprovecha el presente trabajo.

Exactitud por carácter. Proporción de caracteres que el sistema selecciona correctamente respecto al total de caracteres que el usuario intentó escribir.

Hiperparámetro. Valor que define la configuración de un modelo o de su entrenamiento, como el número de filtros o la tasa de aprendizaje, y que no se aprende a partir de los datos.

Intensificación. Iluminación momentánea de una fila o de una columna de la matriz del P300 Speller.

ISI (intervalo entre estímulos). Tiempo que la matriz permanece sin iluminar entre el fin de una intensificación y el inicio de la siguiente.

ITR (tasa de transferencia de información). Cantidad de información que el usuario transmite por unidad de tiempo, expresada en bits por minuto, que combina la exactitud y la velocidad de las selecciones.

Modelo de lenguaje. Modelo que asigna una probabilidad a cada secuencia de palabras, lo que permite estimar cuáles son las palabras más probables dado lo que se ha escrito.

P300. Componente positiva de los ERP que aparece alrededor de 300 ms después de un estímulo poco frecuente y relevante para la persona.

P300 Speller. Sistema de deletreo en el que las filas y columnas de una matriz de caracteres se iluminan en orden aleatorio, y el carácter que el usuario desea se identifica a partir de la P300 que provoca su fila y su columna.

Paradigma del evento raro (*oddball*). Procedimiento en el que se presenta una secuencia de estímulos de dos categorías, una de ellas poco frecuente, y se pide a la persona atender solo a los estímulos de esa categoría, que son los que provocan la P300.

Repetición. Secuencia en la que cada fila y cada columna de la matriz se intensifican una vez.

Sistema internacional 10-20. Estándar que define la posición de los electrodos de EEG sobre la cabeza a partir de distancias del 10 % y del 20 % entre puntos de referencia anatómicos.

Sobreajuste. Situación en la que un modelo memoriza los datos de entrenamiento y pierde la capacidad de desempeñarse correctamente con datos nuevos.

1. Introducción

En las últimas décadas, las Interfaces Cerebro Computadora (BCI, por sus siglas en inglés) se han convertido en una de las áreas de investigación más relevantes dentro de la biónica y la inteligencia artificial orientada al área de la salud, al permitir entablar comunicación directa entre la actividad cerebral de un individuo y un dispositivo externo sin depender de ninguna señal o movimiento muscular. Como se menciona en el trabajo de Felton et al. [1], las BCI traducen señales cerebrales registradas en acciones en tiempo real, lo cual abre la posibilidad de restaurar funciones comunicativas o motoras en personas con discapacidad severa.

Dentro de los paradigmas más estudiados en BCI basadas en electroencefalografía (EEG) se encuentra el uso de los Potenciales Relacionados con Eventos (ERP), específicamente la componente P300, cuya detección mediante la iluminación intermitente de filas y columnas de una matriz de caracteres dio origen al llamado P300 Speller [2]. A partir de este paradigma se han desarrollado sistemas de comunicación asistida tanto en el ámbito nacional como internacional, y algunos de ellos han logrado exactitudes altas y velocidades útiles para la comunicación. Sin embargo, de estos antecedentes se identifican dos limitaciones persistentes en los sistemas P300 basados en EEG, la necesidad de múltiples canales para mantener niveles altos de exactitud, el alto costo del hardware especializado y el basto tiempo necesario para construir palabras.

De esta manera, el presente Trabajo Terminal se orienta al desarrollo de un sistema de comunicación asistida basado en el paradigma P300 Speller utilizando EEG, integrando modelos de aprendizaje profundo para la detección automática de la componente P300 e incorporando estrategias para reducir el número de canales, y optimizar el tiempo de construcción de palabras con un modelo de predicción.

1.1. Objetivos

1.1.1. Objetivo general

Desarrollar un sistema de comunicación asistida implementado en Python que permita a las personas con problemas motrices severos comunicarse por medio de señales electroencefalográficas usando el paradigma P300 Speller, a través de una interfaz gráfica basada en una matriz de selección visual de caracteres mediante la iluminación intermitente de filas y columnas, clasificando las componentes P300 de las señales cerebrales utilizando un modelo de aprendizaje profundo desarrollado en Python.

1.1.2. Objetivos específicos

1. Analizar bases de datos públicas de señales electroencefalográficas sobre el paradigma P300 Speller y recolectar señales propias de voluntarios, con el fin de identificar las características más importantes para el desempeño del modelo.

2. Revisar el estado del arte para seleccionar y analizar los modelos de aprendizaje profundo más adecuados para la detección de la componente P300 en señales cerebrales.

3. Diseñar e implementar un modelo de aprendizaje profundo para la clasificación de la componente P300 en señales EEG, entrenado de forma individual para cada usuario a partir de una sesión de calibración.

4. Evaluar el desempeño del modelo mediante métricas de clasificación buscando minimizar los canales o ciclos necesarios para la detección de la componente P300.

5. Diseñar e implementar el sistema de comunicación asistida, integrando el modelo de detección de P300 con una interfaz que permita la construcción de palabras por parte del usuario.

6. Integrar un módulo de predicción de palabras o autocompletado, orientado a reducir el número de selecciones necesarias para la construcción de mensajes.

7. Evaluar el funcionamiento del sistema mediante pruebas de deletreo, primero con el conjunto de prueba de la base de datos II de la competencia BCI III y después con voluntarios que utilicen el casco, midiendo la exactitud por carácter, la tasa de transferencia de información y el ahorro de selecciones obtenido con la predicción de palabras.

1.2. Justificación

El análisis de señales EEG en paradigmas basados en la componente P300 ha sido ampliamente utilizado en el desarrollo de interfaces cerebro computadora, particularmente en sistemas de selección de caracteres mediante el paradigma P300 Speller. Estos sistemas permiten la comunicación mediante la detección de respuestas cerebrales asociadas a estímulos visuales, lo que representa una alternativa para las personas con compromisos motores severos que tengan problemas de comunicación.

De acuerdo con el trabajo de Feigin et al. [3], los desórdenes neurológicos son la principal causa de discapacidad a nivel mundial, y es posible que la magnitud de estas aumente debido al crecimiento y envejecimiento de la población, y en enfermedades como la esclerosis lateral amiotrófica (ELA) la comunicación puede verse gravemente limitada, lo que impacta directamente en la calidad de vida del paciente.

Dentro de este contexto, el paradigma P300 Speller puede resultar útil para permitir la comunicación a las personas con problemas motrices severos, mejorando así su calidad de vida. Sin embargo, la mayoría de los estudios se enfocan en maximizar la exactitud de clasificación mediante entornos controlados difíciles de llevar a la práctica, de modo que este trabajo interviene en la integración estructural del sistema, priorizando no solo el desempeño del modelo, sino también su incorporación en un sistema funcional que le permita a los usuarios objetivo la construcción efectiva de mensajes.

La reducción del número de canales (electrodos), así como la incorporación de estrategias que faciliten la selección de caracteres, puede contribuir al desarrollo de sistemas BCI más accesibles, portables y de implementación simplificada, ampliando su viabilidad en distintos contextos tecnológicos. De esta manera, el proyecto no se centra solamente en la optimización bajo escenarios aislados, sino que propone un sistema orientado a la aplicación práctica.

En cuanto a la aportación del trabajo, su valor radica en la integración de un modelo de aprendizaje profundo para la detección de la componente P300 con un modelo de predicción de palabras, combinación que permite no solo identificar la selección de caracteres mediante las señales obtenidas por lectura electroencefalografica, sino también optimizar el proceso de construcción de mensajes mediante la asistencia de este otro módulo.

Por lo tanto, la complejidad del trabajo implica el procesamiento y análisis de señales EEG, la implementación y entrenamiento de modelos de aprendizaje profundo, la integración de estos modelos en una aplicación y la evaluación de los resultados, lo cual requiere la aplicación avanzada de conocimientos en procesamiento de señales, aprendizaje profundo y desarrollo de sistemas, competencias del área de ingeniería en inteligencia artificial. Finalmente, el proyecto resulta viable en términos de tiempo y recursos, ya que la exploración de arquitecturas y del preprocesamiento puede apoyarse en bases de datos públicas de paradigmas P300, mientras que la adquisición de señales propias, necesaria para adaptar el modelo a cada usuario, se realizará con un casco comercial de 14 canales, lo que evita el alto costo del hardware especializado con 64 canales de detección de señales EEG.

2. Marco Referencial

En este capítulo se reúnen los fundamentos teóricos en los que se apoya el desarrollo del sistema de comunicación asistida. Se parte del contexto de las personas con discapacidad motora severa y de las limitaciones que tienen para comunicarse, y después se describen la electroencefalografía, los potenciales relacionados con eventos, en particular la componente P300, las interfaces cerebro computadora y el paradigma P300 Speller en el que se basa este trabajo.

Por otra parte, se abordan las técnicas de procesamiento digital de señales que se aplican al EEG antes de clasificarlo, los conceptos de aprendizaje automático y de redes neuronales que hacen falta para entender las arquitecturas convolucionales usadas en la detección de la P300, y las métricas con las que se evalúa tanto la clasificación de las épocas como el sistema completo. Más adelante se revisan las estrategias para reducir canales y repeticiones y los modelos de lenguaje para predecir palabras, y el capítulo cierra con el estado del arte de los sistemas P300 Speller y su comparación con la propuesta.

2.1. Discapacidad motora severa y comunicación

De acuerdo con el Informe mundial sobre la discapacidad de la Organización Mundial de la Salud (OMS) y el Banco Mundial, más de mil millones de personas en el mundo viven con alguna forma de discapacidad. De ellas, cerca de 200 millones tienen dificultades considerables para realizar actividades básicas de la vida diaria [4]. Más concretamente, en México, la Encuesta Nacional de la Dinámica Demográfica de 2018 reportó que el 6.3 % de la población, alrededor de 7.8 millones de habitantes, tiene alguna discapacidad. De este grupo, el 17.8 % tenía dificultad para mover o usar brazos o manos, y el 10.5 % presentaba dificultad severa para hablar o comunicarse [5]. Asimismo, Feigin et al. señalan que los trastornos neurológicos son actualmente la principal causa de discapacidad a nivel mundial y que su carga tiende a crecer con el envejecimiento de la población [3].

Dentro de este grupo se encuentran padecimientos como la esclerosis lateral amiotrófica (ELA), las lesiones medulares altas o los eventos vasculares del tallo cerebral, que en sus etapas avanzadas pueden llevar al llamado síndrome de enclaustramiento (*locked-in*), condición en la que la persona conserva sus funciones cognitivas pero pierde prácticamente todo el control muscular voluntario, incluido el del habla. Uno de los primeros dispositivos de deletreo controlados únicamente con la actividad cerebral fue presentado por Birbaumer et al. precisamente para pacientes con ELA en esta condición, quienes lograron escribir mensajes a partir del control voluntario de potenciales corticales lentos, aunque tras semanas de entrenamiento y a una velocidad de escritura considerablemente baja [6].

La comunicación aumentativa y alternativa agrupa las estrategias y herramientas que complementan o sustituyen el habla, desde tableros de letras hasta sistemas de seguimiento ocular.

Sin embargo, casi todas dependen de algún control muscular que le quede a la persona, ya sea de los ojos, de un dedo o de los párpados, y cuando ese control se pierde por completo dejan de servir. Las interfaces cerebro computadora (BCI) ofrecen en cambio un canal de salida que no pasa por los nervios periféricos ni por los músculos [7]. Sellers y Donchin hicieron las primeras pruebas de un sistema basado en la componente P300 con pacientes con ELA, y encontraron que podían operarlo aun con el avance de la enfermedad [8].

2.2. Electroencefalografía

El electroencefalograma (EEG) se define como el registro de la actividad eléctrica del cerebro tomado por medio de electrodos colocados en la superficie de la cabeza, mientras que la electroencefalografía corresponde a la disciplina que se encarga de registrar e interpretar dichos registros [9]. El primer registro de este tipo en humanos fue reportado en 1929 por el psiquiatra alemán Hans Berger, quien además acuñó el término electroencefalograma y describió el ritmo que hoy se conoce como alfa [10].

2.2.1. Adquisición de la señal

Los potenciales registrados en el cuero cabelludo tienen amplitudes que van de unos cuantos microvolts hasta alrededor de 100 μV, por lo que deben amplificarse considerablemente antes de digitalizarse [11]. Los electrodos más comunes son discos de plata recubiertos de cloruro de plata (Ag/AgCl). Se colocan con un gel conductor para reducir la impedancia de contacto, que idealmente debe ser menor a 5 kΩ. También existen electrodos secos, que no necesitan gel y se colocan más rápido. Su desventaja es que tienen mayor impedancia y son más sensibles a los artefactos de movimiento [12]. En este sentido, el trabajo de Contreras [13] utilizó electrodos secos de un sistema de bajo costo con cuatro canales, mientras que las bases de datos públicas del paradigma P300, como la empleada en la fase exploratoria de este trabajo, fueron adquiridas con equipos de grado de investigación de 64 canales [14]. Para las sesiones de registro propias se utilizará el casco Emotiv EPOC X, de 14 canales, que se encuentra entre ambos extremos. Sus electrodos son almohadillas de fieltro humedecidas con solución salina y la señal se entrega a 128 o 256 Hz [15].

2.2.2. Sistema internacional 10-20

Para que los registros sean comparables entre sujetos y laboratorios, la posición de los electrodos se estandariza mediante el sistema internacional 10-20, propuesto originalmente por Jasper [16] y actualizado por la Federación Internacional de Neurofisiología Clínica (IFCN) [17]. Su nombre se debe a que las posiciones se obtienen dividiendo las distancias entre cuatro puntos de referencia anatómicos (el nasión, el inión y los dos puntos preauriculares) en segmentos del 10 % y del 20 % de su longitud total. Cada electrodo se nombra con una o dos letras según la región que cubre: Fp (frontopolar), F (frontal), C (central), T (temporal), P (parietal) y O (occipital). Después se agrega un número impar si el electrodo está en el hemisferio izquierdo,

un número par si está en el derecho, o la letra *z* si está sobre la línea media [17]. La Figura 2.1 muestra la distribución de los 21 electrodos del sistema, resaltando los de la línea media (Fz, Cz, Pz y Oz), que fueron los utilizados en el trabajo de Contreras [13]. Las bases de datos del paradigma P300 suelen utilizar la extensión 10-10, que agrega posiciones intermedias hasta completar 64 o más canales [14]. Los electrodos del casco Emotiv EPOC X, como AF3, FC5 o P7, también corresponden a posiciones de esta extensión [15].

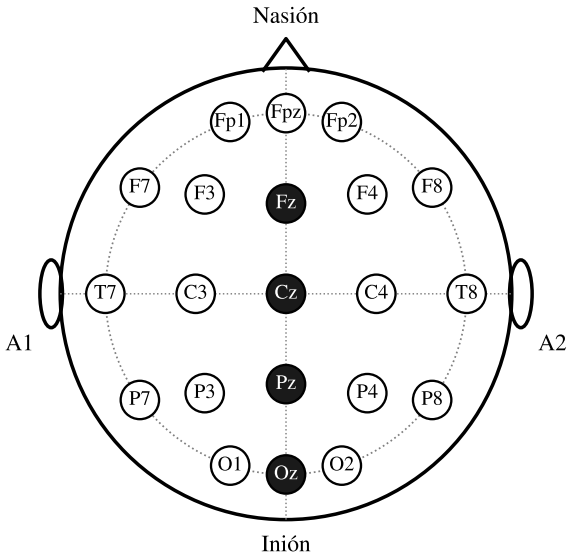


Figura 2.1: Posiciones de los electrodos del sistema internacional 10-20 (vista superior). Se resaltan los electrodos de la línea media Fz, Cz, Pz y Oz. Elaboración propia con base en [17].

2.2.3. Artefactos en la señal de EEG

Debido a su baja amplitud, el EEG es muy susceptible a señales que no provienen de la actividad cerebral, conocidas como artefactos. Los más frecuentes son de origen fisiológico, como los parpadeos y movimientos oculares, cuya amplitud puede ser varias veces mayor que la del propio EEG, la actividad eléctrica de los músculos de la cara y el cuello o la actividad cardiaca. Otros que se pueden presentar son los de origen técnico, como la interferencia de la red eléctrica, que en México se presenta a 60 Hz, o los cambios de impedancia de los electrodos [11], [12]. La Tabla 2.1 presenta los principales artefactos junto con las técnicas más comunes para mitigarlos, algunas de las cuales se retoman en la Sección 2.6.

2.3. Potenciales relacionados con eventos y componente P300

2.3.1. Potenciales relacionados con eventos

A diferencia de la actividad de fondo del EEG, que se produce de manera espontánea, los potenciales relacionados con eventos (ERP, por sus siglas en inglés) son cambios de voltaje que guardan una relación temporal fija con algún suceso, como la aparición de un estímulo

Tabla 2.1: Artefactos comunes en el registro de EEG

Artefacto	**Origen**	**Banda afectada**	**Mitigación**
Parpadeo y movimiento ocular (EOG)	Fisiológico	<4 Hz	Filtrado pasa altas y rechazo de épocas por umbral de amplitud.
Actividad muscular (EMG)	Fisiológico	>20 Hz	Filtrado pasa bajas e instrucciones al sujeto.
Actividad cardiaca (ECG)	Fisiológico	1–2 Hz y armónicos	Referencia adecuada.
Sudoración y deriva de línea base	Fisiológico / electrodo	<0.5 Hz	Filtrado pasa altas, corrección de línea base.
Interferencia de la red eléctrica	Técnico	60 Hz (México)	Filtro notch, blindaje, buena impedancia.
Movimiento o mal contacto del electrodo	Técnico	Banda ancha	Rechazo de épocas por umbral de amplitud.

Elaboración propia con información de [11], [12].

sensorial, la ejecución de un movimiento o un proceso cognitivo como el reconocimiento de un estímulo [18]. Registrado desde el cuero cabelludo, un ERP se observa como una secuencia de deflexiones positivas y negativas a las que se conoce como componentes, y cada una se identifica con la letra P o N de acuerdo con su polaridad y con un número que corresponde a su latencia aproximada en milisegundos, o bien a su orden de aparición dentro de la secuencia [19]. La Tabla 2.2 describe las componentes que aparecen con mayor frecuencia en paradigmas de estimulación visual, y la Figura 2.2 muestra la forma de onda típica de un ERP ante un estímulo objetivo y ante uno no objetivo, en la que la P300 solo aparece en el primero.

Tabla 2.2: Principales componentes de los ERP en paradigmas visuales

Componente	**Latencia**	**Polaridad**	**Proceso asociado**
N100 (N1)	100–200 ms	Negativa	Procesamiento sensorial y orientación de la atención hacia el estímulo.
P200 (P2)	150–250 ms	Positiva	Evaluación de las características físicas del estímulo.
N200 (N2)	200–350 ms	Negativa	Detección de desajuste entre el estímulo y lo esperado, y clasificación del estímulo.
P300 (P3)	250–500 ms	Positiva	Actualización del contexto en la memoria de trabajo ante estímulos relevantes o poco frecuentes.

Elaboración propia con información de [18], [19], [20].

2.3.2. Promediado coherente

El principal problema para observar un ERP es que su amplitud, de unos cuantos microvolts, es considerablemente menor que la de la actividad de fondo del EEG, que para estos fines se comporta como ruido. La forma clásica de resolverlo consiste en presentar el mismo estímulo

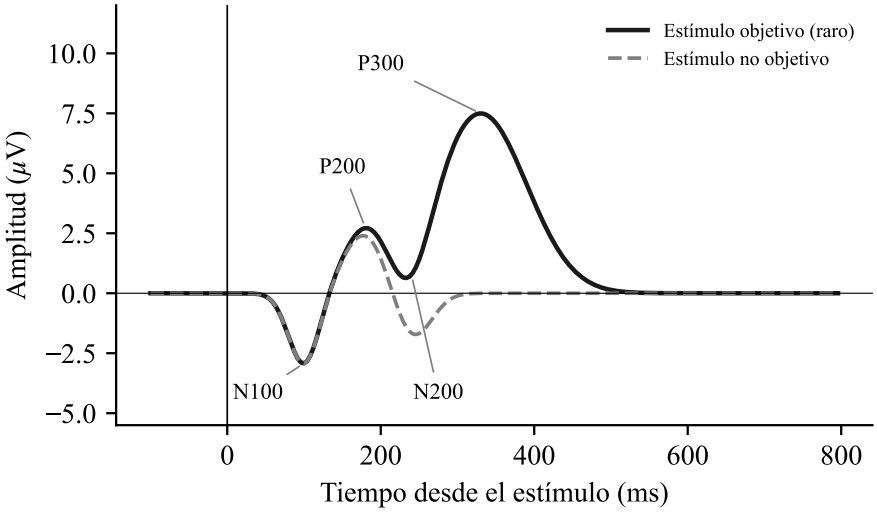


Figura 2.2: Forma de onda ilustrativa de un ERP ante un estímulo objetivo y uno no objetivo, con las latencias de la Tabla 2.2. Elaboración propia con base en [19], [20].

repetidas veces, extraer los segmentos de señal sincronizados con cada presentación y promediarlos [21]. Si cada ensayo $x_i(n)$ se modela como la suma de una respuesta $s(n)$ que se repite de forma idéntica y de un ruido $r_i(n)$ de media cero y varianza σ^2, independiente entre ensayos, el promedio de N ensayos queda como

$$\bar{x}(n) = \frac{1}{N}\sum_{i=1}^{N} x_i(n) = s(n) + \frac{1}{N}\sum_{i=1}^{N} r_i(n), \tag{2.1}$$

donde la desviación estándar del ruido residual baja a $\sigma/\sqrt{N}$ y la relación señal-ruido mejora en proporción a la raíz cuadrada del número de ensayos [19]. Por eso el P300 Speller repite varias veces la intensificación de cada fila y columna, y por eso mismo reducir esas repeticiones, que es uno de los objetivos de este trabajo, afecta directamente la confiabilidad de la detección.

2.3.3. La componente P300

La componente P300 fue descrita por primera vez en 1965 por Sutton et al., quienes observaron que los estímulos cuya ocurrencia era incierta para el sujeto evocaban una onda positiva de gran amplitud alrededor de 300 ms después de su presentación [22]. Años más tarde, Squires, Squires y Hillyard distinguieron dos variantes de esta onda [23], de las cuales el P300 Speller aprovecha la P3b, que se registra en la región parietal y aparece ante estímulos relevantes para la tarea, pues su aparición depende de que el usuario atienda deliberadamente al carácter que desea seleccionar [20].

La P300 se describe principalmente con dos medidas. La amplitud es la diferencia entre el voltaje de la línea base previa al estímulo y el pico positivo más alto, que se busca típicamente entre 250 y 500 ms. La latencia es el tiempo que pasa desde el inicio del estímulo hasta ese pico [20]. En los electrodos de la línea media, la amplitud aumenta de las regiones frontales

hacia las parietales y alcanza su máximo en Pz [24]. La amplitud es mayor cuando el estímulo objetivo es menos probable y más relevante para la tarea. En cambio, disminuye con la fatiga, la habituación y los intervalos cortos entre estímulos [20], [24].

2.3.4. Paradigma del evento raro

El procedimiento experimental más utilizado para provocar la P300 es el paradigma del evento raro, conocido en inglés como *oddball*. En él se presenta al sujeto una secuencia de estímulos de dos categorías, una de las cuales aparece con mucha menor frecuencia que la otra, y se le pide que atienda o cuente únicamente los estímulos de la categoría poco frecuente [2], [20]. Los estímulos raros, que en el contexto de una BCI corresponden al objetivo elegido por el usuario, producen una P300 cuya amplitud es inversamente proporcional a su probabilidad de aparición [2]. La Figura 2.3 representa una secuencia típica de este paradigma.

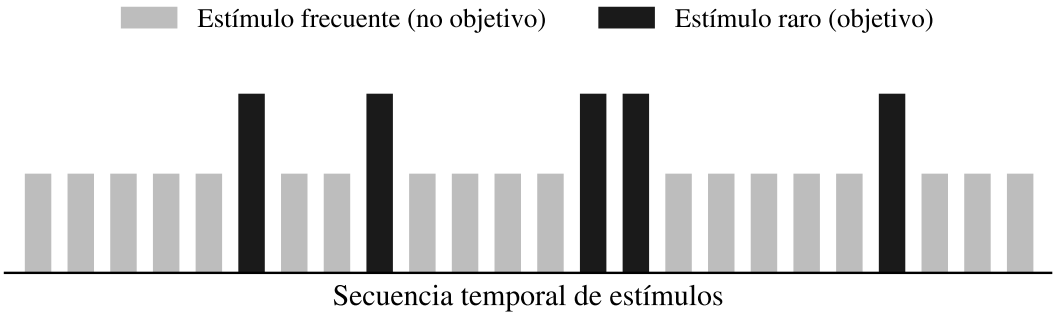


Figura 2.3: Secuencia de estímulos en el paradigma del evento raro (*oddball*). Elaboración propia.

2.4. Interfaces cerebro computadora

2.4.1. Definición y componentes

Una interfaz cerebro computadora (BCI) establece un canal de comunicación entre la actividad cerebral de una persona y un dispositivo externo sin que intervenga ningún movimiento muscular. Wolpaw et al. la definen como un sistema en el que los mensajes o comandos que el usuario dirige al exterior no viajan por las vías de salida habituales del cerebro, es decir, por los nervios periféricos y los músculos [7]. Asimismo, en el trabajo de Felton et al. se señala que estos sistemas convierten en tiempo real las señales cerebrales en acciones, con lo que es posible recuperar funciones de comunicación o de movimiento en personas con discapacidad severa [1].

Independientemente de la señal que utilice, una BCI se compone de una serie de etapas que se ejecutan de forma cíclica, como se ilustra en la Figura 2.4. Primero se adquiere y digitaliza la señal cerebral. Después se preprocesa para reducir el ruido y los artefactos. Luego se extraen las características que mejor representan la intención del usuario, y un clasificador las convierte en un comando para el dispositivo. Finalmente, el resultado se muestra al usuario como retroalimentación para que pueda ajustar su estrategia [25], [26].

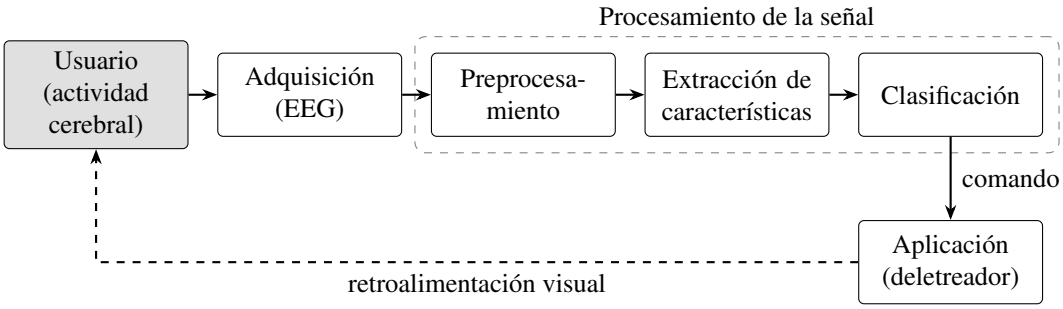


Figura 2.4: Diagrama general de una interfaz cerebro computadora. Elaboración propia con base en [7], [25].

2.4.2. Paradigmas de control

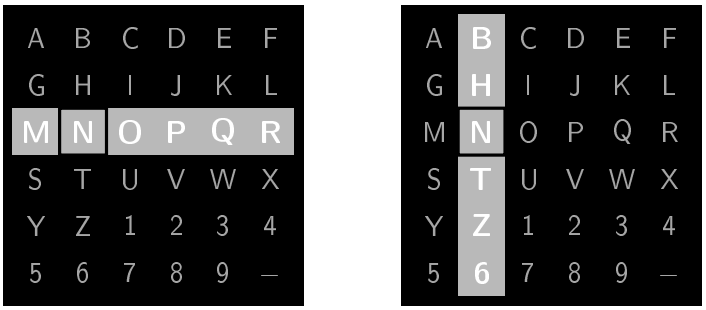
Las BCI basadas en EEG utilizan principalmente cuatro tipos de señales. Las basadas en ritmos sensoriomotores aprovechan la disminución de los ritmos mu y beta sobre la corteza motora al imaginar un movimiento. Las de potenciales evocados visuales de estado estable (SSVEP) usan la respuesta de la corteza visual a estímulos que parpadean a una frecuencia fija. Las de potenciales corticales lentos requieren que el usuario aprenda a modificar voluntariamente la línea base de su EEG. Por último, las basadas en la P300 aprovechan la respuesta del paradigma del evento raro descrita en la sección anterior [7], [26]. La ventaja de este último enfoque es que la P300 aparece de forma natural ante los estímulos relevantes y el usuario casi no necesita entrenamiento previo [2], [13].

2.5. El paradigma P300 Speller

2.5.1. Deletreador de Farwell y Donchin

En 1988 Farwell y Donchin publicaron el sistema que hoy se conoce como P300 Speller o deletreador de Donchin. En su artículo original todavía no se habla de una BCI, sino de una prótesis mental pensada como canal de comunicación para personas cuya discapacidad motora les impide comunicarse [2]. El sistema muestra en pantalla una matriz de 6×6 celdas con las letras del alfabeto, algunos números y comandos simples. Durante su funcionamiento, las filas y columnas se iluminan una por una en orden aleatorio. Mientras tanto, el usuario se concentra en la celda que desea seleccionar, por ejemplo, contando mentalmente cuántas veces se ilumina [2]. De los doce eventos posibles, seis filas y seis columnas, solo dos contienen al carácter objetivo. Esas dos intensificaciones hacen el papel de los estímulos raros del paradigma *oddball* y provocan una P300 que no aparece en las otras diez, como se representa en la Figura 2.5.

El sistema original registraba el EEG únicamente en el electrodo Pz y, con cuatro participantes sanos, alcanzó una exactitud cercana al 95 % con un tiempo promedio de 26 segundos por carácter, equivalente a 2.3 caracteres o 12 bits por minuto [2]. Aunque esta velocidad es muy baja comparada con la escritura convencional, la arquitectura y el principio de operación de este deletreador siguen siendo la base de la mayoría de los sistemas BCI basados en la P300



(a) Intensificación de la fila 3 (b) Intensificación de la columna 2

Figura 2.5: Matriz de 6×6 caracteres del P300 Speller. Si el usuario atiende a la letra N (recuadro), tanto la intensificación de la fila 3 como la de la columna 2 son eventos objetivo que provocan una P300. Las diez intensificaciones restantes son eventos no objetivo. Elaboración propia con base en [2].

[13].

2.5.2. Parámetros de estimulación

El desempeño del P300 Speller depende en buena medida de los tiempos con que se presentan los estímulos. La duración de la intensificación es el tiempo que una fila o columna permanece iluminada. El intervalo entre estímulos (ISI) es el tiempo que la matriz permanece sin iluminar antes del siguiente evento. La suma de ambos se conoce como intervalo entre inicios de estímulos (SOA). A una secuencia completa de las doce intensificaciones se le llama repetición, y el número de repeticiones que se hacen antes de elegir el carácter determina el equilibrio entre velocidad y exactitud [27]. En la base de datos II de la tercera competencia BCI, utilizada en la fase exploratoria de este trabajo, cada intensificación dura 100 ms seguida de 75 ms sin estímulo, por lo que cada repetición dura alrededor de 2.1 s, y cada carácter se deletrea con 15 repeticiones, es decir, con 180 intensificaciones [14].

2.5.3. Épocas de EEG y decodificación del carácter

Para clasificar la señal, el registro continuo se divide en segmentos que inician en el instante de cada intensificación, llamados épocas. Una época es atendida si corresponde a una fila o columna que contiene el carácter objetivo, y no atendida en caso contrario [13]. En lo sucesivo, x_j^f y x_j^c denotan las épocas asociadas a la fila f y a la columna c en la repetición j.

Una vez que un clasificador asigna a cada época un puntaje $g(\cdot)$ que refleja la probabilidad de que contenga una P300, el carácter se decide sumando los puntajes de cada fila y cada columna a lo largo de las J repeticiones y eligiendo aquellas con el valor más alto [28]:

$$\hat{f} = \arg \max_{f \in \{1,\ldots,6\}} \sum_{j=1}^{J} g\left(x_j^f\right), \qquad \hat{c} = \arg \max_{c \in \{1,\ldots,6\}} \sum_{j=1}^{J} g\left(x_j^c\right), \tag{2.2}$$

y el carácter seleccionado es el que está en la intersección de la fila $\hat{f}$ y la columna $\hat{c}$. Con esta estrategia, el ganador de la competencia BCI III alcanzó una exactitud del 96.5 % al utilizar las

15 repeticiones disponibles [28].

Por la propia estructura del paradigma, el conjunto de épocas está fuertemente desbalanceado: en cada repetición solo dos de las doce intensificaciones son objetivo, lo que produce una proporción de una época positiva por cada cinco negativas [29]. Si este desbalance no se considera durante el entrenamiento, un clasificador puede alcanzar una exactitud aparente cercana al 83 % simplemente prediciendo siempre la clase negativa, razón por la cual las métricas de evaluación de la Sección 2.10 deben elegirse con cuidado.

2.5.4. Bases de datos públicas

Gran parte de la investigación sobre detección de la P300 se apoya en bases de datos públicas, lo que permite comparar métodos bajo las mismas condiciones. Una de las más utilizadas es la base de datos II de la tercera competencia internacional de BCI, registrada con 64 canales a 240 Hz con el paradigma de filas y columnas, que contiene registros de dos sujetos con 85 caracteres de entrenamiento y 100 de prueba cada uno [14]. En el presente trabajo se emplea en la fase exploratoria y más adelante se complementa con señales propias de voluntarios (Capítulo 3).

2.6. Procesamiento Digital de Señales Biomédicas

El preprocesamiento de las señales EEG pesa mucho en el desempeño de los modelos de clasificación, ya que estas señales tienen una relación señal-ruido baja y son susceptibles a artefactos fisiológicos y ambientales. Para tratarlas se usa un filtrado pasa banda que delimita el rango de frecuencias de la componente P300, la segmentación de la señal continua en ventanas alrededor de cada estímulo y la normalización de esas ventanas.

2.6.1. Muestreo y teorema de Nyquist

Las señales fisiológicas son analógicas, es decir, están definidas en todo instante y su amplitud puede tomar cualquier valor. Para procesarlas en una computadora se deben muestrear a intervalos regulares $T_s = 1/f_s$, lo que produce la secuencia discreta $x(n) = x_a(nT_s)$ [30]. El teorema de muestreo establece que una señal cuyo contenido en frecuencia está limitado a $f_{\text{máx}}$ puede reconstruirse sin pérdida a partir de sus muestras siempre que

$$f_s \geq 2 f_{\text{máx}}, \tag{2.3}$$

y si esta condición no se cumple, las componentes de frecuencia superiores a $f_s/2$, conocida como frecuencia de Nyquist, se reflejan sobre las frecuencias bajas en un fenómeno llamado *aliasing* [31]. La base de datos utilizada en la fase exploratoria de este trabajo fue muestreada a 240 Hz, por lo que su frecuencia de Nyquist de 120 Hz está muy por encima de la banda de interés de la P300, que se concentra por debajo de 20 Hz, y lo mismo ocurre con los 128 y 256 Hz que ofrecen los cascos comerciales de bajo costo.

2.6.2. Filtros digitales

Un filtro digital modifica el contenido en frecuencia de una señal y, de acuerdo con la banda que deja pasar, puede ser pasa bajas, pasa altas, pasa banda o rechaza banda [30]. En EEG uno de los más utilizados es el filtro de Butterworth, cuya respuesta en magnitud es plana en la banda de paso [31]. El filtro *notch* es un tipo de filtro rechaza banda que elimina una sola frecuencia, como la de la red eléctrica. La Figura 2.6 muestra como ejemplo la respuesta en frecuencia de un filtro pasa banda entre 0.1 y 20 Hz y de un filtro *notch* en 60 Hz.

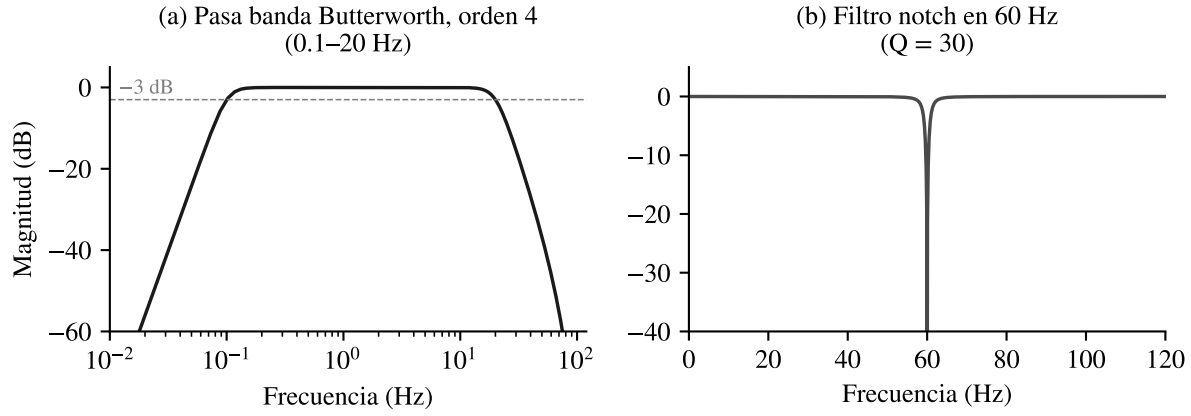


Figura 2.6: Respuesta en magnitud de (a) un filtro pasa banda Butterworth de cuarto orden entre 0.1 y 20 Hz y (b) un filtro *notch* en 60 Hz, para $f_s = 240$ Hz. Elaboración propia.

2.6.3. Remuestreo

El remuestreo permite reducir la frecuencia de muestreo después de filtrar la señal. En la decimación por un factor M se conserva una de cada M muestras. Antes de hacerlo, se debe aplicar un filtro antialiasing que elimine el contenido por encima de la nueva frecuencia de Nyquist [30]. Como la P300 se concentra por debajo de 20 Hz, bajar la frecuencia de muestreo reduce el tamaño de cada época sin perder información útil, y además sirve para llevar a una misma frecuencia señales registradas con equipos distintos.

2.6.4. Segmentación en épocas

La segmentación consiste en dividir la señal continua en ventanas sincronizadas con cada estímulo, que constituyen las muestras de entrada al clasificador. La longitud de la ventana debe ser suficiente para contener la P300 completa. Contreras, por ejemplo, empleó ventanas de 1005 ms a partir del estímulo [13]. Cuando el intervalo entre inicios de estímulos es corto, como los 175 ms de la base de datos de la competencia BCI III, las épocas de intensificaciones consecutivas se traslapan y una época no objetivo puede llegar a contener parte de la P300 de una intensificación objetivo cercana.

2.6.5. Normalización

Las amplitudes del EEG varían entre canales, sesiones y sujetos, por lo que antes de entrenar un modelo se acostumbra normalizar los datos. La normalización *z-score* transforma cada canal para que tenga media cero y desviación estándar unitaria, mientras que la normalización *min-max*, utilizada por Contreras [13], escala los valores al intervalo $[0,1]$:

$$z(n) = \frac{x(n) - \mu}{\sigma}, \qquad x'(n) = \frac{x(n) - \text{mín}(x)}{\text{máx}(x) - \text{mín}(x)}. \tag{2.4}$$

La primera es menos sensible a valores atípicos, algo útil cuando hay artefactos de gran amplitud. Normalmente se aplica de manera independiente a cada canal, para que los electrodos con mayor amplitud no dominen el aprendizaje de la red.

2.7. Aprendizaje automático

El aprendizaje automático es una rama de la inteligencia artificial que reúne métodos para construir modelos a partir de los datos mediante el descubrimiento de patrones, para después aplicarlos a datos nuevos de la misma naturaleza [32]. Cuando los datos de entrenamiento tienen etiquetas conocidas, el aprendizaje es supervisado, y es el caso de la detección de la P300, que corresponde a un problema de clasificación binaria en el que cada época está etiquetada como objetivo o no objetivo. El aprendizaje profundo, a su vez, es el subconjunto del aprendizaje automático basado en redes neuronales con múltiples capas [33].

2.7.1. Sobreajuste y generalización

El objetivo de un modelo de aprendizaje automático no es reproducir los datos con los que fue entrenado sino desempeñarse correctamente con datos que nunca ha visto, capacidad conocida como generalización [33]. Cuando un modelo es demasiado complejo para la cantidad de datos disponibles, o se entrena durante demasiadas iteraciones, empieza a memorizar el ruido del conjunto de entrenamiento. En ese momento, el error de entrenamiento sigue bajando, pero el error de validación deja de disminuir y comienza a subir. Este fenómeno se conoce como sobreajuste y se ilustra en la Figura 2.7 [32], [33]. En el caso del EEG este riesgo es particularmente alto, pues las bases de datos suelen contener pocos sujetos y un número limitado de épocas objetivo.

2.7.2. Esquemas de validación

Para estimar la capacidad de generalización, los datos se dividen en tres conjuntos [33]. El de entrenamiento sirve para ajustar el modelo. El de validación se usa para ajustar hiperparámetros y decidir cuándo detener el entrenamiento. El de prueba solo se utiliza al final. La validación cruzada de k particiones repite este proceso k veces rotando el subconjunto de validación, lo que ofrece una estimación más estable cuando hay pocos datos [32]. En las BCI, además, se distinguen dos tipos de evaluación. En la evaluación intrasujeto, el modelo se entrena y se

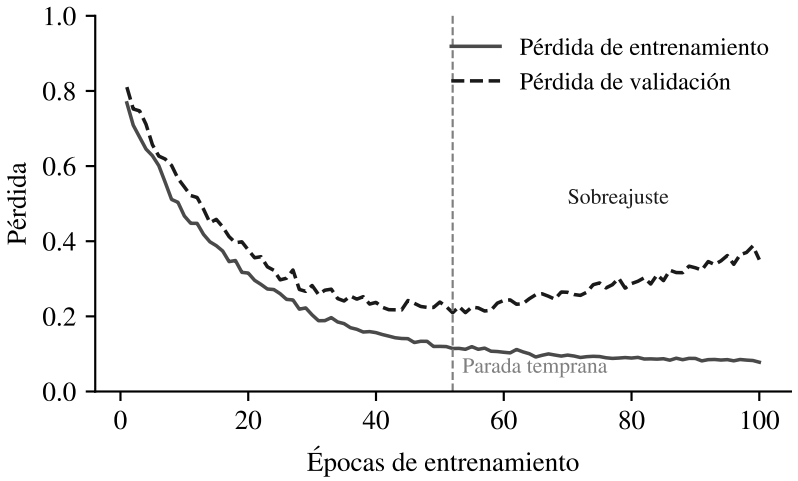


Figura 2.7: Curvas de pérdida de entrenamiento y validación: a partir de cierto punto el modelo comienza a sobreajustarse. Elaboración propia.

prueba con datos de la misma persona. En la evaluación intersujeto, se prueba con una persona que no participó en el entrenamiento [34].

2.8. Redes neuronales artificiales y aprendizaje profundo

2.8.1. La neurona artificial

Las redes neuronales artificiales son modelos inspirados en el sistema nervioso, en los que las unidades de cómputo, llamadas neuronas, se conectan entre sí mediante pesos que cumplen un papel análogo al de la fuerza de las conexiones sinápticas en los organismos biológicos [35]. Cada neurona recibe un vector de entradas $\mathbf{x} = (x_1, \ldots, x_n)$, las multiplica por sus pesos w_i, suma el resultado junto con un sesgo b y aplica una función de activación φ no lineal [36]:

$$y = \varphi\left(\sum_{i=1}^{n} w_i x_i + b\right) = \varphi\left(\mathbf{w}^\top \mathbf{x} + b\right). \tag{2.5}$$

Al organizar muchas de estas unidades en capas, de forma que la salida de una capa sea la entrada de la siguiente, se obtiene el perceptrón multicapa. Las capas intermedias se llaman ocultas, y el número de capas se conoce como profundidad de la red. De ahí proviene el término aprendizaje profundo [33].

2.8.2. Funciones de activación

Sin la función de activación, una red de cualquier profundidad equivaldría a una sola transformación lineal, y es gracias a ella que la red puede representar relaciones no lineales [33]. La Tabla 2.3 presenta las funciones más utilizadas y su uso en las arquitecturas para la detección de la P300.

Tabla 2.3: Funciones de activación más utilizadas

Función	**Definición**	**Rango**	**Uso típico**
Sigmoide	$\sigma(z) = \dfrac{1}{1+e^{-z}}$	$(0,1)$	Salida de clasificación binaria (probabilidad de P300).
Tangente hiperbólica	$\tanh(z) = \dfrac{e^{z}-e^{-z}}{e^{z}+e^{-z}}$	$(-1,1)$	Capas ocultas en [29], [34].
ReLU	$\max(0,z)$	$[0,\infty)$	Capas ocultas de redes profundas.
ELU	z si $z>0$, y $\alpha(e^{z}-1)$ si $z\leq 0$	$(-\alpha,\infty)$	Capas ocultas de EEGNet [37].
Softmax	$\dfrac{e^{z_k}}{\sum_j e^{z_j}}$	$(0,1)$, suma 1	Salida de clasificación multiclase.

Elaboración propia con información de [33], [35].

2.8.3. Función de pérdida

El entrenamiento de una red consiste en ajustar sus pesos para minimizar una función de pérdida que mide la diferencia entre la salida de la red y la etiqueta esperada. Para la clasificación binaria, con etiquetas $y_i \in \{0,1\}$ y salidas $\hat{y}_i \in (0,1)$, se utiliza la entropía cruzada binaria [33]:

$$\mathscr{L}_{\text{BCE}} = -\frac{1}{M}\sum_{i=1}^{M}\Big[y_i \log \hat{y}_i + (1-y_i)\log(1-\hat{y}_i)\Big]. \tag{2.6}$$

Debido al desbalance de las épocas del P300 Speller, en el que por cada época positiva hay cinco negativas, es común ponderar el primer término con un factor $\alpha > 1$ para que los errores sobre la clase minoritaria tengan mayor peso.

2.8.4. Descenso de gradiente y retropropagación

Para minimizar la pérdida se utiliza el método de descenso de gradiente, que actualiza los pesos en la dirección opuesta al gradiente de la función de pérdida,

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta\, \nabla_{\mathbf{w}} \mathscr{L}\big(\mathbf{w}^{(t)}\big), \tag{2.7}$$

donde η es la tasa de aprendizaje. Si es muy pequeña, el entrenamiento resulta lento, y si es muy grande, los pesos oscilan alrededor del mínimo sin alcanzarlo [33]. En redes de varias capas, este gradiente se calcula con el algoritmo de retropropagación, que propaga el error desde la capa de salida hacia las capas anteriores [38].

2.8.5. Regularización

Dado que las redes profundas tienen una gran cantidad de parámetros y los conjuntos de datos de EEG son relativamente pequeños, es indispensable emplear técnicas de regulariza-

ción para evitar el sobreajuste. Entre las más utilizadas se encuentran el *dropout*, que desactiva aleatoriamente una fracción de las neuronas en cada iteración de entrenamiento [39], la normalización por lotes, que normaliza las activaciones de cada capa y estabiliza el entrenamiento [40], y la parada temprana, que detiene el entrenamiento cuando la pérdida de validación deja de mejorar [33]. Las dos primeras forman parte de arquitecturas para la detección de la P300 como EEGNet [37].

2.9. Redes convolucionales para la detección de la P300

2.9.1. Redes neuronales convolucionales

Las redes neuronales convolucionales (CNN) están diseñadas para trabajar con datos organizados en forma de cuadrícula, como las imágenes o las series de tiempo, en los que los valores cercanos están muy relacionados. Su nombre se debe a que usan la operación de convolución en al menos una de sus capas [33]. En una capa convolucional, un filtro o *kernel* de pesos aprendibles se desplaza sobre la entrada y en cada posición calcula la suma ponderada de los valores que cubre. El resultado se denomina mapa de características. Como el mismo filtro se aplica en todas las posiciones, el número de parámetros es mucho menor que en una capa totalmente conectada [35].

En el caso del EEG, cada época puede verse como una matriz de C canales por T muestras, lo que permite separar el procesamiento en dos dimensiones con significado fisiológico distinto: las convoluciones temporales, con filtros de tamaño $1 \times K$, aprenden patrones en el tiempo equivalentes a filtros de frecuencia, mientras que las convoluciones espaciales, con filtros de tamaño $C \times 1$, aprenden combinaciones ponderadas de los electrodos equivalentes a un filtrado espacial. Cecotti y Gräser aplicaron esta separación en la primera CNN diseñada específicamente para detectar la P300, en la que una primera capa espacial es seguida de una capa temporal, alcanzando en la base de datos de la competencia BCI III una exactitud de alrededor del 95 % con 15 repeticiones [29]. Esta misma arquitectura se implementó en la fase exploratoria de este trabajo.

2.9.2. Convoluciones separables en profundidad

Una convolución separable en profundidad descompone la convolución estándar en dos pasos: primero una convolución *depthwise*, que aplica un filtro independiente a cada canal de entrada, y después una convolución *pointwise* de tamaño 1×1, que combina los canales resultantes [41]. Con esta descomposición el número de parámetros baja mucho respecto a una convolución estándar [41]. Sobre esa idea se construyeron dos de las arquitecturas más compactas para EEG, EEGNet [37] y SepConv1D [34], pensadas para cuando hay pocos datos o el modelo tiene que correr en dispositivos con recursos limitados.

2.9.3. EEGNet

EEGNet es una red convolucional compacta propuesta por Lawhern et al. para clasificar señales de EEG en distintos paradigmas de BCI, entre ellos la P300, con un número muy reducido de parámetros [37]. Como se muestra en la Figura 2.8, su primer bloque aplica una convolución temporal que funciona como un banco de filtros de frecuencia. Después, una convolución *depthwise* espacial aprende, para cada filtro temporal, una combinación de electrodos, lo que equivale a un filtrado espacial. El segundo bloque aplica una convolución separable que resume cada mapa de características en el tiempo y combina los mapas entre sí. Por último, la clasificación se realiza con una capa densa con activación softmax [37].

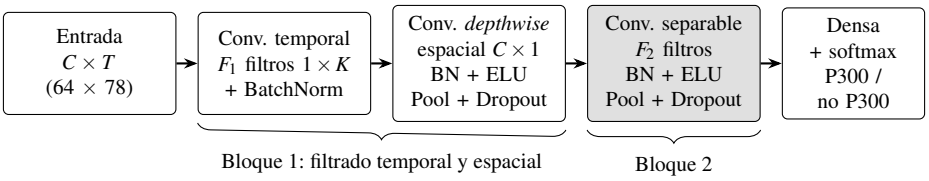


Figura 2.8: Arquitectura general de EEGNet. Elaboración propia con base en [37].

2.9.4. Arquitecturas convolucionales para la detección de la P300

A partir del trabajo de Cecotti y Gräser se han propuesto numerosas arquitecturas convolucionales para detectar la P300. Alvarado-González et al. compararon doce de ellas en cuatro bases de datos distintas, bajo los esquemas intrasujeto y entre sujetos, y encontraron que las diferencias de AUC entre arquitecturas eran pequeñas, al grado de que SepConv1D, con una sola capa convolucional separable de cuatro filtros seguida de una neurona sigmoide, obtuvo un desempeño comparable al de redes con muchos más parámetros [34]. La Tabla 2.4 resume algunas de las arquitecturas evaluadas y los valores de AUC reportados. Contreras utilizó SepConv1D en su sistema con cuatro canales [13].

Tabla 2.4: Algunas arquitecturas convolucionales para la detección de la P300 y AUC promedio reportada en [34]

Arquitectura	**Descripción**	**AUC intra**	**AUC inter**
CNN-1 [29]	4 capas: convolución espacial (10 filtros) y temporal con tangente hiperbólica escalada, con salida sigmoide.	0.82	0.78
DeepConvNet [42]	Cuatro bloques convolucionales seguidos de softmax.	0.84	0.79
EEGNet [37]	Red compacta con convoluciones *depthwise* y separables.	0.84	0.80
SepConv1D [34]	Una capa convolucional 1D separable (4 filtros) y una neurona sigmoide.	0.84	0.78

Elaboración propia con información de [13], [34].

2.10. Métricas de evaluación

El desempeño de un sistema basado en la P300 puede evaluarse en dos niveles: el de la clasificación de cada época como objetivo o no objetivo, que mide la calidad del modelo de aprendizaje profundo, y el del sistema completo, que mide qué tan rápido y con qué exactitud el usuario logra seleccionar caracteres.

2.10.1. Matriz de confusión

En un problema de clasificación binaria, las predicciones del modelo pueden compararse con las etiquetas reales mediante una tabla cruzada conocida como matriz de confusión, representada en la Figura 2.9. Sus cuatro celdas son las siguientes [43]:

- **Verdaderos positivos (TP):** épocas con P300 clasificadas correctamente.
- **Falsos positivos (FP):** épocas sin P300 clasificadas como positivas.
- **Verdaderos negativos (TN):** épocas sin P300 clasificadas correctamente.
- **Falsos negativos (FN):** épocas con P300 que el modelo no detectó.

		Predicción del modelo	
		P300	No P300
Clase real	P300	**TP** Verdaderos positivos	**FN** Falsos negativos
	No P300	**FP** Falsos positivos	**TN** Verdaderos negativos

Figura 2.9: Matriz de confusión para la clasificación binaria de épocas. Elaboración propia.

2.10.2. Métricas de clasificación

A partir de estos cuatro valores se calculan las métricas que se presentan en la Tabla 2.5. La exactitud mide el porcentaje total de aciertos, pero en un conjunto con una proporción de 1 a 5 entre clases puede engañar, como se vio en la Sección 2.5. Por eso se complementa con la sensibilidad, que indica qué proporción de las épocas con P300 fueron detectadas, con la precisión, que indica qué proporción de las detecciones fueron correctas, y con el F1-score, que es la media armónica de ambas [43].

2.10.3. Curva ROC y área bajo la curva

Los clasificadores de la P300 suelen producir un puntaje continuo, y la etiqueta final depende del umbral que se elija: al disminuirlo se detectan más épocas con P300, pero también aumentan los falsos positivos. La curva ROC (*Receiver Operating Characteristic*) representa

Tabla 2.5: Métricas de evaluación para la clasificación binaria

Métrica	**Descripción**	**Fórmula**
Exactitud (*accuracy*)	Proporción de predicciones correctas sobre el total.	$\frac{TP+TN}{TP+TN+FP+FN}$
Precisión (*precision*)	Proporción de épocas clasificadas como P300 que realmente lo son.	$\frac{TP}{TP+FP}$
Sensibilidad (*recall*, TPR)	Proporción de épocas con P300 que fueron detectadas.	$\frac{TP}{TP+FN}$
F1-score	Media armónica entre precisión y sensibilidad.	$2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$

Elaboración propia con información de [43].

este compromiso. Para ello, grafica la sensibilidad contra la proporción de épocas sin P300 clasificadas como positivas en todos los umbrales posibles. El área bajo esta curva (AUC) resume el desempeño en un solo número. Este valor indica la probabilidad de que el clasificador dé un puntaje mayor a una época positiva que a una negativa, ambas elegidas al azar [43]. Un AUC de 0.5 corresponde a un clasificador aleatorio, en el que los puntajes de ambas clases se superponen. Un AUC de 1 indica una separación perfecta. Esta es la métrica utilizada en los trabajos de Alvarado-González et al. y de Contreras. Este último la considera aceptable a partir de 0.7 [13], [34].

2.10.4. Métricas a nivel de sistema

Un AUC alto en la clasificación de épocas no garantiza por sí sola una comunicación eficiente, pues la velocidad depende también del número de repeticiones necesarias para seleccionar cada carácter. En los sistemas de deletreo se reporta además la exactitud por carácter en función del número de repeticiones, los caracteres por minuto y la tasa de transferencia de información (ITR), que de acuerdo con Wolpaw et al. se calcula en bits por selección como [7], [44]

$$B = \log_2 N + P \log_2 P + (1-P) \log_2 \left(\frac{1-P}{N-1} \right), \tag{2.8}$$

donde N es el número de opciones posibles, 36 en una matriz de 6×6, y P es la exactitud por carácter. Al multiplicar B por el número de selecciones por minuto se obtiene la ITR en bits por minuto. Con la misma exactitud, usar menos repeticiones sube la ITR porque caben más selecciones en un minuto. En la práctica, sin embargo, menos repeticiones también bajan la exactitud, y el número óptimo de repeticiones queda en el punto donde la ganancia en velocidad todavía compensa los errores.

2.11. Reducción de canales y repeticiones

Como se señaló en la introducción, los sistemas P300 basados en EEG suelen alcanzar una alta exactitud a costa de utilizar muchos electrodos y de repetir varias veces la estimulación de cada fila y columna. Ambos factores afectan directamente la practicidad del sistema: un mayor número de canales incrementa el costo del equipo y el tiempo necesario para colocar los electrodos, además de dificultar su uso fuera del laboratorio, mientras que un mayor número de repeticiones reduce la velocidad de comunicación y aumenta la fatiga del usuario [13], [27].

2.11.1. Selección de canales

La selección de canales busca identificar el subconjunto mínimo de electrodos que conserve la información necesaria para detectar la P300. Krusienski et al. evaluaron distintos conjuntos de electrodos. El mejor fue un conjunto de ocho canales (Fz, Cz, Pz, P3, P4, PO7, PO8 y Oz), que combina posiciones de la línea media con posiciones parieto-occipitales. Este conjunto superó a los tres canales de la línea media que se usaban tradicionalmente [27]. Por otra parte, Cecotti y Gräser aprovecharon los pesos aprendidos por la capa espacial de su CNN para ordenar los electrodos según su contribución a la clasificación y eliminar los menos relevantes [29], estrategia que resulta natural en arquitecturas como EEGNet, cuya convolución *depthwise* aprende explícitamente un peso por electrodo [37]. En el extremo opuesto, Contreras trabajó con solo cuatro electrodos de la línea media y obtuvo valores de AUC aceptables en la evaluación intrasujeto [13].

En el caso de este trabajo, el casco elegido coloca sus 14 electrodos en las posiciones AF3, F7, F3, FC5, T7, P7, O1, O2, P8, T8, FC6, F4, F8 y AF4, con las referencias en P3 y P4 [15]. Esto significa que no cubre la línea media, donde la P300 alcanza su mayor amplitud, ni las posiciones PO7 y PO8 del conjunto propuesto por Krusienski et al. La selección de canales, entonces, se hará dentro de estos 14 electrodos, entre los cuales O1, O2, P7 y P8 son los más cercanos a la región parieto-occipital. Las 14 posiciones forman parte del montaje de 64 canales de la base de datos II de la competencia BCI III [14], y con ella se pueden hacer los experimentos de reducción de canales usando solo los electrodos que tiene el casco.

2.11.2. Reducción de repeticiones

De acuerdo con la Ecuación (2.1), cada repetición adicional mejora la relación señal-ruido de la P300 en un factor proporcional a $\sqrt{N}$, pero también añade alrededor de 2.1 s al tiempo de cada selección con los parámetros de la base de datos de la competencia BCI III. Una primera estrategia para reducir las repeticiones consiste en mejorar la clasificación de ensayo único, es decir, la capacidad del modelo de detectar la P300 en una sola época sin promediarla con otras, objetivo que persiguen las arquitecturas convolucionales descritas en la Sección 2.9 [29], [37]. En este trabajo se buscará el menor número de repeticiones que mantenga una exactitud aceptable, y ese número será el mismo para todo el sistema.

2.12. Modelado del lenguaje y predicción de palabras

2.12.1. Predicción de palabras en la comunicación asistida

Aun con una detección perfecta de la P300, escribir carácter por carácter en un P300 Speller es un proceso lento, pues cada selección requiere varios segundos. La predicción de palabras, ampliamente utilizada en los sistemas de comunicación aumentativa, reduce el número de selecciones porque le ofrece al usuario una lista de palabras probables a partir de lo que ya escribió, y con una sola selección más puede completar la palabra. Ryan et al. integraron este mecanismo en un P300 Speller agregando a la matriz una región con las palabras sugeridas, y encontraron que los participantes completaban las frases en menos tiempo que con el deletreador convencional, aunque con una exactitud por selección ligeramente menor [45]. El beneficio de estos sistemas suele medirse mediante el ahorro de selecciones,

$$\mathrm{AS} = \frac{S_{\mathrm{sin}} - S_{\mathrm{con}}}{S_{\mathrm{sin}}} \times 100\,\%, \tag{2.9}$$

donde S_{sin} y S_{con} son el número de selecciones necesarias para escribir un mismo texto sin y con predicción, respectivamente.

2.12.2. Modelos de lenguaje

Un modelo de lenguaje asigna una probabilidad a cada secuencia de palabras, y con ella se puede estimar cuál es la palabra, o el carácter, más probable dado lo que se ha escrito. Los modelos más simples son los de n-gramas, que suponen que cada palabra depende únicamente de las $n-1$ palabras anteriores. Sus probabilidades se estiman contando cuántas veces aparece cada secuencia en un corpus de texto [46]. Debido a que están limitados a un contexto corto y fijo, han sido reemplazados progresivamente por modelos neuronales, entre ellos los modelos de lenguaje de gran escala (LLM), entrenados con enormes cantidades de texto [47].

2.12.3. Integración del lenguaje en el P300 Speller

La información del lenguaje puede incorporarse al P300 Speller de dos maneras: como sugerencias explícitas que el usuario selecciona, o como una probabilidad previa que se combina con los puntajes del clasificador para decidir el carácter. Speier et al. siguieron la segunda vía, integrando un modelo de lenguaje en el proceso de clasificación dinámica, y reportaron mejoras tanto en la exactitud como en la tasa de transferencia de información [48]. Más recientemente, Hong et al. propusieron ChatBCI, un P300 Speller que utiliza un LLM para predecir palabras según el contexto de la frase, logrando una reducción del tiempo promedio de escritura de 62.14 % [49].

2.13. Estado del arte

2.13.1. Sistemas P300 Speller y competencias BCI

A partir del deletreador de Farwell y Donchin [2], la investigación sobre el P300 Speller se centró durante varios años en mejorar la clasificación de las épocas con métodos lineales. Las competencias internacionales de BCI jugaron un papel central en este proceso, pues pusieron a disposición de la comunidad bases de datos comunes. En la tercera de ellas, el conjunto de SVM lineales propuesto por Rakotomamonjy y Guigue obtuvo el primer lugar al identificar correctamente el 96.5 % de los caracteres de prueba con 15 repeticiones [28]. En paralelo, Krusienski et al. mostraron que el SWLDA y el discriminante de Fisher eran los clasificadores más robustos entre los evaluados [50], y posteriormente que una adecuada selección de ocho electrodos permitía mejorar el desempeño respecto al uso exclusivo de la línea media [27].

2.13.2. Sistemas de comunicación con usuarios con discapacidad

La validación con usuarios reales ha sido otra línea importante de investigación. Sellers y Donchin realizaron las primeras pruebas de un P300 Speller con pacientes con ELA [8]. Hoffmann et al. propusieron un sistema de seis opciones que evaluaron con personas con distintas discapacidades motoras. Sus registros son hoy una de las bases de datos públicas más utilizadas [51]. En el ámbito latinoamericano, García Cossio et al. desarrollaron un sistema de deletreo con una matriz de estimulación visual [52]. Lo probaron con dos adolescentes con discapacidad motora y obtuvieron porcentajes de acierto promedio de 95 % y 85 % en la prueba de libre deletreo. Por otro lado, Brunner et al. [53] operaron un P300 Speller con señales de electrocorticografía y sostuvieron velocidades superiores a 17 caracteres por minuto, aunque al tratarse de una técnica invasiva, que requiere colocar electrodos directamente sobre la corteza, su uso fuera de entornos clínicos especializados resulta difícil y el EEG sigue siendo la opción más accesible.

2.13.3. Aprendizaje profundo para la detección de la P300

Con la introducción de las redes convolucionales, Cecotti y Gräser mostraron que era posible aprender directamente los filtros espaciales y temporales a partir de la señal, obteniendo en la competencia BCI III resultados comparables a los del ganador [29]. A partir de entonces se propusieron arquitecturas como BN3 [54], OCLNN [55] y EEGNet [37], y la comparación de Alvarado-González et al. mostró que redes muy compactas como SepConv1D, con apenas cuatro filtros en su única capa convolucional, pueden alcanzar un AUC similar al de redes mucho más grandes [34].

Dentro del IPN, en la Escuela Superior de Cómputo, Contreras presentó la tesis de maestría “Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil” [13], en la que se emplea la arquitectura SepConv1D para detectar la P300 a partir de solo cuatro electrodos secos. Al considerar filas y columnas, reportó valores promedio

de AUC cercanos a 0.82 en la evaluación intrasujeto y de 0.70 en la intersujeto, esta última sin calibración individual. Con ello se comprobó que es posible reunir en un mismo sistema funcional el procesamiento del EEG, la extracción automática de características y un modelo de aprendizaje profundo, si bien el sistema se diseñó para controlar una neuroprótesis y no para deletrear mensajes. En la misma escuela, Santos, Romero y Fernández desarrollaron una aplicación para manipular un brazo robótico virtual mediante potenciales P300 con matrices de 5×5 de iconos y de letras, clasificadas con el discriminante lineal de Fisher [56].

2.13.4. Resumen comparativo

Al comparar los trabajos revisados se observa que los sistemas P300 basados en EEG siguen dependiendo de dos factores para alcanzar una buena exactitud, el uso de muchos canales y la repetición de los estímulos varias veces antes de decidir cada carácter. La Tabla 2.6 resume los enfoques descritos, contrastando el número de canales empleados, el clasificador, el uso de un modelo de lenguaje y el desempeño reportado por cada trabajo frente a la propuesta del presente Trabajo Terminal.

Tabla 2.6: Resumen comparativo del estado del arte

Trabajo	**Señal / canales**	**Clasificador**	**Modelo de lenguaje**	**Desempeño**
Farwell y Donchin, 1988 [2]	EEG / 1 (Pz)	SWDA, pico, área y covarianza	No	Exactitud $\approx 95\,\%$, 2.3 caracteres/min
Sellers y Donchin, 2006 [8]	EEG	–	No	Primeras pruebas con pacientes con ELA
Rakotomamonjy y Guigue, 2008 [28]	EEG / 64	Conjunto de SVM	No	96.5 % de caracteres con 15 repeticiones
Krusienski et al., 2008 [27]	EEG / 8	SWLDA	No	Conjunto de 8 canales superior a la línea media
Cecotti y Gräser, 2011 [29]	EEG / 64	CNN	No	$\approx 95\,\%$ de caracteres con 15 repeticiones
García Cossio et al., 2011 [52]	EEG / 6	–	No	Acierto de 95 % y 85 % en libre deletreo
Brunner et al., 2011 [53]	ECoG / 96 subdurales	SWLDA	No	17 caracteres/min
Ryan et al., 2011 [45]	EEG	–	Diccionario	Menor tiempo por frase
Speier et al., 2012 [48]	EEG	Clasificación dinámica	Probabilístico	Mayor exactitud y tasa de transferencia
Santos et al., 2017 (ESCOM) [56]	EEG	LDA de Fisher	No	Precisión de 90.01 % (20 sujetos)
Alvarado-González et al., 2021 [34]	EEG / varios	SepConv1D y otras 11 redes	No	AUC intra ≈ 0.84, inter ≈ 0.78
Contreras, 2021 (IPN) [13]	EEG / 4	SepConv1D	No	AUC ≈ 0.82 (intrasujeto), ≈ 0.70 (intersujeto)
ChatBCI, Hong et al., 2026 [49]	EEG / 32	–	LLM	Reducción de tiempo promedio de 62.14 %
Propuesta TT	EEG / 14	Aprendizaje profundo (CNN)	Predicción de palabras	–

Elaboración propia.

3. Propuesta a desarrollar

Se propone el desarrollo de un sistema de comunicación asistida implementado en Python que permita a personas con compromisos motores severos construir mensajes a partir de sus señales electroencefalográficas, empleando el paradigma P300 Speller descrito en la Sección 2.5. El sistema presentará al usuario una matriz visual de caracteres cuyas filas y columnas se iluminarán de manera aleatoria mientras este concentra su atención en el carácter que desea seleccionar, y las épocas de EEG asociadas a cada intensificación serán clasificadas por un modelo de aprendizaje profundo como objetivo o no objetivo, y a partir de estas clasificaciones se determinará el carácter elegido [2]. Para agilizar la escritura, el texto construido hasta ese momento alimentará un módulo de predicción de palabras que mostrará sugerencias al usuario, de modo que una palabra completa pueda seleccionarse sin deletrearla letra por letra, enfoque que ha mostrado reducir el tiempo de escritura en sistemas de este tipo [45], [49].

El desarrollo del modelo se apoyará en dos fuentes de datos. Las bases de datos públicas del paradigma P300, principalmente la base de datos II de la tercera competencia internacional de BCI [14], se emplearán para comparar arquitecturas de clasificación, definir el preprocesamiento y evaluar estrategias para reducir el número de canales y el número de repeticiones necesarias por carácter, a fin de acercar el sistema a condiciones de uso más prácticas sin comprometer de manera importante su exactitud, que son las dos limitaciones persistentes identificadas en el estado del arte. Debido a que el desempeño de un modelo entrenado con datos de otras personas suele ser menor que el de uno ajustado al propio usuario [34], el modelo de cada usuario se entrenará además con señales propias registradas en una sesión de calibración con un casco comercial de 14 canales, lo que evita depender de equipo especializado de 64 canales. Esta calibración formará parte del registro del usuario en el sistema, que al concluirla entrenará de forma automática su modelo con la arquitectura y la configuración seleccionadas a partir de las bases de datos públicas. Para que esa configuración sea válida con el casco, de la base de datos pública solo se usarán los 14 canales que coinciden con los del casco, y las señales de ambas fuentes se remuestrearán a una misma frecuencia.

3.1. Arquitectura del sistema

La arquitectura general del sistema se compone de las etapas que se muestran en la Figura 3.1: la adquisición de las señales EEG, que durante la exploración provienen de bases de datos públicas y durante la calibración y el uso del sistema, del casco de 14 canales, su preprocesamiento, el entrenamiento del modelo de aprendizaje profundo, la clasificación de los estímulos como objetivo o no objetivo y, finalmente, la construcción del texto apoyada por el modelo de predicción de palabras, que mostrará sugerencias a partir de los caracteres seleccionados hasta ese momento.

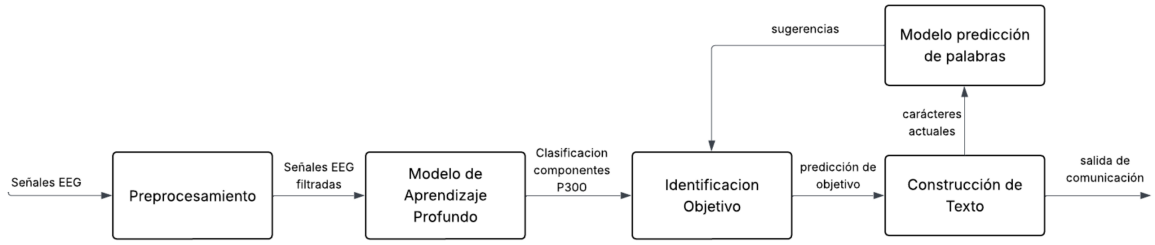


Figura 3.1: Arquitectura del sistema. Elaboración propia.

La etapa de preprocesamiento aplicará las técnicas descritas en la Sección 2.6, entre ellas el filtrado pasa banda, el remuestreo, la segmentación en ventanas temporales posteriores a cada estímulo y la normalización de cada canal, de las cuales resultará el conjunto de datos con el que se entrenará y validará el modelo. El modelo de detección se construirá con la biblioteca PyTorch, y para el procesamiento y manipulación de los datos se emplearán bibliotecas como NumPy y Pandas. La interfaz gráfica, por su parte, se desarrollará con PyQt e integrará la matriz visual del P300 Speller, el área en la que se muestra el texto construido y las sugerencias del módulo de predicción de palabras.

El sistema se implementará inicialmente en una computadora con sistema operativo Windows, en la que se realizará el entrenamiento, la validación y la inferencia de los modelos. Asimismo, se analizará la viabilidad de ejecutar únicamente la etapa de inferencia en un microordenador NVIDIA Jetson, para evaluar si es posible una implementación más portable, en línea con el uso de arquitecturas compactas como EEGNet o SepConv1D, cuyo reducido número de parámetros las hace convenientes para dispositivos con recursos limitados [34], [37].

3.2. Flujo de operación

Durante el uso del sistema, la selección de cada carácter sigue el ciclo que se representa en la Figura 3.2. Las filas y columnas de la matriz se intensifican en orden aleatorio y el usuario mantiene su atención en el carácter que desea escribir, de modo que cuando la fila o la columna que lo contiene se ilumina, se genera un potencial P300 aproximadamente 300 ms después del estímulo [2], [20]. La señal registrada se divide en épocas sincronizadas con cada intensificación, que después de ser preprocesadas se entregan al modelo, el cual asigna a cada una un puntaje que refleja la probabilidad de que contenga una P300. Estos puntajes se acumulan por fila y por columna a lo largo de las repeticiones, conforme a la Ecuación (2.2), y el carácter seleccionado corresponde a la intersección de la fila y la columna con el puntaje más alto.

Una vez que el carácter se agrega al texto, el módulo de predicción de palabras estima las palabras más probables a partir de los caracteres escritos, siguiendo alguno de los enfoques de modelado del lenguaje revisados en la Sección 2.12, y las presenta en la interfaz como opciones adicionales que el usuario puede seleccionar mediante el mismo mecanismo de atención. Así, cada selección puede corresponder a un carácter o a una palabra completa. El número de repeticiones por selección será uno de los parámetros a optimizar, porque determina directamente

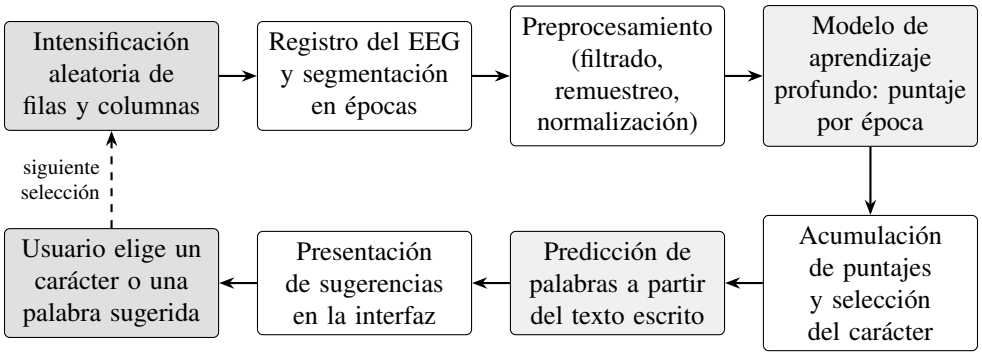


Figura 3.2: Flujo de operación para la selección de un carácter o de una palabra sugerida. Elaboración propia.

la tasa de transferencia de información del sistema (Sección 2.10), y una vez elegido será el mismo para todo el sistema.

3.3. Alcance del sistema

En esta sección se delimita lo que el sistema incluirá y lo que quedará fuera del presente Trabajo Terminal.

1. **Datos:**
   - La base de datos II de la competencia BCI III se usará en la fase exploratoria para comparar arquitecturas, definir el preprocesamiento y evaluar la reducción de canales y repeticiones.
   - Las señales propias se registrarán con el casco Emotiv EPOC X de 14 canales.
   - Las pruebas con señales propias se realizarán con voluntarios.
2. **Modelo de detección de la componente P300:**
   - El modelo se entrenará de forma individual para cada usuario a partir de su sesión de calibración.
   - Un modelo solo se aceptará si alcanza una exactitud por carácter de al menos 70 %.
3. **Predicción de palabras:**
   - La técnica de predicción se seleccionará durante el Trabajo Terminal II.
4. **Desarrollo e integración:**
   - El sistema se desarrollará en Python con PyQt y se implementará en una computadora con Windows.
   - Se analizará la viabilidad de ejecutar la inferencia del modelo en un microordenador NVIDIA Jetson.

- El usuario interactuará con el sistema solo mediante su atención a la matriz, y el operador se encargará de preparar y supervisar cada sesión.
- El sistema no guardará los mensajes que escriba el usuario.

3.4. Metodología

El desarrollo del presente Trabajo Terminal se realizará mediante una combinación de dos metodologías, dado que el proyecto involucra tanto la construcción de un sistema de software como la de un modelo de aprendizaje profundo. Para el desarrollo general del sistema se empleará un modelo de desarrollo incremental, mientras que para el modelo de detección de la componente P300 se utilizará la metodología CRISP-ML, la cual estructura el proceso de construcción, validación y optimización de modelos de aprendizaje automático en fases iterativas [57]. Ambas metodologías se ejecutarán en paralelo y convergerán en el último incremento del sistema, en el que la arquitectura seleccionada y el procedimiento para entrenarla se incorporan a la aplicación.

3.4.1. Metodología de desarrollo del sistema

En el modelo incremental, el software se construye de manera progresiva mediante una serie de incrementos, cada uno de los cuales agrega funcionalidad a los anteriores y produce una versión operativa que puede evaluarse antes de continuar con el siguiente. Este modelo combina flujos de proceso lineales y paralelos. Los requerimientos generales y la arquitectura se establecen al inicio para todo el sistema, y a partir de ellos los incrementos se construyen de forma escalonada en el tiempo, lo que permite que dos incrementos se desarrollen de manera simultánea cuando corresponden a módulos independientes [58].

En consecuencia, el diseño del sistema se realizará en dos niveles. El primero es el diseño general o arquitectónico, que define los módulos que componen el sistema, la responsabilidad de cada uno, la forma en que intercambian información y el segundo es el diseño detallado o a nivel de componentes, que especifica cómo se implementará internamente cada módulo. El diseño general se realizará durante el Trabajo Terminal I, ya que fija los elementos que no cambiarán a lo largo del desarrollo y permite que los módulos se construyan por separado y se integren sin conflictos. El diseño detallado, en cambio, se realizará al inicio de cada incremento durante el Trabajo Terminal II, debido a que varias de sus decisiones dependen de resultados que se obtendrán en ese periodo, como el número de canales que recibirá el modelo de detección dependerá de los experimentos de reducción de canales. La Figura 3.3 ilustra esta metodología.

Análisis y diseño general

Esta etapa se llevará a cabo durante el Trabajo Terminal I, de agosto a noviembre, y sus resultados se presentan en el Capítulo 4. Comprende las siguientes actividades:

1. **Definición de requerimientos del sistema.** A partir de una revisión del estado del arte se identificarán los requerimientos funcionales y no funcionales del sistema de comunica-

ción asistida, así como las características que deberá cumplir la interfaz de usuario y los módulos que integrarán la aplicación.

2. **Diseño de la arquitectura del sistema.** Se definirá la arquitectura general, identificando los módulos que la conforman y las interacciones entre ellos, y entre estos se consideran el módulo de detección de la componente P300, el módulo de predicción de palabras y la interfaz de usuario. En esta etapa se definirán también las entradas y salidas de cada módulo, es decir, los datos que recibe y los que entrega a los demás, así como el flujo completo del sistema, desde la adquisición de las señales EEG hasta la presentación del texto y las sugerencias en la interfaz.

3. **Diseño del módulo de predicción de palabras.** Aquí se determinará la función del módulo dentro del sistema y los enfoques de modelado del lenguaje que podrán emplearse, de entre los revisados en la Sección 2.12.

4. **Diseño de la interfaz de usuario.** Los prototipos de la interfaz gráfica, mediante la cual el usuario interactuará con la matriz del P300 Speller y con las sugerencias del módulo de predicción de palabras, se desarrollarán en esta misma etapa.

Incrementos del sistema

Durante el Trabajo Terminal II el sistema se construirá mediante tres incrementos. Cada uno seguirá el mismo ciclo: diseño detallado del módulo correspondiente, codificación, pruebas del módulo y de su integración con las versiones anteriores y, finalmente, la entrega de una versión operativa que servirá como base para el siguiente incremento. Los incrementos considerados son los siguientes:

1. **Incremento 1: módulo de predicción de palabras (enero a marzo).** En el diseño detallado se seleccionará la técnica de predicción y se elaborará el diagrama de clases del módulo. Posteriormente se implementará el módulo, cuyas pruebas verificarán que las sugerencias sean coherentes con el texto introducido y medirán el ahorro de selecciones obtenido al escribir frases de prueba. Como resultado se obtendrá una primera versión capaz de construir texto y generar sugerencias.

2. **Incremento 2: interfaz de usuario y matriz del P300 Speller (febrero a marzo).** En el diseño detallado se definirán las clases de la interfaz, el control de los tiempos de intensificación y el registro de los eventos de estimulación. Después se implementará la interfaz gráfica con la matriz de caracteres, la intensificación aleatoria de filas y columnas, el área de texto y la presentación de las sugerencias del incremento anterior. Debido a que en este punto el modelo de detección aún se encontrará en desarrollo, la selección de caracteres se probará en un modo de simulación que utiliza las etiquetas de la base de datos, lo que permitirá validar el funcionamiento de la interfaz de manera independiente. Con ello se contará con una segunda versión que incluye la interfaz completa.

3. **Incremento 3: calibración e integración del modelo de detección de la componente P300 (marzo a abril).** En el diseño detallado se definirá el modo de calibración, la forma en que el sistema entrenará y validará el modelo de cada usuario con la arquitectura y la configuración obtenidas mediante la metodología CRISP-ML, la forma de entregarle las épocas de EEG y de acumular sus puntajes por fila y columna, así como el número de repeticiones que se empleará, de acuerdo con los resultados de la evaluación del modelo. A continuación se implementarán la calibración, el entrenamiento automático y la selección del carácter conforme a la Ecuación (2.2), sustituyendo el modo de simulación del incremento anterior. Las pruebas de este incremento consistirán en ejecutar el entrenamiento automático con los caracteres de entrenamiento de la base de datos II de la competencia BCI III, como si se tratara de una sesión de calibración, y en deletrear sus caracteres de prueba, midiendo la exactitud por carácter y la tasa de transferencia de información. En estas pruebas se emplearán únicamente los 14 canales equivalentes a los del casco. Además, como la matriz de esa base de datos contiene letras, dígitos y un guion bajo, y por lo tanto es distinta a la del sistema, el acierto se evaluará comparando la fila y la columna decodificadas con las del carácter objetivo, sin depender del símbolo que muestre la interfaz. El resultado será la tercera versión, que corresponde al sistema completo.

Los incrementos 1 y 2 se desarrollarán de manera simultánea durante febrero y marzo, lo cual es posible porque corresponden a módulos independientes y a que las entradas y salidas de cada módulo quedarán definidas en el diseño general. Mientras el módulo de predicción no esté terminado, la interfaz empleará una versión provisional de este que entrega sugerencias fijas, la cual será sustituida por el módulo real al concluir el primer incremento. El tercer incremento, en cambio, no puede comenzar sino hasta contar con la interfaz y con la arquitectura y la configuración del modelo definidas mediante CRISP-ML, por lo que se ubica al final.

Pruebas del sistema y documentación

Una vez concluidos los incrementos, entre abril y mayo se realizarán las pruebas funcionales del sistema completo, para verificar la interacción entre los módulos y la correcta construcción de palabras mediante el paradigma P300 Speller, tanto con las bases de datos públicas como con voluntarios que utilicen el casco. En estas pruebas se medirán la exactitud por carácter y la tasa de transferencia de información descritas en la Sección 2.10, así como el ahorro de selecciones que aporta la predicción de palabras, definido en la Sección 2.12. En esta misma etapa se analizará la viabilidad de ejecutar la inferencia del modelo en un microordenador NVIDIA Jetson. Por su parte, la documentación técnica y el manual de usuario se elaborarán de forma progresiva a lo largo de todo el proyecto, registrando las decisiones de diseño de cada etapa y las funciones de cada versión conforme se entregan, y se consolidarán en su versión final al término de las pruebas del sistema.

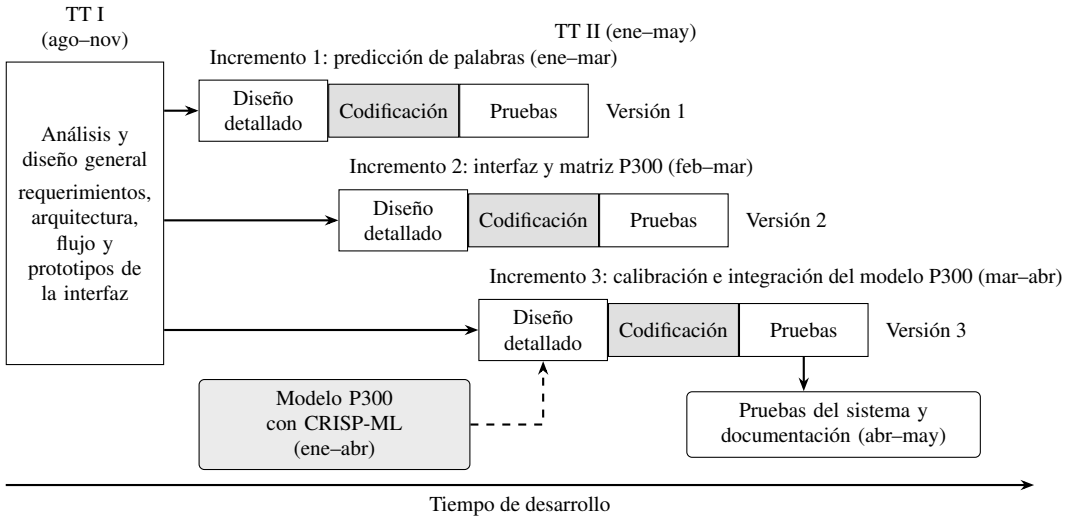


Figura 3.3: Organización del desarrollo del sistema mediante el modelo incremental. Elaboración propia con base en [58].

3.4.2. Metodología para el desarrollo del modelo de aprendizaje profundo

El modelo de detección de la componente P300 se desarrollará siguiendo la metodología CRISP-ML, una adaptación del proceso CRISP-DM para proyectos de aprendizaje automático que organiza el trabajo en fases con retroalimentación entre ellas, lo que permite regresar a la preparación de los datos o al modelado cuando los resultados de la evaluación no son satisfactorios [57]. En su forma original, CRISP-ML(Q) considera seis fases: comprensión del negocio y de los datos, preparación de los datos, ingeniería del modelo, evaluación del modelo, despliegue, y monitoreo y mantenimiento [57]. En el presente trabajo se emplea una adaptación de estas fases: la comprensión del problema y la de los datos se tratan por separado, debido a que la selección y el análisis de las bases de datos públicas constituyen una tarea propia, el despliegue corresponde a la integración del modelo en el sistema, que se realiza en el tercer incremento, y se omite la fase de monitoreo y mantenimiento, ya que el sistema se evaluará con bases de datos públicas y con sesiones controladas de voluntarios, sin ponerse en operación de forma continua. La Figura 3.4 muestra el ciclo de estas fases, que en el presente trabajo se describen a continuación:

1. **Comprensión del problema.** Se establecerán los objetivos particulares de detección del modelo, las métricas con las que se evaluará su desempeño y las estrategias de validación que se emplearán, tanto intrasujeto como intersujeto.

2. **Comprensión y análisis de los datos.** Se seleccionarán bases de datos públicas de señales EEG asociadas al paradigma P300 Speller, analizando su estructura, número de sujetos y cantidad de canales, para determinar qué características son necesarias al entrenar el modelo. Asimismo, se definirá el protocolo de registro de las señales propias, que incluye el número de voluntarios, la duración de la sesión de calibración y los canales del casco que se emplearán.

3. **Preparación de los datos.** Se diseñará e implementará el *pipeline* de preprocesamiento, que aplicará, tanto a las bases de datos públicas como a las señales del casco, técnicas como el filtrado pasa banda, la división en ventanas temporales y la normalización, de las que se obtendrá el conjunto de datos sobre el cual se entrenará y validará el modelo de detección de la componente P300.

4. **Diseño y modelado.** Durante el Trabajo Terminal I se definirán las posibles arquitecturas de aprendizaje profundo para la detección de la componente P300 y se diseñarán los experimentos orientados a la reducción del número de canales y de repeticiones. Durante el Trabajo Terminal II se implementarán y entrenarán dichas arquitecturas, se realizará el ajuste de hiperparámetros y se ejecutarán los experimentos diseñados, con el fin de seleccionar la arquitectura y la configuración con las que el sistema entrenará el modelo de cada usuario a partir de su sesión de calibración.

5. **Evaluación.** Se analizará el desempeño del modelo mediante métricas de clasificación como la exactitud, la sensibilidad, la precisión, el F1-score y el área bajo la curva ROC (AUC), además de la construcción de la matriz de confusión. A nivel del sistema se medirá la exactitud por carácter, que es la que decide si el modelo de un usuario se acepta, y se evaluará el impacto de la reducción de canales y repeticiones en el rendimiento del sistema. Si los resultados no son satisfactorios, se regresará a la preparación de los datos o al modelado.

6. **Integración del modelo.** La arquitectura seleccionada, junto con el procedimiento para entrenarla y validarla, se integrará en el sistema completo de comunicación asistida durante el tercer incremento descrito en la Sección 3.4.1, de modo que el modelo de cada usuario se entrene dentro de la aplicación al concluir su calibración.

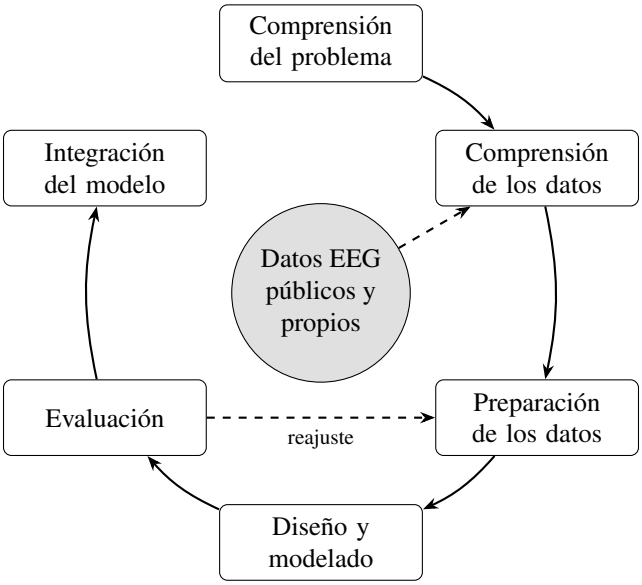


Figura 3.4: Fases de la metodología CRISP-ML aplicadas al desarrollo del modelo de detección de la componente P300. Elaboración propia con base en [57].

4. Análisis y diseño

En este capítulo se presentan el análisis y el diseño del sistema, que corresponden a la etapa de análisis y diseño general del modelo incremental descrita en la Sección 3.4.1. De acuerdo con Pressman, el análisis define qué debe hacer el software, mientras que el diseño define cómo lo hará [58].

El análisis parte de las reglas de negocio del paradigma P300 Speller. A partir de ellas se obtienen los requerimientos funcionales y no funcionales, el catálogo de mensajes y los casos de uso, que describen lo que hacen el usuario, el operador y el casco EEG en cada parte del sistema, desde la creación de una cuenta hasta el deletreo.

El diseño toma esos resultados y los traduce en la estructura del programa. Para ello se presentan la arquitectura de software, los diagramas de clases y de objetos, la estructura de almacenamiento, los diagramas de flujo de los procesos principales, el diagrama de estados, los diagramas de secuencia, el diseño del módulo de predicción de palabras y los mockups de la interfaz.

4.1. Reglas de negocio

Las reglas de negocio son las condiciones y restricciones del dominio que el sistema tiene que respetar sin importar cómo se implemente, y de ellas salen tanto los requerimientos como varias de las validaciones de los casos de uso. En este trabajo la mayoría viene del funcionamiento del paradigma P300 Speller descrito en la Sección 2.5, y otras surgen de que la herramienta será utilizada por varias personas, cada una con su propio modelo de detección y sus propios registros. La Tabla 4.1 las resume.

Tabla 4.1: Reglas de negocio del sistema

Clave	Nombre	Descripción
RN-1	Cuenta de usuario	Cada persona que utilice el sistema deberá contar con una cuenta propia y acceder a ella mediante un inicio de sesión.
RN-2	Secuencia de estimulación	Una secuencia consiste en la intensificación aleatoria de cada fila y de cada columna de la matriz exactamente una vez.
RN-3	Carácter seleccionado	El elemento seleccionado es el que se encuentra en la intersección de la fila y la columna con mayor puntaje acumulado a lo largo de las repeticiones.
RN-4	Tipo de selección	Cada selección corresponde a un carácter, a una palabra sugerida o al comando de borrado.
RN-5	Sincronización de épocas	Cada época de EEG deberá asociarse a una única intensificación, la que se presentó en el instante en que inicia dicha época.
RN-6	Consentimiento y privacidad de las señales	Las señales EEG de una persona solo se registrarán con su consentimiento informado, se asociarán únicamente a su cuenta y solo podrán consultarlas ella y el operador.
RN-7	Modelo por usuario	Cada usuario contará con un modelo de detección que el sistema entrena con los registros de su propia sesión de calibración, y el sistema solo utilizará el modelo asociado a la cuenta con la que se inició sesión.
RN-8	Calibración previa	Un usuario solo podrá iniciar el deletreo cuando su cuenta cuente con un modelo de detección entrenado.

Elaboración propia.

4.2. Requerimientos

Los requerimientos funcionales establecen lo que el sistema debe hacer, es decir, los servicios que ofrece y cómo responde a cada entrada. Los no funcionales, en cambio, describen atributos de calidad como el rendimiento, la usabilidad, la confiabilidad, la seguridad o la mantenibilidad, que no son por sí mismos una función del sistema [58]. Hay que aclarar que la exploración de arquitecturas con bases de datos públicas y la selección de la configuración del modelo las hacen antes quienes desarrollan el sistema (Sección 4.9.2) y no la aplicación. Dentro de la aplicación solo ocurre el entrenamiento del modelo de cada usuario, al terminar su calibración.

4.2.1. Requerimientos funcionales

Los requerimientos funcionales se agrupan según el módulo del sistema al que corresponden: la gestión de cuentas, la adquisición de señales y la calibración, el deletreo mediante el paradigma P300 Speller y la predicción de palabras.

Gestión de cuentas.

- **RF1:** El sistema deberá permitir al operador crear la cuenta de un usuario.
- **RF2:** El sistema deberá permitir al operador iniciar sesión con la cuenta existente de un usuario, de modo que cada usuario acceda únicamente a su propia información.
- **RF3:** El sistema deberá permitir al operador cerrar la sesión activa.

Adquisición de señales y calibración.

- **RF4:** El sistema deberá permitir al operador establecer la conexión con el casco EEG y, a partir de ella, recibir de forma continua las señales de sus canales durante la calibración y el deletreo.
- **RF5:** El sistema deberá registrar el instante y el tipo de cada intensificación presentada, es decir, la fila o columna iluminada, para asociar cada época de EEG con el estímulo que la provocó.
- **RF6:** El sistema deberá mostrar el estado de la señal de cada canal del casco y permitir al operador verificar su calidad antes de iniciar una calibración o una sesión de deletreo.
- **RF7:** El sistema deberá permitir al operador iniciar un modo de calibración en el que se indique al usuario el carácter en el que debe fijar su atención, se presenten las secuencias de estimulación y se registren las señales correspondientes, el cual podrá detenerse antes de que concluya y repetirse por indicación del operador cuando sea necesario actualizar el modelo del usuario.
- **RF8:** El sistema deberá guardar los registros de cada sesión de calibración, junto con los caracteres objetivo y los eventos de estimulación, en la cuenta del usuario que los generó.
- **RF9:** El sistema deberá entrenar de forma automática, al concluir la calibración, el modelo de detección del usuario a partir de sus registros, empleando la arquitectura y la configuración seleccionadas previamente, guardarlo en su cuenta y mostrar su avance al operador durante el proceso.
- **RF10:** El sistema deberá evaluar el modelo entrenado con una parte de los registros de calibración reservada para ese fin y, si su exactitud por carácter es menor al 70 %, valor que se considera el mínimo necesario para comunicarse mediante una BCI [59], informarlo y proponer que se repita la calibración.
- **RF11:** El sistema deberá cargar, al iniciar sesión, el modelo de detección entrenado para ese usuario y permitir al operador iniciar y detener el deletreo, impidiendo iniciarlo si la cuenta aún no tiene un modelo.

Deletreo mediante el P300 Speller.

- **RF12:** El sistema deberá mostrar una interfaz gráfica con una matriz de selección de 6×6 elementos que contenga las letras del alfabeto en español, el espacio y el comando de borrado, y cuyos elementos restantes se destinen a las sugerencias de palabras.
- **RF13:** El sistema deberá intensificar de manera aleatoria las filas y columnas de la matriz durante cada secuencia de estimulación.
- **RF14:** El sistema deberá preprocesar las señales recibidas del casco, aplicando el filtrado, la segmentación en épocas a partir de cada intensificación y la normalización.
- **RF15:** El sistema deberá clasificar cada época como objetivo o no objetivo con el modelo de detección del usuario, asignándole un puntaje de probabilidad.
- **RF16:** El sistema deberá determinar el elemento seleccionado a partir de la acumulación de los puntajes de cada fila y cada columna a lo largo de las repeticiones.
- **RF17:** El sistema deberá mostrar en la interfaz el texto construido por el usuario y actualizarlo después de cada selección.
- **RF18:** El sistema deberá permitir borrar el último carácter o la última palabra seleccionados mediante un elemento de la matriz.

Predicción de palabras.

- **RF19:** El sistema deberá generar sugerencias de palabras a partir de los caracteres escritos hasta ese momento.
- **RF20:** El sistema deberá presentar las sugerencias como elementos seleccionables y permitir elegirlas mediante el mismo mecanismo de estimulación y detección de la componente P300 que se emplea para los caracteres.

4.2.2. Requerimientos no funcionales

- **RNF1:** Una vez concluida la última repetición de una selección, el elemento seleccionado deberá mostrarse en la interfaz en un tiempo no mayor a un segundo, y las sugerencias de palabras deberán actualizarse antes de que inicie la siguiente secuencia de estimulación.
- **RNF2:** La matriz deberá mostrar caracteres claros sobre fondo oscuro, con un tamaño que permita leerlos sin dificultad a unos 60 cm de la pantalla, y al intensificarse los elementos deberán cambiar a un color claro que contraste con los que no lo están.
- **RNF3:** Una vez iniciada la sesión de deletreo, todas las acciones de escritura, selección de sugerencias y borrado deberán poder realizarse únicamente mediante la atención a la matriz, sin requerir teclado ni ratón.

- **RNF4:** La sesión de calibración deberá poder completarse en un tiempo no mayor a 15 minutos, con el fin de limitar la fatiga del usuario, y durante el entrenamiento automático del modelo la interfaz deberá mostrar su avance sin dejar de responder.
- **RNF5:** Si se pierde la conexión con el casco durante una sesión, el sistema deberá detener la estimulación, notificarlo al usuario y conservar el texto construido hasta ese momento.
- **RNF6:** Las contraseñas de los usuarios deberán almacenarse de forma que no puedan leerse directamente en los archivos del equipo.
- **RNF7:** La aplicación deberá permitir consultar los registros EEG de cada usuario únicamente a él y al operador, y estos deberán guardarse identificados solo con el identificador de la cuenta, sin nombre ni otros datos personales, de modo que no revelen la identidad del usuario si se consultan o copian fuera de la aplicación.
- **RNF8:** El sistema deberá tener una arquitectura modular que permita reemplazar el modelo de detección o el modelo de predicción de palabras sin modificar la interfaz.
- **RNF9:** La adquisición de señales deberá realizarse en un módulo independiente, de modo que el casco pueda sustituirse por otro dispositivo de EEG modificando únicamente dicho módulo.

4.3. Catálogo de mensajes

El catálogo de mensajes reúne los avisos que el sistema muestra durante su operación, agrupados por su propósito para que todas las pantallas usen el mismo lenguaje. Como el usuario interactúa casi siempre seleccionando elementos con la componente P300, los textos tienen que ser cortos y decir qué pasó y, si aplica, qué hacer después. Cada mensaje tiene una clave con la que se le menciona en los casos de uso de la Sección 4.4.

4.3.1. Mensajes de error

Los mensajes de error informan que una operación no pudo completarse, ya sea porque los datos proporcionados no son válidos, como al registrar una cuenta o iniciar sesión, o porque un recurso necesario no está disponible, como el modelo de detección o la conexión con el casco EEG, o porque el modelo entrenado no alcanza la exactitud mínima establecida.

La Tabla 4.2 reúne los mensajes de error del sistema.

Tabla 4.2: Mensajes de error

Clave	Causa	Contenido
MSJE1	Datos incompletos o no válidos al crear una cuenta o iniciar sesión (CU_01, CU_02).	Completa o corrige el campo indicado.
MSJE2	El identificador elegido ya pertenece a otra cuenta (CU_01).	Ya existe una cuenta con ese identificador. Elige otro.
MSJE3	El identificador o la contraseña no coinciden con los de una cuenta (CU_02).	El identificador o la contraseña son incorrectos.
MSJE4	No existe una cuenta con el identificador capturado (CU_02).	No existe una cuenta con ese identificador.
MSJE5	No fue posible guardar una cuenta, un registro de calibración o un modelo (CU_01, CU_06, CU_07).	No fue posible guardar la información. Intenta de nuevo.
MSJE6	Se perdió la conexión con el casco durante la calibración o el deletreo (CU_04, CU_06, CU_09).	Se perdió la conexión con el casco. La sesión se detuvo y el texto se conservó.
MSJE7	Uno o más canales presentan una señal deficiente (CU_05).	La señal de los canales marcados es deficiente. Ajusta sus electrodos.
MSJE8	El modelo entrenado no alcanzó la exactitud mínima establecida (CU_07).	El modelo no alcanzó la exactitud mínima. Repite la calibración.
MSJE9	Se intentó iniciar el deletreo con una cuenta sin modelo (CU_08).	Esta cuenta aún no tiene un modelo. Realiza la calibración.
MSJE10	El modelo de la cuenta no pudo cargarse o falló durante la clasificación (CU_08, CU_10).	No fue posible usar el modelo de detección. Repite la calibración.
MSJE11	No se encontró el casco o falló la conexión con él (CU_04).	No fue posible conectar el casco. Verifica que esté encendido y vuelve a intentarlo.

Elaboración propia.

4.3.2. Mensajes de confirmación

Los mensajes de confirmación aparecen antes de acciones que descartan o modifican información, como cerrar la sesión activa, detener una calibración o un deletreo en curso o repetir la calibración de una cuenta que ya tiene modelo, y le piden al operador que confirme. Van dirigidos al operador y no al usuario, ya que este último solo interactúa con la matriz. El borrado del último elemento no pide confirmación porque eso obligaría al usuario a hacer una selección más. La Tabla 4.3 presenta estos mensajes.

Tabla 4.3: Mensajes de confirmación

Clave	Causa	Contenido
MSJC1	El operador solicita cerrar la sesión activa (CU_03).	¿Deseas cerrar la sesión de este usuario?
MSJC2	El operador solicita detener una calibración en curso (CU_06).	¿Deseas detener la calibración? Los registros de esta sesión no se guardarán.
MSJC3	El operador inicia la calibración de una cuenta que ya tiene un modelo (CU_06).	Esta cuenta ya tiene un modelo y se reemplazará al terminar la calibración. ¿Deseas continuar?
MSJC4	El operador solicita detener el deletreo (CU_09).	¿Deseas detener el deletreo?

Elaboración propia.

4.3.3. Mensajes informativos

Los mensajes informativos notifican que una operación se realizó con éxito, por ejemplo la creación de una cuenta, el término de la calibración o el guardado del modelo entrenado.

La Tabla 4.4 presenta los mensajes informativos.

Tabla 4.4: Mensajes informativos

Clave	Causa	Contenido
MSJI1	La cuenta se creó correctamente (CU_01).	La cuenta se creó correctamente.
MSJI2	Concluyó la calibración e inició el entrenamiento (CU_06).	La calibración terminó. Se está entrenando el modelo.
MSJI3	El modelo aprobó la validación y se guardó en la cuenta (CU_07).	El modelo se guardó. El deletreo está habilitado.
MSJI4	Se seleccionó el comando de borrado con el texto vacío (CU_12).	No hay elementos para borrar.

Elaboración propia.

4.4. Casos de uso

Los casos de uso representan las funcionalidades del sistema y se definen a partir de los requerimientos funcionales. Cada uno describe una acción específica con sus precondiciones, sus pasos y los errores que pueden presentarse [58]. Los actores son los roles de las personas o sistemas externos que interactúan con esas funcionalidades, y en este trabajo son tres, el usuario que construye mensajes con el P300 Speller, el operador que prepara y supervisa las sesiones y el casco EEG que entrega las señales (Tabla 4.5).

4.4.1. Actores

Tabla 4.5: Actores del sistema

Actor	**Descripción**
Usuario	Es el actor principal del sistema y corresponde a la persona con compromiso motor severo. Tiene una cuenta propia y, una vez iniciada su sesión, interactúa con el sistema únicamente mediante su atención a la matriz del P300 Speller, con la que participa en la calibración y construye mensajes mediante la selección de caracteres o de palabras sugeridas.
Operador	Persona encargada de preparar y supervisar el uso del sistema, que en el presente trabajo corresponde a quienes lo desarrollan. Crea la cuenta del usuario e inicia su sesión, coloca el casco EEG, establece la conexión y verifica la calidad de la señal, inicia la sesión de calibración, supervisa el entrenamiento automático del modelo de detección del usuario e inicia el deletreo cuando la cuenta ya tiene su modelo.
Casco EEG	Actor externo que corresponde al casco Emotiv EPOC X de 14 canales, el cual entrega al sistema, en tiempo real, las señales electroencefalográficas del usuario, que se sincronizan con los estímulos presentados.

Elaboración propia.

Aparte de lo anterior, el operador explora arquitecturas y preprocesamiento con bases de datos públicas y elige la configuración del modelo antes de usar la aplicación y fuera de ella, así que esas actividades no aparecen como casos de uso. El entrenamiento del modelo de cada usuario sí lo hace la aplicación al concluir la calibración, y en esa parte el operador solo prepara la sesión y supervisa la calibración y el entrenamiento.

4.4.2. Casos de uso de gestión de sesiones

Este grupo comprende las funcionalidades que permiten a distintas personas utilizar la misma herramienta conservando cada una su propio espacio: crear una cuenta, iniciar sesión y cerrar la sesión activa.

Tabla 4.6: Caso de uso crear cuenta de usuario

Caso de uso	**Crear cuenta de usuario**
Identificador	CU_01
Requisitos asociados	RF1
Reglas de negocio	RN-1, RN-6
Actores	Operador
Descripción	El operador registra la cuenta de una persona que utilizará el sistema, con un identificador y una contraseña, a la cual se asociarán en adelante sus registros EEG y su modelo de detección.
Precondición	El operador cuenta con el consentimiento informado de la persona y ha iniciado la aplicación.
Pasos	1. Mostrar el formulario de registro (identificador de la cuenta y contraseña). 2. Validar que los datos estén completos y que el identificador no exista. 3. Guardar la cuenta con su contraseña. 4. Informar al operador que la cuenta fue creada con el mensaje MSJI1 y mostrar la pantalla de inicio de sesión.
Errores	1. Datos incompletos o no válidos: se despliega el mensaje MSJE1, que indica el campo que debe corregirse. 2. Cuenta duplicada: ya existe una cuenta con ese identificador y se despliega el mensaje MSJE2 para solicitar otro. 3. Fallo al guardar: no fue posible almacenar la cuenta y se despliega el mensaje MSJE5.

Elaboración propia.

Tabla 4.7: Caso de uso iniciar sesión

Caso de uso	**Iniciar sesión**
Identificador	CU_02
Requisitos asociados	RF2, RF11
Reglas de negocio	RN-1
Actores	Operador
Descripción	El operador inicia sesión con la cuenta de un usuario para que la información que se consulte y se genere quede asociada únicamente a ella.
Precondición	Existe una cuenta creada previamente.
Pasos	1. Mostrar el formulario de inicio de sesión (identificador y contraseña). 2. Validar que las credenciales coincidan con las de una cuenta existente. 3. Abrir la sesión, cargar el modelo de detección de la cuenta, en caso de que lo tenga, y mostrar la pantalla principal.
Errores	1. Datos incompletos: falta el identificador o la contraseña y se despliega el mensaje MSJE1. 2. Datos incorrectos: el identificador o la contraseña no coinciden, se despliega el mensaje MSJE3 y se permite un nuevo intento. 3. Cuenta inexistente: no hay una cuenta con ese identificador y se despliega el mensaje MSJE4.

Elaboración propia.

Tabla 4.8: Caso de uso cerrar sesión

Caso de uso	**Cerrar sesión**
Identificador	CU_03
Requisitos asociados	RF3
Reglas de negocio	RN-1
Actores	Operador
Descripción	El operador cierra la sesión activa para que otra cuenta pueda utilizar el sistema sin acceso a la información de la anterior.
Precondición	Hay una sesión activa.
Pasos	1. Solicitar la confirmación del cierre de sesión con el mensaje MSJC1. 2. Si el operador confirma, detener la conexión con el casco EEG en caso de que esté activa. 3. Cerrar la sesión y regresar a la pantalla de inicio de sesión.
Errores	No se identifican errores propios de este caso de uso.

Elaboración propia.

4.4.3. Casos de uso de adquisición y calibración

Este grupo comprende la conexión con el casco EEG, la verificación de la calidad de la señal y la sesión de calibración, en la que se presentan al usuario caracteres objetivo conocidos y se registran sus señales, así como el entrenamiento y la validación automáticos del modelo de esa cuenta, y el inicio del deletreo.

Tabla 4.9: Caso de uso conectar el casco EEG

Caso de uso	**Conectar el casco EEG**
Identificador	CU_04
Requisitos asociados	RF4
Reglas de negocio	RN-6
Actores	Operador, Casco EEG
Descripción	El operador establece la conexión entre la aplicación y el casco, de modo que el sistema reciba de forma continua las señales de sus canales.
Precondición	Hay una sesión activa y el casco está encendido y colocado sobre el usuario.
Pasos	1. Buscar los dispositivos disponibles y mostrarlos al operador. 2. Seleccionar el casco que se utilizará. 3. Establecer la conexión y comenzar a recibir las señales de cada canal. 4. Mostrar el estado de la conexión y habilitar la verificación de la señal.
Errores	1. Casco no encontrado o conexión fallida: se despliega el mensaje MSJE11 y se permite reintentar. 2. Pérdida de la conexión durante la recepción: el sistema detiene la estimulación, despliega el mensaje MSJE6 y conserva el texto construido hasta ese momento.

Elaboración propia.

Tabla 4.10: Caso de uso verificar la calidad de la señal

Caso de uso	**Verificar la calidad de la señal**
Identificador	CU_05
Requisitos asociados	RF6
Reglas de negocio	Ninguna
Actores	Operador, Casco EEG
Descripción	El operador revisa el estado de la señal de cada canal del casco antes de iniciar una calibración o una sesión de deletreo, y ajusta los electrodos cuando es necesario.
Precondición	La conexión con el casco está establecida.
Pasos	1. Mostrar en tiempo real el estado de la señal de cada canal. 2. Resaltar los canales cuya calidad sea insuficiente. 3. Permitir al operador ajustar los electrodos y revisar de nuevo el estado. 4. Registrar que la señal fue aceptada y habilitar la calibración o el deletreo.
Errores	1. Canales con señal deficiente: se despliega el mensaje MSJE7 indicando cuáles son y no se da por aceptada la verificación hasta que se corrijan.

Elaboración propia.

Tabla 4.11: Caso de uso realizar la calibración

Caso de uso	**Realizar la calibración**
Identificador	CU_06
Requisitos asociados	RF5, RF7, RF8
Reglas de negocio	RN-2, RN-5, RN-6
Actores	Operador, Usuario, Casco EEG
Descripción	El operador inicia una sesión de calibración en la que el usuario fija su atención en caracteres indicados por el sistema, mientras se registran sus señales y los eventos de estimulación para entrenar su modelo.
Precondición	La conexión con el casco está establecida y la señal fue verificada.
Pasos	1. Iniciar el modo de calibración a solicitud del operador. Si la cuenta ya tiene un modelo, solicitar antes la confirmación con el mensaje MSJC3. 2. Mostrar la matriz e indicar al usuario el carácter objetivo. 3. Presentar las secuencias de estimulación, registrando el instante y el tipo de cada intensificación junto con las señales recibidas. 4. Repetir los pasos 2 y 3 con cada uno de los 20 caracteres objetivo de la calibración. 5. Guardar en la cuenta del usuario los registros, los caracteres objetivo y los eventos de estimulación, y desplegar el mensaje MSJI2.
Errores	1. Pérdida de la conexión con el casco: se detiene la calibración y se despliega el mensaje MSJE6. 2. Fallo al guardar los registros: se despliega el mensaje MSJE5 y se propone repetir la calibración. 3. Detención por el operador: se solicita la confirmación con el mensaje MSJC2 y, si se confirma, la calibración se descarta.

Elaboración propia.

Tabla 4.12: Caso de uso entrenar y validar el modelo

Caso de uso	**Entrenar y validar el modelo**
Identificador	CU_07
Requisitos asociados	RF9, RF10
Reglas de negocio	RN-7, RN-8
Actores	Operador
Descripción	Al concluir la calibración, el sistema entrena el modelo de detección del usuario con sus registros y lo evalúa con una parte reservada de ellos, mientras el operador supervisa el avance.
Precondición	La calibración concluyó y sus registros están guardados en la cuenta.
Pasos	1. Preprocesar los registros de calibración. 2. Separar una parte de los registros para la validación. 3. Entrenar el modelo con el resto, mostrando su avance al operador. 4. Evaluar la exactitud por carácter y el AUC con la parte reservada. 5. Si la exactitud alcanza al menos el 70 %, guardar el modelo en la cuenta e informar con el mensaje MSJI3 que el deletreo está habilitado.
Errores	1. Exactitud insuficiente: se despliega el mensaje MSJE8 y se propone repetir la calibración. 2. Fallo al guardar el modelo: se despliega el mensaje MSJE5 y no se habilita el deletreo.

Elaboración propia.

Tabla 4.13: Caso de uso iniciar el deletreo

Caso de uso	**Iniciar el deletreo**
Identificador	CU_08
Requisitos asociados	RF11
Reglas de negocio	RN-7, RN-8
Actores	Operador
Descripción	El operador inicia una sesión de deletreo para que el sistema, con el modelo de la cuenta, presente la matriz de selección.
Precondición	La cuenta tiene un modelo entrenado, la conexión con el casco está establecida y la señal fue verificada.
Pasos	1. Verificar que la cuenta tenga el modelo de detección cargado al iniciar sesión. 2. Mostrar la matriz de selección y comenzar la estimulación.
Errores	1. Cuenta sin modelo: se impide iniciar el deletreo y se despliega el mensaje MSJE9. 2. Modelo no válido o dañado: se despliega el mensaje MSJE10 y se propone repetir la calibración.

Elaboración propia.

4.4.4. Casos de uso del deletreo

Este grupo corresponde al núcleo del sistema e incluye la presentación de los estímulos sobre la matriz, la clasificación de las épocas y la decodificación del carácter seleccionado, la actualización del texto construido y el borrado del último elemento escrito.

Las Tablas 4.14 a 4.17 describen estos casos de uso, que se ejecutan en ese orden por cada selección mientras el deletreo permanece activo.

Tabla 4.14: Caso de uso presentar los estímulos

Caso de uso	**Presentar los estímulos**
Identificador	CU_09
Requisitos asociados	RF5, RF12, RF13
Reglas de negocio	RN-2, RN-5
Actores	Usuario
Descripción	El sistema presenta la matriz de selección e intensifica de forma aleatoria sus filas y columnas mientras el usuario fija su atención en el elemento que desea seleccionar, y registra el instante y el tipo de cada intensificación.
Precondición	El deletreo se inició (CU_08) y la conexión con el casco está activa.
Pasos	1. Mostrar la matriz de selección con los caracteres, el espacio, el comando de borrado y las sugerencias vigentes. 2. Generar un orden aleatorio en el que cada fila y cada columna se intensifiquen una sola vez. 3. Intensificar cada fila o columna con la duración y el intervalo definidos para el sistema, registrando el instante y el tipo de cada intensificación. 4. Al terminar cada repetición, entregar sus señales y eventos a la decodificación del carácter. 5. Repetir los pasos 2 a 4 hasta completar el número de repeticiones definido para el sistema.
Errores	1. Pérdida de la conexión con el casco: se detiene la estimulación, se despliega el mensaje MSJE6 y se conserva el texto construido. 2. Detención por el operador: se solicita la confirmación con el mensaje MSJC4 y, si se confirma, se detiene la estimulación.

Elaboración propia.

Tabla 4.15: Caso de uso decodificar el carácter

Caso de uso	**Decodificar el carácter**
Identificador	CU_10
Requisitos asociados	RF14, RF15, RF16
Reglas de negocio	RN-3, RN-5, RN-7
Actores	Usuario
Descripción	A partir de las señales registradas durante la presentación de los estímulos, el sistema obtiene las épocas, las clasifica con el modelo del usuario y determina el elemento seleccionado.
Precondición	Se completó una repetición de la selección (CU_09) y el modelo del usuario está cargado.
Pasos	1. Segmentar las señales en épocas a partir de cada intensificación y preprocesarlas. 2. Clasificar cada época con el modelo del usuario y obtener su puntaje. 3. Acumular los puntajes de cada fila y cada columna a lo largo de las repeticiones. 4. Si ya se completaron todas las repeticiones, elegir la fila y la columna con el mayor puntaje acumulado. 5. Entregar el elemento ubicado en su intersección a la actualización del texto.
Errores	1. Épocas incompletas por una interrupción de la señal: se descarta la selección y se repite la presentación de los estímulos. 2. Fallo del modelo de detección: se detiene el deletreo y se despliega el mensaje MSJE10.

Elaboración propia.

Tabla 4.16: Caso de uso actualizar el texto

Caso de uso	**Actualizar el texto**
Identificador	CU_11
Requisitos asociados	RF17
Reglas de negocio	RN-4
Actores	Usuario
Descripción	El sistema incorpora al texto construido el elemento seleccionado según su tipo y muestra el resultado al usuario.
Precondición	Se decodificó un elemento de la matriz (CU_10).
Pasos	1. Identificar el tipo del elemento seleccionado. 2. Si es un carácter o el espacio, agregarlo al final del texto. 3. Si es el comando de borrado, continuar con el caso de uso CU_12. 4. Si es una sugerencia, continuar con el caso de uso CU_14. 5. Mostrar el texto actualizado y solicitar nuevas sugerencias (CU_13).
Errores	No se identifican errores propios de este caso de uso.

Elaboración propia.

Tabla 4.17: Caso de uso borrar el último elemento

Caso de uso	**Borrar el último elemento**
Identificador	CU_12
Requisitos asociados	RF18
Reglas de negocio	RN-4
Actores	Usuario
Descripción	Cuando el usuario selecciona el comando de borrado, el sistema elimina el último carácter o la última palabra incorporados al texto.
Precondición	El elemento decodificado corresponde al comando de borrado (CU_11).
Pasos	1. Consultar el último elemento incorporado al texto. 2. Si fue una palabra sugerida, eliminar la palabra completa junto con el espacio que la sigue. 3. Si fue un carácter o un espacio, eliminar solo ese carácter. 4. Mostrar el texto actualizado y solicitar nuevas sugerencias (CU_13).
Errores	1. Texto vacío: no hay elementos que borrar, el texto no se modifica y se despliega el mensaje MSJI4.

Elaboración propia.

4.4.5. Casos de uso de predicción de palabras

Este grupo abarca la generación de sugerencias a partir de los caracteres escritos y su selección mediante el mismo mecanismo de estimulación y detección de la componente P300 que se

emplea para los caracteres.

Las Tablas 4.18 y 4.19 describen estos casos de uso.

Tabla 4.18: Caso de uso generar sugerencias

Caso de uso	**Generar sugerencias**
Identificador	CU_13
Requisitos asociados	RF19
Reglas de negocio	RN-4
Actores	Usuario
Descripción	Cada vez que cambia el texto, el sistema estima las palabras más probables a partir de lo escrito y las presenta en los elementos de sugerencia de la matriz.
Precondición	Se inició el deletreo o se actualizó el texto construido (CU_11).
Pasos	1. Obtener el texto construido hasta el momento. 2. Si el texto está vacío o termina en espacio, tomar las palabras anteriores como contexto para predecir la siguiente palabra. 3. En otro caso, tomar la palabra en curso como prefijo y las palabras anteriores como contexto. 4. Consultar el modelo de lenguaje y ordenar las palabras candidatas por probabilidad. 5. Asignar las más probables a los elementos de sugerencia y mostrarlas en la matriz.
Errores	1. Sin palabras candidatas: los elementos de sugerencia se muestran vacíos y el deletreo continúa por caracteres.

Elaboración propia.

Tabla 4.19: Caso de uso seleccionar una sugerencia

Caso de uso	**Seleccionar una sugerencia**
Identificador	CU_14
Requisitos asociados	RF20
Reglas de negocio	RN-3, RN-4
Actores	Usuario
Descripción	El usuario elige una de las palabras sugeridas mediante el mismo mecanismo de estimulación y detección que emplea para los caracteres, y el sistema completa con ella la palabra en curso.
Precondición	Hay sugerencias presentes en la matriz (CU_13) y el elemento decodificado corresponde a una de ellas.
Pasos	1. Identificar la palabra contenida en el elemento seleccionado. 2. Reemplazar la palabra en curso por la palabra sugerida y agregar un espacio. 3. Mostrar el texto actualizado. 4. Solicitar las sugerencias de la siguiente palabra (CU_13).
Errores	1. Elemento de sugerencia vacío: la selección se ignora y el texto no se modifica.

Elaboración propia.

4.4.6. Diagramas de casos de uso

Los diagramas de casos de uso muestran de forma gráfica qué funcionalidades utiliza cada actor y cómo se relacionan entre sí, y complementan las tablas descriptivas de las secciones anteriores.

La Figura 4.1 presenta los casos de uso del sistema y su relación con los tres actores. El operador participa en la gestión de cuentas, la conexión del casco, la verificación de la señal, la calibración, el entrenamiento del modelo y el inicio del deletreo. El casco EEG aparece en su propia conexión, en la verificación de la señal y en la calibración, donde entrega las señales que se registran. El usuario participa en la calibración y en todos los casos de uso del deletreo y de la predicción de palabras.

Entre los casos de uso hay tres relaciones. La calibración incluye el entrenamiento y la validación del modelo, que se ejecutan solos cuando termina. El borrado del último elemento extiende la actualización del texto porque solo ocurre si el usuario lo selecciona, y la selección de una sugerencia extiende a su generación. El resto se encadena por las precondiciones de sus tablas, por ejemplo la verificación de la señal no puede hacerse si el casco no está conectado.



Figura 4.1: Diagrama de casos de uso del sistema. Elaboración propia.

4.5. Arquitectura de software

La arquitectura de la Figura 3.1 del Capítulo 3 describe las etapas por las que pasa la señal, desde que se adquiere hasta que se construye el texto. La arquitectura de software describe otra cosa, cómo se organiza el código que realiza esas etapas y cómo se comunican sus componentes. Para ello se propone dividirla en tres capas. La de presentación, hecha con PyQt, contiene la matriz del P300 Speller, el área de texto, las sugerencias y las pantallas de registro, inicio de sesión y calibración. La capa de lógica agrupa el control de la sesión de deletreo y de calibración, la adquisición de las señales, la generación de estímulos, el preprocesamiento, el entrenamiento

y la validación del modelo de cada usuario, la detección de la componente P300, la decodificación del carácter, la construcción del texto y la predicción de palabras. La capa de datos se encarga de las cuentas de usuario, los registros EEG de calibración, el modelo entrenado de cada usuario y el modelo de lenguaje del predictor. Esta división se eligió pensando en el RNF8, para poder cambiar el modelo de detección o el de predicción de palabras sin tocar la interfaz.

La Figura 4.2 muestra esta organización. Las ventanas de la capa de presentación solo se comunican con el control de sesión, que coordina a los ocho componentes de la capa de lógica y decide en qué orden intervienen según se trate de la calibración o del deletreo. Ningún componente de la lógica toca directamente los archivos. Todo pasa por el componente de acceso a datos, que administra la base de datos local con las cuentas y la ubicación de los archivos, además de los archivos de registros de calibración, de modelos de detección y del modelo de lenguaje. El casco EEG queda fuera del sistema y solo se comunica con el componente de adquisición, que es el único que habría que modificar para usar otro dispositivo (RNF9).

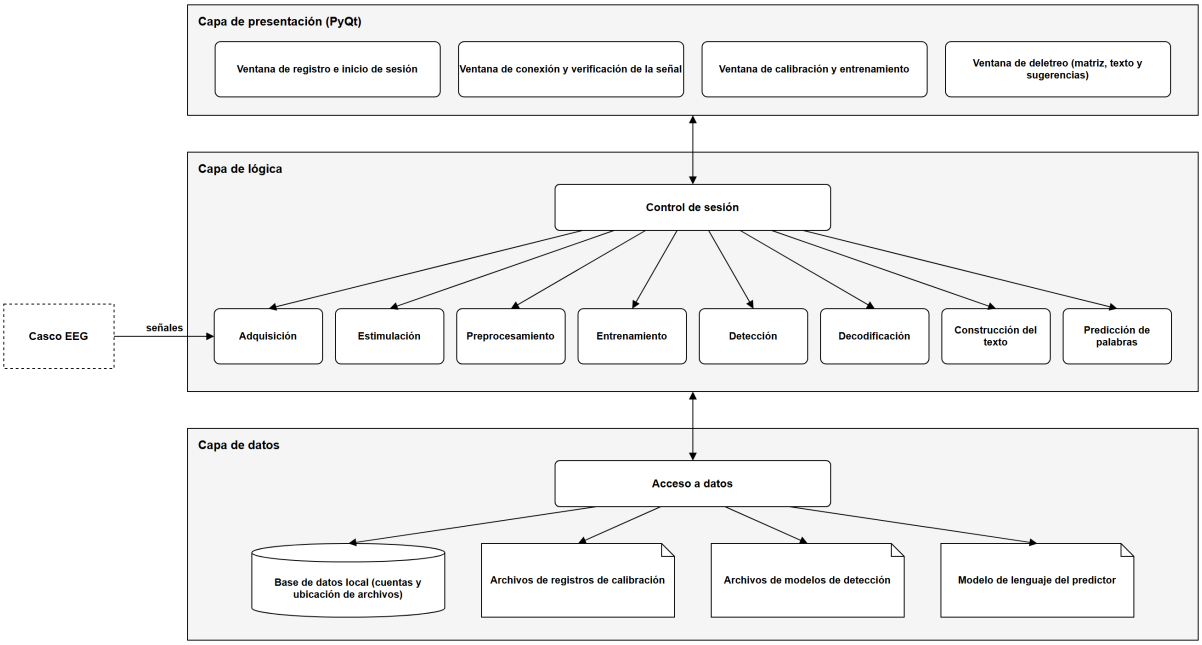


Figura 4.2: Arquitectura de software del sistema. Elaboración propia.

4.6. Diagrama de clases

El diagrama de clases define la estructura estática del sistema a nivel de código, es decir, las clases que lo componen con sus atributos y métodos, así como las relaciones entre ellas. A partir de la arquitectura anterior se identifican clases para las ventanas de la interfaz, para el control de la sesión de deletreo y de calibración, para la adquisición de las señales del casco, para la generación de estímulos, el preprocesamiento, el entrenamiento del modelo, el clasificador de la componente P300 y el decodificador del carácter, para el predictor de palabras y para el acceso a los datos de usuarios.

La Figura 4.3 presenta el diagrama. La clase abstracta Ventana reúne lo que tienen en común

las cuatro ventanas de la interfaz, y estas delegan cualquier operación en ControlSesion. Esta clase guarda al usuario de la sesión, su modelo de detección y el estado actual, y se relaciona con las clases que hacen cada etapa. AdquisicionEEG entrega las señales del casco y guarda los eventos de estimulación que genera Estimulacion, la cual intensifica las filas y columnas de una MatrizSeleccion formada por 36 objetos ElementoMatriz. Preprocesador obtiene las épocas y Entrenador crea el ModeloDeteccion de cada usuario. La arquitectura y los hiperparámetros con los que se entrena son iguales para todos los usuarios porque se eligen antes con la metodología CRISP-ML, y lo único que sale de la calibración de cada usuario son los pesos de la red. Decodificador acumula los puntajes que asigna ese modelo y devuelve el elemento seleccionado. ConstructorTexto mantiene el texto y el historial de selecciones que se usa para borrar el último elemento, PredictorPalabras genera las sugerencias y AccesoDatos administra las cuentas, los registros de calibración y los modelos guardados.

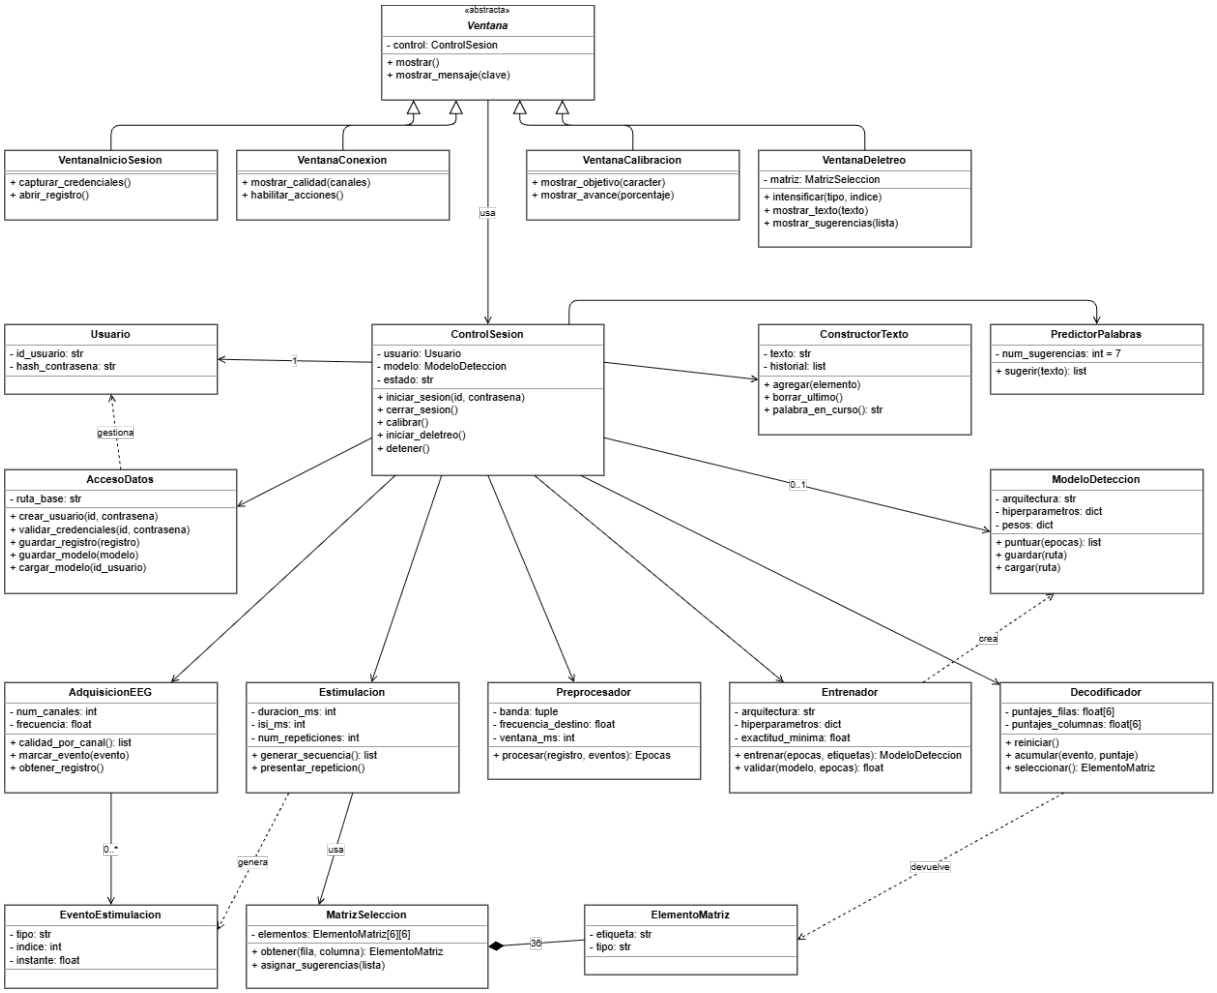


Figura 4.3: Diagrama de clases del sistema. Elaboración propia.

4.7. Diagrama de objetos

A diferencia del diagrama de clases, el diagrama de objetos muestra instancias concretas de esas clases en un momento de la ejecución. Aquí se ilustra el instante en que un usuario con la

sesión abierta selecciona un carácter.

En la Figura 4.4 el usuario usuario_01 está escribiendo la palabra HOLA y acaba de seleccionar la L. Después de cinco repeticiones el decodificador tiene el mayor puntaje acumulado en la fila 2 y en la columna 6, cuya intersección es el elemento L, y el texto pasa de HO a HOL. Enseguida el control de sesión le pide al predictor las sugerencias para la siguiente selección. El objeto del modelo contiene los pesos que se obtuvieron en la calibración de usuario_01 junto con la arquitectura y los hiperparámetros comunes a todos los usuarios. Los valores de repeticiones, arquitectura, hiperparámetros y tiempos de intensificación son solo ilustrativos, se definirán con los resultados de CRISP-ML.

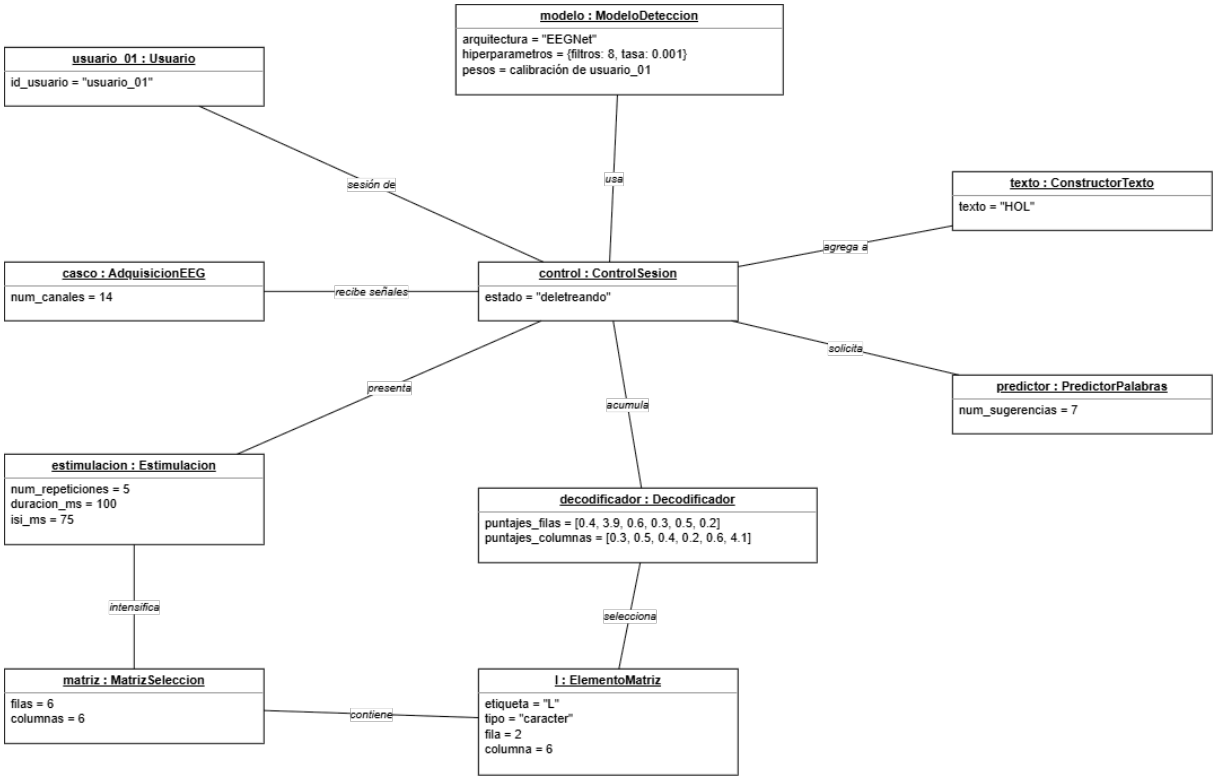


Figura 4.4: Diagrama de objetos durante la selección de un carácter. Elaboración propia.

4.8. Estructura de almacenamiento

Como la herramienta puede ser utilizada por varias personas, cada una con su propia sesión, el sistema tiene que guardar de forma persistente las cuentas de usuario, además de los archivos que ya forman parte del flujo de trabajo, como los registros EEG de las calibraciones y el modelo entrenado de cada usuario. En esta sección se define qué información se almacena y cómo se relaciona. La tecnología con la que se implementará se elegirá durante el Trabajo Terminal II.

Las cuentas y la ubicación de los archivos de cada una se guardan en una base de datos local, cuyo modelo relacional se muestra en la Figura 4.5. Tiene tres tablas. Usuario guarda el identificador y la contraseña de cada cuenta. RegistroCalibracion tiene un renglón por cada sesión de calibración, con su fecha y la ubicación del archivo que contiene las señales, los caracteres objetivo y los eventos de estimulación. Modelo guarda la ubicación del modelo entrenado de la

cuenta. Las dos últimas se relacionan con Usuario por medio de su identificador, y un usuario puede tener varios registros de calibración pero un solo modelo, que se reemplaza cuando se repite la calibración. Las señales y el modelo no se guardan dentro de la base de datos por su tamaño, ahí solo queda la ruta donde se encuentran.

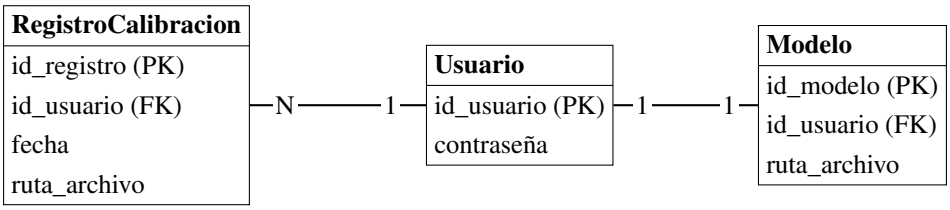


Figura 4.5: Modelo relacional de la base de datos del sistema. Elaboración propia.

Los archivos a los que hace referencia la base de datos se organizan en carpetas, como se muestra en la Figura 4.6. Cada usuario cuenta con su propia carpeta, dentro de la cual se separan los registros de calibración y el modelo.

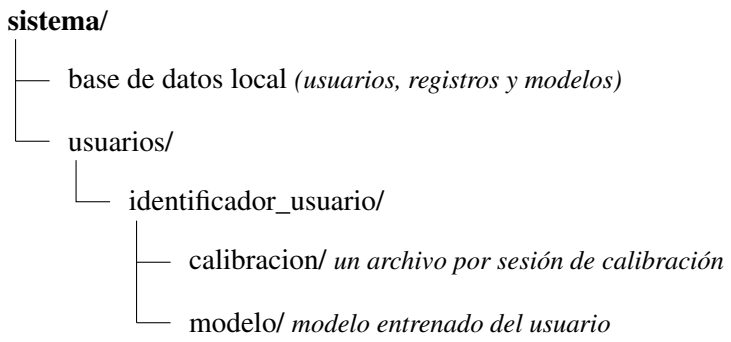


Figura 4.6: Estructura de carpetas del sistema. Elaboración propia.

4.9. Diagramas de flujo

Los diagramas de flujo describen los pasos de los procesos más importantes del sistema. Se presentan tres, que son los que concentran la lógica de las señales y del modelo: el preprocesamiento, el entrenamiento del modelo de detección y la decodificación del carácter seleccionado.

4.9.1. Preprocesamiento de las señales EEG

El preprocesamiento aplica las técnicas de la Sección 2.6, entre ellas el filtrado pasa banda, el remuestreo, la segmentación en épocas posteriores a cada estímulo y la normalización de cada canal. Es el mismo para el entrenamiento y para el uso del sistema, y el modelo recibe los datos con el mismo formato sin importar si vienen de la base de datos pública o del casco EEG. Para que esto se cumpla, cuando el registro viene de la base de datos pública se conservan primero solo los 14 canales que coinciden con los del casco, y el remuestreo lleva las dos fuentes a la misma frecuencia de muestreo. Los valores de cada parámetro se definirán en el diseño experimental.

El flujo de la Figura 4.7 empieza con la recepción del registro, ya sea de la base de datos pública o del casco. Si viene de la base pública se seleccionan primero los canales equivalentes a los del casco, y luego se aplican en orden el filtro pasa banda, el remuestreo, la segmentación en épocas y la normalización de cada canal. Cuando los datos son para entrenar, a cada época se le asigna además la etiqueta de objetivo o no objetivo según la fila o columna que se intensificó. Durante el deletreo las épocas pasan directo al modelo sin etiqueta, porque no se sabe qué carácter quiere seleccionar el usuario.

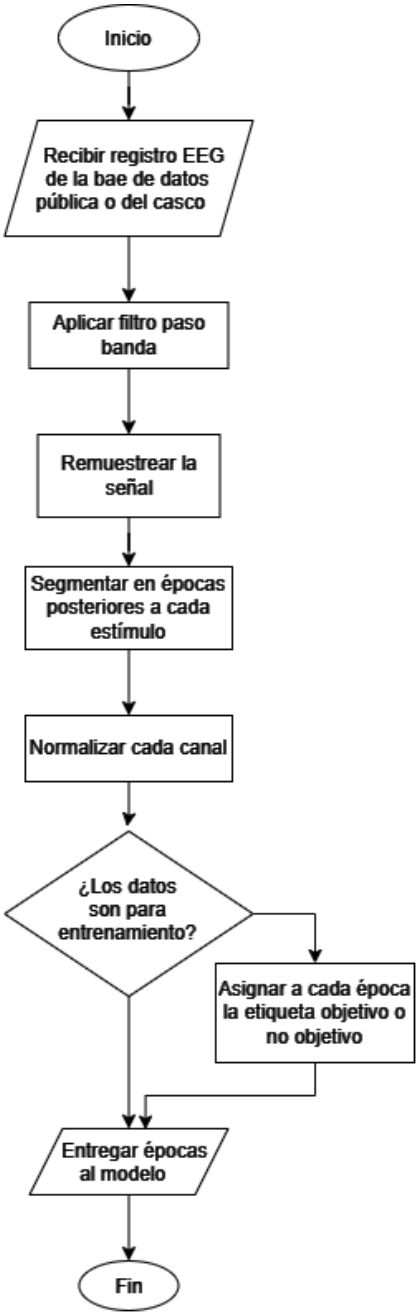


Figura 4.7: Diagrama de flujo del preprocesamiento de las señales EEG. Elaboración propia.

4.9.2. Entrenamiento y evaluación del modelo de detección

El entrenamiento y la evaluación que se representan en esta sección son los que hace la aplicación para cada usuario al terminar su calibración. La arquitectura y la configuración del modelo se definen antes, durante su desarrollo con las bases de datos públicas y con las fases de CRISP-ML descritas en el Capítulo 3, y aquí se toman como dato de entrada. Los registros de calibración del usuario pasan por el mismo preprocesamiento de la sección anterior, una parte se separa para la validación y con el resto se entrena la arquitectura seleccionada. Si la exactitud por carácter en la validación llega al 70 %, el modelo se guarda en la cuenta y se habilita el deletreo. Si no, se propone repetir la calibración.

El flujo se muestra en la Figura 4.8. Cuando la exactitud por carácter queda por debajo del 70 % no se guarda ningún modelo en la cuenta, y el usuario tiene que volver a calibrar antes de poder deletrear.

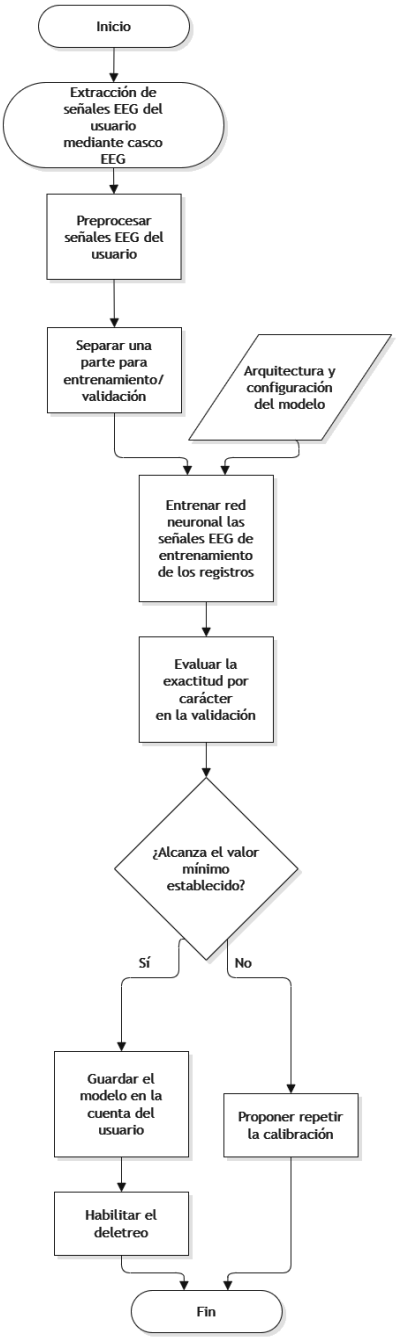


Figura 4.8: Diagrama de flujo del entrenamiento y evaluación del modelo de detección. Elaboración propia.

4.9.3. Decodificación del carácter seleccionado

La decodificación recorre las repeticiones de una selección. En cada una se intensifican las filas y columnas de la matriz, se clasifican las épocas que resultan y se acumulan los puntajes por fila y por columna según la Ecuación (2.2). Al completar el número de repeticiones se elige el elemento que está en la intersección de la fila y la columna con más puntaje.

El flujo de la Figura 4.9 parte del número de repeticiones J, que es el mismo para todos los usuarios. Antes de cada selección se reinician los puntajes de las seis filas y las seis columnas. En cada repetición se intensifican todas en orden aleatorio, se obtienen y clasifican las épocas y

cada puntaje se suma al de la fila o columna que se intensificó. Al terminar las J repeticiones se eligen la fila y la columna con mayor puntaje acumulado, y el elemento de su intersección, que puede ser un carácter, el espacio, el comando de borrado o una sugerencia, pasa a la actualización del texto.

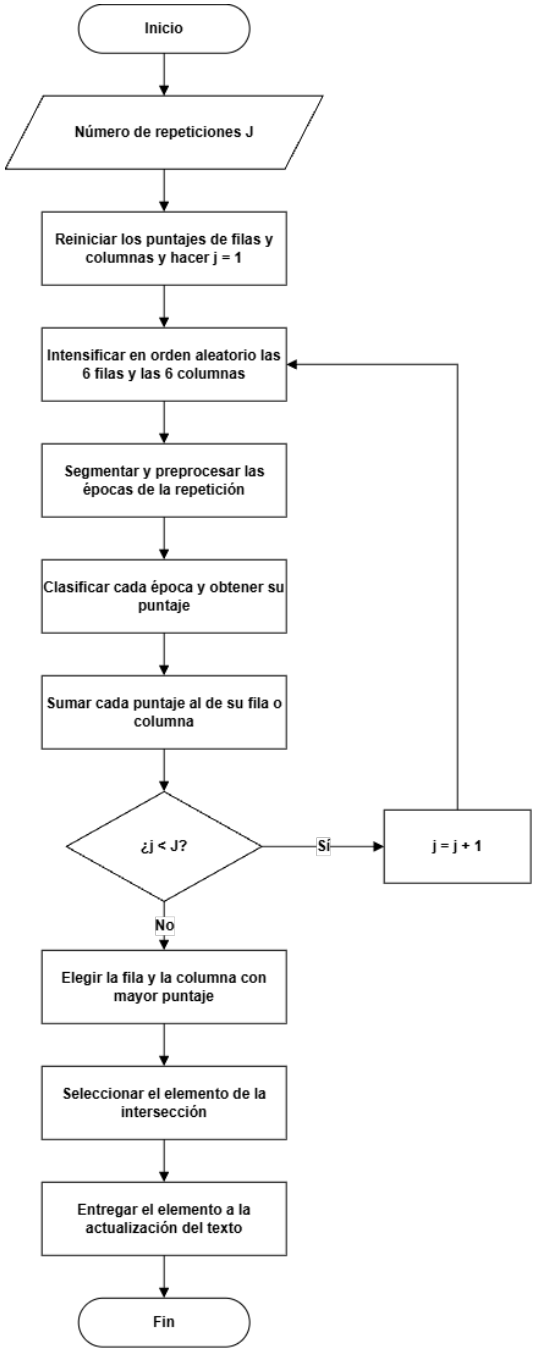


Figura 4.9: Diagrama de flujo de la decodificación del carácter seleccionado. Elaboración propia.

4.10. Diagrama de estados

Durante una sesión de deletreo la interfaz del P300 Speller cambia de comportamiento, porque alterna entre presentar las secuencias de estimulación, clasificar las épocas registradas y actualizar el texto. A esto se suman la conexión con el casco y la calibración. El diagrama de

estados describe cada una de estas situaciones y los eventos que hacen pasar de una a otra.

En la Figura 4.10 se identifican ocho estados principales. El sistema inicia sin usuario autenticado y, al iniciar sesión, pasa a sesión activa. Desde ahí va directo a modelo listo si la cuenta ya tiene uno, o a casco conectado si hace falta calibrar. Con el casco conectado se verifica la señal, se calibra y después se entrena el modelo. Si la validación se aprueba el sistema pasa a modelo listo, y si no, regresa a casco conectado para repetir el proceso. Dentro del estado de deletreo hay un ciclo de estimulación, clasificación y actualización del texto que se repite en cada selección hasta que el operador detiene el deletreo o cierra la sesión.

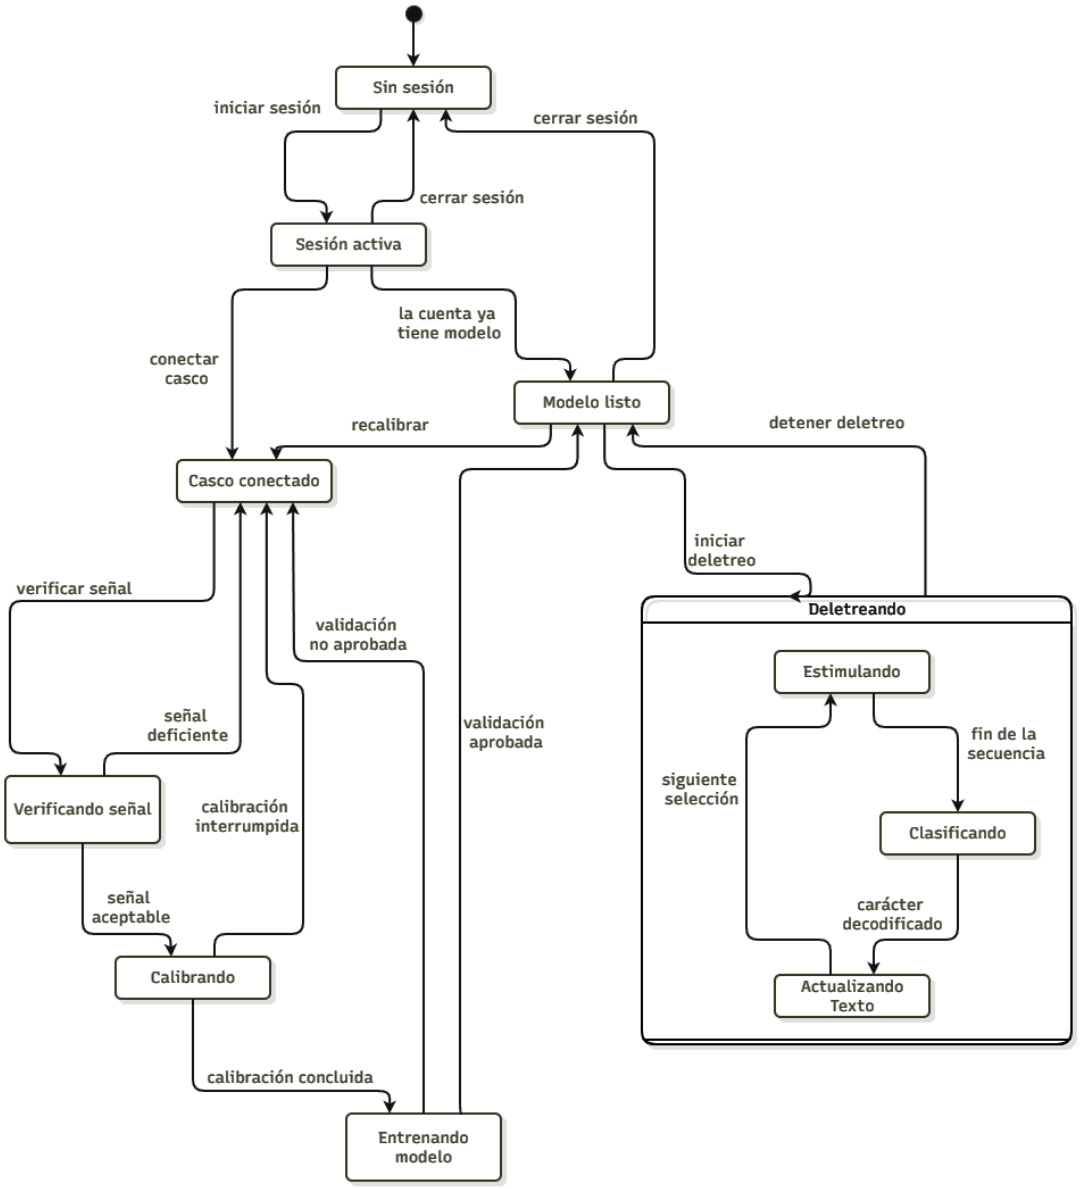


Figura 4.10: Diagrama de estados de la sesión del sistema. Elaboración propia.

4.11. Diagramas de secuencia

Los diagramas de secuencia muestran el orden en que los actores y los componentes del sistema se intercambian mensajes para realizar una tarea. Se presentan los de los cuatro procesos

principales: el inicio de sesión, la calibración, la selección de un carácter y la selección de una sugerencia, cada uno con los componentes de la arquitectura que participan en él.

4.11.1. Inicio de sesión

El diagrama de la Figura 4.11 empieza cuando el operador escribe el identificador y la contraseña en la interfaz, que los manda al control de sesión para que consulte la cuenta en la capa de datos. Si las credenciales son válidas también se busca el modelo del usuario, y la sesión se abre con el modelo cargado o sin él si la cuenta todavía no se ha calibrado. Si son incorrectas, la interfaz muestra un mensaje de error.

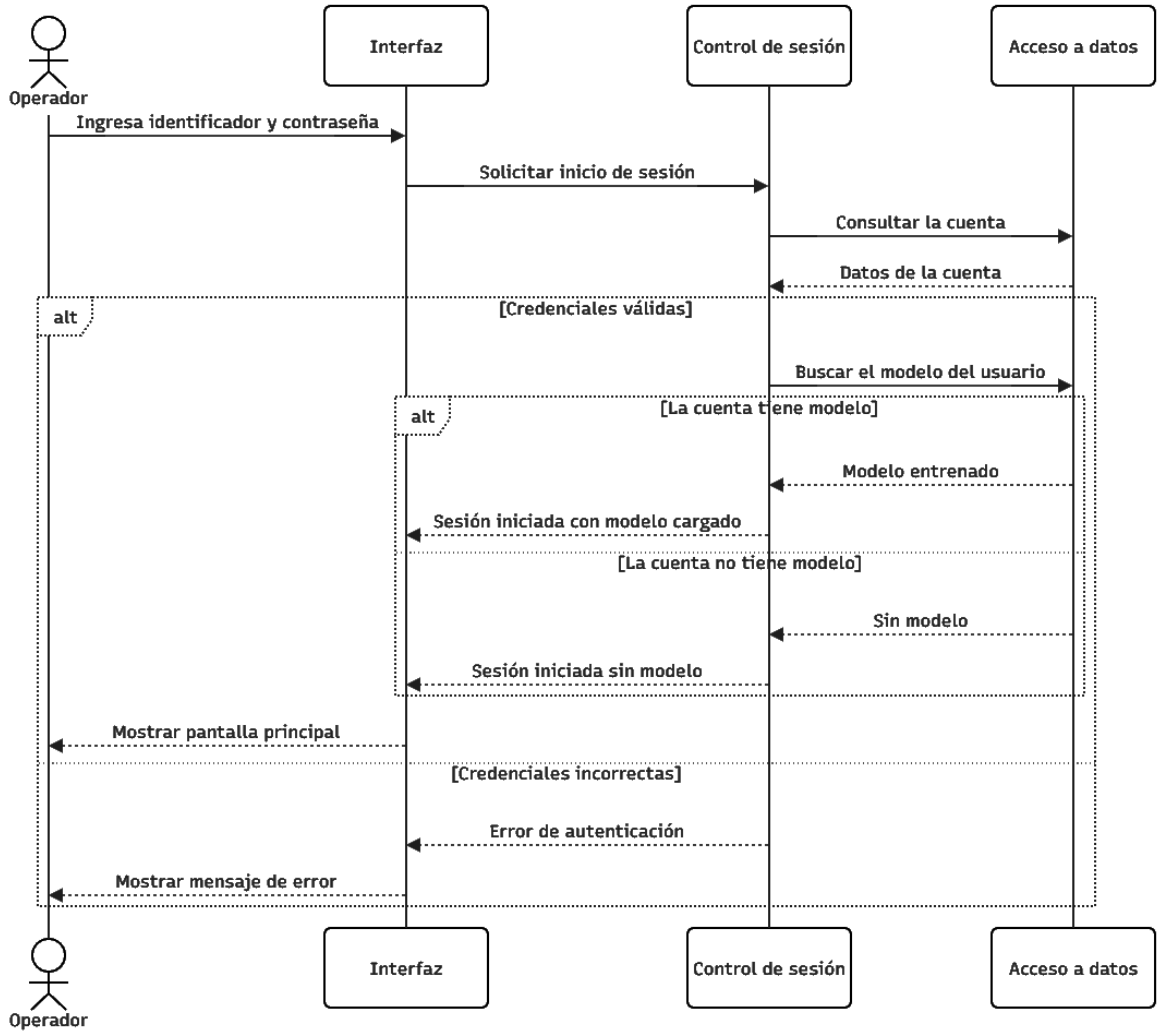


Figura 4.11: Diagrama de secuencia del inicio de sesión. Elaboración propia.

4.11.2. Calibración

En la calibración (Figura 4.12) el control de sesión le pide al módulo de estimulación que presente las secuencias de los caracteres de entrenamiento, y mientras tanto el módulo de adquisición registra las señales del casco con la marca de cada estímulo. El registro se guarda en la cuenta del usuario y se preprocesa, y con él se entrena y valida el modelo. Si la validación se

aprueba, el modelo se guarda en la cuenta y se habilita el deletreo, si no, se propone repetir la calibración.

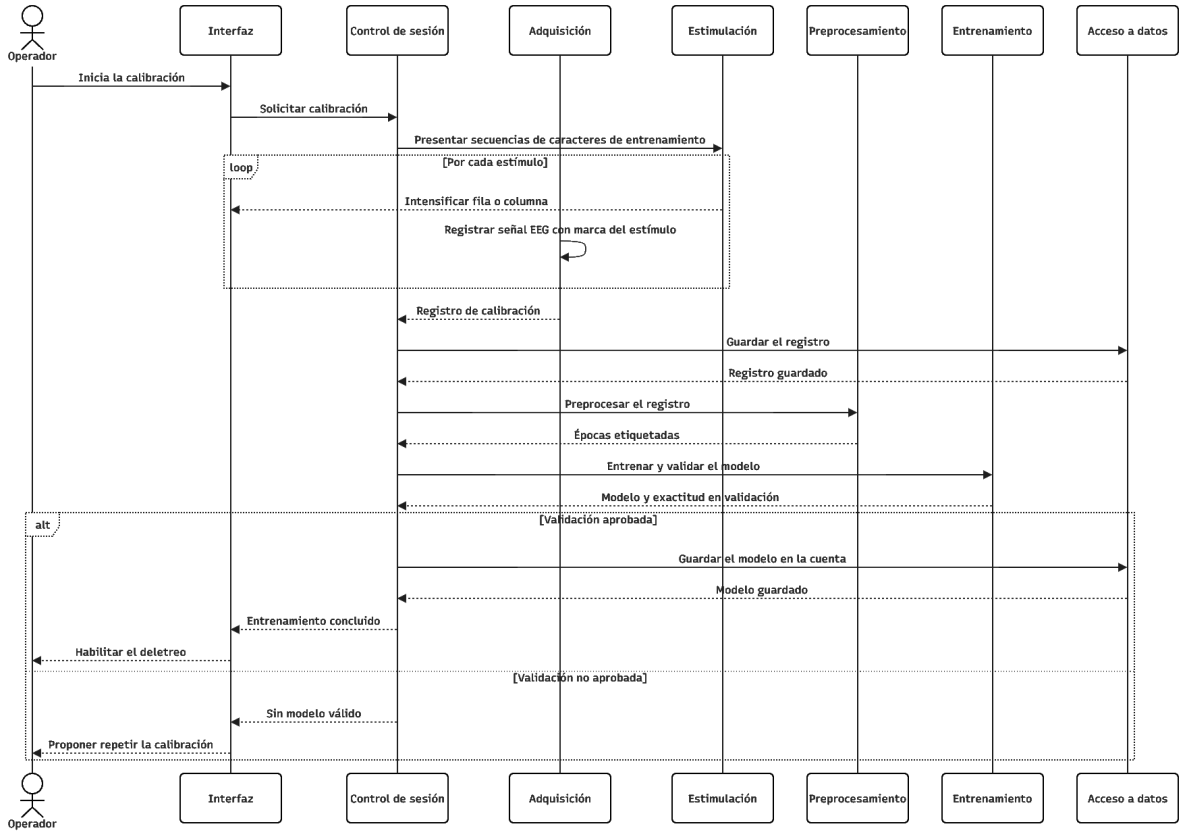


Figura 4.12: Diagrama de secuencia de la calibración. Elaboración propia.

4.11.3. Selección de un carácter

La Figura 4.13 muestra la selección de un carácter. Mientras el usuario fija su atención en el carácter, el control de sesión reinicia los puntajes del decodificador y, en cada repetición, le pide al módulo de estimulación que intensifique las filas y columnas, cuyas marcas registra el módulo de adquisición junto con la señal. Al terminar cada repetición las épocas se preprocesan, el módulo de detección les asigna un puntaje y el decodificador lo acumula. Después de la última repetición el decodificador devuelve el carácter de la intersección. La actualización del texto y la generación de sugerencias que vienen después se indican con una referencia.

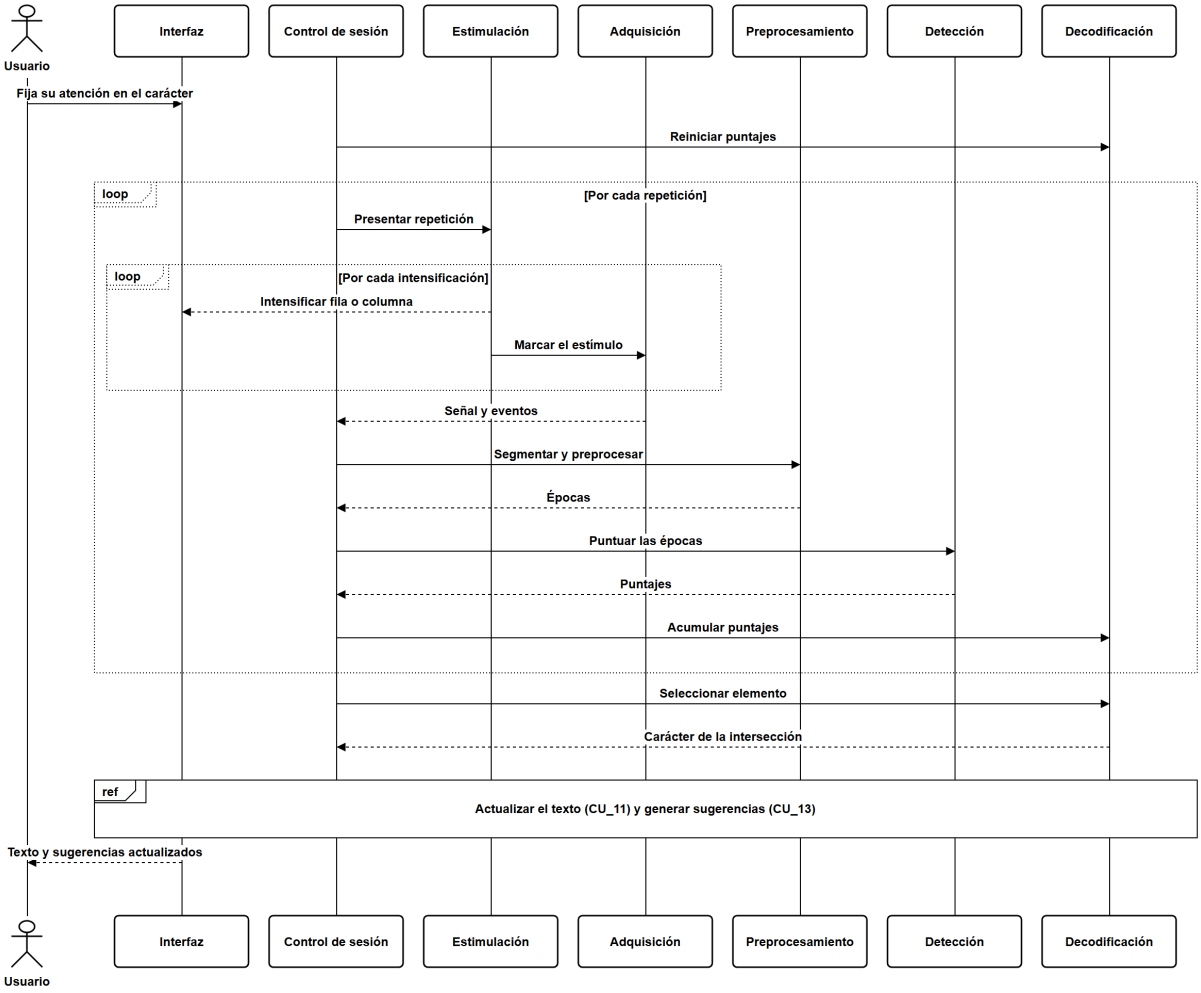


Figura 4.13: Diagrama de secuencia de la selección de un carácter. Elaboración propia.

4.11.4. Selección de una sugerencia

La selección de una sugerencia, representada en la Figura 4.14, comparte con la de un carácter la presentación de los estímulos y la decodificación, por lo que estas se indican mediante una referencia. Si el elemento decodificado contiene una palabra, esta reemplaza a la palabra en curso, se agrega un espacio y se solicitan las sugerencias de la siguiente palabra. Si el elemento está vacío, la selección se ignora y el texto no cambia.

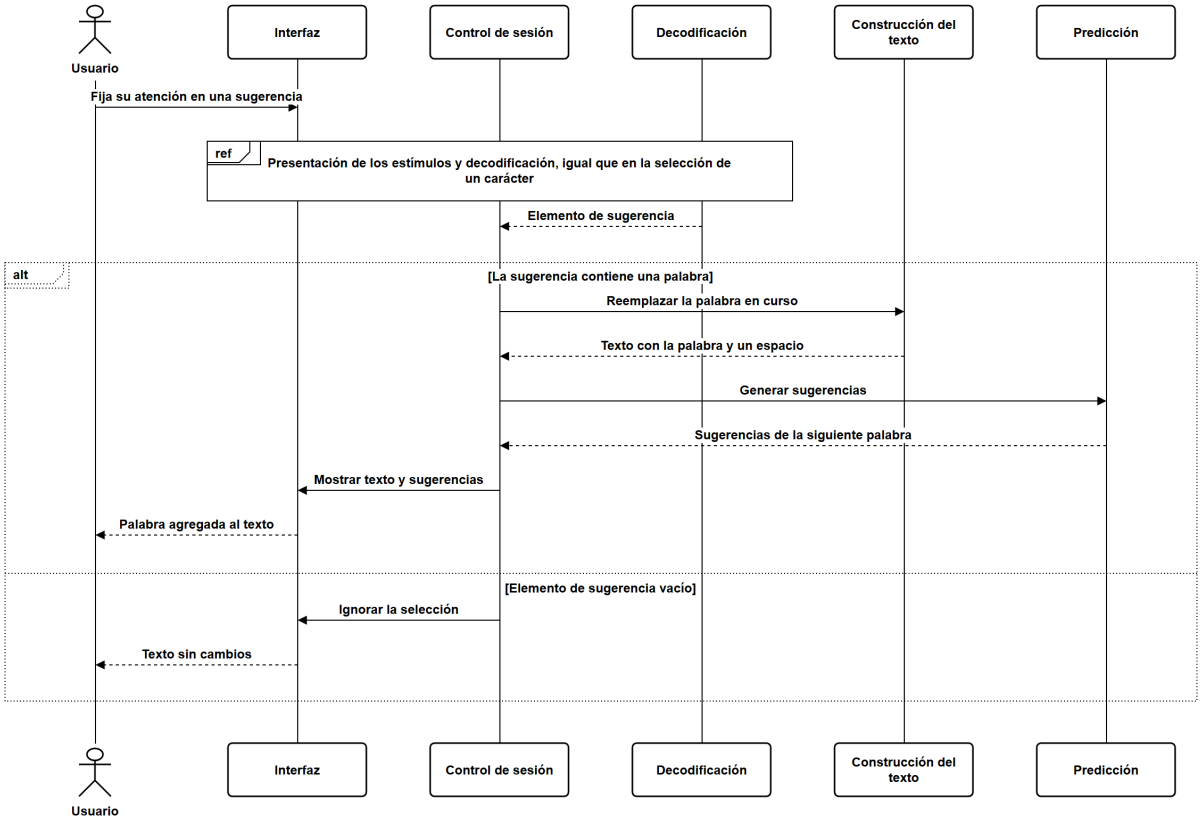


Figura 4.14: Diagrama de secuencia de la selección de una sugerencia. Elaboración propia.

4.12. Diseño del módulo de predicción de palabras

El módulo de predicción de palabras recibe los caracteres escritos hasta el momento y devuelve una lista corta de palabras probables, que la interfaz muestra como opciones adicionales y que el usuario elige con el mismo mecanismo de atención que usa para los caracteres. En esta sección se define qué información intercambia el módulo con el resto del sistema y cómo se presentan y seleccionan las sugerencias. La técnica de predicción, entre los enfoques de la Sección 2.12, se elegirá en el diseño detallado del primer incremento (Sección 3.4.1).

El módulo se implementa en la clase PredictorPalabras, que tiene una sola operación pública que recibe el texto construido y devuelve las sugerencias (Tabla 4.20). Así el resto del sistema no depende del modelo de lenguaje que se elija, y este se puede cambiar sin modificar la interfaz, como pide el RNF8.

Tabla 4.20: Entradas y salidas del módulo de predicción de palabras

Elemento	**Descripción**
Entrada	Texto construido hasta el momento, del cual se obtienen la palabra en curso, que funciona como prefijo, y las palabras anteriores, que funcionan como contexto.
Salida	Lista de palabras ordenadas de mayor a menor probabilidad, tantas como elementos de sugerencia tenga la matriz. La lista puede estar vacía si ninguna palabra es compatible con el prefijo.
Operación	sugerir(texto), de la clase PredictorPalabras.
Momento de uso	Al iniciar el deletreo y después de cada selección que modifique el texto.

Elaboración propia.

Las sugerencias ocupan los elementos de la matriz que no se usan para caracteres. De los 36 elementos, 27 son las letras del alfabeto en español, uno el espacio y uno el comando de borrado, y los siete restantes se destinan a las sugerencias conforme al RF12. Cada sugerencia se intensifica junto con la fila y la columna en la que está, así que para seleccionarla no hace falta un mecanismo distinto al de los caracteres. Cuando el usuario elige una, la palabra sugerida reemplaza a la palabra en curso y se agrega un espacio, con lo que se escribe una palabra completa en una sola selección.

La Figura 4.15 muestra el flujo del módulo. Si el texto está vacío o termina en espacio, el módulo predice la siguiente palabra a partir del contexto. Si no, busca palabras que completen la palabra en curso. Las candidatas se ordenan por probabilidad y las más probables se asignan a los elementos de sugerencia, que se quedan vacíos cuando no hay candidatas.

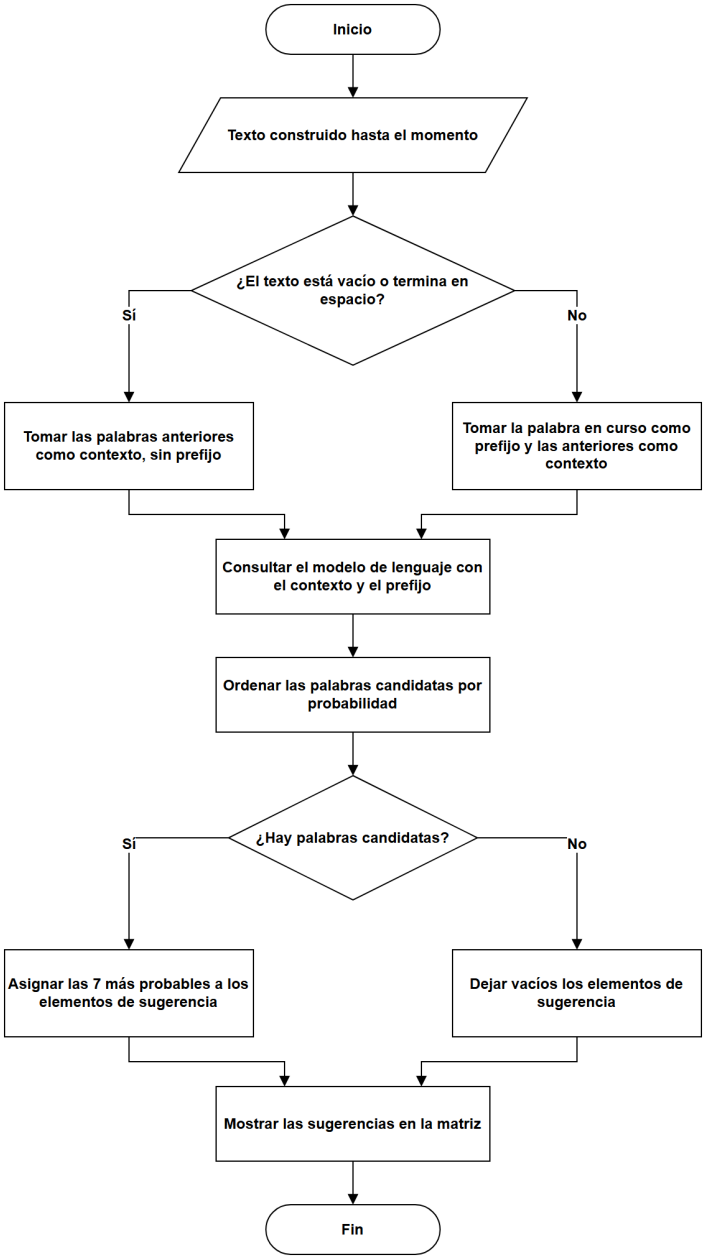


Figura 4.15: Diagrama de flujo del módulo de predicción de palabras. Elaboración propia.

4.13. Mockups

Un *mockup* es una representación visual estática de la interfaz que busca parecerse a su apariencia final, y sirve para revisar la distribución de los elementos y si se cumplen los requerimientos antes de empezar a programar. Los mockups corresponden a la etapa de diseño de la interfaz del modelo incremental y comprenden las pantallas de registro e inicio de sesión, la de conexión con el casco, la de calibración y avance del entrenamiento y la pantalla principal del deletreo con la matriz, el texto construido y las sugerencias de palabras.

La Figura 4.16 muestra la pantalla de creación de cuenta, en la que el operador captura el identificador y la contraseña, y la Figura 4.17 la de inicio de sesión, que además permite ir al registro.

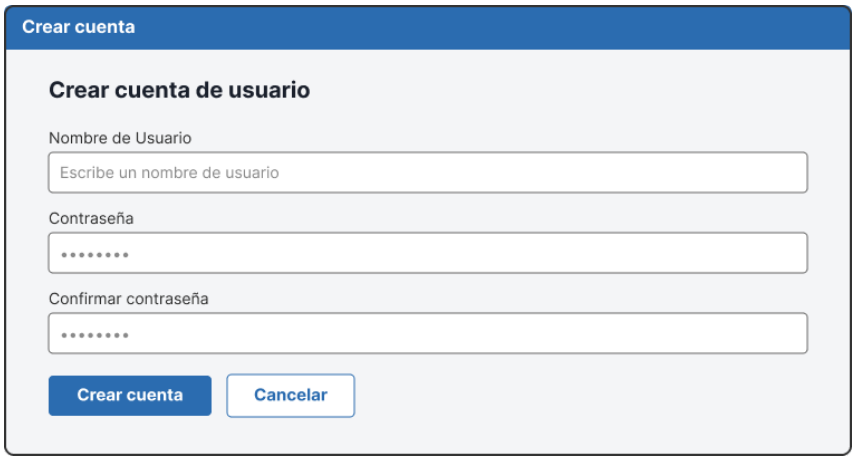


Figura 4.16: Pantalla de creación de cuenta. Elaboración propia.

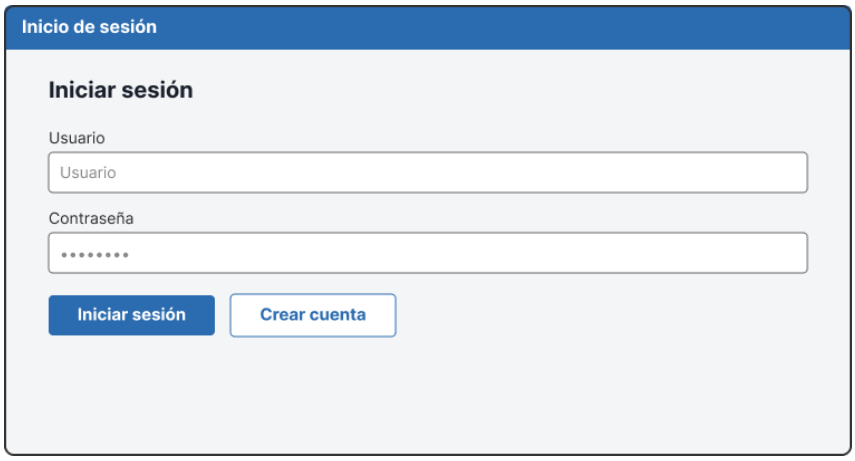


Figura 4.17: Pantalla de inicio de sesión. Elaboración propia.

Una vez iniciada la sesión, la pantalla de la Figura 4.18 permite conectar el casco y revisar la calidad de la señal de cada canal con un código de colores, y deja deshabilitado el inicio del deletreo mientras el usuario no tenga un modelo. La calibración y el entrenamiento aparecen en la Figura 4.19, donde se ve la palabra de calibración con el carácter objetivo resaltado, una barra con el avance de la calibración y, al terminar, el progreso del entrenamiento del modelo.



Figura 4.18: Pantalla de conexión del casco y verificación de la señal. Elaboración propia.

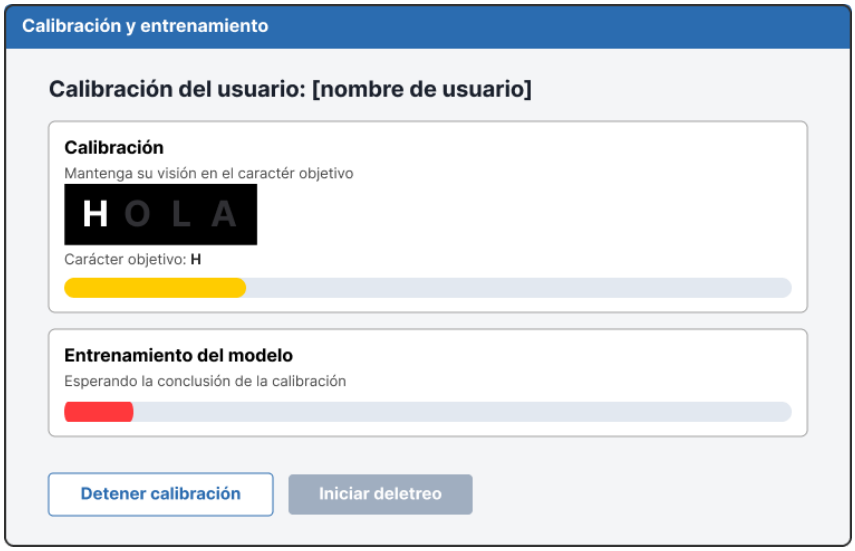


Figura 4.19: Pantalla de calibración y avance del entrenamiento. Elaboración propia.

Por último, la Figura 4.20 muestra la pantalla principal del deletreo. Arriba está el texto construido y debajo la matriz de selección con las 27 letras, el espacio, el comando de borrado y las palabras sugeridas. En el instante representado se intensifica la segunda fila, y en la esquina superior derecha de la matriz se indica la repetición en curso. Los botones para detener el deletreo y cerrar la sesión son para el operador, el usuario hace todas sus selecciones con la atención a la matriz.

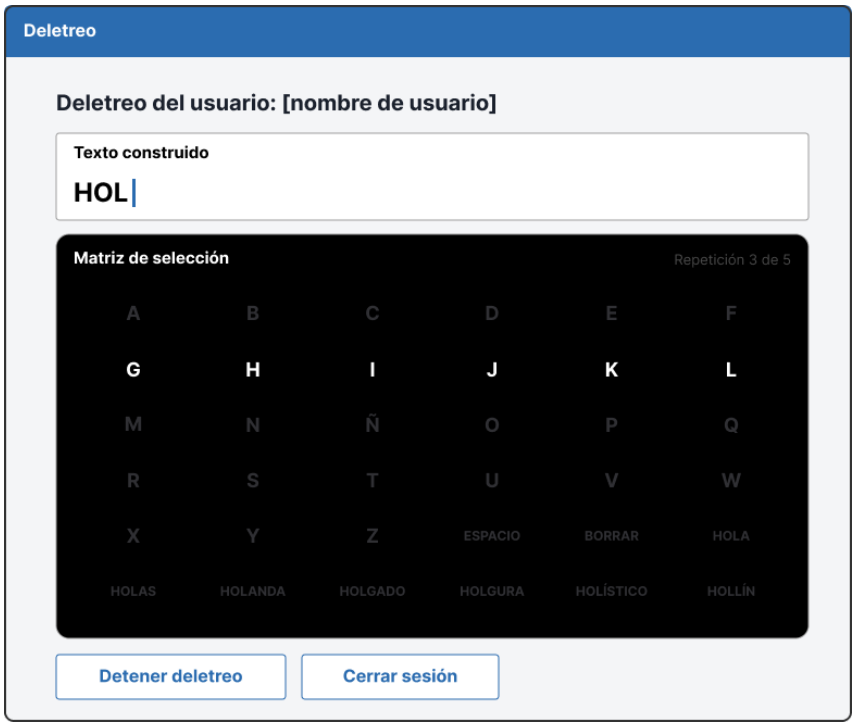


Figura 4.20: Pantalla principal del deletreo. Elaboración propia.

5. Conclusiones

Durante el Trabajo Terminal I se estableció el marco referencial del proyecto donde se revisaron los fundamentos del EEG, la componente P300 y el paradigma P300 Speller, además de las técnicas de preprocesamiento para usar estas señales, junto a las arquitecturas de aprendizaje profundo y las métricas con las que se evalúan estos sistemas. Por otro lado el estado del arte mostró que la mayoría de los sistemas P300 Speller basados en EEG alcanzan una alta exactitud en entornos controlados, pero bajo tres condiciones que dificultan su uso fuera del laboratorio. La primera es el registro con muchos canales, que en la base de datos de la competencia BCI III llega a 64. La segunda es el alto costo de los equipos necesarios para registrarlos.

A partir de lo anterior se desarrolló una propuesta con dos partes. La primera es un modelo de aprendizaje profundo para detectar la componente P300 y la segunda es el sistema de comunicación asistida que integra ese modelo junto con un módulo de predicción de palabras para agilizar la construcción de palabras. Para cada parte se planteó una metodología, CRISP-ML para el modelo e incremental para el sistema. Ambas empatan en el último incremento, cuando la arquitectura seleccionada se incorpora a la aplicación para entrenar el modelo de cada usuario al terminar su calibración.

En el Trabajo Terminal II quedan por construir los tres incrementos del sistema. El primero es el módulo de predicción de palabras, cuya técnica aún está por definirse. Le siguen la interfaz con la matriz del P300 Speller y, al final, la calibración junto con la integración del modelo de detección. En paralelo se completarán las fases de CRISP-ML, con el entrenamiento de las arquitecturas candidatas, y el ajuste de sus hiperparámetros. También se registrarán las señales propias de voluntarios, con las que se probará el sistema completo entre abril y mayo.

Queda pendiente verificar si el hardware seleccionado es compatible con un microordenador NVIDIA Jetson, en el que se analizaría la ejecución de la inferencia del modelo. Si el casco no puede comunicarse con esta tarjeta, la Jetson no se usará y el sistema se implementará únicamente en la computadora con Windows, sin que esto afecte el resto del alcance.

Referencias

[1] E. A. Felton, J. A. Wilson, J. C. Williams y P. C. Garell, «Electrocorticographically controlled brain–computer interfaces using motor and sensory imagery in patients with temporary subdural electrode implants,» *J. Neurosurg.*, vol. 106, n.º 3, págs. 495-500, 2007.

[2] L. A. Farwell y E. Donchin, «Talking off the top of your head: Toward a mental prosthesis utilizing event-related brain potentials,» *Electroencephalogr. Clin. Neurophysiol.*, vol. 70, n.º 6, págs. 510-523, 1988.

[3] V. L. Feigin et al., «The global burden of neurological disorders: translating evidence into policy,» *Lancet Neurol.*, vol. 19, n.º 3, págs. 255-265, 2020. DOI: 10.1016/S1474-4422(19)30411-9 Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9945815/

[4] Organización Mundial de la Salud y Banco Mundial, «Informe mundial sobre la discapacidad,» Organización Mundial de la Salud, Ginebra, Suiza, 2011. Disponible en: https://iris.who.int/handle/10665/75356

[5] Instituto Nacional de Estadística y Geografía, «Encuesta Nacional de la Dinámica Demográfica (ENADID) 2018,» INEGI, Aguascalientes, México, 2018. Disponible en: https://www.inegi.org.mx/programas/enadid/2018/

[6] N. Birbaumer et al., «A spelling device for the paralysed,» *Nature*, vol. 398, n.º 6725, págs. 297-298, 1999. DOI: 10.1038/18581

[7] J. R. Wolpaw, N. Birbaumer, D. J. McFarland, G. Pfurtscheller y T. M. Vaughan, «Brain–computer interfaces for communication and control,» *Clin. Neurophysiol.*, vol. 113, n.º 6, págs. 767-791, 2002. DOI: 10.1016/S1388-2457(02)00057-3

[8] E. W. Sellers y E. Donchin, «A P300-based brain–computer interface: Initial tests by ALS patients,» *Clin. Neurophysiol.*, vol. 117, n.º 3, págs. 538-548, 2006. DOI: 10.1016/j.clinph.2005.06.027

[9] N. Kane et al., «A revised glossary of terms most commonly used by clinical electroencephalographers and updated proposal for the report format of the EEG findings. Revision 2017,» *Clin. Neurophysiol. Pract.*, vol. 2, págs. 170-185, 2017. DOI: 10.1016/j.cnp.2017.07.002 Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6123891/

[10] H. Berger, «Über das Elektrenkephalogramm des Menschen,» *Arch. Psychiatr. Nervenkr.*, vol. 87, págs. 527-570, 1929. DOI: 10.1007/BF01797193

[11] S. Sanei y J. A. Chambers, *EEG Signal Processing*. Chichester, U.K.: John Wiley & Sons, 2007.

[12] E. Niedermeyer y F. Lopes da Silva, *Electroencephalography: Basic Principles, Clinical Applications, and Related Fields*, 5.ª ed. Philadelphia, PA, USA: Lippincott Williams & Wilkins, 2005.

[13] A. E. Contreras Martínez, «Sistema clasificador de señales EEG para el control de una neuroprótesis por medio de un dispositivo móvil,» Tesis de maestría, Esc. Sup. Cómputo, Inst. Politéc. Nac., Ciudad de México, México, 2021.

[14] B. Blankertz et al., «The BCI competition III: Validating alternative approaches to actual BCI problems,» *IEEE Trans. Neural Syst. Rehabil. Eng.*, vol. 14, n.º 2, págs. 153-159, 2006. DOI: 10.1109/TNSRE.2006.875642 Disponible en: https://infoscience.epfl.ch/record/146154

[15] EMOTIV. «Comparison of technical specifications: EPOC X,» visitado 21 de oct. de 2026. Disponible en: https://emotiv.com/pages/comparison-technical-specification

[16] H. H. Jasper, «The ten-twenty electrode system of the International Federation,» *Electroencephalogr. Clin. Neurophysiol.*, vol. 10, págs. 371-375, 1958.

[17] M. Seeck et al., «The standardized EEG electrode array of the IFCN,» *Clin. Neurophysiol.*, vol. 128, n.º 10, págs. 2070-2077, 2017. DOI: 10.1016/j.clinph.2017.06.254 Disponible en: https://archive-ouverte.unige.ch/unige:99725

[18] J. D. Kropotov, *Quantitative EEG, Event-Related Potentials and Neurotherapy*. San Diego, CA, USA: Academic Press/Elsevier, 2009.

[19] S. J. Luck, *An Introduction to the Event-Related Potential Technique*, 2.ª ed. Cambridge, MA, USA: MIT Press, 2014.

[20] J. Polich, «Updating P300: An integrative theory of P3a and P3b,» *Clin. Neurophysiol.*, vol. 118, n.º 10, págs. 2128-2148, 2007. DOI: 10.1016/j.clinph.2007.04.019 Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2715154/

[21] S. Tong y N. V. Thakor, eds., *Quantitative EEG Analysis Methods and Clinical Applications*. Norwood, MA, USA: Artech House, 2009.

[22] S. Sutton, M. Braren, J. Zubin y E. R. John, «Evoked-potential correlates of stimulus uncertainty,» *Science*, vol. 150, n.º 3700, págs. 1187-1188, 1965. DOI: 10.1126/science.150.3700.1187

[23] N. K. Squires, K. C. Squires y S. A. Hillyard, «Two varieties of long-latency positive waves evoked by unpredictable auditory stimuli in man,» *Electroencephalogr. Clin. Neurophysiol.*, vol. 38, n.º 4, págs. 387-401, 1975. DOI: 10.1016/0013-4694(75)90263-1

[24] T. W. Picton, «The P300 wave of the human event-related potential,» *J. Clin. Neurophysiol.*, vol. 9, n.º 4, págs. 456-479, 1992. DOI: 10.1097/00004691-199210000-00002

[25] J. R. Wolpaw y E. W. Wolpaw, eds., *Brain–Computer Interfaces: Principles and Practice*. New York, NY, USA: Oxford University Press, 2012.

[26] L. F. Nicolas-Alonso y J. Gomez-Gil, «Brain computer interfaces, a review,» *Sensors*, vol. 12, n.º 2, págs. 1211-1279, 2012. DOI: 10.3390/s120201211 Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3304110/

[27] D. J. Krusienski, E. W. Sellers, D. J. McFarland, T. M. Vaughan y J. R. Wolpaw, «Toward enhanced P300 speller performance,» *J. Neurosci. Methods*, vol. 167, n.º 1, págs. 15-21, 2008. DOI: 10.1016/j.jneumeth.2007.07.017 Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2349091/

[28] A. Rakotomamonjy y V. Guigue, «BCI competition III: Dataset II—Ensemble of SVMs for BCI P300 speller,» *IEEE Trans. Biomed. Eng.*, vol. 55, n.º 3, págs. 1147-1154, 2008. DOI: 10.1109/TBME.2008.915728

[29] H. Cecotti y A. Gräser, «Convolutional neural networks for P300 detection with application to brain–computer interfaces,» *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 33, n.º 3, págs. 433-445, 2011. DOI: 10.1109/TPAMI.2010.125 Disponible en: https://pure.ulster.ac.uk/en/publications/452a7bd8-8a35-4f40-9976-8203480f778c

[30] J. G. Proakis y D. G. Manolakis, *Tratamiento digital de señales*, 4.ª ed. Madrid, España: Pearson Prentice Hall, 2007.

[31] A. V. Oppenheim y R. W. Schafer, *Discrete-Time Signal Processing*, 3.ª ed. Upper Saddle River, NJ, USA: Pearson, 2010.

[32] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.

[33] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

[34] M. Alvarado-González, G. Fuentes-Pineda y J. Cervantes-Ojeda, «A few filters are enough: Convolutional neural network for P300 detection,» *Neurocomputing*, vol. 425, págs. 37-52, 2021. DOI: 10.1016/j.neucom.2020.10.104 arXiv: 1909.06970.

[35] C. C. Aggarwal, *Neural Networks and Deep Learning*. Cham, Suiza: Springer, 2018.

[36] B. Martín del Brío y A. Sanz Molina, *Redes neuronales y sistemas difusos*, 2.ª ed. México: Alfaomega, 2002.

[37] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung y B. J. Lance, «EEGNet: A compact convolutional neural network for EEG-based brain–computer interfaces,» *J. Neural Eng.*, vol. 15, n.º 5, 2018, art. n.º 056013. DOI: 10.1088/1741-2552/aace8c arXiv: 1611.08024.

[38] D. E. Rumelhart, G. E. Hinton y R. J. Williams, «Learning representations by back-propagating errors,» *Nature*, vol. 323, n.º 6088, págs. 533-536, 1986. DOI: 10.1038/323533a0

[39] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdinov, «Dropout: A simple way to prevent neural networks from overfitting,» *J. Mach. Learn. Res.*, vol. 15, n.º 56, págs. 1929-1958, 2014. Disponible en: https://jmlr.org/papers/v15/srivastava14a.html

[40] S. Ioffe y C. Szegedy, «Batch normalization: Accelerating deep network training by reducing internal covariate shift,» en *Proc. 32nd Int. Conf. Mach. Learn. (ICML)*, ép. PMLR, vol. 37, 2015, págs. 448-456. arXiv: 1502.03167. Disponible en: https://proceedings.mlr.press/v37/ioffe15.html

[41] F. Chollet, «Xception: Deep learning with depthwise separable convolutions,» en *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2017, págs. 1251-1258. DOI: 10.1109/CVPR.2017.195 arXiv: 1610.02357.

[42] R. T. Schirrmeister et al., «Deep learning with convolutional neural networks for EEG decoding and visualization,» *Hum. Brain Mapp.*, vol. 38, n.º 11, págs. 5391-5420, 2017. DOI: 10.1002/hbm.23730 arXiv: 1703.05051. Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5655781/

[43] T. Fawcett, «An introduction to ROC analysis,» *Pattern Recognit. Lett.*, vol. 27, n.º 8, págs. 861-874, 2006. DOI: 10.1016/j.patrec.2005.10.010

[44] J. R. Wolpaw et al., «Brain–computer interface technology: A review of the first international meeting,» *IEEE Trans. Rehabil. Eng.*, vol. 8, n.º 2, págs. 164-173, 2000. DOI: 10.1109/TRE.2000.847807

[45] D. B. Ryan et al., «Predictive spelling with a P300-based brain–computer interface: Increasing the rate of communication,» *Int. J. Hum.-Comput. Interact.*, vol. 27, n.º 1, págs. 69-84, 2011. DOI: 10.1080/10447318.2011.535754 Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3029027/

[46] D. Jurafsky y J. H. Martin, *Speech and Language Processing*, 3.ª ed. 2025, Borrador en línea. visitado 23 de sep. de 2026. Disponible en: https://web.stanford.edu/~jurafsky/slp3/

[47] T. B. Brown et al., «Language models are few-shot learners,» en *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020, págs. 1877-1901. arXiv: 2005.14165.

[48] W. Speier, C. Arnold, J. Lu, R. K. Taira y N. Pouratian, «Natural language processing with dynamic classification improves P300 speller accuracy and bit rate,» *J. Neural Eng.*, vol. 9, n.º 1, 2012, art. n.º 016004. DOI: 10.1088/1741-2560/9/1/016004 Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3360927/

[49] J. Hong, W. Wang y L. Najafizadeh, «ChatBCI, a P300 speller BCI with context-driven word prediction leveraging large language models,» *Sci. Rep.*, vol. 16, 2026, art. n.º 6379. DOI: 10.1038/s41598-025-25660-7 arXiv: 2411.15395. Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC12909297/

[50] D. J. Krusienski et al., «A comparison of classification techniques for the P300 Speller,» *J. Neural Eng.*, vol. 3, n.º 4, págs. 299-305, 2006. DOI: 10.1088/1741-2560/3/4/007 Disponible en: https://hal.science/hal-00521054

[51] U. Hoffmann, J.-M. Vesin, T. Ebrahimi y K. Diserens, «An efficient P300-based brain–computer interface for disabled subjects,» *J. Neurosci. Methods*, vol. 167, n.º 1, págs. 115-125, 2008. DOI: 10.1016/j.jneumeth.2007.03.005 Disponible en: https://infoscience.epfl.ch/record/101093

[52] E. García Cossio, C. Fernández, M. E. Gaviria, C. Palacio, L. Alvarán y R. A. Torres Villa, «Interfaz cerebro–computador basada en P300 para la comunicación alternativa: estudio de caso en dos adolescentes en situación de discapacidad motora,» *Rev. Fac. Ing. Univ. Antioquia*, n.º 60, págs. 9-19, 2011. DOI: 10.17533/udea.redin.13651 Disponible en: https://revistas.udea.edu.co/index.php/ingenieria/article/view/13651

[53] P. Brunner, A. L. Ritaccio, J. F. Emrich, H. Bischof y G. Schalk, «Rapid communication with a P300 matrix speller using electrocorticographic signals,» *Front. Neurosci.*, vol. 5, 2011, art. n.º 5. DOI: 10.3389/fnins.2011.00005 Disponible en: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3037528/

[54] M. Liu, W. Wu, Z. Gu, Z. Yu, F. Qi e Y. Li, «Deep learning based on batch normalization for P300 signal detection,» *Neurocomputing*, vol. 275, págs. 288-297, 2018. DOI: 10.1016/j.neucom.2017.08.039

[55] H. Shan, Y. Liu y T. Stefanov, «A simple convolutional neural network for accurate P300 detection and character spelling in brain computer interface,» en *Proc. 27th Int. Joint Conf. Artif. Intell. (IJCAI)*, 2018, págs. 1604-1610. DOI: 10.24963/ijcai.2018/222 Disponible en: https://www.ijcai.org/proceedings/2018/222

[56] I. Santos, R. Romero y A. Fernández, «Estudio de las ondas cerebrales captadas por una BCI asociada a biomecanismos,» Trabajo Terminal, Esc. Sup. Cómputo, Inst. Politéc. Nac., Ciudad de México, México, 2017.

[57] S. Studer et al., «Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology,» *Mach. Learn. Knowl. Extr.*, vol. 3, n.º 2, págs. 392-413, 2021. DOI: 10.3390/make3020020 arXiv: 2003.05155.

[58] R. S. Pressman, *Ingeniería del software: un enfoque práctico*, 7.ª ed. México: McGraw-Hill, 2010.

[59] A. Kübler, B. Kotchoubey, J. Kaiser, J. R. Wolpaw y N. Birbaumer, «Brain–computer communication: Unlocking the locked in,» *Psychological Bulletin*, vol. 127, n.º 3, págs. 358-375, 2001. DOI: 10.1037/0033-2909.127.3.358